EDN · RÉVISION MÉDICALE

LCA

Révision médicale complète · 15 chapitres · 139 illustrations

EDN

Informations

© 2026 EDN. Tous droits réservés.

Document de révision destiné à l'usage personnel des étudiants en médecine. Ce document n'est pas un avis médical et ne remplace aucun enseignement universitaire ni le référentiel officiel.

Source : documentation de révision EDN mise à disposition publiquement.

Langue : français. Format : EPUB 3.

Les tableaux de la source ont été convertis en texte : le libellé de chaque ligne est repris tel quel, et chaque colonne est nommée. Aucune donnée n'a été ajoutée, supprimée ni réordonnée.

Navigation : la table des matières de la liseuse donne accès à chaque chapitre. Les sections encadrées sont repliables d'un toucher.

Sommaire

PARTIE 1 — SELON LE TYPE D'ÉTUDE
1 Étude épidémiologique
2 Études thérapeutiques
3 Études diagnostiques
4 Études pronostiques
5 Revue systématique et Méta-analyse
PARTIE 2 — COURS
6 Structure d'un article
7 Types d'étude
8 Population
9 Comparabilité des groupes
10 Biais, Validité interne et Validité externe
11 Critère de jugement
12 Calcul du NSN
13 Règles d'éthique
14 Analyse statistique
15 Tableaux et figures

PARTIE 1

Selon le type d'étude

Étude épidémiologique

Différents types d'études épidémiologiques (selon leur finalité)

Choix du type d'étude selon sa finalité

Objectif de l'étude

Estimer la **prévalence** *(descriptive)*

Estimer l'**incidence** *(descriptive)*

Rechercher les **facteurs de risque** *(étiologique)*

Rechercher les **facteurs pronostiques**

Évaluer l'effet d'une action de santé (intervention sur les habitudes de vie, dépistage, programme d'éducation à la santé, politique de santé…)

Étudier les pratiques de soin

Type d'étude

Étude transversale descriptive

Étude descriptive d'incidence à partir de système d'enregistrement

Étude descriptive de **cohorte prospective**

Étude de **cohorte prospective**Étude cas-témoinÉtude cas-témoin nichée dans une cohorte

Étude de **cohorte prospective**

Étude de cohorte rétrospective

Essai randomisé individuel (préférable si possible)

Essai randomisé en cluster (à utiliser quand la randomisation individuelle des sujets est impossible)

Enquêtes avant–après/ici-ailleurs (à utiliser surtout quand l'intervention ne peut être appliquée que sur l'ensemble de la population)

Étude transversale ++

Étude de cohorte

Étude en cluster

Enquête avant-après

Enquête ici-ailleurs

Descriptives

Description de caractéristiques brutes de l'état de santé d'une population (incidence, prévalence, morbidité, mortalité ...)

Ainsi que leurs éventuelles variations :

- Variations dans l'espace (variations géographiques)
- Au cours du temps (variations temporelles)
- Selon certaines grandes catégories (âge, sexe, statut socio-économique ...)

Étiologiques

(ou analytiques)

Évaluation de l'ampleur d'un phénomène de santé : maladie, décès, FR, pratiques de soins ...

Autres

- Études d'évaluation des interventions en santé
- Études pronostiques
- Études pratiques

Estimation des risques selon le type d'étude observationnelles

Estimer un taux

- Prévalence (étude transversale)
- Incidence (cohorte rétrospective ou prospective)

Mesurer une association

- Risque relatif (RR, **rapport des incidences** de la maladie entre 2 groupes de la cohorte : exposés/non-exposés)
- Odds ratio (OR, **estimation du risque relatif** : études cas-témoins, ou cohorte exposés/non-exposés)

Mesurer un impact

- Excès de risque (différence entre risque absolu des exposés, et risque de base des non exposés dans études de cohorte)
- Fraction de risque attribuable (RA, proportion de cas imputable au facteur)

Impact en population : Fraction attribuable

Exemple de LCA Facile sur la fraction étiologique

Fraction étiologique

Le « **risque attribuable pour les exposés** » (ou « **fraction étiologique** ») mesure la **proportion de cas de la maladie qu'on peut attribuer au facteur de risque parmi les sujets exposés à ce facteur** (par exemple, pourcentage des cas de cancer du poumon dus au tabagisme parmi les fumeurs).

La **fraction étiologique vaut : (RR − 1)/RR**.

Ainsi, si le RR vaut 4, la fraction étiologique vaut : (4 − 1)/4 = 0,75.

C'est-à-dire que 75 % des cas survenus chez des sujets exposés peuvent être attribués à l'exposition au facteur de risque, et auraient donc pu être évités.

Prenons l'exemple du cancer du poumon :

- si le RR vaut 4 parmi la population fumeuse par rapport à la population non fumeuse, cela signifie que pour 4 cas de cancer chez les fumeurs on a 1 cas de cancer chez les non-fumeurs pour des populations identiques en effectif ;
- imaginons maintenant que les 4 patients fumeurs n'aient pas fumé au cours de leur vie, ils rejoindraient alors le risque de la population générale. On aurait alors parmi ces 4 patients non pas 0 cas de cancer mais bien 1 cas de cancer, ce qui correspond bien au risque de la population générale ;
- donc en pratique, on peut dire que le tabac explique 3 cas de cancer sur 4 chez les patients fumeurs, soit 75 % des cas survenus chez les patients exposés au tabac. Ce pourcentage correspond bien à la fraction étiologique évoquée ci-dessus en cas de RR à 4.

Formule : Fraction de risque attribuable (RA, proportion de cas imputable au facteur en population générale)

$$R.A. = \frac{PF \times (RR - 1)}{PF \times [RR - 1] + 1}$$

image.png

Principe. RR ou un OR significatif ne reflète pas forcément que l'exposition ait un impact très important en population générale, cela va dépendre de la fréquence de l'exposition et de la taille de l'effet

Fraction attribuable

FRACTION ATTRIBUABLE = RISQUE ATTRIBUABLE (RA) = FRACTION ÉTIOLOGIQUE EN POPULATION GÉNÉRALE

- Déf. : proportion de cas ou décès d'une maladie **en population générale** que l'on peut attribuer à un FR/exposition
- Calcul : [PF x (RR-1)] / [PF x (RR-1) + 1]
  - Avec PF (fréquence d'exposition) = proportion de sujets exposés au facteur dans la population
  - Type d'étude dédié au calcul de la Fraction du Risque attribuable = étude de cohorte prospective
  - Si **étude cas-témoins** : RR est estimé par OR, et PF est la prévalence de l'exposition chez les témoins
- Intérêt du RA : quantifier le pourcentage de cas évitables si l'on pouvait supprimer le facteur d'exposition
  - *À différencier du RR ou du OR qui cherchent à mesure une association, ici on mesure un impact*
  - Multiplication du RA par la prévalence de la maladie permet d'estimer le nombre de cas qui seraient évités si l'exposition était supprimée
- Conditions indispensables pour pouvoir calculer la fraction du risque attribuable :
  - Avoir des informations sur la proportion de sujets exposés dans la population (pas toujours possible)
  - Existence d'un lien de nature causale entre le facteur et la maladie (sinon calcul de RA non valide)

Fraction étiologique

Fraction étiologique (FE) = FRACTION DE RISQUE ATTRIBUABLE CHEZ LES EXPOSÉES

- Def. = proportion de cas attribuables au facteur **parmi les sujets exposés**,

- Calcul : FE = (RR-1)/RR

Taille de l'effet. Ces dernières années ont vu naître des études ayant des effectifs tellement importants qu'une différence d'âge de 3 mois entre deux groupes sera significative, il est donc également important de raisonner en termes de taille d'effet et de pertinence clinique

Classification des études épidémiologiques

Épidémiologie interventionnelle (expérimentale ou évaluative)

Généralités

Toute enquête où l'attribution de l'exposition est contrôlée par l'investigateur

- Très rare en pratique, car **ce type d'étude n'est souvent pas éthique** (on ne peut pas randomiser sur un facteur de risque)
- Caractéristiques : toujours prospectives, randomisées ou non, souvent contrôlées
- Si groupes comparables + biais contrôlés : la différence observée entre les groupes permet de poser un lien de causalité

Essais semi-expérimentaux

Correspond à l'évaluation de l'**impact** d'un programme de prévention ou de dépistage :

- Études transversales "avant/après" : comparaison du même groupe avant/après le programme de prévention
- Études transversales "ici/ailleurs" : comparaison de 2 groupes ayant suivi ou pas le programme de prévention
- Études transversales "avant/après" et "ici/ailleurs" : combinaison des 2

Épidémiologie observationnelle (non expérimentale)

Toute enquête où l'attribution de l'exposition n'est pas contrôlée par l'investigateur

Enquêtes descriptives

> *Il en existe 2 types :*

Portant sur des individus isolément

- Calcul de la **prévalence** (hors exposition) : étude transversale descriptive
- Calcul de l'**incidence** et de la **mortalité** : étude de cohorte descriptive (typiquement rétrospective, mais possible prospective)

Portant sur des groupes de personnes (surveillance épidémiologique)

Recours à des systèmes d'enregistrement permanent

(statistiques nationales/régionales de mortalité, registres de mobidités, INSEE, données du SNIIRAM …)

Reposent sur le calcul du **taux d'incidence ou de mortalité sur une zone géographique définie**

Requiert de manière indispensable une standardisation *(sur l'âge, le sexe …)* afin que les résultats puissent être comparés avec d'autres zones géographiques ou d'autres périodes temporelles

Cas particulier : étude de corrélation écologique (ecological study)

Surveillance épidémiologique : étude descriptive portant sur des groupes de personnes

Recours à systèmes d'enregistrement permanent

- Statistiques nationales ou régionales de mortalité
- Registres de morbidités (dans une population géographiquement définie)
- INSEE, données du SNIIRAM (système national d'information d'inter-régimes de l'assurance maladie) ...

Méthodes de standardisation (indispensable pour ces études)

Reposent sur le calcul du taux d'incidence (ou de mortalité)

Taux d'incidence = nombre de nouveaux cas survenus au cours d'une année dans une zone géographiquement définie, divisé par le nombre de personnes à risque (en pratique : le nombre de personnes résidant dans la zone géographique pour l'année considérée)

En pratique la comparaison des taux entres les zones géographiques (ou entre les périodes) nécessitent une standardisation sur l'âge (ou souvent le sexe) : car la répartition âge/sexe peut varier selon la zone/période

Cas particulier : étude de corrélation écologique (ecological study)

Définition. Étude cherchant à mettre en relation les variations temporelles (ou géographiques) de taux d'incidence (ou de mortalité) avec des variations analogues de données agrégées de facteurs environnementaux ou socio-économiques

Intérêt. Utile pour élaborer des hypothèses sur les facteurs potentiellement associé à la survenue d'un événement de santé

Avantages

- Durée courte, Coût faible, Facile à mettre en place (car reposent le plus souvent sur des bases de données déja existantes)
- Fournissent des estimations non biaisées quand ces bases de données incluent des individus non sélectionnés (statistiques nationales de mortalité, registres de morbidité ...) nécessaires pour la surveillance épidémiologique des populations
- Adaptées pour des comparaisons internationales

Inconvénients

- Qualité variable de informations recueillies de façon systématique dans certaines bases de données (l'interprétation de étude de corrélation écologique doit être extrêmement prudente)
- Analyse statistique complexe (grosses bases de données qui nécessitent des équipes qualifiées)

Enquêtes analytiques

Consistent en la recherche d'une association statistique entre une maladie et une expostion à un facteur (permettent d'établir une association statistique, mais pas un lien de causalité ⚠️)

Il en existe 5 types :

Cohorte. Sélection sur l'exposition pour étude de maladies, Calcul d'un risque relatif (RR)

Cas témoins. Sélection sur la maladie pour étude d'expositions, Calcul d'un odds ratio (OR)

Cohortes mixtes ou "historico-prospectives" (mélange des deux). exemple : *étude pour recherche un lien entre les infections en début de grossesse (exposition), et les malformations néonatales (maladie) : interrogatoire rétrospectif des femmes au 3° mois de grossesse sur les infections des 3 premiers mois puis suivi prospectif de femmes du 4° mois à la naissance*

Cohortes historiques. Cas le plus fréquent des cohortes rétrospectives, il s'agit d'une étude où les données ont été recueillies antérieurement à la mise en place de l'étude avec des auteurs qui reprennent les données a posteriori pour les analyser une par une car l'analyse est prospective

Cas-témoins "nichées dans une cohorte"

En anglais : nested
case-control study

Étude cas-témoins qui sélectionne les cas et les témoins à partir de la même unité de recrutement (une cohorte antérieure, un même centre, un même registre...)

- Intérêt : augmente la validité interne car permet d'augmenter la comparabilité initiale des groupes

(cas et témoins sont issus de la même cohorte, ce qui les rend a priori plus comparable entre eux)

- Inconvénient : surtout pas oublier qu'il s'agit avant tout d'une étude cas-témoins, seul le mode de recrutement est particulier

Attention, finesse importante : parfois on récupère tous les cas de la cohorte, et on tire au sort un certain nombre de témoins pour l'appariement → cela n'a bien sûr rien à voir avec une randomisation

Épidémiologie évaluative

Domaine de l'épidémiologie cherchant à estimer et quantifier l'impact d'une action sur l'état de santé d'une population (programme d'éducation, campagne de dépistage, essai thérapeutique)

Il repose sur la mise en place d'études épidémiologiques pouvant répondre à différents schémas :

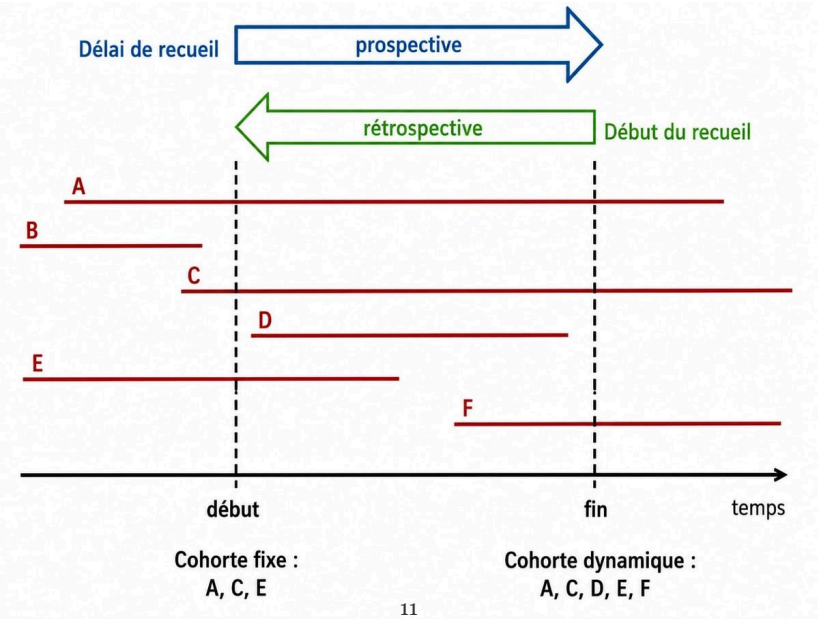


image.png

Type d'étude

Principaux types d'étude épidémiologique

Étude de Cohorte, Étude Cas-témoins

Choix entre étude cas-témoin et étude de cohorte va dépendre de la question posée

Critères de choix, Protocoles : cohorte vs cas-témoins

	Cohorte	Cas-témoins
Critères de choix		
Contexte	Facteur de risque unique ; Maladies multiples	Maladie unique ; Facteurs de risque multiples
Maladie	Fréquente ; À latence courte	Rare ; À latence longue
Exposition	Rare	Fréquente
Biais	Perdus de vus	Mémorisation + Sélection
Durée/Coût	Longue ; Coût élevé	Courte ; Coût moindre
Protocole		
Niveau de preuve	Niveau 2 (grade B)	Niveau 3 (grade C)
Groupes	Exposés vs Non-exposés	Cas vs Témoins
Critères de sélection	Exposition	Maladie
Chronologie	Prospectif	Rétrospectif
Comparaison	Incidence de la maladie	Cotes d'exposition au facteur
Résultat/Mesure de l'association	Risque relatif (RR), *et OR*	Odds Ratio (OR)

Untitled

Avantages/Inconvénients : cohorte, cas-témoins

Cohorte vs Cas-Témoins — Avantages et Inconvénients

Avantages

Cohorte :

- Adaptés aux expositions rares ou complexes
- Étude de plusieurs maladies comme conséquence d'une exposition unique
- Meilleur niveau de preuve (élevé) = moins de biais- Permet un calcul d'incidence et donc du RR
- Étude précise de la séquence temporelle (chronologie) entre exposition et maladie

Cas-Témoins :

- Adapté aux maladies rares ou à latence longue (ex. cancer) ou nécessitant des méthodes diagnostiques lourdes
- Étude de plusieurs expositions comme facteurs étiologiques potentiels d'une même maladie
- Rapide (obtention rapide des résultats) et coût faible
- Plus simple, parfois les seules réalisables
- **Effectifs limités**

Inconvénients

Cohorte :

- Longue durée (obtention tardive des résultats) et Coût élevé

- **Effectifs importants** (nécessité d'un échantillon de grande taille le plus souvent)
- Risque important de biais de sélection liés de perdus de vue en cas de suivi incomplet
- Non adapté pour les maladies rares ou à latence longue
- **Étude d'une seule exposition**

Cas-Témoins :

- **Pas de calcul d'incidence** (on se contente du calcul de l'OR)
- Nombreux biais, 2 importants : **biais de classement différentiel** (biais de mémorisation) **biais de sélection** (choix des témoins difficile)
- Niveau de preuve faible
- Mal adapté pour les expositions rares
- **Étude d'une seule maladie**
- Séquence temporelle impossible à affirmer

Études de cohorte

Selon l'objectif

- Cohorte descriptive : déterminer l'incidence d'une maladie sans étude de la causalité
- Cohorte analytique : rechercher association statistique entre survenue d'une maladie et exposition à un facteur d'exposition

Prospective ou Rétrospective ? Étude de cohorte est le plus souvent prospective mais peut aussi être rétrospective (cohorte historique)

Selon le mode de sélection des sujets

- Enquêtes sur échantillon : réalisées sur des sujets extraits par sondage de la population source
- Enquêtes exposés/non-exposés : ici, le nombre de sujets exposés et de sujets non exposés étant fixé a priori, l'incidence de la maladie ne peut pas être estimée directement, souvent utilisées en milieu professionnel

Dans tous
les cas

- Sujets doivent être indemnes de l'événement étudié à l'entrée dans la cohorte
- Enquêtes ne peuvent être réalisées que si la maladie et l'exposition sont toutes 2 fréquentes

---

Choix de la population - Recrutement

Différents types de cohorte

Cohorte est une ensemble de sujet avec des caractéristiques semblables, il peut s'agit d'un groupe de personne :

- Nées la même année (génération)
- Appartenant à un même corps professionnel (cohorte Gazel)
- Soumis à une même exposition (Hiroshima) → *cohorte analytique*
- Défini sur une base géographique (Framingham)
- Hospitalisées à partir d'une même date ou ayant commencé une maladie au cours d'une même période

Il existe 2 possibilités pour le choix de la population :

Cohorte en population

Échantillon peut être plus ou moins représentatif de la population cible, pour avoir un échantillon représentatif, l'idéal est de procéder par sondage à partir d'une population source correspondant à la population cible

- *Exposition mesurée à l'inclusion*
- ***Possible uniquement si exposition et maladie fréquentes***
- ***Généralisable** à la population cible*

Cohortes exposés - non exposés

Ici, on recrute 1 cohorte exposée à un FR et 1 cohorte non-exposée au FR, ces 2 cohortes vont être suivies dans le temps et doivent avoir un suivi similaire :

- Ne permet pas d'évaluer simultanément plusieurs facteurs de risque ❌
- À privilégier quand l'exposition est rare et l'évènement relativement fréquent ✅
- Adapté à l'étude de FR professionnels (ex. l'exposition à l'amiante)
- ***Non généralisable à la population cible***
- *Pas d'estimation directe de l'incidence dans la population cible (on calcule l'incidence de la cohorte pas celle de la population)*

On distingue aussi 2 types de cohorte sur le mode de recrutement :

Cohorte fixe (fermée). Toutes les personnes de la cohorte sont incluses au début de l'étude

Cohorte dynamique (ouverte). Inclusion des patients se poursuit au cours de l'essai

Receuil des facteurs de risque

Il existe 2 modes d'inclusion possible (temporalité du receuil de données) :

Cohorte concourante ou « prospective »

Inclusion se faire au début du suivi

Recueil des FR se fait au moment de l'entrée dans l'étude et éventuellement pendant le suivi

Si l'exposition au FR n'est recueillie qu'au début, cela peut poser problème car l'exposition au FR peut varier au cours du temps (ex. si le facteur de risque est la consommation de tabac)

Cohorte historique ou « rétrospective » Inclusion est reconstitué a posteriori (dossiers médicaux, registres), intéressant pour les maladies ayant un long délai de latence (ex. cancers, maladie d'Alzheimer), cependant, il faut vérifier la qualité du recueil des données : s'il y a des données manquantes ou si un facteur de confusion important n'a pas été collecté, cela va poser problème

Exemple de cohorte rétrospective

> *Exemple de cohorte rétrospective :*

Dans une étude évaluant l'association entre le type de ventilation (ventilation non invasive ou ventilation mécanique) et la mortalité chez des patients hospitalisés en réanimation pour une décompensation de BPCO, les auteurs ont cherché rétrospectivement dans les dossiers tous les patients hospitalisés pour une décompensation de BPCO ayant nécessité une ventilation non invasive ou mécanique. Ils ont recueilli leurs données et ont évalué ensuite leur devenir (décès ou non).

> **Mais tous les cas, l'analyse est faite dans un sens prospectif**

Différence cohorte vs cas-témoin (schéma)

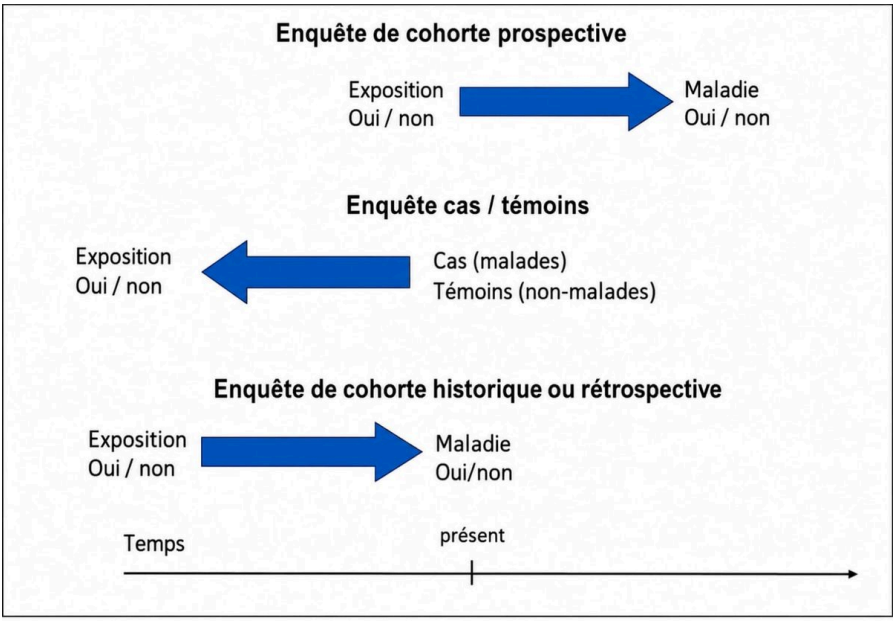


image.png

Recueil de la maladie (critère de jugement)

✅

Caractéristiques du recueil du statut malade ou non-malade :

- Identique - Fiable - Standardisé - Reproductible chez les exposés et non-exposés
- Définition de la maladie précise et objective
- Évaluation du statut malade/non-malade en aveugle du statut expose/non-exposé (limiter le biais de classement)

⚠️

Le plus souvent, il s'agira d'un critère dont la mesure peut être subjective (cancer, IDM ...), risque de biais de classement :

- **Différentiel** (évaluation de la maladie n'est pas faite en aveugle de l'exposition au FR, peut conduire au sur-diagnostic chez les exposés)
- Erreur **non-différentielle** (risque de variabilité et d'erreur de mesure entre les évaluateurs)

Risque principal ⚠️ des études de cohortes

Risque. Risque principal est lié aux perdus de vus

Paramètres faisant varier ce risque

- Durée de suivi = plus elle est importante, et plus le risque est élevé
- Nombre d'événements = plus il est faible et plus le risque est élevé

Conséquences

- Si les perdus de vue se répartissent également dans les groupes en nombre et caractéristiques et ne concernent pas une catégorie particulière de patients, la seule conséquence sera une **perte de puissance** (rare car le plus souvent si on est perdu de vue ce n'est pas pour rien ... ex. rupture de soins et/ou mauvaise observance ...)
- S'il y a plus de perdus de vue dans un groupe que dans l'autre, ou si les sujets pdv ont des caractéristiques spécifiques, on risque, outre la perte de puissance, un **biais d'attrition** (ou **biais de sélection des perdus de vue**)

Influence

Influence de la proportion de perdus de vue dépend de la fréquence de survenue de l'événement étudié

- Si le nombre de perdus de vue > nombre d'évènements, cela pose problème

Limiter ce risque

Pour limiter ce risque, il faut un suivi long et rigoureux = relancer et **analyser les perdus de vue**

Moyens de prendre en compte les perdus de vue liés à un suivi incomplet :

- Nombre ou pourcentage de perdus de vue fourni dans l'article (devrait être obligatoire dans toute étude de cohorte)
- Raisons du suivi incomplet des perdus de vue fourni dans l'article (idem)
- Si perdus de vus > 5-10% : nécessité de comparaison des caractéristiques initiales des sujets perdus de vue et non perdus de vue doit être rapportée dans l'article

> **Quel que soit le type d'étude de cohorte, le suivi des sujets exposés doit être identique au suivi des sujets non-exposés**

Dans les études de cohorte prospective, il faut définir une durée de suivi suffisante pour pouvoir observer la maladie

---

Notion de cohorte « avec groupe de référence externe »

Indication. Type d'étude de cohorte à proposer en cas d'étude d'exposition rare concentrée sur une population, classiquement pour les **expositions professionnelles** (ex : amiante)

Principe. Cohorte avec sélection de patients exposés à l'exposition rare que l'on compare à un groupe de référence externe pris en dehors de la cohorte (ex. la population générale)

Exemple. *Exemple : étude évaluant le lien entre l'exposition professionnelle à l'amiante et développement d'une péricardite chronique constrictive avec sélection d'une cohorte de travailleurs de l'industrie, exposés à l'amiante, que l'on va comparer à une cohorte de référence comme la population générale*

Études cas-témoin

Principe

Objectif. Étude analytique/étiologique, vise à rechercher un lien entre le fait d'avoir une maladie et l'exposition à un facteur

Principes

- Sélection des groupes en fonctions de la maladie : cas (M+) et témoins (M-)
- Pas de suivi (étude cas-témoin est toujours **rétrospective** : recherche rétrospective au facteur pour cas et témoins)
- Comparaison de la fréquence d'exposition des 2 groupes *(puis mesure de l'association maladie-facteur par l'OR)*
- Étude cas-témoins est le seul cas où il n'existe pas de critère de jugement principal ⭐

Différence cohorte vs cas-témoin (schéma)

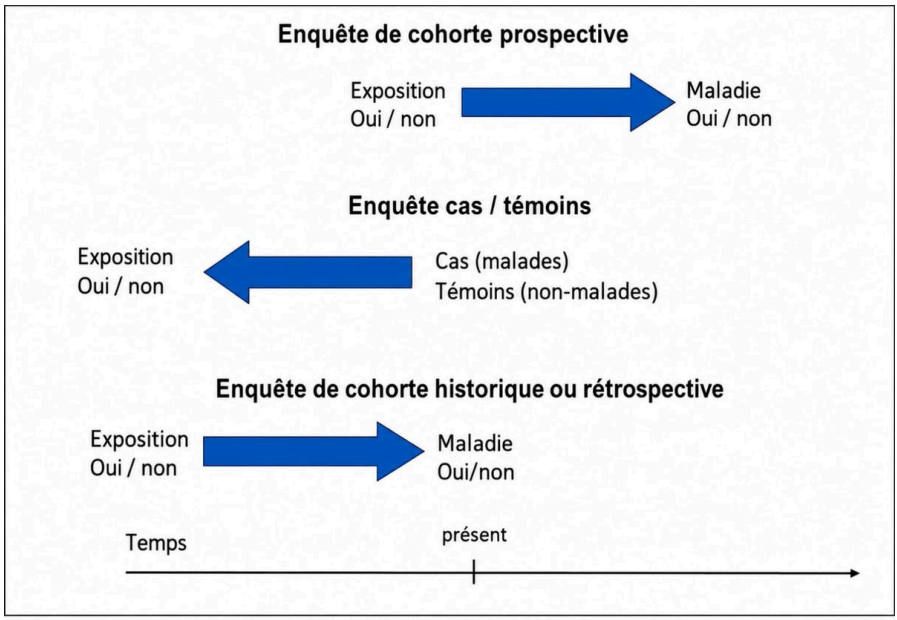


image.png

Population d'étude

> **Sélection des cas et des témoins doit être indépendante des facteurs de risque étudiés → Recrutement des cas et des témoins doit se faire sans connaître leurs éventuelles expositions à des facteurs de risque**

Sélection des cas

Cas doivent être représentatifs de la population de malades, il faut distinguer :

Cas incidents

(à privilégier ✅)

Inclus dans l'étude quand ils deviennent malades (ici, on ne recrute que les nouveaux malades)

préférable surtout quand la maladie présente un risque de décès élevé

Cas prévalants

⚠️

Mélange de nouveaux cas et de cas déjà malades auparavent et ayant survécu

- conduit à un biais de **sélection** particulier : biais de survie sélective (cas prévalents sont forcément moins graves et biaisent la population (ex: sélection de cancers du poumon parmis des patients suivis déjà depuis 1 an)

Il faut discuter, selon le plan d'expérience, tout particulièrement dans les études étiologiques, l'inclusion de cas incidents (nouveaux cas) ou de cas prévalents ; **l'inclusion de cas incidents est préférable, car elle évite les biais de survie sélective**. Concernant les **cas prévalents, les sujets ont pu modifier leurs habitudes de vie par rapport au début de la maladie et il devient alors difficile de distinguer si le facteur a précédé le début de l'affection ou s'il est apparu ultérieurement**.

Choix des témoins dans les études cas-témoins

Caractéristiques

✅

- Témoins appartiennent à la même population d'origine que les cas (idéalement cas/témoins ne diffèrent que par la maladie)
- Appariement de cas avec un témoin (sexe, âge, origine …), mais le nombre de facteurs d'appariement doit être limité (1-5) :
  - Plus le nombre de facteurs d'appariement est élevé, plus il sera difficile de former des paires cas/témoins
  - Si on ne limite pas les facteurs d'appariement, risque de biais de sélection

(les sujets non appariés ayant toujours des caractéristiques très particulières)

Focus sur l'appariement

avantages

inconvénients

- Appariement peut être équilibré (ratio 1/1) ou déséquilibré (1 cas pour n témoins avec **n ≤ 5**)

(**appariement déséquilibré permet d'augmenter la puissance** ⭐ en réduisant les fluctuations d'échantillonnage)

- Appariement risque d'introduire des biais de sélection

(car on « choisit » quels témoins seront inclus et reliés à quel maladie, au lieu de se baser sur un échantillon aléatoire)

- Appariement diminue le risque de biais de confusion (en réduisant les biais de confusion sur les facteurs d'appariement, ce qui permet aussi d'augmenter en efficacité statistique par une réduction de la variabilité entre les groupes)

Il est difficile de choisir la population de témoins, il existe plusieurs possibilités, chaque choix à des avantages/inconvénients :

Accès — Témoins hospitaliers : Facile ; Témoins en population générale : Difficile, **couteux** ; Témoins familiaux : Facile

Motivation — Témoins hospitaliers : Forte (malades) ; Témoins en population générale : Faible (bonne santé) ; Témoins familiaux : Forte (c'est la miff)

Taux de réponse — Témoins hospitaliers : Élevé ; Témoins en population générale : Faible ; Témoins familiaux : Élevé

Biais

Témoins hospitaliers :

Risque important de biais de sélection (biais de **Berkson**)

Témoins en population générale :

- Risque faible de biais de sélection
- Risque de **biais de mémorisation différentielle**

Témoins familiaux :

Risque important de biais de sélection *(famille du patient peut partager les mêmes FR que celui-ci, donc mauvais témoins)*

> **Annale : les témoins hospitaliers ne sont pas comparable aux cas, même si les cas sont recrutés à l'hôpital**

Recueil des facteurs de risque

Dogme. Recueil et mesure de l'exposition est toujours rétrospectif

✅

- Questionnaires objectifs - validés - par un évaluateur entraîné …
- Éviter si possible de focaliser l'interrogatoire (ex. pour l'évaluation de la consommation d'alcool, poser des questions sur toutes les boissons)
- Évaluation de l'exposition en aveugle du statut malade/non-maladie (cas/témoins)

Risque. Biais de mémoire = biais de **classement différentiel** (les cas vont avoir tendance à exagérer leur exposition à un facteur de risque et les témoins à la minimiser)

> *Exemple :*

Par exemple, si on étudie le lien entre l'exposition à un médicament A et le risque de fausse couche spontanée (FCS), les femmes ayant fait une FCS se souviendront mieux avoir pris le médicament A que les femmes n'ayant pas fait de FCS, car il s'agit d'un événement traumatisant.

NSN dans les études cas-témoins

Éléments clés dans le calcul du nombre de cas à inclure dans l'étude

- **fréquence de l'exposition chez les témoins**
- **taille de l'OR** que l'on souhaite mettre en évidence
- **risques d'erreur consentis** : alpha en règle fixé à 5 % et beta en règle inférieur ou égal à 20 % → Augmenter le nombre de témoins (par rapport à celui des cas) permet d'augmenter la puissance de l'étude +++

Mesure de l'association

Mesure de l'association dans une étude de cohorte

1ère étape

- Faire un tableau de contingence : M+/M- et E+/E-
- Déterminer :
  - Risque de base (P0, risque chez les non-exposés) = P(M+/E-) = nombre de malade qui n'été pas exposé/nombre de total de sujet

- Risque absolu (P1, risque chez les exposés) = P(M+/E+) = nombre de malade qui été exposé/nombre de total de sujet

2nd étape

- RAR (réduction absolue du risque) = Risque en excès (ou différence de risque) = différence entre risque absolu et risque de base RAR = P1 - P0

(si l'excès de risque = 0, alors pas de relation entre la maladie et le facteur, aux fluctuations d'échantillonnage près)

- Risque relatif (RR) = rapport entre la probabilité d'être malade et exposé sur la probabilité d'être malade et non exposé : RR = P1/P0
- Réduction relative du risque (RRR) est une autre manière d'exprimer le RR : RRR = 1 - RR

(si RR > 1 on parle d'augmentation relative du risque)

OR ou RR ?

Il est également possible d'utiliser des OR dans les études de corhorte, mais ce n'est pas la méthodologie de référence

(peut arriver dans le cadre d'une cohorte suivie sur une courte période ou pour laquelle la date exacte d'arrivée de l'événement n'est pas connue)

Mesure de l'association dans une cas-témoin

1ère étape. Faire un tableau de contigence : M+/M- et E+/E-

2nd étape

PARTICULARITÉS DES ÉTUDES CAS TÉMOINS ⭐ :

- Dans les enquêtes cas-témoins, le nombre de cas et de témoins étant fixé par l'expérimentateur, **on ne peut pas estimer P1 et P0** et **le risque relatif ne peut pas être calculé**, l'odds ratio (OR) est une approximation du risque relatif, il représente le rapport des « chances » (ou rapport de cotes) d'être ou non malade selon l'existence ou l'absence d'exposition, il s'agit d'un rapport de ratios
- OR = (nombre de malade exposé/nombre de malade non exposé) / (nombre de non malade exposé/nombre de non malade non exposé)
- Plus l'événement est fréquent, plus OR surestime ton risque relatif quand OR > 1, à l'inverse il le sous-estime quand OR < 1

(mais dans les études cas-témoins l'événement est rare, donc OR sera proche de RR)

Résultats : RR et OR

- Objectifs : mesurer la force de l'association entre un facteur d'exposition et un événement
- Savoir dresser le **TABLEAU DE CONTINGENCE** (à connaître parfaitement !) :

Exposés (E^+)

Non-exposés (E^-)

M^+

a

c

Cote M^+ (cas) = a / c

OR = Cote M^+ / Cote M^-

M^-

b

d

Cote M^- (témoins) = b / d

Incidence E^+ = a / (a + b)

Incidence E^- = c / (c + d)

RR = IE^+ / IE^-

Exemples

- *Si le RR = 2,2 on peut dire que le risque de maladie chez les exposés est 2,2x plus élevé que chez non-exposés*
- *Si la prévalence de la maladie dans la population cible est de 8% et que l'on estime un OR à 1,5 sur un échantillon, alors on peut dire sans trop se tromper « le risque de maladie est 1,5 fois plus élevé chez les exposés que chez les non exposés » (phrase qui correspond normalement au risque relatif)*
- *Si la prévalence de la maladie dans la population cible est de 35% et que l'on estime un OR à 3,2 sur un échantillon, alors il est probable que la phrase « le risque de maladie est 3,2 fois plus élevé chez les exposés que chez les non exposés » soit fausse. Il faudra dire « il y a 3.2 fois plus de malades par rapport aux non-malades chez les exposés que de malades par rapport aux non-malades chez les non exposés. »*

Risque relatif RR

Rapport de l'incidence estimée chez les exposés sur l'incidence estimée chez les non-exposées

- Utilisés pour les études de cohortes prospectives ou études transversales ⭐
  - Attention, le **calcul de l'incidence est impossible dans les études de cas-témoins** ❌

(car le nombre de cas et de témoins est fixé à priori)

Odds ratio OR

Rapport de la cote estimé chez les exposés sur la cote estimée chez les non-exposés

- on peut le calculer quel que soit le type d'étude (contrairement au risque relatif)

Si la prévalence de la maladie est faible (**maladie rare**) dans la population cible : OR est proche de RR, on dit que c'est un bon estimateur du RR, et on pourra l'interpréter comme un RR *(notamment dans les études cas-témoins)*

- détail important car dans les modèles de régression logistique, on ne peut estimer que des OR

Interprétation

- RR ou OR = 1 → pas de relation démontrée (mais ne n'élimine pas)
- RR ou OR > 1 → facteur de risque *(ex. OR ou RR de 1,2 augmente le risque de 20%)*
- RR ou OR < 1 → facteur protecteur *(ex. OR ou RR de 0,6 réduit le risque de 40%)*

Conditions d'interprétation

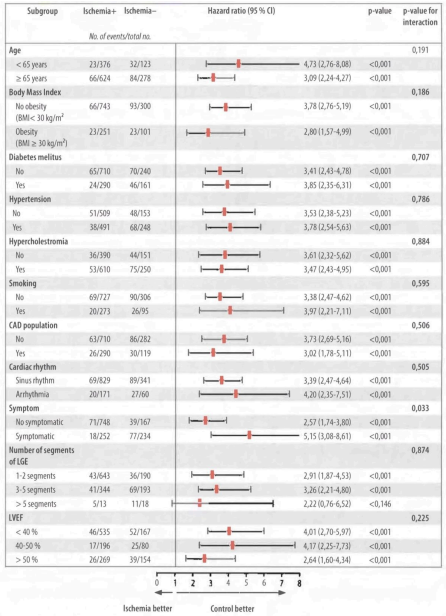
Il faut toujours interpréter un RR ou OR avec son :

- Intervalle de confiance à 95% → significatif si le RR/OR > IC et que l'IC ne comprend pas 1
- Degré de significativté p → p < alpha

Attention piège. Attention aux études de survie où le OR < 1 signifie que c'est un facteur de mortalité

Interprétation graphique = diagramme de FOREST « Forest Plot »

Exemple



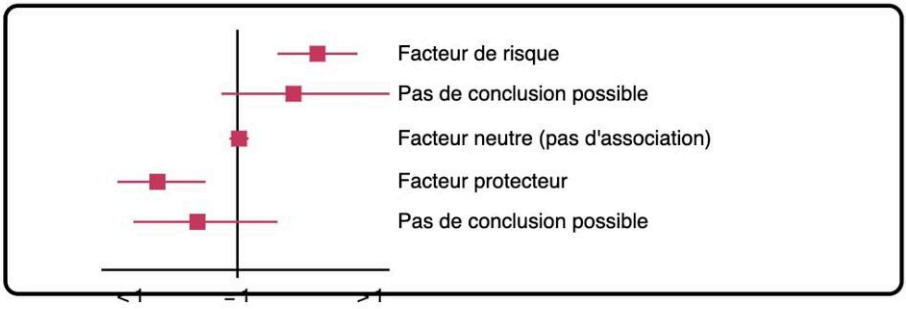
Subgroup	Ischemia+	Ischemia−	Hazard ratio (95 % CI)	p-value	p-value for interaction
	No. of events/total no.				
Age					0,191
< 65 years	23/376	32/123	4,73 (2,76-8,08)	<0,001	
≥ 65 years	66/624	84/278	3,09 (2,24-4,27)	<0,001	
Body Mass Index					0,186
No obesity (BMI< 30 kg/m²)	66/743	93/300	3,78 (2,76-5,19)	<0,001	
Obesity (BMI ≥ 30 kg/m²)	23/251	23/101	2,80 (1,57-4,99)	<0,001	
Diabetes melitus					0,707
No	65/710	70/240	3,41 (2,43-4,78)	<0,001	
Yes	24/290	46/161	3,85 (2,35-6,31)	<0,001	
Hypertension					0,786
No	51/509	48/153	3,53 (2,38-5,23)	<0,001	
Yes	38/491	68/248	3,78 (2,54-5,63)	<0,001	
Hypercholestromia					0,884
No	36/390	44/151	3,61 (2,32-5,62)	<0,001	
Yes	53/610	75/250	3,47 (2,43-4,95)	<0,001	
Smoking					0,595
No	69/727	90/306	3,38 (2,47-4,62)	<0,001	
Yes	20/273	26/95	3,97 (2,21-7,11)	<0,001	
CAD population					0,506
No	63/710	86/282	3,73 (2,69-5,16)	<0,001	
Yes	26/290	30/119	3,02 (1,78-5,11)	<0,001	
Cardiac rhythm					0,505
Sinus rhythm	69/829	89/341	3,39 (2,47-4,64)	<0,001	
Arrhythmia	20/171	27/60	4,20 (2,35-7,51)	<0,001	
Symptom					0,033
No symptomatic	71/748	39/167	2,57 (1,74-3,80)	<0,001	
Symptomatic	18/252	77/234	5,15 (3,08-8,61)	<0,001	
Number of segments of LGE					0,874
1-2 segments	43/643	36/190	2,91 (1,87-4,53)	<0,001	
3-5 segments	41/344	69/193	3,26 (2,21-4,80)	<0,001	
> 5 segments	5/13	11/18	2,22 (0,76-6,52)	<0,146	
LVEF					0,225
< 40 %	46/535	52/167	4,01 (2,70-5,97)	<0,001	
40-50 %	17/196	25/80	4,17 (2,25-7,73)	<0,001	
> 50 %	26/269	39/154	2,64 (1,60-4,34)	<0,001	

0 1 2 3 4 5 6 7 8

Ischemia better — Control better

Untitled

Schéma synthèse : Savoir analyser un facteur d'exposition sur un diagramme de Forest



EDN PRO

image.png

Contexte. Figure de référence pour présenter les résultats d'une analyse en sous-groupe (peut être utilisé dès lors qu'une analyse en sous-groupe est proposée, que ce soit pour une étude interventionnelle ou épidémiologique)

Objectif. Permet de visualiser très facilement le résultat d'intérêt sur le critère de jugement principal, et/ou les critères de jugement secondaire au sein d'un grand nombre de sous-groupes de l'étude

Abscisses (horizontal). Effet du traitement (rapport de cotes pour le décès ou l'invalidité)

Ordonnées (vertical). Sur lequel on place les sous-groupes selon une échelle arbitraire

Chaque ligne. Sur chaque ligne, l'effet du traitement observé dans un sous-groupe est représenté par un symbole (rond ou carré) entouré d'un trait horizontal qui représente l'intervalle de confiance associé

« p value for interaction »
= test
d'homogénéité
Permet de mettre en évidence l'existence de facteurs de confusion au sein de l'étude (interaction entre l'un des facteurs étudiés et la survenue du critère de jugement principal, indépendemment du FR étudiés ou de l'intervention étudiée)

- Si p value for interaction < alpha : alors le facteur étudié est bien un **facteur de confusion potentiel**
  - *dans l'exemple du pezel : la présence de symptômes est un facteur de confusion*

Intérêts

- Soit à visée complémentaire en soutenant que le **résultat principal de l'étude est retrouvée sur la totalité de la population étudiée** (homogène dans les différents sous-groupes)
- Soit à visée exploratoire lorsque le **résultat est plus pertinent cliniquement dans certains sous-groupes**, et permet de proposer de nouvelles études explorant ces différents sous-groupes

Interprétation ⚠️
Piège :

- Il est possible de dire qu'une différence étudiée est plus importante dans l'un des sous-groupes

(= « est-ce que c'est significatif ? »)

- Mais attention, on n'a jamais le droit de conclure sur une analyse en sous-groupe ⚠️

(même si le résultat est statistiquement significatif)

Autres indices à connaître

Réduction du risque — RRR et RAR

Réduction relative du risque (RRR)

```
RRR = (1-RR) x 100
```

Réduction absolue du risque (RAR)

```
RAR = (IE+) - (IE-)
```

- dans les essais thérapeutiques, la RAR permet de calculer le nombre moyen de sujets à traiter pour éviter un événement avec :

```
NST = 1/RAR
```

Exemple d'expressions pouvant sembler très différentes d'un même résultat d'un essai thérapeutique

- risque traitement (A) = 10 % et placebo (B) = 30 %
- RR = 0,33
- RRR = 66,7 %
- RAR = 20 %
- NST = 1/ 20 % = 5

Notion de « test de tendance » (trend) : tombé en annale

Dans quelle étude ? Test réalisé dans les études épidémiologiques analytiques *(cohorte, cas-témoin …)*

Objectif

Mettre en évidence une relation dose-effet entre un facteur d'exposition et une maladie
(ex. plus les patientes voient du café et plus le taux de nouveau-né avec fente palatine est élevé)

Autres types d'études épidémiologiques

Études transversales

Descriptive

Études transversales épidémiologiques sont principalement descriptives, permet de :

- Estimer la prévalence d'un événement de santé
- Estime la fréquence d'une exposition

Ces taux doivent en théorie toujours être présentés avec leur intervalle de confiance à 95 % (IC95 %) lorsque l'enquête repose sur un échantillon, l'IC permet d'avoir une idée de la précision de l'indicateur de santé estimé

Attention, contrairement aux IC95% des risques relatifs ou odds ratio (OR), cet IC95 % ne permet pas de conclure à une quelconque significativité, cela n'a d'ailleurs aucun sens de conclure à la significativité d'une prévalence (ni d'une incidence)

Étiologique

Étude transversale étiologique possible : inclusion du patient concomitante avec le receuil simultané d'information sur la maladie et les facteurs de risque à un instant donné t

Ici, la mesure de l'association peut se faire avec 2 mesures possibles :

- RR (rapport des fréquences de la maladie chez les exposés et non-exposés)
- OR (le plus souvent, obtenu par le modèle de régression logistique, mais attention dans ce type d'étude la maladie est souvent fréquente et l'OR ne pourra pas être interprété comme un RR)

Preuve. Niveau de **preuve** faible (niveau 4, grade C)

Études Transversales — Avantages / Inconvénients

6 avantages

Étude de **plusieurs maladies**

Permet l'**estimation de la prévalence** (équivalent de RR)

Mesure d'**expositions complexes** (en milieu professionnel par exemple)

Facilité de réalisation

Faible coût

Rapide (obtention rapide des résultats)

6 inconvénients

Séquence temporelle impossible à affirmer entre exposition et maladie

Nécessite un **échantillon représentatif** si l'étude a un volet descriptif

Mal adaptée aux **maladies rares**

Risque important de **biais de sélection** dans la constitution de l'échantillon

Risque important de **biais de classement différentiel** dans la mesure des expositions

Risque de **biais de confusion**

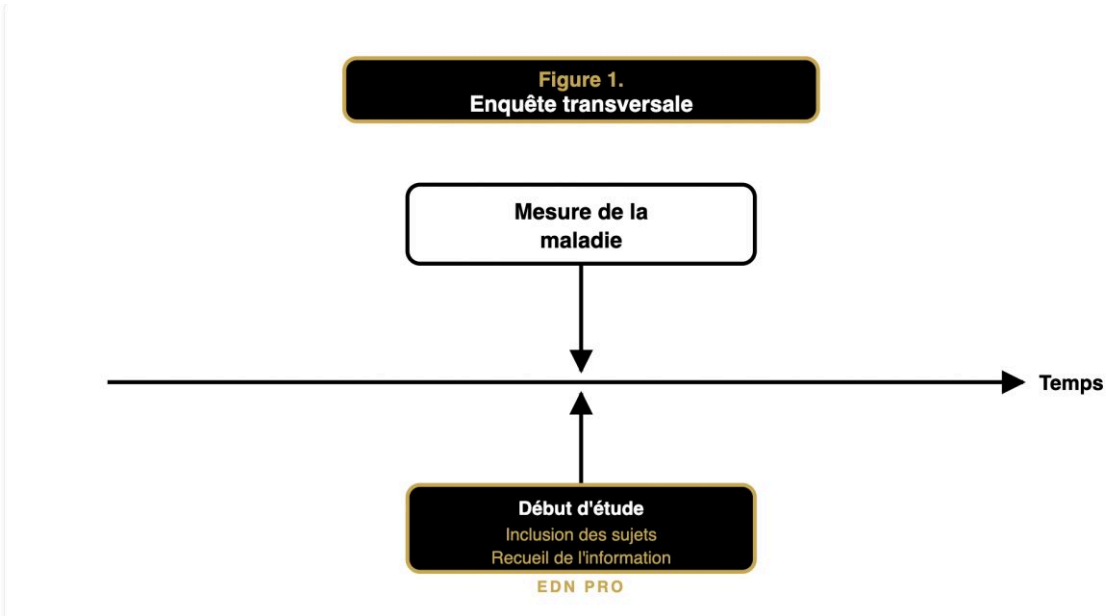


image.png

Études des interventions de santé

Principe. Évaluation d'action ou de programmes de santé dans un but de prévention primaire, secondaire ou tertiaire

Exemples

1/ Quel est l'impact d'une campagne d'information au sein des boites de nuit échangistiques sur la consommation de cocaïne chez les jeunes de 16-26 ans

2/ Quel est l'impact d'une nouvelle organisation au sein des urgences d'un hôpital pour la gestion des douleurs thraciques sur le taux de décès par IDM dans l'hôpital

Critères conditionnant le choix du type d'étude méthodologique

- Choix de la population ciblée par l'intervention
- Choix de la question posée selon la nature de l'intervention
- Choix du critère d'évaluation

Essai contrôlé randomisé (type d'étude de référence ++)

Essais contrôlés randomisés d'évaluation des interventions de santé

Quel est le type d'étude de référence pour les « études d'évaluation des interventions de santé » ?
→ **essai contrôlé randomisé +++** (**PCZ**) car permet de porter un jugement de causalité sur l'efficacité de l'intervention

4 inconvénients des essais contrôlés randomisés d'évaluation des interventions de santé

- risque de **diminution de la VALIDITÉ EXTERNE** (**PCZ**) : l'essai randomisé **ne permet pas de reproduire la situation réelle d'application de l'intervention** ce qui limite l'extrapolation des résultats dans la « vraie vie »
- risque de **BIAIS DE CLASSEMENT DE SUIVI** (**PCZ**) : **l'absence d'aveugle sur l'allocation de l'intervention est généralement la règle**, sauf si les auteurs ont pris des précautions lors de la mesure du critère
- risque de **nombreux PERDUS DE VUE** : l'adhésion des sujets au protocole peut être difficile à obtenir avec le risque d'un **taux élevé de refus de participation**
- risque de « **contamination entre les bras** » : **du fait de l'absence d'aveugle**, le groupe témoin adopte les procédures suivies dans le groupe expérimental en raison d'informations véhiculées par le personnel de l'étude (le risque est une sous-estimation des différences entre les 2 groupes)

Essai randomisé en grappes (cluster)

Principe

- **essai randomisé pour l'étude de groupes de patients** (ex : randomisation de centres entiers par rapport à d'autres centres) et **non pris les patients isolément**

- **exemples de clusters** (unité sociale) = **centres de soins (90 % des cas)**, cliniciens, cabinets libéraux…

3 situations recommandées pour réaliser un essai en grappes

- **l'intervention testée concerne un groupe** et non un individu

Exemple : dans le cadre de la lutte contre l'alcool au volant, une campagne intensive d'affichage public à l'échelle municipale est mise en place par tirage au sort dans certaines villes (villes expérimentales) et pas dans d'autres (villes témoins).

- **en cas de risque de contamination élevé entre les groupes** : fréquent pour l'évaluation de l'impact de nouvelles modalités de prise en charge des patients, de programme éducatif ou de programme de dépistage

Exemple : pour réduire les coups de soleil dans l'enfance, un programme éducatif dispensé par les professeurs est mis en place dans des écoles tirées au sort. Il était nécessaire de travailler au niveau d'une école entière plutôt qu'au niveau des professeurs ou des élèves

- **Contexte de considérations éthiques, logistiques ou politiques**.

Exemple : il est plus acceptable de proposer une supplémentation protidique chez l'ensemble des enfants de différents villages d'Afrique et de ne pas proposer cette supplémentation dans d'autres villages, plutôt que de donner une supplémentation à certains enfants et pas à d'autres au sein d'un même village

5 inconvénients des essais en grappe

- risque de **BIAIS DE SÉLECTION important** (**PCZ**) : **soit parce que l'on recrute moins de participants dans l'un des groupes** (expérimental ou témoin) avec le risque éventuel qu'une grappe soit vide, **soit parce que l'on ne recrute pas le même type de sujets dans les deux groupes**. Ce biais de sélection est accentué par l'absence habituelle d'aveugle (décision du recruteur influencée)
- risque de **BIAIS DE CLASSEMENT de SUIVI et de MESURE** (**PCZ**) : **lié à l'absence d'aveugle** dans le suivi et l'évaluation du critère de jugement
- risque de **MANQUE DE PUISSANCE** (**PCZ**) : avec **NSN d'un essai en cluster plus important que celui d'un essai classique**
- **analyse statistique complexe** : avec nécessité de **méthodes adaptées tenant compte de la corrélation entre les sujets d'une même grappe** (appelée « corrélation intraclasse ») pour éviter une sous-estimation des intervalles de confiance et des degrés de signification et donc, éviter des conclusions erronées
- **chronologie des essais classique non respectée** : dans les essais en cluster on commence par sélectionner les clusters puis on les randomise et ensuite on inclut les individus, après recueil du consentement

Particularités du consentement dans les essais en grappe

- nécessité de **2 niveaux de consentement** :
  - celui des **responsables de cluster** (professionnels de santé)
  - celui des **patients** : **soit par recueil du consentement, soit juste par information sur le fait qu'ils participent à une étude sans recueil du consentement**
- **loi JARDE 2016 sur les essais randomisés en cluster** : **PAS DE NÉCESSITÉ DE CONSENTEMENT SYSTÉMATIQUE pour certains essais randomisés en cluster**, si justification méthodologique +++ (**PCZ**)

(information sans nécessité de consentement signé, dans certaines situations à large échelle, comme pour une étude sur un traitement de l'eau ou l'utilisation à large échelle d'insecticides…)

Principe de l'évaluation de la comparabilité initiale des groupes

- nécessité de 2 niveaux de vérification avec 2 figures type « tableau 1 » (**PCZ**)
  - **1er tableau** = caractéristiques des **2 groupes** à l'inclusion → vérifier la comparabilité entre groupes
  - **2e tableau** = caractéristiques des **individus au sein des clusters** à l'inclusion → vérifier l'homogénéité de chaque cluster

Particularités de l'analyse statistique

- **principe** = implique une **structure hiérarchique** des données : les individus sont « emboîtés » dans les clusters, ce qui entraîne une **corrélation entre les participants d'un même cluster**, évaluée par le **coefficient intra-classe (CCI)**
- **CCI (coefficient intra-classe) = degré de ressemblance entre les participants d'un même cluster** (CCI = 0 indique qu'il y a indépendance entre les patients d'un même cluster ; à l'inverse, plus le coefficient est élevé, plus les patients d'un cluster sont semblables, et leurs données corrélées)
- **2 moments clés de l'étude qui doivent tenir compte de la corrélation entre les participants d'un même cluster** :
  - **calcul du NSN** (**PCZ**) = doit **tenir compte de cette corrélation** entre les participants d'un même cluster (car **cette corrélation induit une augmentation du NSN**)
  - **analyse statistique** = doit utiliser des méthodes statistiques dédiées qui intègrent cette corrélation sous peine d'augmenter le risque de conclure à tort à une différence qui n'existe pas entre les groupes de traitement

Évaluation de la validité EXTERNE

- **si peu de clusters (centres) randomisés** = l'effet observé peut être le fait de l'intervention ou le fait des caractéristiques des clusters randomisés dans le bras expérimental
- **plus le nombre de clusters (centres) randomisés est important = plus on augmente la VALIDITÉ EXTERNE** (**PCZ**) (plus on se rapproche de l'essai avec randomisation individuelle)

Étude quasi-expérimentale avant-après

Principe

Consiste à **comparer les sujets avant et après la mise en place de l'intervention**. Ces études sont actuellement **moins utilisées** en raison du développement récent des essais en cluster

2 situations recommandées pour réaliser une étude quasi-expérimentale avant-après

- **s'il est impossible de faire une randomisation individuelle ou en grappes** car l'intervention ne peut être limitée à une partie de la population
- **système d'enregistrement systématique d'informations à disposition** depuis plusieurs années

4 inconvénients des études avant-après

- risque de **biais important**
- **niveau de preuve faible (niveau 4)**
- **possibilité que la différence observée entre les deux temps soit liée non pas à l'intervention mais à une évolution « spontanée »**, à un changement de méthodes diagnostiques, à une **évolution concurrente d'autres pratiques** (il est recommandé de disposer de multiples points avant l'intervention et après l'intervention pour mieux distinguer la tendance temporelle sous-jacente sans rapport avec l'intervention)
- **difficulté de trouver un groupe témoin comparable avant l'intervention** (on peut en effet adjoindre un groupe témoin contemporain de l'intervention pour tenter de contrôler le risque d'autres facteurs concurrents à l'intervention)

Études de pratique

Principe

Enquêtes visant à **décrire et évaluer les pratiques de soins** des professionnels **de santé**, qui s'inscrivent dans une **démarche d'assurance-qualité**

Exemples

- Est-ce que les pratiques de prise en charge de la FA ont évolué après publication des dernières recommandations ESC de 2016 ?
- Quelles sont les pratiques d'utilisation des différentes techniques d'imagerie cardiaque dans le diagnostic de la cardiomyopathie hypertrophique ?

Liste des éléments évaluables par une étude de pratique

- apprécier les **connaissances des professionnels de santé** sur une situation clinique
- connaître l'**état des lieux des pratiques adoptées avant recommandations** dans une situation clinique (afin de guider l'élaboration de ces recommandations)
- identifier les **déterminants des pratiques de soins**
- évaluer la **diffusion de nouvelles recommandations** ou d'une nouvelle thérapeutique
- rechercher les **déterminants de l'utilisation en routine de nouvelles recommandations**
- évaluer l'**impact de nouvelles recommandations** sur les pratiques
- évaluer l'utilisation en routine d'une nouvelle technologie médicale (modalités de réalisation, indications, tolérance, expériences des opérateurs)

2 critères intervenant dans le choix du type d'étude méthodologique

- **choix de la question posée** : à l'échelle individuelle du professionnel de santé ou **collective** à partir de base de données
- choix du **critère d'évaluation** :
  - **soit enquête DÉCLARATIVE** : le professionnel rapporte ses connaissances sur les recommandations, la pratique qu'il pense avoir ou ses opinions (par un entretien, par téléphone, par courrier ou par internet)
  - **soit enquête FACTUELLE** : s'appuyant sur des données objectives telles que le dossier médical, les examens complémentaires, des bases de données

Quel est le type d'étude le plus fréquemment utilisé pour une étude de pratique ?

- **étude transversale +++** (**PCZ**)
- **soit transversale répétée dans le temps avant-après** :
  - *Question ECNi blanche nationale* : avant et après publication de recommandations par exemple
- **soit transversale de type enquête ici-ailleurs** : menée dans différentes zones géographiques

2 autres types de recueil des données pour une étude de pratique

- **recueil prospectif des pratiques = risque majeur de modification des pratiques liée à l'enquête**
- **recueil rétrospectif des pratiques** : à partir d'un enregistrement systématique de données au cours du temps (permet de pallier le problème d'une modification des pratiques liée à l'enquête). **La qualité de l'étude dépend alors de la qualité des données enregistrées** (exhaustivité de l'enregistrement, données manquantes…)

Quelle technique est recommandée pour protéger la validité externe d'une étude de pratique ?

- **tirage au sort à partir d'une base de sondage +++**
  - **technique lourde et pas toujours possible** en l'absence de base de sondage
  - **risque de biais de sélection majeur +++** (**PCZ**) car risque d'un **taux de non-réponse élevé** (même si un professionnel de santé est tiré au sort, il est souvent peu enclin à participer à une enquête)
- **utilisation des méthodes d'analyse statistique** pour aider à corriger les biais (extrapolation à l'échelle individuelle)

Grands principes d'interprétation en épidémiologie

Causalité ne peut pas être affirmée par une seule étude observationnelle (différence statistiquement significative ≠ causalité) ⚠️

Toujours privilégier l'**analyse multivariée** dans une étude épidémiologique (prise en compte des facteurs de confusion souvent nombreux)

Notion de calcul des « personne-temps » (annale)

Schéma explicatif

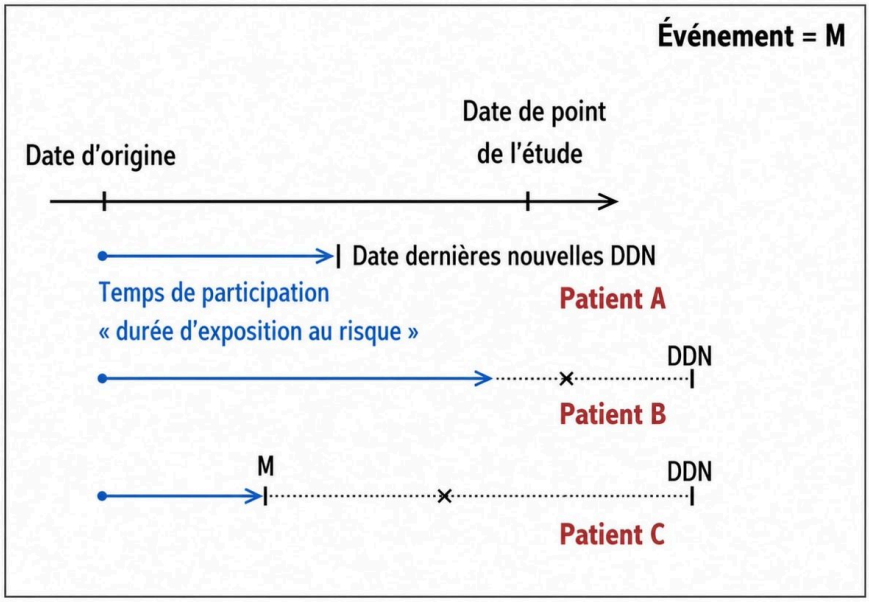


image.png

> *(Le temps de participation, donc d'exposition au risque, correspond à la différence entre la date de fin de participation et la date d'origine. La date de fin de participation peut être, selon les patients, la date des dernières nouvelles [patient A], la date de point de l'étude [patient B], ou encore la date de l'événement d'intérêt [patient C]).*

Définition. Unité de mesure correspondant à la durée (le temps) pendant laquelle un sujet est susceptible de permettre l'observation du phénomène étudié

Intérêt. Permet de mieux prendre en compte la contribution exacte à l'indicateur de chaque sujet pour la période pendant laquelle il est réellement observé

Exemple

« mortalité » est calculée :

- *Soit sous la forme d'une proportion rapportant le nombre de cas à la taille de la population*
- *Soit sous la forme taux rapport le nombre de décès au nombre de personne-temps sur la période considérée*

Personnes-années

En pratique, le nombre de personnes-années correspond au cumul des durées de participation de chaque personne (*même principe que celui de l'estimation de l'exposition tabagique par le calcul des paquets-années*)

Ex. une valeur de 100 personnes-années peut correspondre par exemple à une exposition de 50 personnes pendant 2 ans ou une exposition de 100 personnes pendant 1 an

Calcul. Dans les études prospectives, les données de suivi ainsi que les dates de survenue des événements sont connus de façon précise pour chaque sujet inclu → permet de calculer de manière exacte les personnes-temps « à risque »

Causalité

Il faut bien différencier association statistiquement significative et lien causal, ce n'est pas parce qu'on a montré une association statistiquement significative entre un facteur et un critère de jugement qu'il y a un lien causal !

La seule manière d'affirmer un lien de causalité, c'est de comparer des groupes qui ne diffèrent que par l'exposition ou non à l'élément soumis à évaluation, c'est-à-dire comparables sur toutes les autres caractéristiques. Ainsi, toute différence observée entre les groupes sera imputable à l'élément soumis à évaluation

Critères de Hill (décrits par Sir Bradford Hill) 🔔

Il s'agit d'un faisceau d'arguments indirects suggérant l'existence d'un lien de causalité (mais sans jamais le prouver !) Outil dédié essentiellement aux études épidémiologiques avec niveau de preuve 2, 3 ou 4

Critères internes à l'étude (cohérence interne)

Association statistique entre exposition/maladie, et Forte intensité de l'association (plus le RR et le OR s'éloigne de 1 avec un intervalle de confiance étroit) → critère ni nécessaire, ni suffisant

Relation de type "**dose-effet**" entre exposition/maladie

- critère ni nécessaire, ni suffisant
  - cf test de tendance p-trend

Spécificité de la relation entre exposition/maladie

Minimisation des biais de sélection et de classement, Prise en compte correcte de l'ensemble des facteurs de confusion connus

Absence d'ambiguïté temporelle (exposition doit précéder la maladie) → critère nécessaire mais non suffisant

Critères externes à l'étude (cohérence externe)

Concordance avec les résultats d'études antérieures

Plausibilité biologique (au mieux, **explication physiopathologique**)

Concordance avec les expérimentations menées **in vitro** ou chez **l'animal**

Gradients géographiques parallèles de l'exposition et de la maladie

Diminution de l'incidence de la maladie lorsque l'exposition est supprimée ou réduite

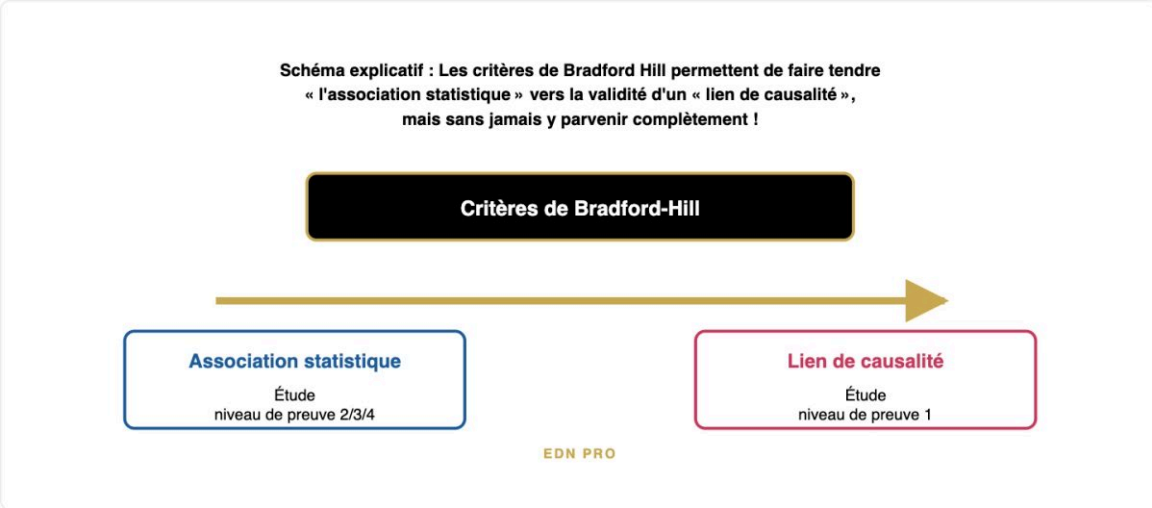


image.png

Pour comprendre — OR, RR et causalité

- **OR et RR ne témoignent que de l'existence d'une association statistique donc ne prouvent pas l'existence d'un lien de causalité**

Pour conclure à la causalité, il faut faire une étude expérimentale randomisée (difficile car non éthique pour un facteur de risque ou même un facteur protecteur ; en effet, on ne pourrait pas imaginer une étude avec des patients randomisés sur le tabac…)

Essai contrôlé randomisé ✅ . s'il est bien conduit, permet d'affirmer un lien causal car la randomisation permet d'obtenir des groupes comparables pour tous les facteurs de confusion connus ou inconnus

Étude observationnelle ❌. Ne **permet pas de conclure à un lien de causalité**, mais certains éléments s'ils sont présents sont cependant en faveur d'un lien causal → ces éléments ont été décrits par Sir Bradford Hill

Biais dans les études épidémiologiques ✅

Biais de sélection

Biais des témoins travailleurs (healthy worker effect)

= biais de récrutement

Sujets témoins travailleurs sont forcément en meilleur santé que les cas) : si probabilité d'inclusion dans l'étude est liée au facteur étudié

Biais d'auto-sélection

= biais du volontariat

Inclusion est due à la décision du patient (non représentatif de la population)

Biais de Berkson. Recrutement de témoins en milieu hospitalier qui ne sont pas représentatifs de la population générale

Biais de survie sélective

(biais des cas prévalents)

Dans les études **cas-témoins** si inclusion de cas prévalents (mélange de patients incidents et de malades déjà connus et ayant survécu), les cas prévalents sont forcément moins graves et biaisent la population

- Prévention par la sélection de cas incidents ✅

Biais d'attrition

(biais des perdus de vus)

Dans les études de **cohorte prospective**

- toujours vérifier que nombre de sujet inclus = sujets analysés (biaisé si les sujets perdues de vue sont exclus de l'analyse)

Biais de classement

- Biais d'évaluation subjective de l'enquêteur

Biais de mémorisation (différentiel ou non) : retrouvé dans les études cas-témoins

Principe

- Un cas se souvient toujours mieux d'une exposition qu'un témoin, car il est + concerné : il majore son exposition au FR
- Le témoin minimise son exposition au FR

Mode de receuil. Systématique si le mode de réceuil est déclaratif (interrogatoire), majorée si l'évaluation n'a lieu qu'une fois

Correction

Pour le corriger :

- Les sujets sont en aveugle des hypothèses
- Évaluation d'après des données recueillies de manière objective

- Biais de prévanication : lorsque le patient ne dit pas la vérité (comme pour la prise d'une substance illicite)
- Biais de jugement : évaluateur peut être influencé s'il connait le statut exposé/non-exposé du patient ou inversement (ex: classé un cas dans le groupe exposé juste parce qu'on sait qu'il est malade)
- Biais liés au mode d'évaluation

Notion de biais différentiel (à éviter absolument) ou non-différentiel (moins grave, car simple risque de perte de puissance) est majeure en étude épidémiologique

Mesures préventives

- Receuil des données par questionnaires standardisés, objectifs et validés
- Enquêteurs en aveugle du groupe
- Formation des enquêteurs
- Étude de la variabilité inter-enquêteurs
- Si données déclaratives : mesures répétées

Biais de confusion

Prise en compte du facteur de confusion lors de la planification de l'étude

- Appariement *avec un témoin* : Utiliser l'appariement de façon à équilibrer la distribution du facteur de confusion entre le groupe exposé et le groupe non-exposé, afin que le facteur de confusion ne soit plus lié à l'exposition (ex. si l'âge est facteur de confusion, on associe à chaque sujet exposé un sujet non exposé de même classe d'âge)
- Restriction de la population étudiée (ne pas inclure ceux qui présente le facteur de confusion, ou les exclure)
- Stratification : restreindre la population d'étude à 1 seule strate du facteur de confusion

Prise en compte dans l'analyse statistique

- Analyse stratifiée = subdiviser la population de chaque pour une analyse en sous-groupe selon les facteurs
- Ajustement par l'analyse statistique multivariée : permet de corriger l'estimation des OR ou RR, mais cette correction peut malheureusement n'être qu'imparfaite, on parle alors de confusion résiduelle (residual confounding)
  - Nécessite au préalable que les informations sur ces facteurs de confusion aient été préalablement renseignées

Exemple si le facteur de confusion est le tabac

- Restriction de la population étudiée : on exclut les fumeurs
- Appariement : si on inclut un fumeur dans un groupe, on inclut un fumeur dans l'autre groupe
- Stratification : on mesure l'association avec l'événement chez les fumeurs, et l'association avec l'événement chez les non fumeurs

Il s'agit du **seul biais qui peut être pris en compte lors de l'analyse statistique** (contrairement aux biais de sélection ou classement où ce n'est pas possible)

Recommandations pour rapporter une étude étiologique

Checklist STROBE des informations à inclure pour rendre compte des résultats d'études observationnelles

Titre et Résumé

Titre et résumé	1	(*a*) Indiquer le type d'étude avec des termes courants, dans le titre ou le résumé
		(*b*) Fournir un résumé informatif et équilibré de ce qui a été fait et ce qui a été trouvé

Introduction

Introduction		
Contexte/rationnel	2	Expliquer le contexte scientifique et le rationnel de l'investigation rapportée
Objectifs	3	Présenter les objectifs spécifiques et les hypothèses de travail

Méthodes

Méthodes		
Type d'étude	4	Présenter précocement les éléments-clefs du type d'étude
Contexte d'étude	5	Décrire le contexte, les lieux et dates d'intérêt, notamment les périodes de recrutement, d'exposition, de suivi et de recueil de données
Participants	6	(*a*) *Etude de cohorte* — présenter les critères d'éligibilité et les sources et méthodes de sélection des sujets. Décrire la méthode de suivi des sujets. *Etude cas-témoin* — présenter les critères d'éligibilité et les sources et méthodes de diagnostic des cas et de sélection des témoins. Expliquer le rationnel du choix des cas et des témoins *Etude transversale* — présenter les critères d'éligibilité et les sources et méthodes de sélection des sujets
		(*b*) *Etude de cohorte* — en cas d'appariement, donner les critères d'appariement et le nombre d'exposés et de non-exposés *Etude cas-témoin* — en cas d'appariement, donner les critères d'appariement et le nombre de témoins par cas
Variables	7	Définir clairement tous les critères de jugement, expositions, facteurs prédictifs, facteurs de confusion potentiels et facteurs d'interaction. Préciser les critères diagnostiques, le cas échéant.
Source de données / mesure	8*	Pour chaque variable d'intérêt, préciser les sources de données et les détails sur les méthodes d'évaluation (mesure). Décrire la comparabilité des méthodes d'évaluation s'il y a plus d'un groupe.
Biais	9	Décrire toute mesure prise pour éviter les sources de biais
Taille de l'échantillon	10	Préciser la taille de l'échantillon obtenu

Variables quantitatives	11	Expliquer comment les variables quantitatives ont été traitées dans les analyses. Le cas échéant, décrire quelles catégorisations ont été choisies et pourquoi
Méthodes statistiques	12	(*a*) Décrire toutes les méthodes statistiques, notamment celles utilisées pour prendre en compte la confusion
		(*b*) Décrire toute méthode utilisée pour étudier des sous-groupes et des interactions
		(*c*) Expliquer comment les données manquantes ont été prises en compte
		(*d*) *Etude de cohorte* — si approprié, expliquer comment les perdus de vue ont été pris en compte dans l'analyse *Etude cas-témoin* — si approprié, expliquer comment l'appariement des cas et des témoins a été pris en compte dans l'analyse *Etude transversale* — si approprié, décrire les méthodes d'analyse prenant en compte la stratégie d'échantillonnage
		(*e*) Décrire toute analyse de sensibilité

Résultats

Résultats		
Participants	13*	(a) Préciser le nombre de sujets à chaque étape de l'étude — par exemple, le nombre de sujets potentiellement éligibles, dont l'éligibilité a été évaluée, dont l'éligibilité a été confirmée, inclus dans l'étude, ayant eu un suivi complet, et analysés
		(b) Préciser les raisons de non-participation à chaque étape
		(c) L'utilisation d'un *flow chart* devrait être considérée
Données descriptives	14*	(a) Donner les caractéristiques des sujets (démographiques, cliniques, sociales…) et des informations sur les expositions et les facteurs de confusion potentiels
		(b) Pour chaque variable d'intérêt, indiquer le nombre de sujets dont la donnée est manquante
		(c) *Etude de cohorte* — décrire la durée de suivi (par exemple durée moyenne et totale)
Critères de jugement	15*	*Etude de cohorte*—Préciser le nombre d'événements correspondant au critère de jugement, ou un autre indicateur équivalent
		Etude cas-témoin — Préciser les effectifs de sujets dans chaque catégorie d'exposition, ou un autre indicateur de mesure d'exposition
		Etude transversale — Préciser le nombre d'événements correspondant au critère de jugement, ou un autre indicateur équivalent
Résultats principaux	16	(*a*) Donner les estimations non ajustées, et le cas échéant les estimations ajustées sur les facteurs de confusion, et leur précision (par exemple intervalle de confiance à 95%). Exposer clairement quels facteurs de

Untitled

		confusion ont été pris en compte et pourquoi
		(*b*) Préciser les limites des catégories lorsque les variables continues ont été catégorisées
		(*c*) Le cas échéant, on pourra traduire les estimations de risque relatif en risque absolu sur une période de temps pertinente
Autres analyses	17	Décrire les résultats des autres analyses effectuées — par exemple analyses en sous-groupes, recherche d'interactions, analyses de sensibilité

Untitled

Discussion

Discussion		
Résultats-clés	18	Résumer les résultats-clés en regard des objectifs de l'étude
Limites	19	Discuter des limites de l'étude, en tenant compte des sources de biais potentiels et de l'imprécision des estimations. Discuter le sens et l'intensité de tout biais potentiel.
Interprétation	20	Donner une interprétation globale des résultats, en restant prudent, en considérant les objectifs, les limites, la multiplicité des analyses, les résultats d'études similaires, et d'autres éléments pertinents
Généralisabilité	21	Discuter la généralisabilité (validité externe) des résultats de l'étude

Untitled

Autres informations

Autres informations		
Financement	22	Préciser les sources de financement et le rôle des financeurs dans la présente étude et, le cas échéant, dans l'étude originale sur laquelle le présent article est basé

Études thérapeutiques

> *Bien que la plupart des études interventionnelles soient des essais thérapeutiques, leur cadre est bien plus large : l'intervention peut être un nouveau traitement (étude thérapeutique), utilisation d'un nouveau test diagnostique (étude diagnostique), une stratégie de prise en charge, une campagne de communication ...*

Donc étude interventionnelle ≠ étude thérapeutique

Ce cours aurait pu s'intituler « essai randomisé », car toute étude interventionnelle devrait être randomisée

Commandements de l'essai thérapeutique = les 10 commandements de Bergmann

1. Essai contrôlé (contrôle = placebo ou traitement de référence)
1. Étude randomisée (listes générées par ordinateur, assignation secrète respectée avec randomisation centralisée)
1. Étude en double aveugle (voire triple aveugle)
1. Nombre de sujets nécessaires calculés à priori
1. Population d'inclusion claire : critères précis d'inclusion, de non-inclusion, d'exclusion
1. Critère de jugement principal d'évaluation **unique** : objectif et cliniquement pertinent
1. Analyse en intention de traiter
1. Analyse du critère de jugement principal en fin d'étude sur l'ensemble de population incluse (gestion des données manquantes)
1. Différence statistiquement significative [$p < \alpha$, IC 95% ne comprend pas 1 (ratio) ou 0 (différence), ou dans les essais selon borne de non-infériorité ou d'équivalence selon la borne d'équivalence]
1. Différence cliniquement significative : taille de l'effet, indice de l'effet adapté

> **Obsessions dans une étude thérapeutique :**

- Efficacité démontrée
- Tolérance (parfois implicite dans l'article, mais toujours y penser)

Méthodes

Phases des essais thérapeutiques

Il s'agit en général d'un essai de phase 3 dont les résultats peuvent conduire à l'autorisation de mise sur le marché (AMM) :

Population

Phase préclinique :

- Animal 🐁 = in vivo
- Milieux artificiels = in vitro
- Programme informatique (prédiction de l'action d'une protéine) = in silico

Phase 1 :

Petit nombre de volontaires sains

Phase 2 :

Petit nombre de malades

(ou à des sujets sains si « phase 2a »)

Phase 3 :

Grand nombre de malades

- Permet l'obtention de l'AMM

Phase 4 :

Population générale (<u>après AMM</u>)

Essai

Phase 1 :

Ouvert, non contrôlé

Phase 2 :

- Ouvert, non contrôlé
- Essai de phase 2 peut être randomisé/contrôlé
- **Peuvent porter sur plusieurs molécules**

Phase 3 :

Randomisé, Contrôlé,
Double aveugle

Phase 4 :

- Étude observationnelle
- Randomisé, Contrôlé, Double aveugle

Objectif

Phase préclinique :

- **Toxicologie** ☠
- Pharmacocinétique

Phase 1 :

- Tolérance, *Toxicité*
- Pharmacocinétique
- Mode d'administration
- Dose maximale tolérée
- Calcul des doses pour la phase 2

Phase 2 :

- Efficacité pharmacologique ⭐

(*pharmacodynamique*)

- *Toxicité à court terme*
- *Étude de la pharmacocinétique*
- *Étude de la relation dose-effet*
- Calcul des doses pour la phase 3

(dose efficace)

Phase 3 :

- Efficacité clinique ⭐

(efficacité thérapeutique comparative)

- Tolérance
- *Rapport bénéfice/risque*

Phase 4 :

- **Pharmacovigilance**
- Recherche de nouvelles indications

Certains auteurs distingue au sein de la Phase 2, la phase 2A et 2B :

2A. Il s'agit de la phase **préliminaire**, c'est un screening ayant pour but de déterminer, sur le **nombre le plus restreint possible de sujets**, si une drogue peut être considérée comme inactive et donc non retenue pour les phases suivantes

2B. Vise à estimer le taux de réponse avec la nouvelle drogue avec une précision donnée, cette étape est indispensable pour disposer des éléments qui permettront le calcul du nombre de sujets nécessaires pour les essais de phase 3

Focus :

1 contre-indication à la réalisation d'une phase 1. Étude d'affections malignes (cancers, hémopathies) : car les chimiothérapies ont le plus souvent un risque de favoriser un cancer secondaire et de donner une infertilité, il est donc exclu de les proposer en essai de phase 1 à des sujets sains

2 situations où un essai de phase 2 est envisageable

- Soit étude d'une nouvelle molécule
- Soit étude d'une molécule ayant déjà l'AMM mais dont on veut évaluer l'intérêt dans une autre indication

---

Choix du comparateur (élément important à évaluer)

> **Groupe contrôle est systématique pour les essais cliniques de Phase 3 (mais pas pour les essais de phase 2)**

Choix dépend de la pathologie étudiée :

- S'il existe un traitement ayant fait la preuve de son efficacité dans cette pathologie, ce traitement devrait être le comparateur
- Si aucun traitement n'a fait la preuve de son efficacité dans la pathologie étudiée, le groupe contrôle devrait recevoir un placebo

Effet placebo

Correspond à l'effet positif de la prise d'un médicament qui n'est pas lié aux propriétés physico-chimiques de la molécule, mais au fait que l'on prend un traitement (effet psychologique), selon le collège de thérapeutique, on distingue :

- Placebo pur : aucun effet pharmacologique
- Placebo impur : traitement **dénué d'effet utile dans l'indication où il est utilisé**, mais **dotés d'autres effets pharmacologique**

Effet placebo est en général de courte durée, et s'estompe rapidement

Effet nocebo. Effet **négatif** (survenue d'événements indésirables) **qui n'est pas lié aux propriétés physico-chimiques de la molécule**

Conditions pour utiliser un placebo

- Si pas de traitement de référence, et si Pas de perte de chance (symptômes sont réversibles, bénins)
- **Il n'est pas éthique d'utiliser un placebo si il existe un traitement de référence** ⚠️
- 2 cas particuliers où l'utilisation du placebo est possible alors qu'il existe un traitement de référence :
  - Étude en « add-on » : tous les patients reçoivent traitement de référence + nouveau traitement ou placebo
  - Étude sur un traitement de référence qui peut être interrompu sur une courte période, sans risque important

(alors on l'arrête pour le remplacer durant la durée de l'étude soit par le nouveau traitement soit par le placebo-

Paramètres augmentant le risque d'effet placebo

- Malade : Patient crédule et anxieux
- Pathologie : personnes souffrant de maladie chronique/symptomatique semblent répondre d'avantage
- Critère de jugement fonctionnel et subjectif (douleur ...)
- Médecin charismatique, persuadé de l'intérêt du traitement, et convaincant
- Intervention invasive et sanglante (injection), ou Traitement per os de mauvais gout : patients y répondent d'avantage
- Proportionnel à l'effet attendue (plus d'effet si on présente le traitement comme un palier 3 plutôt qu'un palier 1)

Sham procedure

Place des "interventions factices" (sham procedure) :

- Chirurgie ou procédure lourde sont **interdites en placebo car non éthique,** on fait courir des risques importants au patient
- Dispositifs implantables peu invasifs (pace-maker ...) : discutés au cas par cas au comité d'éthique à priori de l'étude

Malheureusement, même dans les pathologies pour lesquelles il existe des traitements efficaces, les essais sont fréquemment réalisés contre placebo. Ces essais ont un intérêt limité car ils ne permettent pas de savoir si le nouveau traitement a un intérêt par rapport à celui qui existe déjà. Ils ne permettent pas de répondre aux questions pragmatiques que se posent les médecins c'est-à-dire dans cette pathologie, quel est le meilleur traitement à donner à mon patient ?

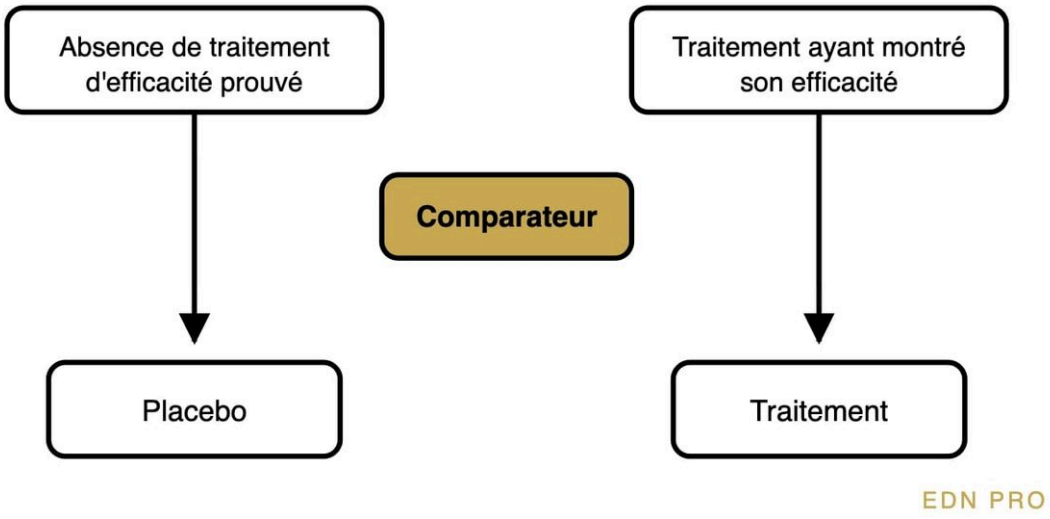


image.png

Plan expérimental

Essai contrôlé randomisé peut être à visée thérapeutique ou diagnostic, le principe est le même (comparaison de 2 groupes), mais pas le protocole

Focus : Cross-over

Schéma

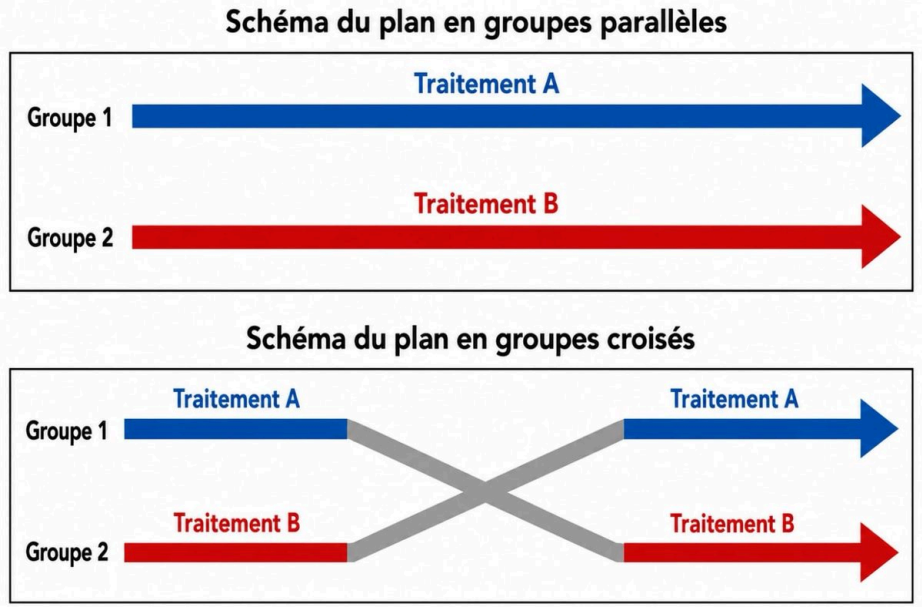


image.png

Principe

Patient est pris comme son propre témoin

- 1 groupe reçoit le traitement A puis le traitement B, l'autre groupe reçoit le B puis le A

Avantages

- Augmente la **validité interne** par gain de comparabilité des groupes car élimine la variabilité inter-individuelle
- Gain de **puissance** (chaque patient compte x2, effectif est donc diminué par 2 par rapport aux essais à 2 bras parallèles)

Wash-out

Wash out (période de lavement) correspond à la période sans traitement entre les 2 phases de traitement

- En pratique, on recommande une durée de ≥ 5x la demi-vie
- Objectif = éliminer l'effet rémanent (ou carry-over) du 1er traitement car sinon risque d'interférence

Conditions nécessaires

- **Maladie étudiée** doit être chronique et stable (sinon patient non comparable à lui-même), ex : asthme, épilepsie, migraine
- **Critère de jugement** doit pouvoir être mesurée à plusieurs reprises chez le même patient (pas la mortalité)
  - Mesure répétée du critère de jugement doit être dépourvue d'effet d'apprentissage

(sinon risque « d'effet d'ordre », les auteurs utilisent donc souvent des questionnaires compliqués)

- **Traitement** doivent être symptomatiques, avec des effets d'apparition rapide et réversibles à l'arrêt (pas irréversible), pas d'effet rémanent ou d'effet rebond (n'est donc pas adapté aux

interventions chirurgicales)
    - Absence d'effet-période = effet modifié si traitement reçu en 1er ou en 2ème
    - Effet du 1er traitement ne doit plus interagir avec le critère de jugement après la période de wash-out
    - Patient ne doit pas guérir après le 1er épisode
    - Patient ne doit pas s'habituer à des effets secondaires
- Peu de perdus de vue en 1ère période

Analyse. Il faut systématiquement tester la possibilité d'un effet carry-over en évaluant s'il y a une interaction entre la période et l'effet du traitement. Si on met en évidence une telle interaction, il y a un effet carry-over et on ne pourra pas analyser correctement les résultats de l'essai en cross-over

Groupes parallèles
(le plus fréquent)
Patients randomisés en 2 groupes (ou plus) qui sont suivis simultanément

- chaque groupe reçoit l'un des traitements testés A ou B → comparaison en fin d'essai

Groupes croisées
(cross-over)
Patient est pris comme son propre témoin

- 1 groupe reçoit le traitement A puis le traitement B, l'autre groupe reçoit le B puis le A

Plan factoriel 2x2
Permet de tester les efficacités des traitements A et B par rapport au placebo, mais aussi de tester l'interaction entre ces 2 traitements (synergie ? antagonisme ?), se fait par la constitution de 4 groupes :

- Groupe 1 : reçoit trt A + trt B
- Groupe 2 : reçoit trt A + placebo de B
- Groupe 3 : reçoit placebo A + trt B
- Groupe 4 (groupe témoin) : reçoit placebo A + placebo B

Plan séquentiel
Essai thérapeutique dont l'analyse est effectuée régulièrement tous les « n » sujets au fur et à mesure de l'inclusion et de l'évaluation du critère de jugement chez les sujets inclus

- Avantage : meilleure maîtrise des risques d'erreurs statistiques alpha et bêta

---

Notion de « période de run in » et de Dose-test

Période de run in

Définition. Phase de pré-inclusion durant laquelle tous les patients prennent le placebo

Objectifs (2)

- Repérer les patients « placebo-répondeurs » (afin de les **exclure**)
- Sélectionner les meilleurs observants (afin de **diminuer les perdus de vue**)

Objectifs (2). Dose test

Principe

Administration d'une dose-test chez tous les patients, avant la randomisation, afin d'évaluer la bonne tolérance du nouveau médicament

- permet d'**exclure les patients non tolérants** avant la randomisation

1 Indication. Proposée si le nouveau médicament est connu pour être mal toléré lors de son introduction, par une proportion significative de patients

2 Conditions

- Prendre en compte les différents effets secondaires relevés lors de l'administration de la dose-test
- Limiter les conclusions de l'étude aux patients qui ont toléré la dose-test

---

Essai explicatif vs Essai pragmatique

Distinguer « Essai EXPLICATIF » et « Essai PRAGMATIQUE » :

- **essai explicatif** :
  - étude thérapeutique qui **vise à montrer l'effet d'un médicament sur un critère de jugement principal clinique ou physiologique dans des condition optimales**
  - la **population est homogène car très sélectionnée** (critères d'exclusion nombreux)
- **essai pragmatique** (plus rare mais en croissance dans l'avenir) :
  - étude thérapeutique (qui **vise à évaluer l'intérêt du nouveau traitement pour la pratique dans des conditions, au plus près de la vraie vie** (par une évaluation simultanée de son efficacité, ses effets indésirables, sa faisabilité, et parfois même son coût [direct et indirect] dans des conditions pragmatiques de la vraie vie)
  - la **population est plus hétérogène car moins sélectionnée** (moins de critères d'exclusion)

Étude de supériorité ? Non-infériorité ou d'équivalence ?

Essai de supériorité *(le plus souvent)*

Objectif. Démontrer que l'un des traitements est supérieur à l'autre "traitement A meilleur que traitement B"

Type d'analyse

Analyse en intention de traiter : diminue la probabilité de mettre en évidence une différence

- ce qui **renforce la supériorité du traitement si le résultat est positif malgré cela**

Si négative

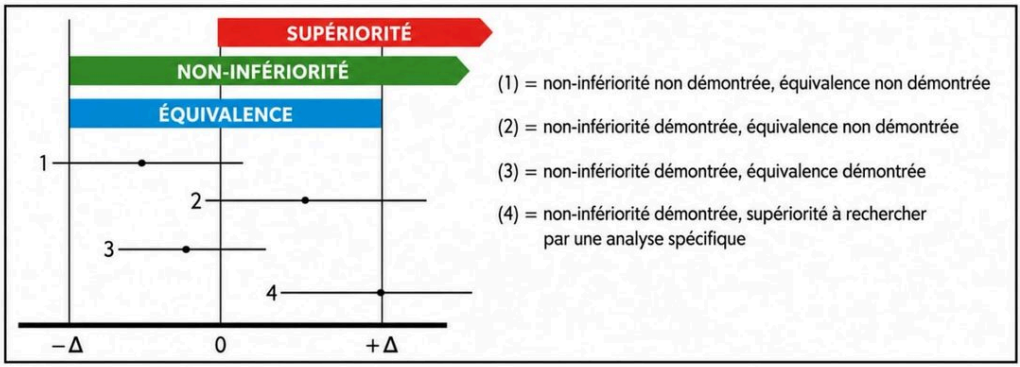
Hypothèses à évoquer devant une étude de supériorité négative :

- Traitement testé est bien **meilleur mais manque de puissance** pour le montrer
- Traitement testé est "**équivalent**" au traitement contrôle
- Traitement testé est **inférieur** au traitement contrôle

Piège ⚠️ : ne pas interpréter "essai de supériorité négatif" comme de l'équivalence

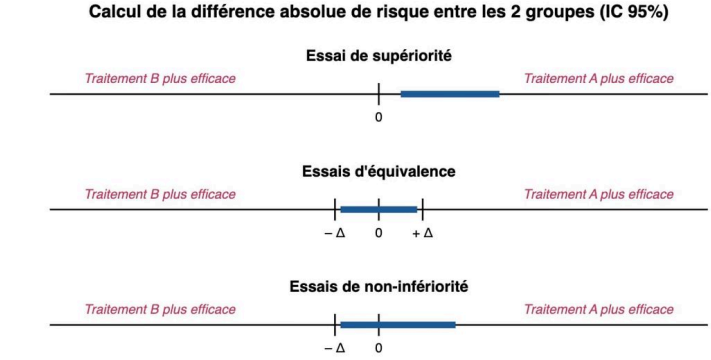
Essai de non-infériorité ou d'équivalence

Schéma



Conduite à tenir si $IC_{95\ \%}$ situé entre [0 ; + ∞] : on peut proposer une étude de supériorité complémentaire par une analyse spécifique

image.png



Dans ce schéma, Δ représente la borne d'équivalence ou de non infériorité. Dans le premier cas de figure, pour conclure à la supériorité du traitement A, il faut que l'IC à 95% de la différence soit strictement supérieur à 0. Dans le second cas de figure, pour conclure à l'équivalence entre A et B, il faut que l'IC à 95% de la différence soit strictement inclus entre − Δ et + Δ (le traitement A ne doit être ni trop inférieur à B ni trop supérieur). Dans le 3ème cas de figure, pour conclure à la non infériorité de A par rapport à B, il faut que l'IC à 95% de la différence soit strictement supérieur à − Δ (le traitement A peut être supérieur).

EDN PRO

image.png

Objectif

Démontrer que la différence entre les 2 traitements est négligeable "traitement A est aussi bon que le B"

- *Non-infériotié : le traitement A est au moins aussi performant que le B (équivalent ou superieur)*
- *Équivalence : le traitement A est aussi performant que le traitement B*

Intérêt

Utile seulement si le traitement expérimental est avantageux autrement que par son efficacité (ex. moins cher, mieux toléré, meilleur galénique, moins de prises par jour, surveillance plus simple, générique)

Particularités méthodologiques

- Tout essai de non-infériorité ou d'équivalence doit être justifié dans le protocole de l'étude **a priori** (il **n'est pas accetable de tirer a posteriori, des conclusions d'équivalence ou de non-infériorité d'une étude de supériorité négative**, par contre, une étude de non-infériorité peut être complétée d'une étude de supériorité)
- Seuil Δ d'équivalence ou de non-infériorité (ou borne/limite/marge conservatrice) doit être fixé a priori
  - Pour conclure à une non-infériorité : ensemble de l'**IC 95%** doit se trouver dans le domaine de non infériorité [**-Δ** ; **+∞**]
  - Pour conclure à l'équivalence : ensemble de l'**IC 95%** doit se trouver dans le domaine d'équivalence [-Δ ; **+Δ**]
  - Choix de la borne est très difficile, il doit se faire en fonction de la spécialité et du type de critère de jugement
  - Borne va conditionner le nombre de patients à inclure :
    - Plus la borne est petite, **plus il faudra inclure de patients** dans l'essai
      - Si la borne est trop large, ce serait erroné de considérer que les 2 traitements ont une efficacité comparable

Type d'analyse

à réaliser

Réaliser analyse per-protocole + ITT, et les résultats des 2 analyses doivent être concordantes pour pouvoir trancher :

- Rôle du per-protocole : **augmente la probabilité de mettre en évidence la différence** entre les 2 groupes et donc **renforce la non-infériorité** si l'hypothèse de non infériorité est retenue (absence de différence malgré le fait d'avoir augmenté la différence entre les groupes par le per-protocole)
- Rôle de l'ITT : permettre la réalisation d'une étude de supériorité complémentaire si besoin (l'analyse en ITT a tendance à **diminuer les différences entre les groupes** : risque de faire conclure plus facilement à l'équivalence ou à la non-infériorité)

Tests statistiques. Test statistiques d'une étude de non-infériorité sont spécifiques de ce type d'études *(en effet, si on utilisait des tests classiques comme le Chi-2 dédié à une étude de supériorité, les résultats n'apparaîtraient pas significatifs à tord)*

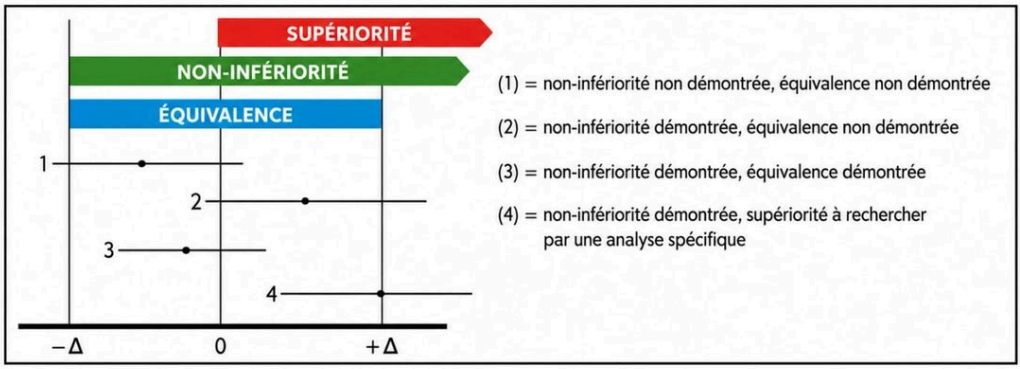
Distinction entre ces différents types d'études

Hiérarchie des grandeurs de NSN pour les 3

types d'études

NSN d'une étude de non-infériorité >>> NSN d'une étude de supériorité > NSN d'une étude d'équivalence

En effet, le calcul du NSN doit tenir compte du territoire d'hypothèses explorées NSN est plus bas en cas d'essai d'équivalence car territoire plus étroit des hypothèses explorées : en regard la figure le nombre de territoire exploré en vert (non-infériorité) > rouge (supériorité) > équivalence (bleu)



Conduite à tenir si $IC_{95\ \%}$ situé entre [0 ; + ∞] : on peut proposer une étude de supériorité complémentaire par une analyse spécifique

image.png

Pour faire le distinction entre supériorité/non-infériorité, il faut regarder l'hypothèse utilisée pour le calcul du NSN :

- Si c'est une "différence attendue" = supériorité
- Si c'est une "borne d'équivalence" = non-infériorité

L'hypothèse de recherche vise à montrer que :

- soit, l'une des deux interventions est meilleure que l'autre (hypothèse de **supériorité bilatérale**)
- soit, l'intervention A est meilleure que le comparateur B (hypothèse de **supériorité unilatérale**)
- soit, l'intervention testée est au moins aussi performante que le comparateur (hypothèse de **non-infériorité**)
- soit, les deux interventions sont autant performantes l'une que l'autre (hypothèse d'**équivalence**)

Résultats

Interprétation des résultats pour le critère de jugement principal ⭐

1. Est-ce le résultat pour le critère de jugement principal est statistiquement significatif ? → évaluer le degré de significativité du test

1. Est-ce que la différence observée est cliniquement pertinente ? → pour évaluer si la différence observée est cliniquement pertinente, il faut évaluer la taille d'effet (effect size) :
   - En particulier la réduction absolue du risque (RAR, qui correspond à la différence de risque entre les 2 groupes)
   - ou Nombre de patients à traiter pour éviter un évènement (NNT, correspond à l'inverse de la réduction absolue du risque)

Mais le Réduction relative du risque (RRR) ❌ peut donner une estimation trompeuse de la taille d'effet (Ex. une réduction relative du risque de 50% peut correspondre à une réduction absolue de risque de 1% ce qui est très faible et peu pertinent)

Exemple : Dans un essai contrôlé randomisé, la mortalité à 3 mois est de 20/200 (10%) dans le bras expérimental et de 30/200 (15%) dans le groupe contrôle.

Nous avons :

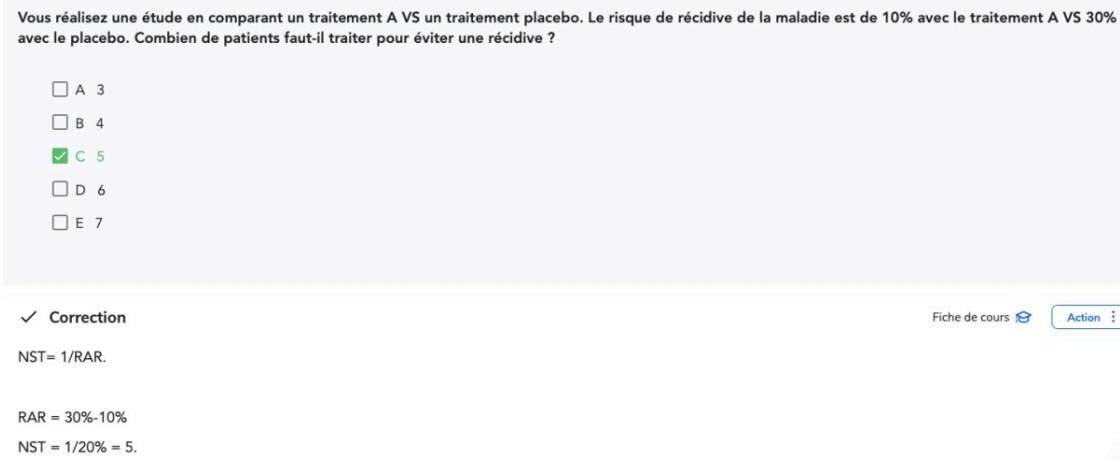
- Réduction absolue du risque : 15%-10%=5%
- Réduction relative du risque : (15%-10%)/15%=33%
- Nombre de patients à traiter pour éviter un évènement : 1/0.05=20 c'est-à-dire qu'il faudra traiter 20 patients pour éviter un seul décès à 3 mois.

> *Garder à l'esprit qu'une différence statistiquement significative ne traduit pas forcément une différence cliniquement pertinente En effet, plus l'essai aura inclus de patients, plus il aura de puissance pour mettre en évidence de faibles différences qui ne sont pas forcément pertinentes*

Notion de résultat dans les essais thérapeutiques (RR, RRR, RAR, NNT) : tombe en annale ⚠️

Exemples

- *exemple 1 :*
  - *décès (A) = 20 % et décès (B) = 10 %*
  - *→ NST = 1/10 % = 10 patients*
  - *traduction clinique = « Il faut traiter 10 patients pendant 1 an pour éviter 1 décès »*



Untitled

A

B

R0 = survenue (en % pas en effectif) du critère principal pour le placebo (ou traitement de référence)

R1 = survenue (en % pas en effectif) du critère principal pour le traitement expérimental

RR. Risque relatif = R1/R0

RAR

Diminution absolue du risque = R0-R1

- aucun test de significatif associé au RAR
  - plutôt utilisée pour minimiser une **augmentation d'un événement défavorable** (car chiffre moins élevé)

RRR

Réduction relative du risque = (R0-R1)/RO

- aucun test de significatif associé au RRR
  - plutôt exprimée pour une **diminution d'un risque ou d'un événement défavorable** ou de l'**augmentation d'un événement favorable** (car chiffre plus élevé et donc plus impressionnant sur une étude)

NNT/NST

Nombre de patients à traiter = 1/RAR = 1/(RO-R1) *avec A et B en pourcentage et non en effectif*

- il s'agit du nombre de sujets à traiter pour éviter la survenue d'un événement
  - NNT se calcule sur une durée donnée et pour un événement donné (critère d'évaluation), il faut donc prendre la RAR correspondant à ce critère d'évaluation pour ce délai *(ex. si NNT par an sur la mortalité, il faut prendre le résultat mortalité totale à 1 an, et non pas à 6 mois)*

> **En pratique, il est souvent difficile d'apprécier si la différence est pertinente cliniquement, cela dépend de la pathologie et du critère de jugement.**

Ex. en réduction absolue du risque de 5% est très importante quand il s'agit de la mortalité globale mais moins importante quand il s'agit d'autres critères comme la proportion de patients douloureux

Interprétation des résultats pour les critères secondaires

Résultats des critères de jugement secondaires doivent être interprétés précautionneusement surtout si le résultat pour le critère de jugement principal n'est pas statistiquement significatif. En effet, en général le nombre de critères de jugement secondaires est assez important ce qui entraîne une **inflation du risque alpha** de conclure à une différence qui n'existe pas.

> **Il n'est pas possible de conclure à l'efficacité d'un traitement sur la base du résultat d'un critère de jugement secondaire si le résultat pour le critère de jugement principal n'est pas statistiquement significatif**

Analyse de survie

1. Analyse descriptive = courbe de Kaplan-Meier
1. Analyse univariée = test du Log rank
1. Analyse mutlivriée = modèle de Cox (synonyme de modèle à risque proportionnels = *proportional hazards model)*

Analyse stratifiée en sous-groupes

Exemple

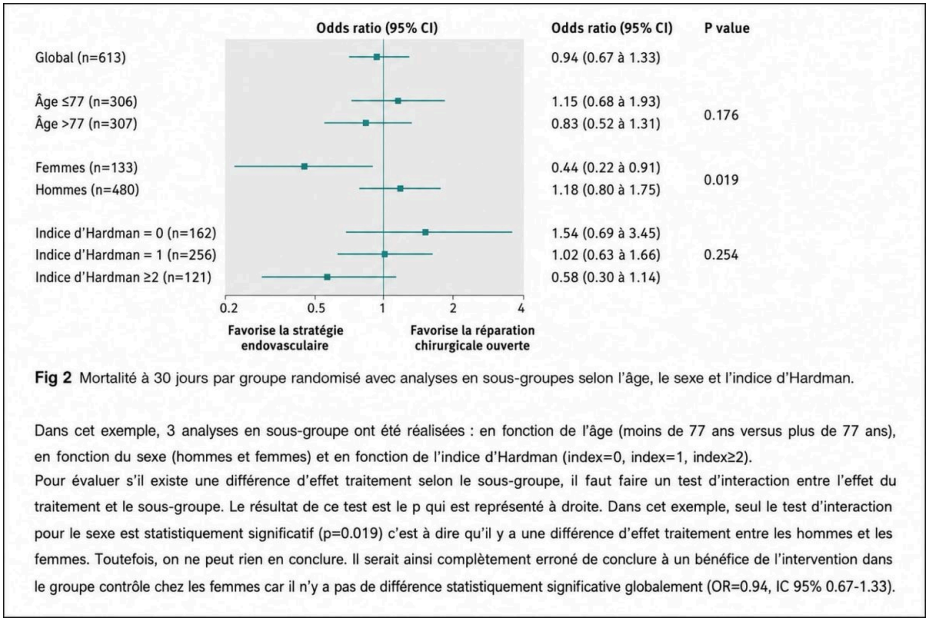


Fig 2 Mortalité à 30 jours par groupe randomisé avec analyses en sous-groupes selon l'âge, le sexe et l'indice d'Hardman.

Dans cet exemple, 3 analyses en sous-groupe ont été réalisées : en fonction de l'âge (moins de 77 ans versus plus de 77 ans), en fonction du sexe (hommes et femmes) et en fonction de l'indice d'Hardman (index=0, index=1, index≥2).
Pour évaluer s'il existe une différence d'effet traitement selon le sous-groupe, il faut faire un test d'interaction entre l'effet du traitement et le sous-groupe. Le résultat de ce test est le p qui est représenté à droite. Dans cet exemple, seul le test d'interaction pour le sexe est statistiquement significatif (p=0.019) c'est à dire qu'il y a une différence d'effet traitement entre les hommes et les femmes. Toutefois, on ne peut rien en conclure. Il serait ainsi complètement erroné de conclure à un bénéfice de l'intervention dans le groupe contrôle chez les femmes car il n'y a pas de différence statistiquement significative globalement (OR=0.94, IC 95% 0.67-1.33).

image.png

Focus : inflation du risque alpha (ou biais de comparaison multiples)

Définition

Lorsqu'on réalise plusieurs mesures, il existe un risque que l'une des mesures soit statistiquement significative simplement par le fait du hasard, plus on réalise de mesures et plus ce risque augmente

(= inflation du risque alpha, soit augmentation du risque de conclure à tort à l'existence d'une différence qui existe)

Situations

à risque

- Analyse sur plusieurs critères de jugement secondaires
- Analyse en sous-groupes avec analyse sur plusieurs sous-groupes de patients
- Analyse intermédiaire avec mesures répétées du critère de jugement principal
- Analyse du critère de jugement principal sur > 2 groupes différents (3 ou 4 maximum en pratique)

Comment le limiter ?

Afin de limiter le biais des comparaisons multiples (inflation du risque alpha), il existe l'ajustement du risque alpha (pondération du risque) par une méthode type Bonferroni (la plus simple) ou O'Biren et Flemming

Principe de la méthode de Bonferroni :

- Consiste à diviser le seuil de signification (en général fixé à alpha = 0,05) par le nombre de tests
- ex. si 10 comparaisons multiples sont faites, on retiendra comme significatives celles dont le seuil est < 0,005

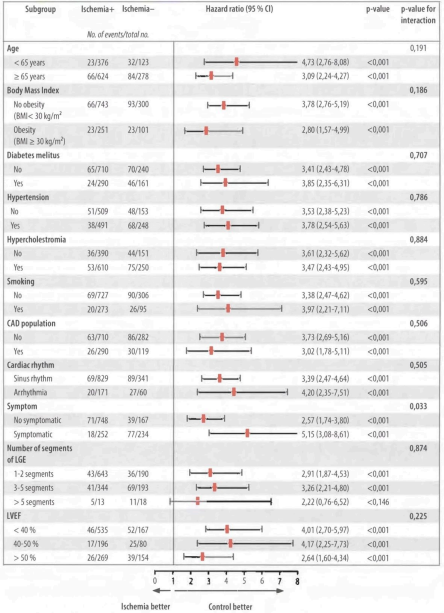
Autre solution

Dans les cas des mesures répétées du CDJ principal, afin de contrôle le risque d'inflation du risque alpha, on peut se ramener à 1 seul critère de jugement qui sera suivi dans le temps par une analyse de survie de Kaplan-Meier

(pas pour la réduction du risque d'inflation du risque alpha dans les mesures de plusieurs CDJ secondaires)

Focus : interprétation d'un diagramme de Forest

Exemple



Untitled

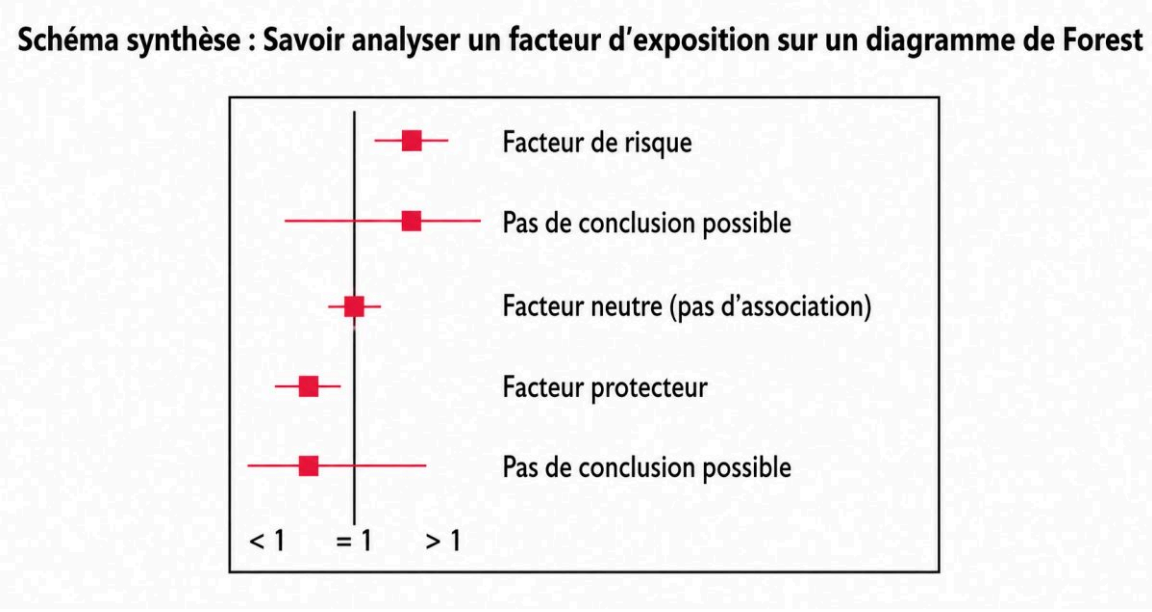


image.png

Contexte. Figure de référence pour présenter les résultats d'une analyse en sous-groupe (peut être utilisé dès lors qu'une analyse en sous-groupe est proposée, que ce soit pour une étude interventionnelle ou épidémiologique)

Objectif. Permet de visualiser très facilement le résultat d'intérêt sur le critère de jugement principal, et/ou les critères de jugement secondaire au sein d'un grand nombre de sous-groupes de l'étude

Abscisses (horizontal). Effet du traitement (rapport de cotes pour le décès ou l'invalidité)

Ordonnées (vertical). Sur lequel on place les sous-groupes selon une échelle arbitraire

Chaque ligne. Sur chaque ligne, l'effet du traitement observé dans un sous-groupe est représenté par un symbole (rond ou carré) entouré d'un trait horizontal qui représente l'intervalle de confiance associé

« p value for interaction »
= test
d'homogénéité
Permet de mettre en évidence l'existence de facteurs de confusion au sein de l'étude (interaction entre l'un des facteurs étudiés et la survenue du critère de jugement principal, indépendemment du FR étudiés ou de l'intervention étudiée)

- Si p value for interaction < alpha : alors le facteur étudié est bien un **facteur de confusion potentiel**
  - *dans l'exemple du pezel : la présence de symptômes est un facteur de confusion*

Intérêts

- Soit à visée complémentaire en soutenant que le **résultat principal de l'étude est retrouvée sur la totalité de la population étudiée** (homogène dans les différents sous-groupes)
- Soit à visée exploratoire lorsque le **résultat est plus pertinent cliniquement dans certains sous-groupes**, et permet de proposer de nouvelles études explorant ces différents sous-groupes

Interprétation ⚠
Piège :

- Il est possible de dire qu'une différence étudiée est plus importante dans l'un des sous-groupes

(= « est-ce que c'est significatif ? »)

- Mais attention, on n'a jamais le droit de conclure sur une analyse en sous-groupe ⚠

(même si le résultat est statistiquement significatif)

Principe. Il s'agit de l'analyse du critère de jugement **principal** dans une **partie seulement de l'effectif** total (ex. âge, sexe, stade de la maladie), permet de mettre en évidence des résultats qui se rapportent à cette sous-population d'intérêt clinique

Préalable
Pour bénéficier du maximum de validité interne, il est recommandé que les analyses en sous-groupes soient justifiées et programmees **à priori** dans le protocole de l'étude grâce à une **randomisation stratifiée**, elles doivent être considérées comme des analyses exploratoires, afin d'**éviter la présentation sélective des seuls sous-groupes pour lesquels les résultats sont significatifs**

- afin de vérifier que ces analyses ont été prévues à l'avance, on vérifie que la randimisation était stratifiée sur ces critères afin d'augmenter la comparabilité des groupes *(de ce fait les sous-groupes du groupe contrôle et du groupe expérimental sont comparables, en d'autres termes : sous-groupes du tableau 1 après randomisation sont les sous-groupes repris pour cette analyse)*

Objectif
Interprétation

Intéressant dans la mesure où les résultats en sous-groupes pourront être confirmées ultérieurement par des études consacrés à cet effet 🎯

À ne pas faire

Mais la conclusion de l'essai doit porter sur le résultat pour toute la population et non sur l'un des sous-groupes ⚠️ et ce d'autant plus qu'il n'y a pas de différence statistiquement significative dans la population globale

- essai doit montrer un résultat statistiquement significatif sur le résultat de la population étudiée totale (condition nécessaire pour assurer une bonne fiabilité de l'analyse en sous-groupe, *sinon risque que la différence soit le fait de l'inflation du risque alpha*)

Limites

- Défaut de puissance en raison du faible effectif du sous-groupe et des IC à 95% très larges (NSN a été calculé pour obtenir une puissance satisfaisante sur le critère de jugement principal avec l'ensemble de l'effectif, le risque de l'analyse en sous-groupe est donc de ne pas mettre en évidence une différence existante)
- Inflation du risque alpha (biais des comparaisons multiples)
- Biais de sélection avec perte de la comparabilité (uniquement en l'absence de randomisation par stratification préalable ⚠️)
- **Analyse en sous-groupes ne doivent jamais servir de base à la conclusion de l'étude** ⚠️
  - rôle uniquement descriptif et exploratoire pour de nouvelles hypothèses de rechercher (« il semble que … »)

Figure. Manière la plus élégante de présenter une analyse en sous-groupe est le diagramme de Forest (Forest plot)

Test d'homogénéité

Permet de tester l'interaction entre une caractéristique définissant un sous-groupe, et le résultat sur le critère de jugement principal

- **si p < alpha pour le test d'homogénéité**, alors on peut évoquer que le résultat sur le CDJ principal est différent d'un sous-groupe à l'autre, ce qui diminue la pertinence clinique *(potentiel facteur de confusion)*

> **Analyse en sous-groupe est une analyse univariée pour chacun des sous-groupes analysés par rapport à l'événement étudié**

Analyse intermédiaire

Exemple

"We planned two interim analyses at 2500 patient-years and 5000 patient-years. The study could be stopped according to Peto's rule if a significant difference in all-cause mortality was seen between the two groups at p < 0.001 (two-tailed log-rank test)."

Les auteurs définissent bien les règles d'arrêt des deux analyses intermédiaires : le moment (2500 et 5000 patients-années) et le seuil de signification (p < 0,001).

"2647 patients were enrolled into the study and followed up for a mean of 1.3 years. (…) The trial was stopped early because all-cause mortality was significantly less in the bisoprolol group than in the placebo

group (figure 1). In the bisoprolol group, 156 (11.8%) patients died, compared with 228 (17.3%) in the placebo group (p < 0.0001).”

Les auteurs ont fait une analyse intermédiaire comme prévu à environ 2500 patients-années (2647 patients dont on additionne les durées de suivi, ce qui fait probablement 2500), le test statistique (log-rank) abouti à un p < 0.0001. Il est inférieur au seuil fixé a priori (0.001). L'étude a donc été arrêtée et les auteurs ont conclu à un effet du traitement.

Principe

Analyse en cours d'étude sur des données partielles pour éventuellement interrompre l'étude si besoin

- avec pour effet, d'augmenter le NSN (correspond à une analyse effectuée avant l'inclusion de tous les sujets prévus)

Réalisée le plus souvent lorsque l'étude est longue et qu'il y a un risque pour les patients : l'idée est que si le nouveau traitement, ou l'intervention, fonctionne vraiment bien (ou vraiment mal), ce n'est peut-être pas la peine (voire contraire à l'éthique) d'attendre la fin de l'étude pour présenter les résultats

2 Conditions

- Analyse intermédiaire et les règles d'arrêt de l'étude doivent être définies **a priori** dans le protocle
- Ajustement du risque alpha avec diminution de la valeur seuil habituelle (< 5%) : en effet, si on répète l'analyse au fur et à mesure des inclusions, on risque de trouver à un moment donné une différence statistiquement significative par le simple fait du hasard (inflation du risque alpha ❌), si l'on arrête alors l'étude, on va conclure à l'existence d'une différence alors qu'elle est possiblement due au hasard

Comité

Idéalement, ces analyses intermédiaires sont gérées par un comité indépendant : le Data Safety Monitoring Board

Steering commitee = comité de pilotage

6 Objectifs

- Arrêt pour efficacité : détecter au plus tôt le bénéfice du traitement afin d'éviter de traiter des patients avec un placebo ou une thérapeutique donnée si les données intermédiaires sont suffisantes pour conclure à l'efficacité du traitement étudié
- Arrêt pour toxicité : détecter au plus tôt un éventuel effet délétère pour limiter le nombre de patients exposés au risque
- Arrêt pour futilité : arrêter une étude dont on peut prédire avec une certitude raisonnable qu'elle ne pourra pas aboutir
- Vérifier le taux d'écart par rapport au protocole : essai est-il de qualité ?
- Vérifier la taux d'inclusion : essai pourra être réalisé dans un délai acceptable ?
- Vérifier les caractéristiques des patients

Étude thérapeutique de dose

Principe

Étude thérapeutique qui vise à :

1/ Comparer des doses différentes du même médicament à un test de référence ou placebo (analyse de la tendence)

2/ Puis à les comparer entre elles (analyse de chaque dose)

Analyse de la tendance

On évalue si globalement le nouveau traitement semble plus efficace que le contrôle de référence ou placebo, pour des doses croissantes

- on utilisera un test statistique d'analyse de variance type ANOVA

Analyse de la chaque dose

On peut ensuite comparer chaque dose du même médicaments entre elles

- mais **à condition que l'analyse de tendance soit bien positive et statistiquement significative** +++

Interprétation des résultats de tolérance

Tolérance d'un traitement est un élément essentiel à évaluer mais elle est fréquemment mal rapportée dans les essais.

Tous les évènements indésirables doivent être décrits par groupe de traitement avec leur fréquence de survenue. Les évènements indésirables graves qui sont définis par le décès, tout évènement clinique ayant entraîné la prolongation d'une hospitalisation, une anomalie congénitale, ou une incapacité, doivent être rapportés par groupe de traitement avec leur fréquence de survenue.

Analyses de tolérance manquent fréquemment de puissance car les évènements indésirables sont rares (particulièrement les évènements indésirables graves) et le calcul d'effectif n'est fréquemment pas fait sur des critères de tolérance

- Le fait qu'il n'y ait pas de différence statistiquement significative ne permet donc absolument pas de conclure à un bon profil de tolérance du traitement évalué ❌
- Il faudra évaluer la différence de pourcentages entre les 2 groupes ✅

Conclure à la causalité

Si essais contrôlés randomisés en double aveugle

▶ Arguments directs de causalité :

- la différence entre les groupes est bien imputable à l'intervention !
- niveau de preuve élevé (niveau 1)

▶ Limites :

- parfois impossible à réaliser pour des raisons techniques (coût – délai…)

- ou éthiques (les études épidémiologiques ne peuvent pas être interventionnelles en pratique)

Si essais ouverts – non randomisés…

▶ PAS d'arguments directs de causalité car :

- nombreux biais présents (biais de suivi, biais de mesure…)
- niveau de preuve inférieur (2, 3 ou 4)

Focus : Score de propension

Études non randomisées

Méthode d'analyse particulièrement adaptée pour minimiser le biais de confusion dans les études en pharmaco-épidémiologie (lorsque les études ne sont pas randomisés), elle vise à évaluer la comparabilité des groupes, afin d'estimer au mieux les effets causaux d'une intervention

- En effet, dans ce type d'étude, les **investigateurs n'ont pas le contrôle sur l'attribution du traitement** (qui est **souvent influencé par les caractéristiques du patient à l'état initial**), ce qui implique potentiellement des **groupes de patients déséquilibrés non comparables**
- Score de propension = outil de détection et de correction du biais de sélection, utilisé pour pallier ce problème

Études randomisées. Ici, le score de propension sert à juger l'efficacité de la randomisation en évaluant la comparabilité des groupes

Principe

On l'estime à l'aide d'une **régression logistique** avec :

- Variable à expliquer : prescription ou non du traitement
- Variables explicatives : caractéristiques des patients, éventuellement des médecins les prenant en charge

Permet de tenir compte des facteurs de confusion liés à la prescription du traitement (patients qui reçoivent le traitement ne sont pas les mêmes que les patients qui ne le reçoivent pas) et de minimiser ainsi un éventuel biais d'indication (qui est un biais de confusion)

Limite

Principale limite réside dans la possibilité d'un biais de confusion résiduelle
(si tous les facteurs de confusion n'ont pas fait l'objet d'un recueil de données dans l'étude)

Interprétation

- Score de propension estime, pour chaque individu, la probabilité conditionnelle P de recevoir le traitement étudié, étant donné ses caractéristiques initiales, il s'agit donc d'une **probabilité estimée entre 0** (pas de chance de recevoir le traitement) à **1** (de chance de recevoir)
- *On « découpe » ensuite des strates de patient en fonction de leur probabilité de recevoir le traitement (ex. strate à probabilité élevée)*
- Plus le nombre de variables introduites pour estimer le score de propension est élevé, meilleure sera la description de la probabilité des effets nets du traitement

Évaluation de la qualité du score

Afin d'évaluer la qualité du score de propension :

1. Comparation de la distribution dans chaque strates de chacune des variables intégrées dans la construction du score de propension
2. Si différences détectées, il faut examiner le nombres de variables concernées, si peu de variables concernées on retient une sous-classification de la strate et on vérifie si la différence persiste, si elle persiste ou si le nombre de variables concernées est importants, on réestime le score de propension
3. Répéter ces étapes jusqu'à l'obtention d'un score de propension équilibrée

Analyse de sensibilité. Analyse de sensibilité permet de s'assurer de la robustesse des résultats du score de propension, en examinant comment les résultats de l'analyse varient si on fait varier la valeur des variables clés dans un intervalle déterminé

Définition et intérêt du score de propension

Définition

- La méthode du **score de propension** est une technique statistique assez récente avec pour **objectif d'évaluer la comparabilité des groupes**, afin d'estimer au mieux les effets causaux d'une intervention. Cette technique est l'instrument le plus souvent utilisé dans les études expérimentales **non randomisées**, mais aussi parfois en théorie au sein des études expérimentales randomisées
- Sur le plan statistique, le **score de propension est estimé, pour chaque individu**, la probabilité conditionnelle P de recevoir le traitement étudié. **Sa valeur est comprise entre 0 et 1**
- Le score de propension est exprimé sous une probabilité donc, sa **valeur est comprise entre 0 et 1**.

Intérêts du score de propension

- Dans une étude expérimentale non randomisée +++ (le plus classique) :
- il sert à **évaluer la comparabilité des groupes afin de pallier l'absence de randomisation** en effet, les essais cliniques randomisés ne sont pas toujours possibles à mettre en place (coût élevé, attribution du traitement par tirage au sort posant des problèmes éthiques)
- lors d'études de ce type, les investigateurs n'ont pas la maîtrise d'éventuels biais inhérents aux groupes ; ils ne sont en général pas comparables d'un point de vue des caractéristiques des patients à l'état initial. Cela implique alors potentiellement, des **groupes de patients déséquilibrés** entre les variables observées et non observées. Le score de propension permet alors d'éviter cette limitation de l'effet traitement (biais de sélection) ; le score de propension peut alors être utilisée pour palier ce problème

▶ Dans une étude expérimentale randomisée :

- il **sert à juger l'efficacité de la randomisation** en **évaluant la comparabilité des groupes**

(*Dans les études randomisées, les individus ont en moyenne une chance sur deux de faire partie du groupe témoin. La randomisation doit permettre, du moins en théorie, d'obtenir deux groupes identiques en moyenne, c'est-à-dire que les caractéristiques initiales des individus du groupe traité et du groupe témoin sont semblables, tant du point de vue des caractéristiques observables qu'inobservables*)

▶ En résumé :

- la distribution du **score de propension offre un critère de comparabilité des groupes**. La **comparaison de la distribution des scores dans chacun des groupes**, permet de s'assurer que les individus traités et témoins sont suffisamment semblables pour que la comparaison ait un sens. Si ce n'est pas le cas, que le score de propension peut être utilisé pour **corriger le biais de sélection**
- ainsi, le score de propension permet d'abord de **détecter l'existence de différences préexistantes à la mise en œuvre de l'intervention**. En cas de différences, il permet ensuite de **corriger le biais de sélection et de comparaison des effets nets d'un traitement**
- retenez que **plus le nombre de variables introduites pour estimer ce score de propension est élevé**, **meilleure sera la description de la probabilité des effets nets du traitement**…

Interprétation

Une fois le score de propension estimé, il est nécessaire de **divisier les groupes**. Une fois faite, on peut comparer les distributions des **scores de propension** dans les 2 groupes.

- Si la distribution des scores de propension est différente, on conclut que les groupes ne sont pas comparables et que la **distribution par score de propension** est utile.
- (On insère donc les variables qui résument l'ensemble des variables des 2 distributions sont une indication de la *cause* du score de propension)
- si la **différence est minime**, l'utilisation du **score de propension** ne fournira pas plus de renseignements que ne le ferait un modèle classique avec ajustement sur les facteurs de confusion
- si les **deux distributions sont totalement différentes**, retenez que les deux populations ne **peuvent en aucun cas être comparées avec le score de propension** ; le score serait dans ce cas inutilisable
- si les **deux distributions sont superposables**, c'est que la **randomisation a été efficace** et qu'il n'y a pas de biais à compenser avec le score de propension
- les deux **distributions doivent être différentes** entre elles mais avec quelques zones de superposition pour pouvoir utiliser le score de propension

Conditions statistiques pour pouvoir appliquer un score de propension

Il appuie sur 2 hypothèses fondamentales :

▶ **1) L'hypothèse d'indépendance conditionnelle à des caractéristiques observables** (*conditional independance assumption*) :

Cette hypothèse stipule qu'à des variables observables près, l'évolution résultats pour les individus traités et les non traités est en moyenne la même. Cela revient à dire que les caractéristiques observables permettent de capter intégralement les processus de sélection et les phénomènes d'auto-sélection. Cette hypothèse ne peut être testée d'un point de vue statistique. Ce n'est en revanche le travail de l'investigateur, basé sur ses connaissances et sa réflexion qu'il sera mieux à même d'identifier l'ensemble des covariables pertinents pour le score de propension. Cette hypothèse est forte, et il convient de garder à l'esprit qu'il existe en général un grand nombre de potentiels confondants, qu'il s'agira au moment de la construction du score de propension d'en sélectionner certains, et donc d'en mettre d'autres en arrière-plan. C'est précisément l'origine d'un certain nombre de **limites du score de propension** vues précédemment.

▶ **2) L'hypothèse de la condition de support commun** (*overlap*) :

Cette hypothèse se rapporte au support de la distribution du score de propension. Cette hypothèse permet de s'assurer que les individus avec un même ensemble de covariables peuvent être à la fois traités ou non traités, ou autrement dit, que **les individus de chaque groupe d'analyse se ressemblent suffisamment pour que la comparaison ait un sens**. Si la condition de support commun entrainerait ce qu'on appelle un **facteur de confusion structurale** (*structural confounding*) et interdirait toute conclusion quant à l'effet causal d'un traitement.

Pour prévenir ce problème, le score de propension ne doit pas être utilisé en dehors de la zone de support commun, c'est-à-dire la zone commune de la distribution des scores de propension des groupes traités et témoin.

Trois techniques possibles pour utiliser un score de propension

Une fois le score de propension estimé pour chaque patient, il existe plusieurs méthodes d'utilisation du score de propension

Techniques d'ajustement

Appariement — Avantages : Une seule variable d'ajustement ; Limites : Patients non appariés exclus

Stratification

Avantages :
5 strates suppriment 90 % du biais
Estimation du **RR**

Limites :
Effectif par strates suffisant

Régression logistique

Avantages :
Convient aux effectifs réduits

Plus robuste qu'un modèle classique quand le nombre de facteurs de confusion est important

Limites :
Estimation de l'**OR** (et non du RR)

Principe de l'analyse de sensibilité du score de propension

Définition générale : **analyse de sensibilité**
Une analyse de sensibilité est un **processus par lequel on évalue la robustesse d'un modèle statistique** en examinant comment les résultats de l'analyse varient lorsque la valeur des variables clés varie dans un intervalle determiné.
Analyse de sensibilité évaluant un score de propension :

- Il est possible que l'équilibre des covariables les plus importantes ne soit pas atteint après l'application du score de propension
- si c'est le cas, le score de propension peut être ré-estimé en ajoutant des interactions sur les variables dans le modèle comme déjà cité plus haut. Cette méthode itérative peut être répétée jusqu'à plusieurs reprises tant que l'équilibre n'est pas atteint
- en dépit de toutes ces étapes l'équilibre n'est toujours pas obtenu, il est possible de conclure que les groupes ne sont pas tout simplement pas comparable
- Avant de valider ce type de calculs sur un score de propension, la mise en place d'une **analyse de sensibilité est recommandée pour vérifier qu'il ne manque pas de facteur confondant +++**
- En résumé : **l'analyse de sensibilité permet de s'assurer de la robustesse du résultat du score de propension +++ (PCZ)**

Focus

Rappel des biais dans un essai contrôlé randomisé

Biais de sélection

Biais de sélection

Biais de recrutement — Définition ou Conséquences : Perte de la comparabilité initiale des groupes ; Prévention : Randomisation correcte

Biais des perdus de vue — Définition ou Conséquences : *Trop de pdv*, risque de baisse de puissance (car diminution des effectifs) ; Prévention : *Prendre en compte les pdv dans le calcul du NSN*

Biais d'attrition

Définition ou Conséquences :
Perte de la comparabilité finale (patients sont analysés un groupe différent de la randomisation : 1 partie des partients a été exclue de l'analyse, *il s'agit en général des perdu du vue)*

Prévention :
Analyse en intention de traiter (ITT)

+ Stratégies des données manquantes

- toujours vérifier que nombre de sujet inclus

= sujets analysés

Biais « effet-centre »
(étude multicentrique)
Définition ou Conséquences :
Lié à la non-représentativité du centre (il traduit l'impact de l'hétérogénéité des performances de chaque centre, si un centre donné est excellent et que tout les patients y sont randomisés sont dans le groupe A, alors les résultats du groupe A seront tirés vers le haut par l'effet-centre et non par le traitement A)
Prévention :
Stratification sur le centre permet de s'assurer que la répartition de chaque bras dans chaque centre est équilibrée (il s'agit d'un moyen de se prémunir de l'effet centre, *le centre aura des patients avec le traitement A et des patients avec le traitement B*)
Biais des survivants — Définition ou Conséquences : Présent lorsqu'on inclut des patients qui ont déjà reçu dans le passé, l'un des traitements étudiés, crée un biais en faveur du traitement étudié (car par définition **ces patients vont mieux le tolérer car ils l'ont déjà reçu**, et **chez qui le traitement sera plus efficace** : son effet sera donc surestimé par rapport à l'effet réel en population générale) ; Prévention : *Ne pas inclure des patients qui ont déjà reçu, dans le passé, le traitement étudié*

Biais de classement

Biais de suivi
(ou de performance)
Perte de la comparabilité des groupes au cours du suivi
Biais d'évaluation. **Mesure du CDJ principal différentes** dans les 2 groupes

Biais de réalisation
Soins prodigués de manière différente

Mesures de prévention

- **Double aveugle**
- Critère d'évaluation principal : unique, standardisé, validé, reproductible ...
- Comité d'adjudication d'évaluateurs indépendants : avec évaluation en aveugle
- Investigateurs différents pour le diagnostic, la randomisation, l'acte thérapeutique et le suivi

Précautions supplémentaires en cas d'essai réalisé en ouvert

- Suivi organisé par un évaluateur différent du practicien ayant administré le traitement (qui lui n'aura pas connaissance du traitement reçu par le patient)
- Critère de jugement "dur" parfaitement objectif (ex: mortalité toute cause)

- Évalutation du critère de jugement principal, de manière centralisée, par un comité d'adjudication indépendant et en aveugle du traitement

Biais de confusion

4 sous-types de biais

- Effet placebo du médicament
- Caractéristiques intrinsèques des patients : âge, sexe, ATCD ...
- Effet non médicamenteux de la prise en charge
- Évolution naturelle de la maladie

5 Mesures préventives

- Existence d'un groupe contrôle

2 techniques de prise en compte dans la planification (à priori)

- Randomisation par stratification
- Restriction de la population étudiée = on n'inclue pas ceux qui présentent des facteurs de confusion (critères d'inclusion ou d'exclusion)

2 techniques de prise en compte dans l'analyse (à postériori)

- Analyse stratifiée = subdiviser la population de chaque groupe pour une analyse en sous-groupes selon les facteurs de confusion
- Ajustement par analyse multivariée : pondérer les facteurs de confusion

Rappel des principaux biais dans un essai contrôlé randomisé

Nom du biais

Biais de sélection

A quoi ça correspond ? :
Sélection d'un échantillon non représentation

Absence de comparabilité initiale des groupes favorisant une des interventions

Comment limiter le risque de biais ? :
Sélection d'un échantillon représentatif

Séquence de randomisation aléatoire et respect de la clause d'ignorance (assignation secrète)

Biais de performance — A quoi ça correspond ? : Le patient et son médecin peuvent être influencés s'ils savent quelle intervention le patient a reçue ; Comment limiter le risque de biais ? : Double aveugle si possible (dépend du type d'intervention)

Biais de classement

A quoi ça correspond ? :

L'évaluateur peut être influencé s'il sait quelle intervention le patient a reçue

Comment limiter le risque de biais ? :

Critère de jugement objectif (décès toutes causes confondues)

OU

Evaluation du critère de jugement en aveugle du traitement reçu si critère de jugement subjectif

Biais d'attrition

A quoi ça correspond ? :

Exclusion de patients de l'analyse

Comment limiter le risque de biais ? :

Analyse en intention de traiter

ET

Stratégie de gestion des données manquantes

Recommandations de reporting pour les essais contrôlés randomisés

Titre, Résumé et Introduction

TITRE & RESUME		
	1a	Identification en tant qu' "essai randomisé" dans le titre
	1b	Résumé structuré du plan d'essai, méthodes, résultats et conclusions (pour une aide spécifique voir CONSORT pour Abstract)
INTRODUCTION		
Contexte et objectifs	2a	Contexte scientifique et explication du bien-fondé
	2b	Objectifs spécifiques et hypotheses

Untitled

Méthodes

MÉTHODES		
Plan de l'essai	3a	Description du plan de l'essai (tel que : groupes parallèles, plan factoriel) en incluant le ratio d'allocation
	3b	Changements importants de méthode après le début de l'essai (tel que les critères d'éligibilité), en expliquer la raison
Participants	4a	Critères d'éligibilité des participants
	4b	Structures et lieux de recueil des données
Interventions	5	Interventions pour chaque groupe avec suffisamment de détails pour pouvoir reproduire l'étude, en incluant comment et quand elles ont été véritablement conduites
Critères de jugement	6a	Critères "à priori" de jugement principal et secondaires entièrement définis, en incluant comment et quand ils ont été évalués
	6b	Changement quelconque de critères de jugement après le début de l'essai, en expliquer la raison
Taille de l'échantillon	7a	Comment la taille de l'échantillon a-t-elle été déterminée ?
	7b	Quand cela est applicable, explication des analyses intermédiaires et des règles d'arrêt

Randomisation

RANDOMISATION		
Production de la séquence	8a	Méthode utilisée pour générer la séquence d'allocation par tirage au sort
	8b	Type de randomisation, en incluant les détails relatifs à une méthode de restriction (comme par ex. : par blocs, avec la taille des blocs)
Mécanisme d'assignation secrète	9	Mécanisme utilisé pour mettre en œuvre la séquence d'allocation randomisée (comme par exemple : l'utilisation d'enveloppes numérotées séquentiellement), en décrivant chaque mesure prise pour masquer l'allocation jusqu'à l'assignation des interventions.
Mise en œuvre	10	Qui a généré la séquence d'allocation, qui a enrôlé les participants et qui a assigné les participants à leurs groupes
Aveugle	11a	Au cas où, décrire qui a été en aveugle après l'assignation des interventions (par exemple, les participants, les administrateurs de traitement, ceux qui évaluent les résultats) et comment ont-ils été empêchés de savoir
	11b	Si approprié, description de la similitude des interventions
Méthodes statistiques	12a	Méthodes statistiques utilisées pour comparer les groupes au regard des critères de jugement principal et secondaires
	12b	Méthodes utilisées pour des analyses supplémentaires, telles que des analyses de sous-groupes ou des analyses ajustées

Untitled

Untitled

Résultats

RESULTATS		
Flux des participants (un diagramme est fortement conseillé)	13a	Pour chaque groupe, le nombre de participants qui ont été assignés par tirage au sort, qui ont reçu le traitement qui leur était destiné, et qui ont été analysés pour le critère de jugement principal
		Pour chaque groupe, abandons et exclusions après la randomisation, en donner les raisons
Recrutement	14a	Dates définissant les périodes de recrutement et de suivi
	14b	Pourquoi l'essai a-t-il pris fin ou a été interrompu
Données initiales	15	Une table décrivant les caractéristiques initiales démographiques et cliniques de chaque groupe
Effectifs analysés	16	Nombre de participants (dénominateur) inclus dans chaque analyse en précisant si l'analyse a été faite avec les groupes d'origine
Critères de jugement et estimations	17a	Pour chaque critère de jugement principal et secondaire, donner les résultats pour chaque groupe, et la taille estimée de l'effet ainsi que sa précision (comme par ex. : intervalles de confiance à 95%)
	17b	Pour les variables binaires, une présentation de la taille de l'effet en valeurs absolues et relatives est recommandée
Analyses accessoires	18	Résultats de toute analyse supplémentaire réalisée, en incluant les analyses en sous-groupes et les analyses ajustées, et en distinguant les analyses spécifiées à priori des analyses exploratoires
Risques	19	Tous les risques importants ou effets secondaires inattendus dans chaque groupe (pour un conseil détaillé voir '*CONSORT for harms*')

Untitled

Discussion

DISCUSSION		
Limitations	20	Limitations de l'essai, en tenant compte des sources de biais potentiels ou d'imprécision, et au cas où, en tenant compte de la multiplicité des analyses
"Généralisabi-lité"	21	"Généralisabilité" (validité externe, applicabilité) des résultats de l'essai
Interprétation	22	Interprétations/conclusions cohérentes avec les résultats, en tenant compte du ratio bénéfices/risques et de possibles autres faits pertinents

Untitled

Informations supplémentaires

INFORMATIONS SUPPLEMENTAIRES		
Enregistrement	23	Numéro d'enregistrement de l'essai en précisant le registre utilisé
Protocole	24	Où le protocole complet de l'essai peut-il être consulté, si possible
Financement	25	Sources de financement et autres ressources (par ex. : fourniture de médicaments), rôle des donateurs

Untitled

CONSORT 2010 Flow Diagram

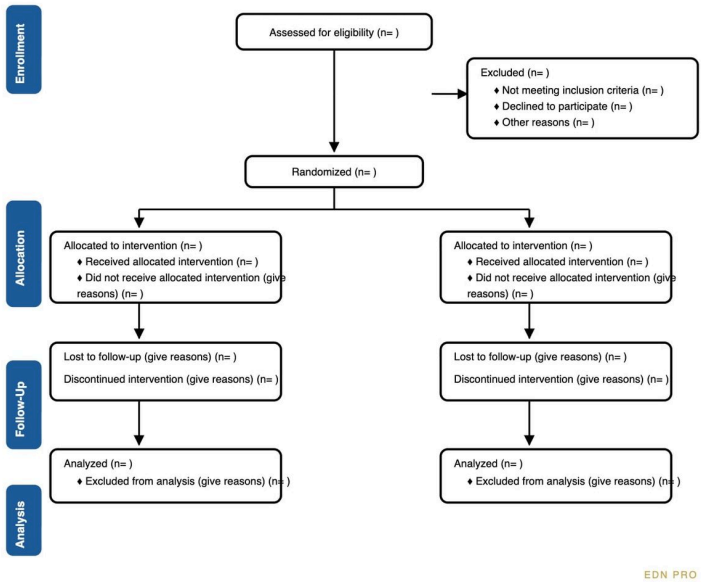


image.png

Partie 1 — Selon le type d'étude

Études diagnostiques

Il peut s'agit de l'évaluation d'un test diagnostique, algorithme diagnostique, signe clinique ...

Enjeux principaux devant une étude diagnostique (2) :

- Déterminer l'objectif / critère de jugement principal
- Validité externe : afin d'évaluer la capacité d'utiliser les résultats de l'étude en pratique quotidienne auprès d'une population réelle

Objectif

Évaluer la performances diagnostiques du test (avant sa mise en place)

CDJ principal :

Performances diagnostiques du test :

- **Se**, **Sp**, **VPN**, **VPP**, **RVP**, **RVN**
- Courbe **ROC** éventuelle (***Pearson***, *diagramme de* ***Bland et Altman***)

(discrimer M+/M- de façon fiable)

Types détude :

- Étude transversale ++ (**privilégié**) : **ne doit pas être confondu avec une étude de cohorte** lorsqu'on parle de **"étude prospective" qui peut juste vouloir dire qu'il y un recrutement prospectif des patients** ⚠️
  - TOMBÉ EN ANNALE, ÇA M'A MIT LE DOUTE LEUR "PROSPECTIVE" ALORS QUE C'ÉTAIT TRANSVERSALE
- Étude de cohorte prospective : lorsqu'il s'agit de suivre les patients, pour compléter le Gold Standard
- Étude cas-témoins : utile si maladie rare, ou au stade de développement initial d'un nouveau test (phase 2 like)
  - attention, ici biais très important avec des performances du test surestimées !

Évaluer l'impact du test déjà mis en place

CDJ principal :

- Survie
- Apparition de complications

Types détude :

- Essai contrôlé randomisé (à préférer)
  - Compare l'évolution d'un groupe de patients bénéficiant de l'outil diagnostique de celle d'un groupe contrôle
  - Recommandé de faire une analyse en ITT pour ce type d'étude (étude interventionnelle de supériorité),

peut être appelée si « en intention de diagnostiquer » ou « en intention de dépister » (c'est la même chose)

- Étude observationnelle (équivalent d'étude épidémiologique analytique dans la forme, avec pour facteur d'exposition "exposition au test diagnostique") → proposé pour un test diagnostique/dépistage déjà en place

> **Accurancy a 2 traductions possibles : « précision diagnostique » = « performance diagnostique »**

Focus : Essai diagnostique

Principe : type d'étude à préférer pour évaluer l'impact d'un test déjà mis en place

En comparant l'évolution clinique d'un groupe de patients bénéficiant de l'outil diagnostique de celle d'un groupe contrôle

Ex. on évalue l'impact de la mise en place de la troponine de façon systématique aux urgences, vs pas de troponine systématique en terme de mortalité à 1 mois

> **Recommandé de faire une analyse en intention de traiter pour ce type d'étude (étude interventionnelle de supériorité)**

Auteurs utilisent aussi le nom de "analyse en intention de diagnostiquer/dépister" : c'est le même principe

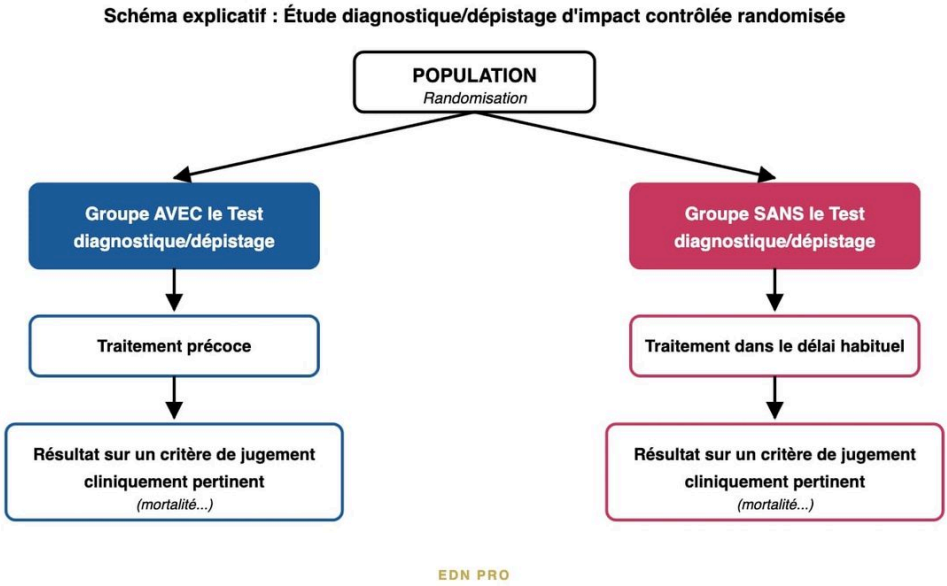


image.png

Critères indispensables à la validité interne de l'essai diagnostique

Critères d'une étude diagnostique de qualité

- **Inclusion prospective** – étude multicentrique – calcul du NSN *a priori*
- Sélection et représentativité de l'échantillon (avec les paramètres extrinsèques)

- **Examen de référence (Gold standard)** = le test doit être validé avec Se-Sp fournies
- **Définition de la maladie par le gold standard avec description précise du test**
- **Tous les sujets ont eu à la fois le test à l'étude et le test de référence**
- Réalisation et interprétation des deux tests **en aveugle** par un comité d'adjudication
- Reproductibilité du test / étude de la variabilité inter- et intra-observateurs
- Ensemble des paramètres opérationnels fournis (3x2) avec **IC 95 %** pour chacun
- Choix du seuil argumenté → **courbe ROC** fournie
- **Validité externe** = applicabilité / risque / coût-bénéfice

Classification des essais diagnostiques (ECNi 2018)

Essai

Essai de phase I — Principe : On pratique le **test à l'essai** sur une **population saine** et une **population malade**. On recherche une **différence significative entre les deux populations**. ; Exemple : Faire un dosage du BNP chez des patients en décompensation cardiaque.

Essai de phase II — Principe : On regarde **si le test permet de bien classer les patients en sains / malades** : on compare les résultats à un **gold standard** ; on regarde la sensibilité (Se) et spécificité (Sp) d'un BNP vs ETT → étude rétrospective. ; Exemple : BNP vs ETT dans une étude rétrospective

Essai de phase III

Principe :
On pratique le test à laisser sur une population de patients suspects d'être malade.
On regarde si le test permet de différencier les patients sains et malades.

Exemple :
Voir si le BNP est prédictif du résultat de l'ETT
—> Etude prospective

Essai de phase IV — Principe : Comparer les résultats sur le critère d'évaluation avec et sans le test à l'essai. ; Exemple : Voir si le dosage du BNP aux urgences améliore la survie à 6 mois.

Exemples pour les Types d'étude

Étude diagnostique/dépistage de performance

Étude transversale = privilégié : afin d'avoir au même moment les données de la réalisation du test étudié et du Gold Standard

Attention "étude prospective" qui peut juste vouloir dire qu'il y un recrutement prospectif des patients ⚠️

Exemple très fort : Etude transversale avc pratique contemporaine du test étudié (Tropo) et du test e référence (Coro), mais tous les patients qui se présentent aux urgences de l'hôpital avec une douleur thoracique sont recrutés de manière consécutive (prospective) ave une utilisation possible dans Matériels et Méthodes » du terme de « COHORTE » par les auteurs, c'est un abus de langage fréquent !! mais on parlera bien, au final, d'une étude TRANSVERSALE qui est don adaptée pour répondre à la question posée et pas d'étude de cohorte

Autres types d'étude possibles :

Étude de cohorte prospective : lorsqu'il s'agit de suivre les patients, pour compléter le Gold Standard

Exemple : pour le test diagnostique des D-Dimères dans le diagnostic d'EP, le test de référence était soit l'Angioscanner si la probabilité de l'EP était élevée, soit le simple suivi clinique prospectif avec recherche d'EP dans le cas d'une probabilité d'EP faible, car il n'était pas acceptable que des patients avec une probabilité faible d'EP subissent un test de référence invasif comme l'Angioscanner

Étude cas-témoins : utile dans le cas d'une maladie rare, ou au stade de développement initial d'un nouveau test (*phase 2 like)*

Exemple : on prend des cas confirmés avec une maladie et on les apparie à un ou plusieurs témoins, puis on réalise à tout le monde le test étudié et voit s'il arrive à discriminer cas et témoins

> **Mais attention biais très important avec des performances du test surestimées !**

Étude diagnostique/dépistage d'impact

Ici, 2 types d'études possibles :

Essai contrôlé randomisé (à préférer)

En comparant l'évolution clinique d'un groupe de patients bénéficiant de l'outil diagnostique de celle d'un groupe contrôle

Ex. on évalue l'impact de la mise en place de la troponine de façon systématique aux urgences, vs pas de troponine systématique en terme de mortalité à 1 mois

> **Recommandé de faire une analyse en intention de traiter pour ce type d'étude (étude interventionnelle de supériorité)**

Auteurs utilisent aussi le nom de "analyse en intention de diagnostiquer/dépister" : c'est le même principe

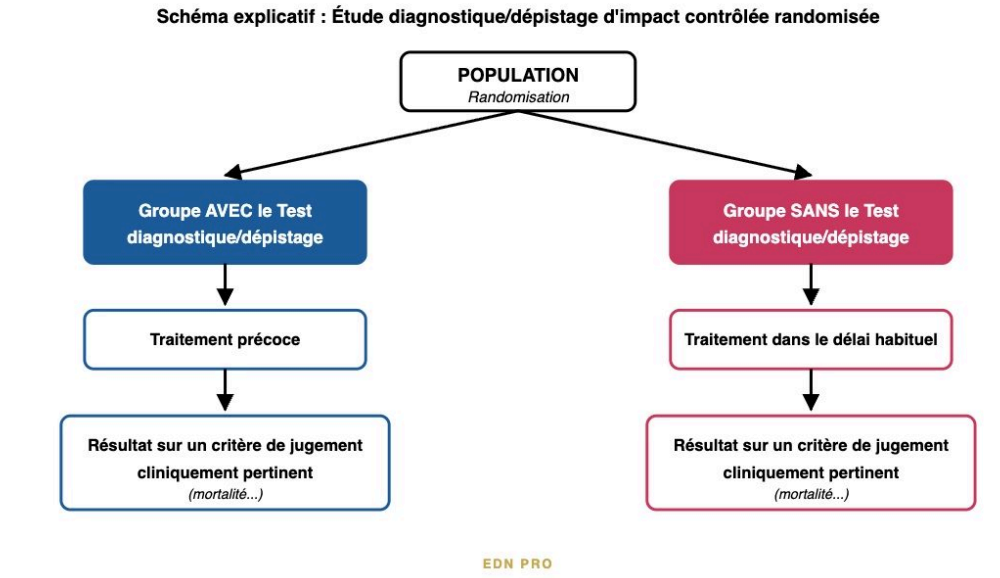


image.png

- Étude observationnelle : équivalent d'étude épidémiologique analytique dans la forme, avec pour facteur d'exposition "exposition au test diagnostique"

> **Type d'étude observationnelle ou interventionelle n'est pas toujours fixé selon ce critère de jugement**

Ce chapitre est consacré aux études diagnostiques portant sur l'évaluation de la performance diagnostique du test à l'étude

Focus : test de dépistage

Intervention de prévention ou de dépistage

Introduction : prévention

Définition de la prévention

Prévention = ensemble de mesures permettant d'éviter l'apparition, l'aggravation et l'extension de certaines maladies

Épidémiologie fournit les données essentielles à l'élaboration des mesures préventives en identifiant des déterminants des maladies et en demontrant l'utilité de leur élimination, elle permet donc aussi la validation des mesures de prévention

Trois types de prévention sont actuellement considérés :

- Prévention primaire : vise à éviter la survenue de la maladie et des facteurs de risque (ex. mesures législatives, éducatives)

- Prévention secondaire : vise à reconnaître une maladie plus tôt dans l'histoire naturelle, avant que cette maladie soit symptomatique ou rapidement après (ex. dépistage, mesures curatives)
- Prévention tertiaire : vise à réduire les conséquences d'une maladie déjà déclarée (ex. rééducation, réadaptation, éducation thérapeutique)

Types de Stratégies de prévention

Stratégies de prévention peuvent s'inscrire dans deux cadres : collectif ou individuel, pour la majorité des maladies, une combinaison de ces deux types de stratégies est utilisée

Prévention n'est pas toujours acceptée de la même manière par tout le monde car les messages préventifs peuvent véhiculer de l'inquiétude et l'interprétation du rapport bénéfice/risque n'est pas toujours identique : certains ne voient que le bénéfice (ex : le dépistage) alors que d'autres ne voient que le risque (ex : les effets secondaires attribués aux vaccins).

Prévention de masse vs Prévention individuelle

Prévention de masse
(toute la population)
Souvent passive(peu d'implication des individus)
Bénéfice individuel petit
Bénéfice collectif grand
Fluoration de l'eau
Vaccination antipoliomyélite
Port de la ceinture de sécurité

Prévention individuelle
(population à haut risque)
Le plus souvent active(implication active des individus)
Bénéfice individuel grand
Bénéfice collectif petit
Régime alimentaire chez les obèses
Traitement de l'hypertension

Dépistage

Définitions

Dépistage. Procédure de dépistage vise à identifier dans une population a priori en bonne santé des sujets ayant une maladie inapparente ou à risque élevé de présenter une maladie, en vue d'examens complémentaires, d'un suivi plus rapproché ou de mesures de prévention

Opportuniste
Individuel

Fait sur proposition du médecin traitant, d'un spécialiste ou d'un médecin du travail de faire un test susceptible de découvrir au stade asymptomatique une maladie curable qui n'est pas l'objet de la consultation

Collectif ou organisé

(« systématique » ou « de masse »)

Mis en place sur décision de l'état et prend souvent la forme de grandes campagnes menées en population

- Il est **pris en charge totalement**

Sélectif (ciblé). Appliqué sur une population recrutée sur des critères préalablement définis (**facteurs de risque**)

Différences entres tests de dépistage et tests de confirmation

Objectif — Test diagnostique de dépistage : **Dépistage d'une maladie latente** pour **diminution de la mortalité** ; Test diagnostique de confirmation : **Diagnostic de certitude** pour **décision thérapeutique**

Contexte

Test diagnostique de dépistage :

Problème de santé publique

Prévention secondaire

Histoire naturelle connue

Test diagnostique de confirmation :

À la suite d'un test de dépistage si doute diagnostique

Sujets

Test diagnostique de dépistage :

Sur une population

Dépistage de masse

Test diagnostique de confirmation :

Sur un individu

Confirmation ciblée

Sensibilité (Se) / Spécificité (Sp)

Test diagnostique de dépistage :

Se élevée +++ (et Sp la moins pire possible)

VPN maximale

Test diagnostique de confirmation :

Sp élevée +++ (et Se la moins pire possible)

VPP maximale

Avantages

Test diagnostique de dépistage :

Coût faible – Rapide

Bonne faisabilité

Bonne acceptabilité

Réconfort des sujets négatifs

Test diagnostique de confirmation :

Validité élevée

Bonne reproductibilité

Peu de biais

Inconvénients

Test diagnostique de dépistage :

Faible validité = **biais souvent nombreux**

Risque de **faux négatifs** (faux réconfort)

Risque de **faux positifs** (inquiétude et examens de confirmation inutiles voire dangereux)

Risques iatrogéniques des tests diagnostiques et des traitements après dépistage

Allongement de la période de maladie (marquage)

Test diagnostique de confirmation :

Coût plus élevé

Plus lourd – souvent invasif

Maladies candidates au dépistage

Toutes les maladies ne sont pas de bonnes candidates au dépistage (désagréments et coûts liés au test peuvent en limiter l'utilité)

Traitement doit être plus efficace au stade où la maladie est dépistée

Révéler la maladie aux sujets dépistés peut avoir des conséquences psychologiques et sociales importantes. S'il n'y a pas de traitement efficace disponible, le dépistage n'aura pour effet que d'étiqueter les sujets malades sans qu'il y ait plus de bénéfices que lorsque la maladie est découverte naturellement au cours de son évolution

- Gain de temps sur l'évolution de la maladie doit se traduire en gain de survie ou de qualité de vie

Évaluation d'un bénifice lié au dépistage

Si aucun traitement efficace n'est prodigué, le dépistage allonge la durée de la maladie car sa découverte est plus précoce mais son évolution n'est pas modifiée. C'est la situation "dépistage inefficace", aucun bénéfice pour le sujet ni pour la société n'en est retiré, voire même, le phénomène d'étiquetage évoqué ci-dessus peut avoir des conséquences délétères

En revanche, un dépistage efficace se traduira par une avance au diagnostic permettant l'administration d'un traitement et l'augmentation de la survie du patient, la diminution de la durée de la maladie et/ou une augmentation de sa qualité de vie

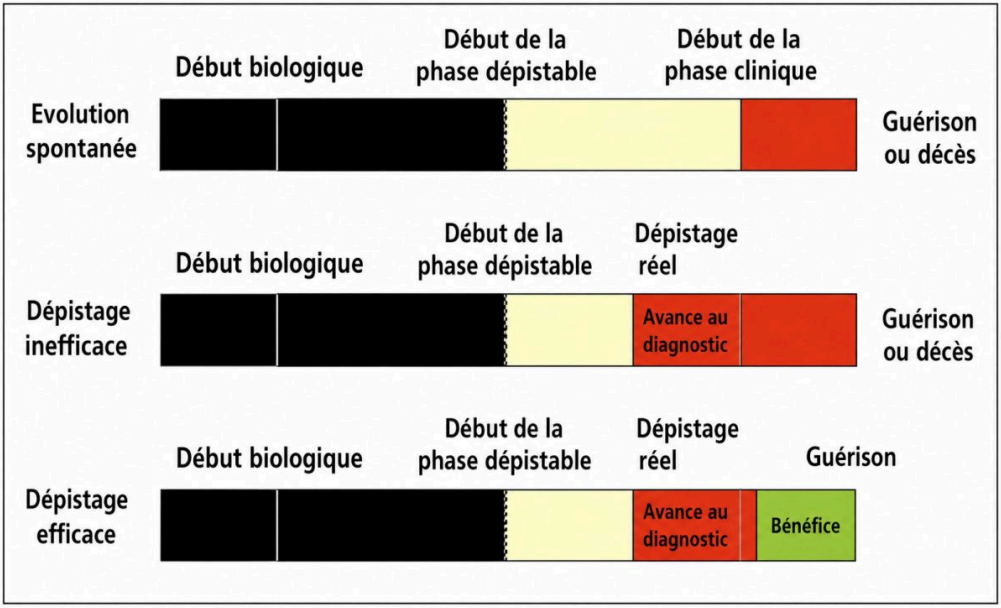


image.png

Test disponible pour le dépistage

Propriétés métrologiques satisfaisantes

But du dépistage est d'identifier le maximum de malades afin de leur faire bénéficier au plus tôt du traitement

- Minimum de faux résultats négatifs par le test doit donc être exigé
- Qualités métrologiques habituellement exigées pour un test de dépistage sont donc une bonne valeur prédictive négative (si le test est négatif, la probabilité d'absence de maladie est élevée) et donc une bonne sensibilité
- Valeur de la spécificité du test est aussi à prendre en compte, en particulier lorsque la maladie est rare et que les tests diagnostiques qui suivront un résultat positif du test de dépistage sont invasifs ou dangereux (minimum de faux positifs doivent être exposés à ces tests).

Acceptabilité, simplicité et coût

Acceptabilité du test par les différents acteurs d'une procédure de dépistage doit être évaluée :

- S'il est trop douloureux, le test peut être redouté par les sujets
- S'il est trop compliqué à mettre en œuvre, c'est le personnel soignant qui peut hésiter à le systématiser
- Si le coût est trop important, c'est au niveau des décideurs et de la société en général que la réflexion sur sa prise en charge peut ralentir son adoption

Toutes ces propriétés sont importantes à évaluer et doivent être réunies afin d'assurer la réussite d'un programme de dépistage

Évaluation de l'efficacité d'un test de dépistage

- lorsque l'on évalue un test de dépistage il faut distinguer **3 situations** :
  - **évolution spontanée** = absence de test de dépistage
  - **test de dépistage inefficace** = permet une avance au diagnostic mais sans bénéfice clinique
  - **test de dépistage efficace** = permet une avance au diagnostic associé à un bénéfice clinique

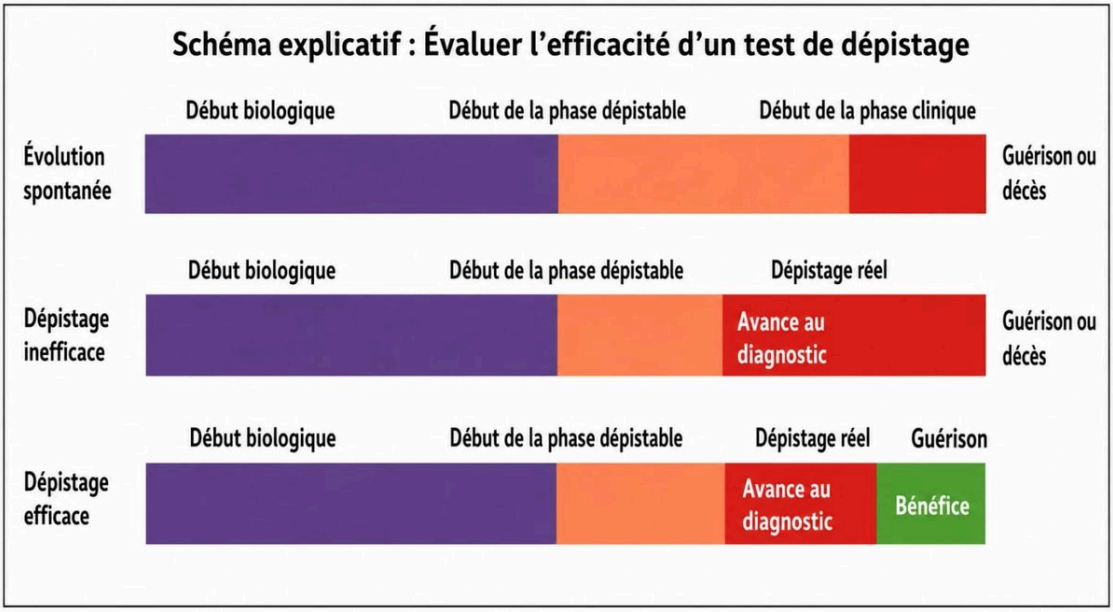


image.png

Évaluation

Formulation de l'objectif

L'objectif doit être formulé de manière claire et complète. Pour cela, il faut reprendre les différents éléments du **PECO** où le **P** représente la population concernée ; le **E**, la procédure de dépistage évaluée ; le **C**, est l'absence de dépistage et le **O** le critère de jugement.

Par exemple, évaluer l'efficacité d'un **dépistage organisé par frottis cervico-vaginal (E)** par rapport à une **absence de dépistage organisé (C)** en termes de **mortalité (O)** chez les **femmes de 25 à 65 ans (P)**.

Type d'étude

Essai contrôlé randomisé est la référence pour évaluer l'efficacité d'une procédure de dépistage car il permet de limiter les biais et apporte (en théorie) le niveau de preuve scientifique le plus élevé

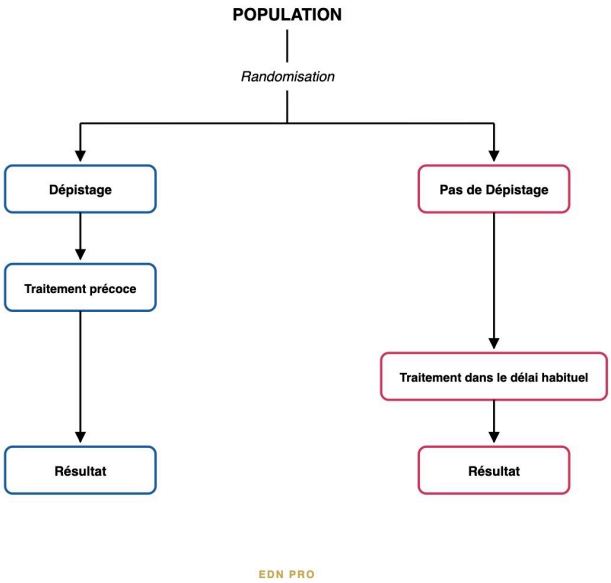


image.png

Points à évaluer

Notions précédemment vues dans les essais contrôlés randomisés s'appliquent ici également

Il faudra accorder une attention particulière à :

- Qualité de la randomisation
- Critère de jugement principal : pertinence clinique ? subjectivité ? mode d'évaluation ?

Analyse en intention de dépister

La même chose que l'analyse en intention de traiter mais pour une procédure de dépistage c'est-à-dire l'analyse de tous les patients randomisés dans le groupe dans lequel ils ont été randomisés quel que soit leur suivi, leur compliance et l'intervention qu'ils ont effectivement reçue

L'analyse en intention de dépister est le reflet de l'impact de la procédure de dépistage organisé dans la vraie vie car on sait très bien que tous les individus qui reçoivent une invitation pour un dépistage organisé ne vont pas forcément le faire et que certains individus randomisés dans le groupe absence de dépistage auront la procédure de dépistage dans le cadre d'un dépistage dit opportuniste via leurs médecins

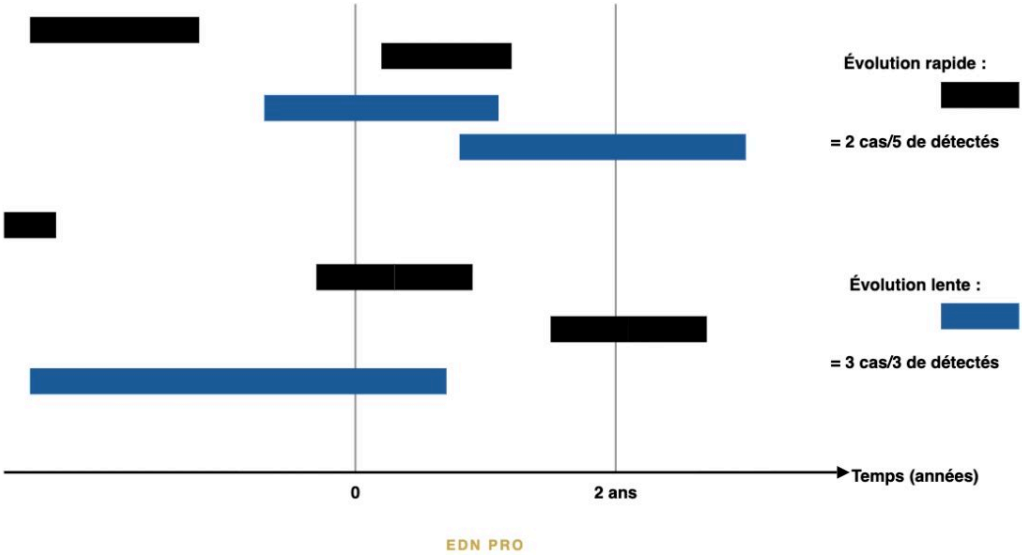
Interprétation des résultats

Il faut évaluer si la différence est statistiquement significative et si celle-ci est cliniquement pertinente

- Pour cela, il faut considérer la réduction absolue du risque et le nombre de sujets à dépister pour éviter un évènement
- Attention, il est normal que ce nombre soit plus élevé que dans un essai thérapeutique classique car les sujets ne sont pas malades ⚠️

Biais spécifiques aux études d'évaluation d'une procédure de dépistage

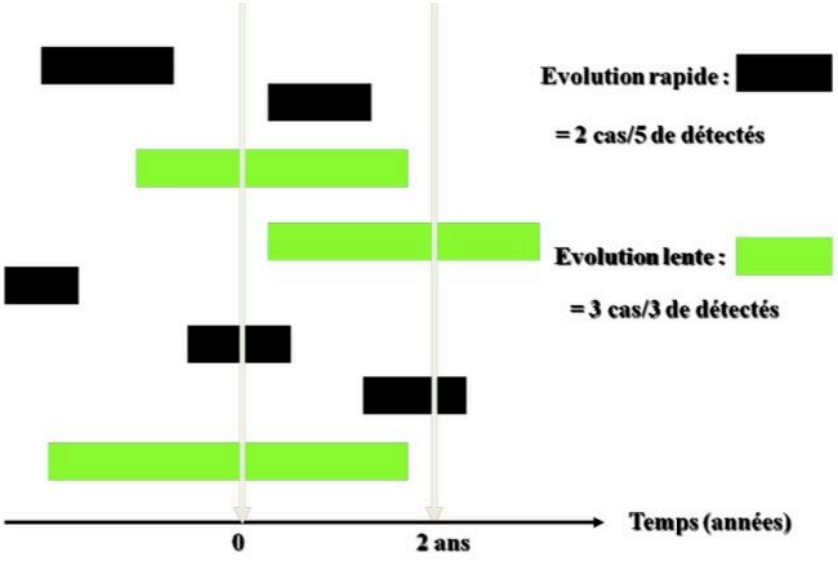
Schéma : lenth time bias



EDN PRO

image.png

Figure 29 : Influence de la durée d'évolution de la maladie et de la périodicité du dépistage



Untitled

Biais d'avance
au diagnostic
(lead time bias)
À évoquer si test de dépistage permettant une avancée au diagnostic mais sans bénifice clinique en termes de survie (= test de dépistage inefficace), ici la **survie des patients n'est pas augmentée**, juste ils savent qu'ils sont malades pendant plus longtemps

Biais de sélection des formes lentes (length time bias)

À évoquer lorsque le test de dépistage évalue une maladie qui comprend à la fois des formes à évolution rapide et à la fois à évolution lente, les résultats risquent d'être modifiés par la fréquence de réalisation des tests de dépistage chez un même individu :

- On détectera plus frequemment une forme à évolution rapide par rapport à une évolution plus progressive
- Dépistage trouve plus souvent les tumeurs de croissance lente que les tumeurs les plus agressives

Biais du surdiagnostic

À évoquer lorsque le test de dépistage évalue une maladie à évolution très lente, qui ne serait probablement jamais manifestée
(ex. cancer de la prostate)

Critères justifiant la mise en place d'un dépistage organisé (OMS)

Liés à la maladie dépistée

- Maladie doit être un problème de santé publique par sa fréquence, sa sévérité ou son impact socio-économique
- **Histoire naturelle** de la maladie doit être bien **connue**
- Maladie doit pouvoir être détectée pendant sa **phase de latence asymptomatique**
- Il n'existe pas de facteurs de risque accessibles à la prévention primaire ❌
- Précocité du traitement doit être démontrée comme un facteur de bon pronostic

Liés au test de dépistage

- Forte **sensibilité** et une forte **spécificité**
- Simple à utiliser et avoir une bonne acceptabilité par les patients (> 60% d'acceptabilité par la population) et les professionnels
- **Intervalles de répétition du test** doivent être connus
- Risques physiques et psychologiques du dépistage doivent être démontrés inférieurs aux bénéfices obtenus
- Coût du dépistage (y compris le diagnostic et le traitement) ne doit pas être disproportionné par rapport au coût global des soins médicaux
- Programme de dépistage doit avoir fait la preuve de son efficacité avec des **essais contrôlés randomisés**

Liés à la population dépistée

- Population cible identifiée et sensibilisée (ex. femmes entre 50-75 ans)
- Population ayant accès aux moyens diagnostiques et thérapeutiques
- Moyens existent pour réaliser le programme de dépistage de façon continue et pour faire face aux charges supplémentaires induites par la pratique du test

Méthodes

PECO (objectif, CDJ, population étudiée)

Objectif/PECO :

Infos à traquer

- Quel est le test de référence ? (ex. culture)
- Quelle maladie ? (ex. angines à SGA)
- Quel contexte ? (ex. aux urgences)

Exemple

(PECO)

Par exemple, évaluer la performance diagnostique de la palpation manuelle (E) par rapport à l'échographie (C) pour diagnostiquer des présentations non-céphaliques (O) chez des femmes en fin de grossesse (P)

Population d'étude :

Enjeu

Population de l'étude doit être proche de la population à laquelle seront appliqués les résultats de l'étude

- en effet, le test peut être très performant dans un contexte mais beaucoup moins dans un autre

✅ . Recrutement systématique et consécutif dans un service permet d'avoir un échantillon représentatif avec un spectre de gravité homogène → **augmente la validité interne**

Biais

⚠️

Si la population d'étude comporte des patients trop malades ou trop peu malades

- risque de biais de **sélection** appelé **biais de spectre**
  - résultats seront difficilement transposables à la pratique clinique courante

Critère de jugement principal :

CDJ commun. Paramètres opérationnels : Se, Sp, VPN, VPP, RVP, RVN

Si test quantitatif

- Critère principal : paramètres opérationnels pour un seuil prédéfini
- Critères secondaires :
  - Courbe ROC : valeur seuil optimal / aire sous la courbe
  - Corrélation linéaire de Pearson (r et p)
  - Bland-Altman (biais moyen, limites d'agrément, performance diagnostique segmentaire)

Choix du test de référence (élément très important à évaluer)

Utilité

Test de référence est le test qui va permettre d'identifier véritablement les malades et les non-malades et d'évaluer la performance diagnostique du test évalué (en Anglais, diagnostic accuracy), on l'appelle également gold standard

- il doit donc être incontestable pour différencier les personnes malades des non-malades et préalablement validé

5 paramètres

Paramètres à toujours préciser pour qualifier le test de référence :

- Description précise de la méthode utilisée

- Performances - Reproductibilité - Fiabilité - Validité
- Standardisation
- Valeurs « normales » et « Seuils de positivité »
- Contrôle de qualité

Pas toujours possible

Il n'est pas toujours possible d'avoir un test de référence : dans certaines situations, seul un faisceau d'arguments, l'opinion d'un expert voire l'évolution clinique du patient, fournit une procédure de référence

- ceci encourage à ce que les critères diagnostiques permettant de définir la référence soient parfaitement décrits

---

Méthodologie

Principe. Compare les résultats avec le test à l'épreuve contre test de référence (intérêt seulement si moins cher, plus facile, plus rapide …)

NSN

NSN calculé pour obtenir une précision suffisante dans l'estimation des indices de performance diagnostique :

- Hypothèse sur la prévalence de la maladie
- Hypothèse sur la Se ou Sp du test
- Hypothèse sur la largeur de l'intervalle de confiance

Population

1 seul échantillon de patients avec suspicion de la maladie (M)

- *ex. patient avec douleur thoracique pour test de la troponine*

Réalisation des tests

- Tests doivent être réalisés de manière standardisée
- Tests (test à évaluer et test de référence) doivent être réalisés chez tous les patients : réalisation de l'examen de référence uniquement chez les patients avec un résultat positif du test à évaluer surestime les performances diagnostiques du test → risque de biais de vérification (work up bias)
- Tests doivent être interprétés indépendamment l'un de l'autre :
  - Personne qui évalue le nouveau test doit être en **aveugle** des résultats de l'examen de référence
  - Sinon il y a un risque de biais de classement (biais d'information, biais de contexte)

Analyse

- Tableau de contingence (calcul Se/Sp, RVP/RVN) + Courbe ROC si quantitatif
- RV = gain diagnostique = probabilité pré/post-test (avec RV = Likelihood Ratios)

Conclusion

- Avantage ou non du test par rapport à ceux existants
- Discussion de la validité externe du test (toujours y penser)

Figures

Focus : Diagramme de flux spécial pour les études diagnostiques

Exemples

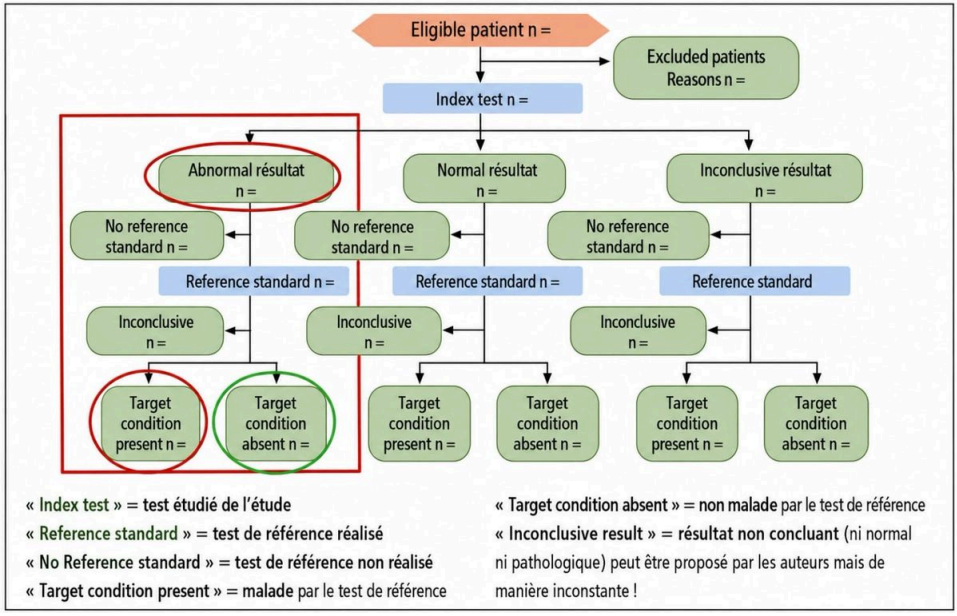


image.png

Focus : Tableau 1 (patients éligibles vs patients inclus) et Tableau 2 (malades vs non-malades)

Tableau 1 sous différentes formes pour étude diagnostique (Question ECNi 2018)

- **Tableau 1** comparant les patients éligibles vs les patients inclus
- **Tableau 2** comparant les patients malades vs les patients non malades parmi les patients inclus (1er et 2e colonnes) et présentation de la population étudiée pour la comparer à la population cible en termes de validité externe (3e colonne)

Table 1 : Patient demographics (exemple)

Age, mean (SD), y — Eligible patients (n = 1004) : 53.0 (11.6) ; Enrolled patients (n = 821) : 53.2 (11.6)

Race

White — Eligible patients (n = 1004) : 764 (76.1) ; Enrolled patients (n = 821) : 624 (76.0)

Hispanic or Latino — Eligible patients (n = 1004) : 24 (2.4) ; Enrolled patients (n = 821) : 23 (2.8)

Black — Eligible patients (n = 1004) : 168 (16.7) ; Enrolled patients (n = 821) : 136 (16.6)

Pacific Islander — Eligible patients (n = 1004) : 2 (0.2) ; Enrolled patients (n = 821) : 2 (0.2)

Asian — Eligible patients (n = 1004) : 24 (2.4) ; Enrolled patients (n = 821) : 20 (2.4)

Other — Eligible patients (n = 1004) : 6 (0.6) ; Enrolled patients (n = 821) : 4 (0.5)

Unknown — Eligible patients (n = 1004) : 16 (1.6) ; Enrolled patients (n = 821) : 12 (1.5)

Menopausal status

Premenopause — Eligible patients (n = 1004) : 359 (35.8) ; Enrolled patients (n = 821) : 297 (36.2)

Surgical menopause — Eligible patients (n = 1004) : 195 (19.4) ; Enrolled patients (n = 821) : 161 (19.6)

Postmenopause — Eligible patients (n = 1004) : 383 (38.1) ; Enrolled patients (n = 821) : 313 (38.1)

Perimenopause — Eligible patients (n = 1004) : 61 (6.1) ; Enrolled patients (n = 821) : 49 (6.0)

Unknown — Eligible patients (n = 1004) : 1 (0.1) ; Enrolled patients (n = 821) : 1 (0.1)

Missing — Eligible patients (n = 1004) : 5 (0.5) ; Enrolled patients (n = 821) : 0

Family history of breast cancer

No — Eligible patients (n = 1004) : 507 (50.5) ; Enrolled patients (n = 821) : 496 (60.4)

Yes — Eligible patients (n = 1004) : 391 (39.0) ; Enrolled patients (n = 821) : 315 (38.4)

First-degree relative — Eligible patients (n = 1004) : 214 (21.3) ; Enrolled patients (n = 821) : 170 (20.7)

Other relative — Eligible patients (n = 1004) : 183 (18.2) ; Enrolled patients (n = 821) : 145 (17.7)

Unknown — Eligible patients (n = 1004) : 11 (1.1) ; Enrolled patients (n = 821) : 9 (1.1)

Missing — Eligible patients (n = 1004) : 7 (0.7) ; Enrolled patients (n = 821) : 1 (0.1)

Prior hormone use

No — Eligible patients (n = 1004) : 226 (22.5) ; Enrolled patients (n = 821) : 184 (22.4)

Yes — Eligible patients (n = 1004) : 768 (76.5) ; Enrolled patients (n = 821) : 632 (77.0)

Missing — Eligible patients (n = 1004) : 10 (1.0) ; Enrolled patients (n = 821) : 5 (0.6)

Prior benign breast biopsy

No — Eligible patients (n = 1004) : 792 (78.9) ; Enrolled patients (n = 821) : 649 (79.0)

Yes — Eligible patients (n = 1004) : 200 (19.9) ; Enrolled patients (n = 821) : 167 (20.3)

Missing — Eligible patients (n = 1004) : 12 (1.2) ; Enrolled patients (n = 821) : 5 (0.6)

Table 2 : Baseline characteristics of and clinical presentation for 297 patients with suspected meningitis (exemple)

Characteristic

At baseline

Age, median years (range) — Patients without meningitis : 41 (18-93) ; Patients with meningitis : 37 (22-92) ; All patients : 40 (18-93)

No. (%) of patients > 60 years old — Patients without meningitis : 37/217 (17) ; Patients with meningitis : 9/80 (11) ; All patients : 46/297 (15)

Sex, n/N (%)

Male — Patients without meningitis : 97/217 (45) ; Patients with meningitis : 37/80 (46) ; All patients : 134/297 (45)

Female — Patients without meningitis : 120/217 (55) ; Patients with meningitis : 43/80 (54) ; All patients : 163/297 (55)

Ethicity, n/N (%)

White — Patients without meningitis : 104/217 (48) ; Patients with meningitis : 51/80 (54) ; All patients : 163/287 (45)

Black — Patients without meningitis : 68/217 (31) ; Patients with meningitis : 21/80 (26) ; All patients : 89/297 (30)

Hispanic — Patients without meningitis : 40/217 (18) ; Patients with meningitis : 7/80 (9) ; All patients : 47/297 (16)

Other — Patients without meningitis : 5/217 (2) ; Patients with meningitis : 1/80 (1) ; All patients : 6/297 (2)

Immunocompetence, n/N (%)

Unimpaired — Patients without meningitis : 162/217 (75) ; Patients with meningitis : 63/80 (79) ; All patients : 225/297 (76)

Immunocompromised

HIV positive — Patients without meningitis : 38/217 (18) ; Patients with meningitis : 12/80 (15) ; All patients : 50/297 (17)

Immunosuppressed — Patients without meningitis : 17/217 (8) ; Patients with meningitis : 5/80 (6) ; All patients : 22/297 (7)

Principaux biais dans une étude diagnostique

Biais de sélection

Communs. Biais de sélection communs aux autres essais : étude monocentrique, volontariat, restriction

Spécifique

Biais de spectre :

- Sélection de sujets malades très graves pour le test diagnostique
- Conduit à l'**augmentation articielle** de la sensibilité et de la **RV +** (rapport de vraissemblance positif)
- Contexte fréquent = étude cas-témoin

Ex. pour tester la sensibilité à la troponine, on inclut que des infarctus étendus et sévères qui auront des taux de troponine beaucoup plus élevés que des infarctus limités)

Il peut s'agir à l'inverse de la sélection de trop peu de malades

Quoi vérifier ? Vérifier que la population de l'étude doit être proche de la population cible

Biais de classement

"Gold standard n'est pas si gold"

Si le test à l'épreuve est meilleur que le test de référence (or on considère que le test de test de référence permet un diagnostic de certitude) :

- Résultats sont alors erronés : VP (diagnostiqués par le test à l'épreuve) sont considérés comme des FP (car non diagnostiqués par le test de référence)
  - Il faut faire une nouvelle étude pronostique évaluant chacun des 2 tests

Biais de vérification

(work up bias)

Certains patients ont le test à l'étude mais pas le test de référence, souvent car le test de référence est trop invasif/cher/compliqué

- Si le test de **référence** est réalisé seulement chez les patients **positifs au test à l'étude** on va **surestimer la performance** diagnostique
  - Tous les individus doivent recevoir les 2 tests ✅

Biais d'interdépendance

À évoquer lorsque le diagnostic final du statut « malade » est posé à l'aide du nouveau test évalué, souvent associé au biais de vérification

(car en l'absence du test de référence, on utilise le nouveau test pour conclure, c'est très critiquable)

Biais d'information

Pas d'aveugle car on connait le résultat de l'un pour interpréter l'autre

- Résultats des tests doivent être interprétés de manière indépendante

Biais de contexte. Évaluateur des tests a une connaissance du contexte clinique, d'autres résultats complémentaires ...

Autres (reproductibilité)

- Description insuffisante de la méthodologie des tests : la description des tests doit être la plus précise possible, elle est fondamentale pour la reproductibilité des test, définir aussi les "non-malades" et les "malades"
- Reproductibilité inter-évaluateur insuffisante ou non détaillée : souvent taux de concordance insuffisant, rechercher le coefficient Kappa

Biais dans les résultats pour étude diagnostique

Les sources de biais dans l'analyse

- **le nombre de résultats indéterminés ou non interprétables ou aberrants** n'est pas mentionné
- **le nombre de résultats indéterminés est important**
- < 90 % des données des patients inclus sont disponibles pour l'analyse

- **les analyses en sous-groupes ne sont pas appropriées** ou ne sont pas interprétables
- conclure sur l'étude à partir des **VPP et VPN** (dépendent de la prévalence !!!) et non sur la Se ou Sp

Biais spécifiques des études d'évaluation d'une procédure de dépistage

Schéma : lenth time bias

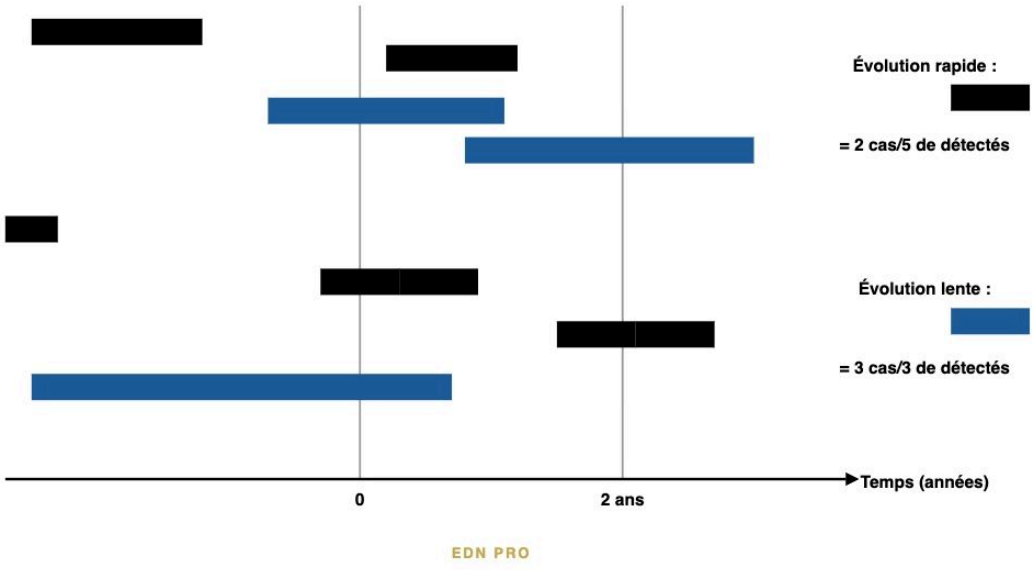


image.png

Biais d'avance

au diagnostic

(lead time bias)

À évoquer si test de dépistage permettant une avancée au diagnostic mais sans bénifice clinique en termes de survie (= test de dépistage inefficace), ici la **survie des patients n'est pas augmentée**, juste ils savent qu'ils sont malades pendant plus longtemps

Biais de sélection des formes lentes (length time bias)

À évoquer lorsque le test de dépistage évalue une maladie qui comprend à la fois des formes à évolution rapide et à la fois à évolution lente, les résultats risquent d'être modifiés par la fréquence de réalisation des tests de dépistage chez un même individu :

- On détectera plus frequemment une forme à évolution rapide par rapport à une évolution plus progressive
- Dépistage trouve plus souvent les tumeurs de croissance lente que les tumeurs les plus agressives

Biais du surdiagnostic

À évoquer lorsque le test de dépistage évalue une maladie à évolution très lente, qui ne serait probablement jamais manifestée

(ex. cancer de la prostate)

En cas d'écart au protocole : quels sont les paramètres évaluables ?

Ecart au protocole

Test de référence n'est pas réalisé lorsque le test étudié est positif (implique une dépendance entre les 2 tests)

Test de référence n'est réalisé que lorsque le test étudié est positif

Test étudié n'est réalisé que lorsque le test de référence est positif (donc uniquement chez les malades)

Unique paramètre évaluable dans ce cas

VPN

VPP

Se

Évaluation de la performance diagnostique d'un test

> **Dogme : étude ne pourra jamais conclure que le test étudié est meilleur que le test de référence ++ (puisqu'on part du principe que le test de référence énonce la vérité quant au statut M+/M-)**

Résultat

Test qualitatif :

- **Binaire** (dichotomique) = positif ou négatif (ex. crachats BK)
- **Nominal** = échelle sans hiérarchie (ex. groupes sanguins : A/B/AB/O)
- **Ordinal** = échelle hiérarchique

Test quantitatif :

- Toujours une **valeur numérique continue** (ex. glycémie)
- Enjeu/Problème : valeur seuil normale / pathologique

Mesure de la validité — Test qualitatif : Paramètres opérationnels d'un test diagnostique ; Test quantitatif : Paramètres opérationnels d'un test diagnostique

Mesure de la fiabilité

Test qualitatif :

Évaluation de la reproductibilité :

- Intra-observateur : CV intra-observateur, coefficient kappa
- Inter-observateur : CV inter-observateur, coefficient kappa

Test quantitatif :

- Reproductibilité intra-observateur : ICC
- Détermination de la valeur seuil par courbe ROC (± Pearson ou Bland-Altman)

Différences entres tests de dépistage et tests de confirmation

Test diagnostique de dépistage vs Test diagnostique de confirmation

Objectif — Test diagnostique de dépistage : **Dépistage d'une maladie latente** pour **diminution de la mortalité** ; Test diagnostique de confirmation : **Diagnostic de certitude** pour **décision thérapeutique**

Contexte

Test diagnostique de dépistage :
Problème de santé publique
Prévention secondaire
Histoire naturelle connue

Test diagnostique de confirmation :
À la suite d'un test de dépistage si doute diagnostique

Sujets

Test diagnostique de dépistage :
Sur une population
Dépistage de masse

Test diagnostique de confirmation :
Sur un individu
Confirmation ciblée

Sensibilité (Se) / Spécificité (Sp)

Test diagnostique de dépistage :
Se élevée +++ (et Sp la moins pire possible)
VPN maximale

Test diagnostique de confirmation :
Sp élevée +++ (et Se la moins pire possible)
VPP maximale

Avantages

Test diagnostique de dépistage :
Coût faible – Rapide
Bonne faisabilité
Bonne acceptabilité
Réconfort des sujets négatifs

Test diagnostique de confirmation :
Validité élevée
Bonne reproductibilité
Peu de biais

Inconvénients

Test diagnostique de dépistage :
Faible validité = **biais souvent nombreux**
Risque de **faux négatifs** (faux réconfort)
Risque de **faux positifs** (inquiétude et examens de confirmation inutiles voire dangereux)
Risques iatrogéniques des tests diagnostiques et des traitements après dépistage
Allongement de la période de maladie (marquage)
Test diagnostique de confirmation :
Coût plus élevé
Plus lourd – souvent invasif

Paramètres opérationnels d'un test diagnostique

Généralités +++ ⭐

```
Efficacité diagnostique = (VP + VN)/(VP+VN+FP+FN)
```

Performances informationnelles d'un test diagnostique

Test positif (T+) — Malade : VP ; Non-malade : FP ; **VPP = VP / (VP + FP)**
Test négatif (T−) — Malade : FN ; Non-malade : VN ; **VPN = VN / (FN + VN)**
Test négatif (T−) — Malade : **Se = VP / (VP + FN)** ; Non-malade : **Sp = VN / (VN + FP)**

> *Fortement recommandé de faire un tableau de contingence* ++++ ⭐

Test évalué + — M+ : a = **VP** ; M− : b = **FP** ; Prévalence = (a + c) / (a + b + c + d) : **VPP = a / (a + b)**
RV+ = Se / (1 − Sp)
Test évalué − — M+ : c = **FN** ; M− : d = **VN** ; Prévalence = (a + c) / (a + b + c + d) : **VPN = d / (c + d)**
RV− = (1 − Se) / Sp
Test évalué − — M+ : **Se = a / (a + c)** ; M− : **Sp = d / (b + d)** ; Prévalence = (a + c) / (a + b + c + d) :
Efficacité diagnostique : E = (a + d) / (a + b + c + d)
Éléments à vérifier pour que l'article soit valable :

- Définition précise et valable pour FP-FN-VP-VN
- Échantillon représentatif (critères de sélection, prévalence)

Intérêt — Paramètres intrinsèques : Déterminent la validité intrinsèque du test ; Paramètres extrinsèques : Déterminent la validité extrinsèque du test
Paramètres — Paramètres intrinsèques : Se, Sp, RVP, RVN ; Paramètres extrinsèques : VPP, VPN

Définition
Paramètres intrinsèques :

- **Ne dépendent pas de la prévalence** ++++
- Dépendent du seuil si quantitatif

Paramètres extrinsèques :

Dépendent de la prévalence ++++ (et de Se/Sp) :

- VPP/VPN évaluées sur l'échantillon sont donc sujettes à caution si la prévalence de la maladie dans l'échantillon diffère de celle de la population générale
- Si la maladie est fréquente : probabilité que le patient soit malade sera élevée, quel que soit le résultat du test, donc la VPP sera élevée et la VPN faible
- Si la maladie est rare : probabilité que le patient soit malade sera élevée, quel que soit le résultat du test, donc la VPP sera faible et la VPN élevée

Théorème de Bayes sur nomogramme de Fagan

Théorème de Bayes sur nomogramme de Fagan

- **p (post-test) = p (pré-test) × RV** → on a **VPP = k × prévalence × RVP** (avec k un facteur fixe)
- **plus le RVP est > 1** = plus il augmente la probabilité **post-test d'être M+**
- **plus le RVN est < 1** = plus il augmente la probabilité **post-test d'être M–**

> ***Nomogramme de Fagan*** *(iconographie à interpréter sortable !) associe* ***p (post-test)*** *à chaque* ***p (pré-test) et RV*** *:*

- la probabilité pré-test est de 30 %
- le RVP est de 20 donc la VPP est de 90 %
- le RVN est de 0,2 donc 1 − VPN est de 7,5 % soit une VPN de 92,5 %

VPN = Sp × (1 − prévalence avec test réf. / 1 − prévalence avec test exp.)

Remarque

- **si on veut une VPN élevée** → il faut une **p (pré-test) assez basse**
  - *exemple* = test diagnostique de confirmation → D-dimères inutile si la probabilité clinique d'EP élevée
- **si on veut une VPP élevée** → il faut une **p (pré-test) assez élevée**
  - *exemple* = test diagnostique de dépistage → pas de dépistage du cancer de l'ovaire par échographie

Intérêts du rapport de vraisemblance

- **indépendant de la prévalence (intrinsèque)** = ne dépend pas du groupe de patient
- intérêt individuel en **fonction de la probabilité pré-test d'un patient donné**
- valeur différente selon le niveau quantitatif du test

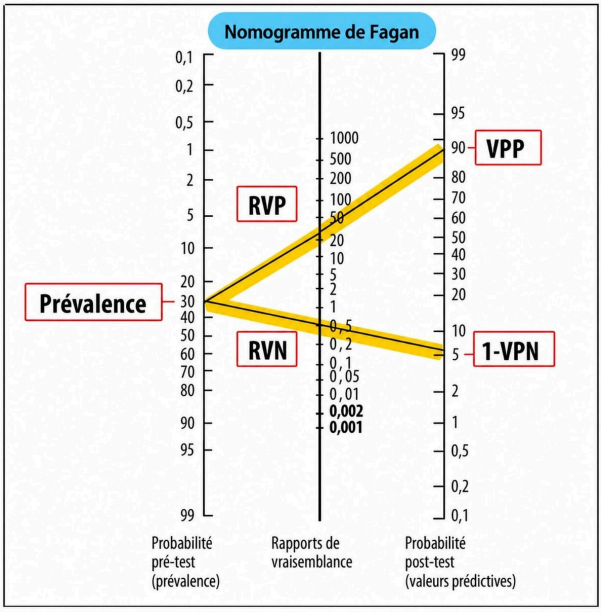


image.png

Se/Sp (paramètres intrinsèques, ou capacités informatives ou qualités informationnelles intrinsèques)

Sensibilité (Se)

Définition :
Probabilité d'avoir un test positif (T+) si on est malade (M+)
Estimée par la proportion de VP parmi les sujets atteints de la maladie (VP + FN)

Calcul :
P(T+/M+) = VP / (VP + FN)

Remarque :
VP + FN correspond au nombre total de sujet malade

Spécificité (Sp)

Définition :
Probabilité d'avoir un test négatif chez les non malades
Estimée par la proportion de VN parmi les sujets indemnes de la maladie (VN + FP)

Calcul :
P(T-/M-) = VN / (VN + FP)

Remarque :
VN + FP correspond au nombre total de sujets qui ne sont pas malades
Indice de Youden — Définition : Permet un aperçu global simultané de la Se et Sp ; Calcul : Y = Se + Sp - 1 ; Remarque : Un indice de Youden maximal correspond au meilleur compromis global entre Se et Sp ⭐

Souvent lorsque la sensibilité d'un test donné augmente, la spécificité diminue, et vice-versa (il s'agit d'une question de seuil pour lequel on définit la positivité du test)

RVP/RVN (paramètres intrinsèques, ou qualités informationnelles intrinsèques)

Schéma

RV− *(utile pour éliminer)*

Valeur neutre

RV+ *(utile pour affirmer)*

Valeur

< 0,1

0,1 − 0,2

> 0,2

1

< 5

5 − 10

> 10

Interprétation

Excellente performance pour éliminer une maladie

Performances modérées

Performances médiocres

Aucun intérêt

Performances médiocres

Performances modérées

Excellente performance pour affirmer une maladie

Il s'agit d'un autre mode d'expression des performances intrinsèques du test (indépendant de la prévalence)

Définition

Rapport de vraissemblance positif (RV+ ou RVP) :
Rapport entre les probabilités d'avoir :

- Test **positif** chez les **malades** d'une part
- Test positif chez les **non-malades** d'autre part

Rapport de vraissemblance négatif (RV- ou RVN) :
Rapport entre les probabilités d'avoir :

- Test **négatif** chez les **malades** d'une part
- Test négatif chez les **non-malades** d'autre part

Calcul — Rapport de vraissemblance positif (RV+ ou RVP) : P(T+/M+) / P(T+/M-) = Se / (1 - Sp) ;
Rapport de vraissemblance négatif (RV- ou RVN) : P(T-/M+) / P(T-/M-) = (1 - Se) / Sp

Valeurs possibles — Rapport de vraissemblance positif (RV+ ou RVP) : Varient entre 1 et l'infini ;
Rapport de vraissemblance négatif (RV- ou RVN) : Varient entre 0 et 1

Interprétation — Rapport de vraissemblance positif (RV+ ou RVP) : Sujet a RVP fois plus de risque d'avoir un test positif s'il est malade que s'il ne l'est pas ; Rapport de vraissemblance négatif (RV- ou RVN) : Sujet a RVN fois plus de risque d'avoir un test négatif s'il est malade que s'il ne l'est pas

Utilité

Rapport de vraissemblance positif (RV+ ou RVP) :
Plus le **RVP** est **élevé**, plus on aura confiance dans le résultat d'un test positif pour **confirmer** le diagnostic

- Important (bon) : si RVP **≥ 10**
- Modéré (moyen) : si RVP 5-10
- Faible (mauvais) : si RVP 1-5
- Aucun : si **RVP = 1**

Rapport de vraissemblance négatif (RV- ou RVN) :
Plus le **RVN** est **faible**, plus on aura confiance dans le résultat d'un test négatif pour **éliminer** le diagnostic

- Important (bon) : si RVN **≤ 0,1**
- Modéré (moyen) : si RVN 0,1-0,2
- Faible (mauvais) : si RVN 0,2-1
- Aucun : si **RVN = 1**

VVP/VPN (paramètres extrinsèques, ou capacités informatives ou qualités informationnelles intrinsèques)

Valeur prédictive positive (VPP) — Définition : Probabilité conditionnelle d'être malade (M+) si on a un test positif (T+) ; Calcul : P(M+/T+) = VP / (VP + FP) ; Remarque : VP + FP correspond au nombre total de sujets ayant un test positif

Valeur prédictive négative (VPN) — Définition : Probabilité conditionnelle de ne pas être malade (M-) si on a un test négatif (T-) ; Calcul : P(M-/T-) = VN / (VN + FN) ; Remarque : VN + FN correspond au nombre total de sujets ayant un test négatif

> **VPP/VPN dépend de la Se, Sp et de la prévalence de la maladie :**

Si maladie fréquente. VPP élevée, VPN faible (probabilité que le patient soit malade sera élevée, quel que soit le résultat du test)
Si malade rare. VPP faible, VPN élevée

Si test sensible
Meilleure VPN (résultat négatif conforme l'absence de maladie)

- car sensibilité élevée alors peu de FN donc VPN plus haute car = VN / (VN + FN)

Si test spécifique
Meilleure VPP (résultat positif conforte le diagnostic suspecté)

- car spécificité élevée alors peu de FP donc VPP plus haute car = VP / (VP + FP)

Formules et paramètres

4 formules incontournables

- **VPP = k × PRÉVALENCE × RVP** (avec k un coefficient fixe)
- **1 − VPN = PRÉVALENCE × RVN**
- **VPP = sensibilité × (prévalence avec le test de référence / prévalence avec le test étudié)**
- **VPN = spécificité × (1 − prévalence avec le test de référence / 1 − prévalence avec le test étudié)**
- Deux paramètres pour les caractéristiques extrinsèques (**VPP-VPN**) :
  - **prévalence de la maladie**
    - si prévalence (p) augmente → alors **VPP** augmente et **VPN** diminue (astuce mémoire = « si p augmente alors VPP augmente car les p vont au p »)
    - si prévalence (p) diminue → alors **VPP** diminue et **VPN** augmente
      - → VPP et VPN ne peuvent donc pas être correctement estimées si la prévalence de la maladie dans l'échantillon d'étude est différente de la prévalence réelle en population générale !
    - **représentativité de l'échantillon** : conséquence directe de ce qui précède

---

Postulats de Galen et Gambino, pour le choix pratique des tests diagnostiques

Test sensible

Situations où il faut préférer ce type de test :

- Maladie grave
- Maladie traitable
- Résultats FP n'entraînent pas de traumatisme psychologique ou économique chez le patient

Exemple :
Phéochromocytome (fatal si ignoré, contrôlable à 100% si diagnostiqué)

Test spécifique

Situations où il faut préférer ce type de test :

- Maladie sérieuse mais difficilement guérissable/curable
- Fait de savoir que l'on n'a pas la maladie présente une importante sanitaire et psychologique
- Résultats FP peuvent être psychologiquement et économiquement traumatisants

Exemple :
SEP, cancer au stade infraclinique
Test à VPP élevée — Situations où il faut préférer ce type de test : Si le traitement des sujets FP peut avoir des conséquences graves ; Exemple : Radiothérapie/Lobectomie chirurgicale pour FP CBNPC

Test à valeur globale élevée

Situations où il faut préférer ce type de test :

- Maladie sérieuse mais possiblement traitable efficacement

- Résultats FP et FN sont tous 2 traumatisants et entraînent des conséquences graves

Exemple :
IDM possibilement fatal si non traitée mais traumatisant si FP

Analyse d'un test diagnostique qualitatif (binaire)

> *Ici, la mesure de la fiabilité repose sur la reproductibilité des tests :*

Reproductibilité intra-observateur

Variabilité de mesure d'un test chez un même observateur peut avoir 2 explications :

Variabilité analytique

Variabilité liée à la technique de mesure

(ex. variabilité du dosage de la troponine dans un échantillon de sang d'une mesure à l'autre)

Variabilité d'interprétation

Variabilité liée à la lecture du test

(ex. relecture d'un coroscanner par le même cardiologue quelques semaines plus tard, pourra conduire à une interprétation différente)

Il existe 3 techniques pour mesurer la reproductibilité intra-observateur :

Coefficient de variation (CV) intra-observateur. On parle alors de CV analytique lorsqu'on mesure uniquement la variabilité analytique

Coefficient de concordance (KAPPA k)

Mesuré **en cas d'étude d'une variable qualitative**, il s'agit de la mesure de la concordance intra-observateur en excès par rapport à la concordance attendue par le hasard, avec reproductibilité qui est d'autant meilleure que k tend vers 1 :

- Excellente si k = 0,81 - 1
- Bonne/Correct si k = 0,61 - 0,80
- Moyenne si k = 0,41 - 0,60
- Faible si k = 0,40 - 0,21
- Mauvaise si k = 0 - 0,20

Coefficient de corrélation intraclasse (ICC)

Mesuré **en cas d'étude d'une variable quantitative**, il est compris entre :

- ICC à 0 (concordance liée uniquement au hasard)
- ICC à **1** (concordance parfaite)

Reproductibilité inter-observateur

Comment la mesurer ? Mesurée en comparant des mesures réalisées par des évaluateurs différents

Techniques de mesure

- Mesure du CV (coefficient de variation) inter-observateur (qui est **toujours plus élevé que le CV intra-observateur** PMZ)
- Mesure du coefficient de concordance kappa k (aussi appelé *Cohen's Kappa*) qui mesure la concordance inter-observateur en excès par rapport à la concordance attendue par le hasard *(selon Descart : le coefficient kappa va de **-1** (les 2 opérateurs sont en désaccord total) à **1** (les opérateurs sont en accord total)*

Calcul du coefficient Kappa nécessite d'évaluer la concordance inter-opérateur

Test par opérateur 2 positif — Test par opérateur 1 positif : C1 ; Test par opérateur 1 négatif : NC2

Test par opérateur 2 négatif — Test par opérateur 1 positif : NC1 ; Test par opérateur 1 négatif : C2

> ***C1 + C2** = Nombre de tests concordants ; **NC1 + NC2** = nombre de tests non concordants*

Analyse d'un test diagnostique quantitatif

Conditions d'utilisation

Courbe ROC

Courbe ROC ne peut être utilisée que dans les études diagnostiques de performance (pour l'ECN)

- Uniquement lorsque le test diagnostique étudiée est une variable quantitative ⭐ (ex. plupart des dosages biologiques)
- Attention au piège : le test de référence (gold standard) n'est soumis à aucune condition particulière (pas forcément quantitatif)

Corrélation linéaire de Pearson. Pour l'utiliser, il faut nécessairement que la mesure du nouveau test diagnostique étudié et celle du test de référence gold standard soient toutes les 2 des variables quantitatives *(à la différence de la courbe ROC où seul le nouveau test doit être quantitatif)*

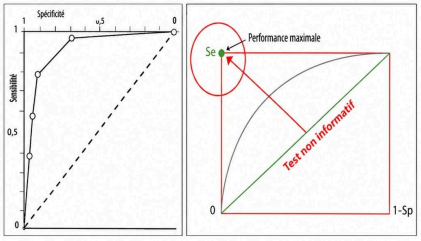
Diagramme de Bland et Altman

Pour l'utiliser, il faut nécessairement que la mesure du nouveau test diagnostique étudié et celle du test de référence gold standard soient toutes les 2 des variables quantitatives avec nécessairement la même unité

(à la différence de la courbe ROC où seul le nouveau test doit être quantitatif)

Courbe ROC *(Receiver Operating Characteristic)*

Schémas ++



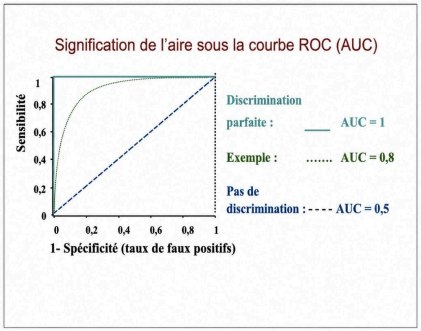


image.png

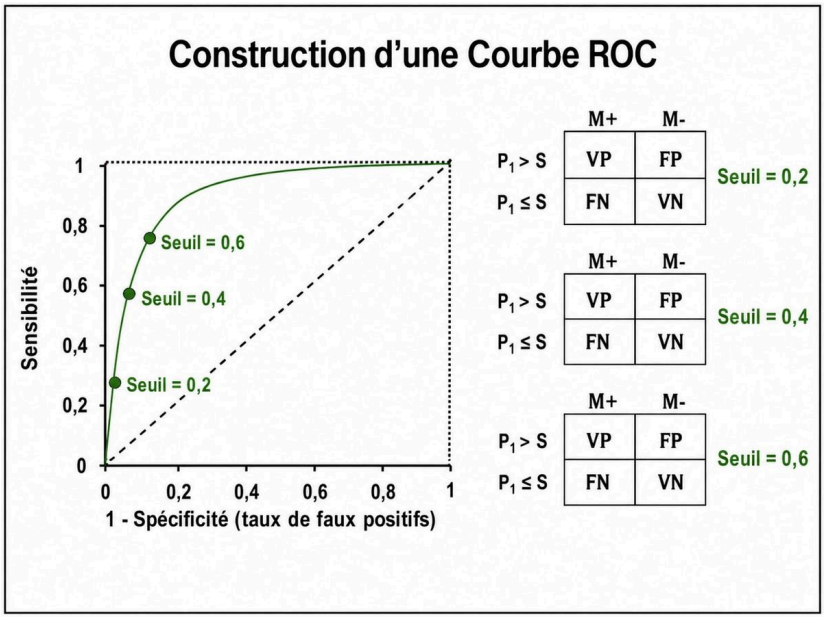


image.png

Construction d'une courbe ROC / Seuil de normalité S (ou ligne de partage)

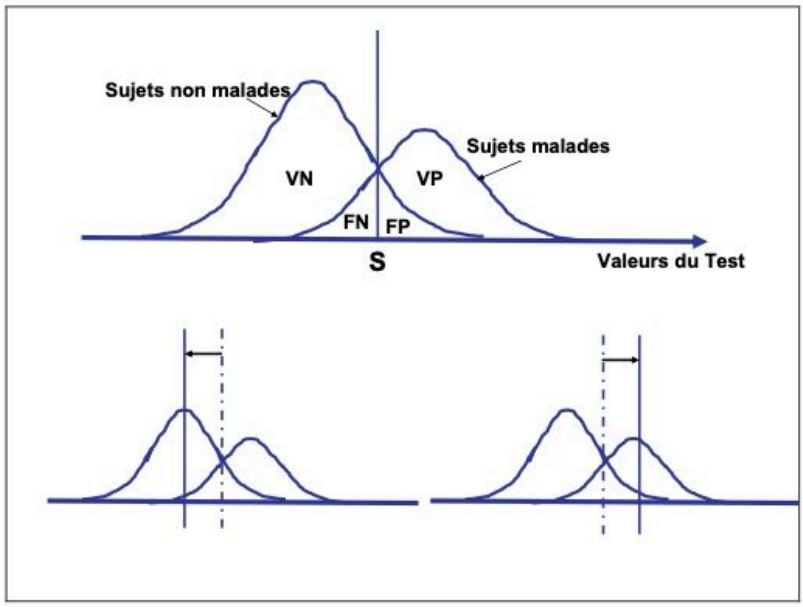
Utilité. Courbes ROC permettent d'étudier les vairations de la spécificité et de la sansibiltié d'un test pour les différentes valeurs du seuil de discrimination entre tests positifs et tests négatifs (patients présents malades ou présents non malades)

Construction. Courbe ROC se construit de façon empirique en calculant la sensibilité puis la spécificté d'un test pour les différents niveaux d'un seuil de discrimination

Seuil de normalité S

Fixation d'un seuil de normalité S (ou ligne de partage) définit la répartition des vrais positifs, vrais négatifs, faux positifs et faux négatifs

- déplacement de la ligne de partage du test modifie les proportions de VP, VN, FP, FN



Untitled

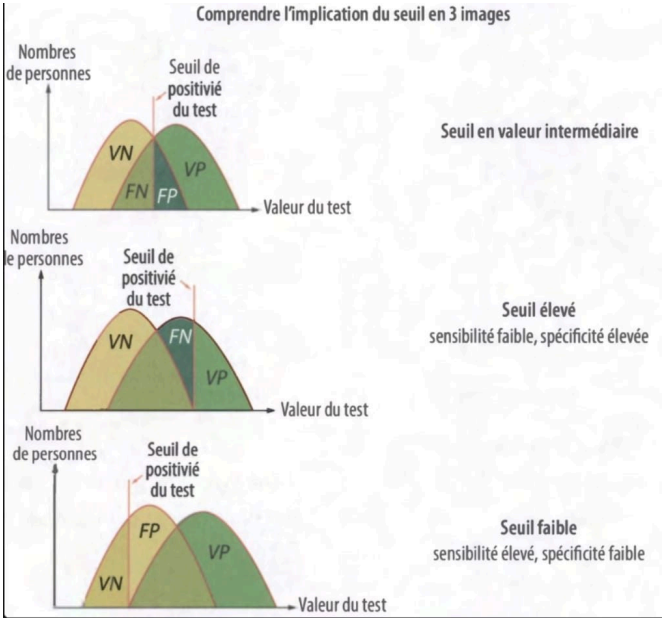


image.png

Cas particulier : courbe ROC évaluant l'intérêt d'une variable par rapport à un modèle multivarié de base

Cas particulier : Courbe ROC évaluant l'intérêt d'une variable par rapport à un modèle multivarié de base

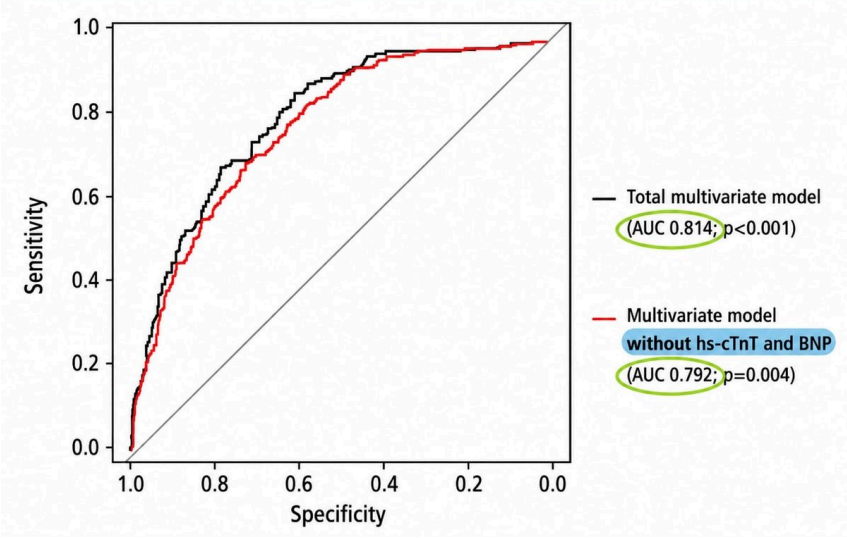


image.png

- En effet, la question posée ici (plus rarement rencontrée dans les dossiers SIDES) permet d'évaluer, non pas la performance diagnostique du test, mais **à quel point le nouveau test diagnostique étudié**, ajouté aux facteurs de risque étudiés déjà connus, permet d'améliorer la prédiction du modèle de survenue de l'événement étudié (la maladie) (**FdR**). C'est prédire la maladie.
- Ainsi le principe est de construire un **premier modèle multivarié** incluant l'ensemble des **paramètres traditionnellement utilisés pour prédire la survenue de l'événement étudié** (courbe noire sur la figure ci-dessus, courbe rouge) (*dans cet exemple, les facteurs de risque connus du modèle sont les facteurs de risque cardiovasculaire : âge, sexe, tabac, diabète, hypertension, dyslipidémie, et hérédité cardiovasculaire ; l'évènement étudié est la survenue d'évènements cardiovasculaires*).
- Puis de rajouter à un des tests diagnostiques étudiés (*dans cet exemple : la troponine et le BNP courbe noire*).
- Il existe une **incrémentation = « amélioration » de la prédiction du modèle à l'aide du test ajouté** (**FdR**).
- En QCM, on est donc demandé de comparer les aires sous la courbe de cette courbe et d'observer à quel point, l'adjonction du nouveau test permet l'incrémentation de la prédiction de risque de l'évènement étudié.

Courbe ROC (Receiver Operating Characteristic)

Contexte

Figure classique utilisée dans les études diagnostiques de performance afin d'établir :

- Performance diagnostique globale du test (Aire sous la courbe, AUC = *area under the curve*)
- Seuil optimal diagnostique pour un test quantitatif

Type d'étude

(condition)

Courbe ROC ne peut être utilisée que dans les études diagnostiques de performance (pour l'ECN)

- Uniquement lorsque le test diagnostique étudiée est une variable quantitative ⭐ (ex. plupart des dosages biologiques)
  - Attention au piège : le test de référence (gold standard) n'est soumis à aucune condition particulière (pas forcément quantitatif)

Ordonnée

Abscisse

- Ordonnée : sensibilité
- Abscisse : taux de FP (1 - spécificité)

Interprétation

- Plus la courbe s'étire vers le haut à gauche, plus elle a tendance à passer par un point d'abscisse 0 et d'ordonnée 1, ce qui signifie qu'il existe un seuil du test pour lequel la sensibilité et la spécificité se rapprochent de 100%
- Inversement, si la courbe se rapproche de la diagonale, cela signifie que pour un plus grand nombre de seuils possibles, la sensibilité est égale à (1 – spécificité), ce qui équivaut à un rapport de vraisemblance positif = 1, donc un test non discriminant, dont le gain par rapport à la probabilité pré-test est nulle
- Si ROC médiane ayant 0 pour origine = test sans intérêt
- Courbe superposable à la diagonale a une AUC de 0,5 avec un test qui ne fait pas mieux que le hasard !!

AUC

Calcul de l'aire sous la courbe (± comparaison statistique avec un autre test) permet de :

- Comparer 2 tests (le plus performant a une courbe ROC qui s'écarte le plus de la diagonale, avec l'AUC la plus grande)
- Évaluer la capacité discriminante globale du test (pour être valable AUC doit être ≥ 70-75%) :
  - Excellente : AUC entre 0,9 - 1
  - Bonne : 0,8 - 0,9
  - Moyenne : 0,7 - 0,8
  - Médiocre : AUC entre 0,5 - 0,7

« Seuil optimal »

Point d'inflexion de la courbe = choisir le plus près de l'angle supérieur gauche, et donc le plus éloigné de la diagonale

Valeur seuil pour laquelle sensibilité et spécificité sont optimales, selon le type de test :

- Dépistage = on veut **Se** ≈ 100% (avec la meilleure Sp possible)
  - Confirmation = on veut **Sp** ≈ 100% (avec la meilleur Se possible)
  - Indice de Youden maximal correspond au meilleur compromis global entre Se et Sp ⭐

2 Intérêts de l'étude

- Évaluer la performance diagnostique du nouveau test diagnostique, en comparant au test de référence → via AUC

- Rechercher le seuil optimal (déterminé en ROC) : ce seuil optimal sera celui à utiliser, lors de la prochaine étude correspond à une étude diagnostique à impact clinique (afin de valider l'utilité du test)

Corrélation linéaire de Pearson

Exemples / Schéma ++

> *Cas de corrélation linéaire de Pearson*

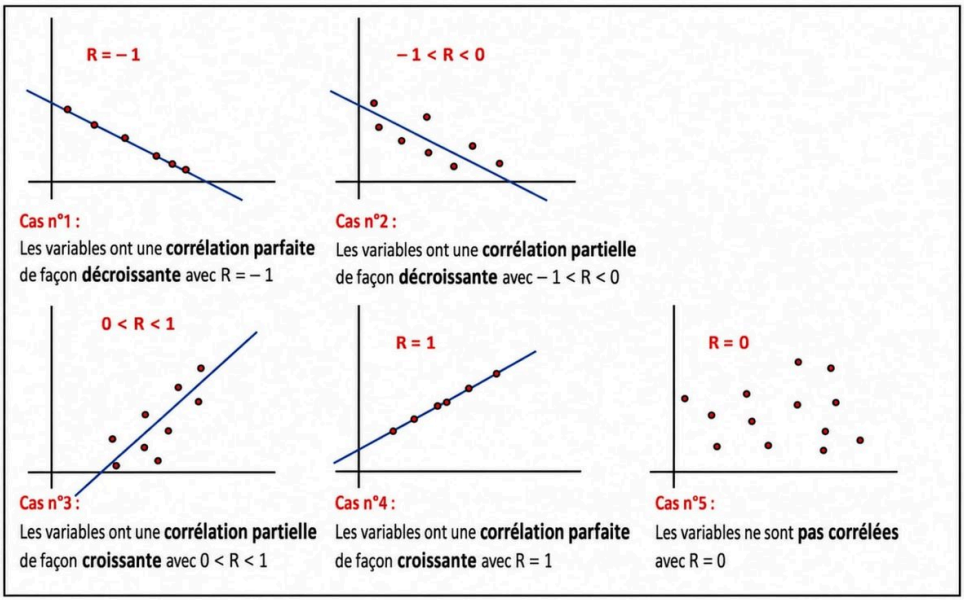


image.png

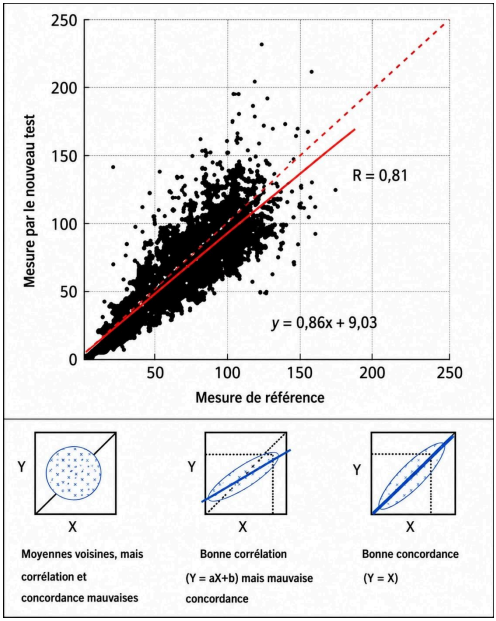


image.png

Conditions d'utilisation. Pour l'utiliser, il faut nécessairement que la mesure du nouveau test diagnostique étudié et celle du test de référence gold standard soient toutes les 2 des variables

quantitatives *(à la différence de la courbe ROC où seul le nouveau test doit être quantitatif)*

Objectifs

Attention, il faut distinguer 2 situations cliniques d'utilisation différente :

- Soit celle où l'on compare les 2 tests : « est-ce que le test à l'étude est aussi bon que le test de référence ? »
  - Évalue à quel point le nouveau test donne un résultat proche (corrélé) à celui du test de référence
  - Dogme : **étude ne pourra jamais conclure que le test étudié est meilleur que le test de référence** ++

(puisqu'on part du principe que le test de référence énonce la vérité quant au statut M+/M-)

- Soit celle où l'on compare 2 méthodes de mesure du nouveau test diagnostique étudié
  - Ex. classique : comparer 2 opérateurs différents évaluant la même chose, typiquement en échographie, on placera

les résultats obtenus par l'un des opérateurs en abscisse et ceux de l'autre opérateur en ordonnée

- Attention, dans ce cas il ne s'agit plus d'une évaluation de la performance diagnostique du nouveau test diagnostique

étudié mais d'une évaluation de sa reproductibilité inter-observateurs

Principe

Construction

1/ Chaque point correspond à un patient défini, aboutit à un nuage de points (ensemble des patients), avec :

- En ordonnée : mesure obtenue avec le nouveau test diagnostique
  - En abscisses : mesure obtenue avec le test de référence

2/ Ensuite un modèle mathématique permet de tracer une droite correspondant à la synthèse linéaire mathématique passant par ce nuage de points (sous la forme d'une équation de droite : $Y = Ax + B$)

Calcul du r

Coefficient de corrélation (r) est compris entre -1 et 1, il permet d'interpréter facilement la force de liaison entre 2 variables :

- Si R = 1 → corrélation parfaite entre les 2 tests dans le sens positif de l'association (corrélation positive)
- Si R = -1 → corrélation parfaite entre les 2 tests dans le sens contraire de l'association (corrélation négative)
- Après avoir calculé le coefficient de corrélation r entre 2 variables X et Y, un test de corrélation permettra d'évaluer cette force de liaison mesurée, permettant de juger si le résultat est bien significatif (estimer si il est suffisamment éloigné de 0)

En pratique on met au carré R^2 pour éliminer les signes (on obtient une valeur absolue qui **s'exprime en pourcentage**) :

- Si R > 0,6 soit > 60% = bon (performances du test étudié se rapprochent bien de celles du test de référence)

- Si R > 0,8 = excellent (performandes du test étudié sont très proches de celles du test de référence)
- Si R = 1 = identique (théorique : les performances du test étudié sont identiques à celles du test de référence)

Calcul du p

Significativité de la corrélation (p) : obtention d'un p est significatif si p < alpha

- degré de significativité est fourni par le test de corrélation

Diagramme de Bland et Altman

Schéma / Représentation ++

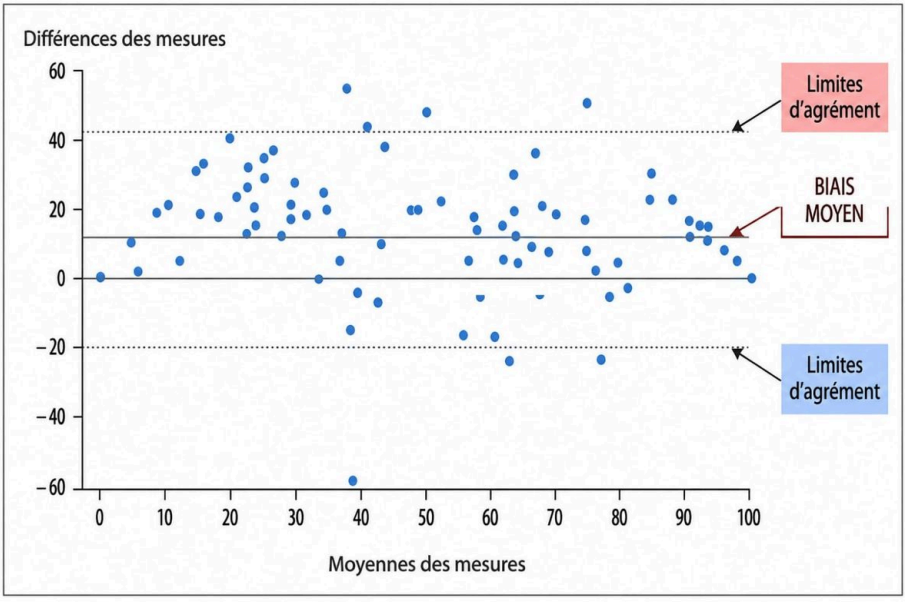


image.png

> *Distinguer 3 types de résultats typiques sur Diagramme de Blanc-Altman*

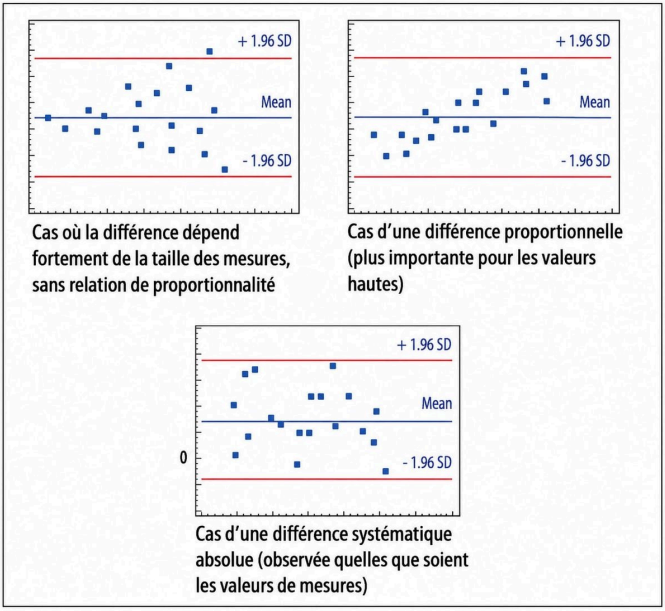


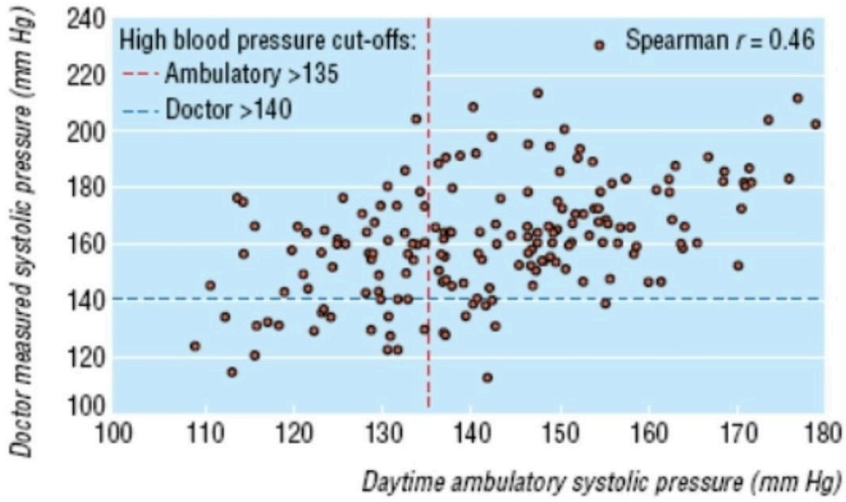
image.png

Exemples de Descartes

Ce graphe permet de visualiser :

- Un écart par rapport à 0, de la différence moyenne entre les 2 mesures (cet écart est de +18.9 dans l'exemple ci-dessous)
- Une corrélation entre la différence des deux mesures et leur moyenne (test r de Spearman dans l'exemple ci-dessous)

Exemple : Dans un échantillon de patients, on obtient pour chaque patient deux mesures de la pression arterielle obtenue l'une par un medecin avec un manometre a mercure (Yi), l'autre obtenue par les patients avec un appareil automatique d'auto-mesure (Xi)



(d'après Little et al. BMJ 2002 ; 325 :254)

image.png

Diagramme de Bland et Altman

Objectifs

- Évaluer la performance diagnostique globale du nouveau test étudié par rapport au test de référence
  - via le **biais moyen** et les **limites d'agrément**
- Évaluer la performance diagnostique segmentaire du nouveau test étudiée
  - se fait à vue d'oeil de la **répartition du nuage de points sur l'intervalle sélectionné**

Conditions d'utilisation

Pour l'utiliser, il faut nécessairement que la mesure du nouveau test diagnostique étudié et celle du test de référence gold standard soient toutes les 2 des variables quantitatives avec nécessairement la même unité

(à la différence de la courbe ROC où seul le nouveau test doit être quantitatif)

Construction

Chaque point correspond à un patient défini par :

- En abscisse : la moyenne obtenue entre la mesure réalisée avec le nouveau test et celle avec le test de référence
- En ordonnée : la différence des mesures réalisées (entre la mesure avec le nouveau test et celle avec le test de référence)

Biais moyen

Attention aux faux amis, il ne s'agit en aucun cas d'un biais en tant qu'erreur systématique

- Correspond à la différence moyenne chez tous les patients entres les mesures du nouveau test et du test de référence
- Interprétation : plus ce biais moyen tend vers 0, plus la performance diagnostique globale du nouveau test est grande

- cela traduit le fait que le nouveau test donne très souvent une valeur proche du test de référence

Limites d'agrément

- Définition : il s'agit de l'équivalent de l'intervalle de confiance du biais moyen
- Interprétation : plus les limites d'agrément sont resserrées autour du biais moyen, autrement dit, plus cet intervalle est étroit,

et plus la performance diagnostique globale du nouveau test est grande

- traduisant un peu de dispersion des différences de mesure autour de ce biais moyen

Performance diagnostique segmentaire

Évaluée sur l'axe des abscisses, en fonction de la mesure réalisée, interprétation en fonction de l'exemple du cours :

- Pour une valeur prise entre 0-40 (sur l'axe des abscisses) : la quasi-totalité des points se trouve au-dessus de l'axe 0
  - traduisant une tendance à la surestimation du nouveau test diagnostique par rapport au test de référence
- Pour une valeur prise entre 60-80 : majorité des points sont autour de l'axe 0
  - traduisant une performance diagnostique segmentaire, ici meilleure

En gros, la performance diagnostique segmentaire consiste à dire que le nouveau test diagnostique à une meilleure performance diagnostique pour certaines mesures (60 à 80, plutôt que 0 à 40)

Résultats - Discussion

Impact de la réalisation du test : va-t-elle modifier la prise en charge du patient ?

Dépend de 3 paramètres :

Rapport de vraisemblance

Entraîne une modification de la prise en charge si :

- Rapport suffisamment élevé (rapport de vraisemblance positif)
- Rapport suffisament bas (rappport de vraisemblance négatif)

Seuil diagnostique

Seuil au-délà duquel une **prise en charge** sera proposée

= seuil thérapeutique qui conditionne le besoin et l'importance d'un test

Seuil d'investigation. Seuil au-dessous duquel la pratique d'un test diagnostique n'apportera plus d'élément complémentaire, permettant ainsi d'**arrêter les investigations**

L'intérêt dépendra des critères suivants :

- **test** = reproductif – simple – fiable – acceptable
- **impact diagnostique** = paramètres de performance
- **impact thérapeutique** = modifie la prise en charge

- **impact de santé publique** = coût – résistances...

Recommandations pour rapporter un article diagnostique

> *Checklist STARD pour rapporter les résultats des études de performance diagnostique*

Titre - Résumé - Mots clés

TITRE/RESUME/ MOTS-CLEFS	1	Identifier l'article comme une étude sur la justesse d'une méthode diagnostique (recommander les mots clefs MeSH 'sensitivity et specificity')

Untitled

Introduction

INTRODUCTION	2	Qualifier les questions posées ou les buts de l'étude, telles que l'estimation de la justesse d'un test diagnostique ou la comparaison de la justesse diagnostique de deux (ou plusieurs) tests ou de plusieurs groupes de sujets

Untitled

Méthodes

METHODES		Décrire :
Participants	3	la population étudiée : les critères d'inclusion et de non-inclusion, la mise en œuvre, l'endroit où les données ont été collectées
	4	le recrutement des participants : était-il fondé sur des symptômes, des résultats de tests antérieurs ou sur le fait que le nouveau test ou le test de référence a été réalisé chez les participants ?
	5	l'échantillonnage des participants : s'agissait-il d'une série de cas consécutifs définie par des critères de sélection issus des items 3 et 4 ? Si non, spécifier la façon dont les patients ont été sélectionnés.
	6	la collecte des données : le recueil des données a-t-il été planifié avant que le nouveau test et le test de référence aient été réalisés (étude prospective) ou après (étude rétrospective) ?
Méthodes des tests	7	Le test de référence et son rationnel
	8	les spécifications techniques du matériel et des méthodes concernées, y compris comment et quand les mesures ont été réalisées et/ou citer les références utilisées pour le nouveau test et pour le test de référence
	9	la définition et le rationnel pour les unités, les seuils et/ou les catégories utilisées pour exprimer les résultats du nouveau test index et du test de référence
	10	le nombre, le degré d'entraînement et d'expertise des personnes (a) exécutant et (b) lisant les résultats du nouveau test et du test de référence
	11	oui ou non les évaluateurs du nouveau test, respectivement du test de référence, ont-ils réalisé en aveugle (masqués) la lecture de l'un, et de l'autre test ; ont-ils décrit toute autre information clinique dont ils disposaient
Méthodes statistiques	12	les méthodes de calcul ou de comparaisons des mesures de justesse diagnostique et les méthodes statistiques utilisées pour quantifier l'incertitude (par ex. intervalles de confiance à 95%)
	13	Méthodes de calcul de la reproductibilité du test, le cas échéant

Untitled

Résultats

RESULTATS		Notifier :
Participants	14	quand l'étude a été réalisée, incluant les dates de début et de fin du recrutement
	15	les caractéristiques cliniques et démographiques (par ex. âge, sexe, type de symptômes, comorbidité, traitement(s) actuel(s), centre(s) de recrutement)
	16	combien de participants satisfaisant les critères d'inclusion ont, ou n'ont pas eu le nouveau test et/ou le test de référence; décrire pourquoi les participants n'ont pas eu l'un ou l'autre test (un diagramme de flux est fortement recommandé)
Résultats du test	17	l'intervalle de temps entre la réalisation du nouveau test et celle du test de référence et l'administration éventuelle d'un traitement entre temps

Untitled

	18	la distribution de la sévérité de la maladie (définir les critères) chez ceux qui présentent l'affection étudiée ; décrire les autres diagnostics pour les participants ne présentant pas l'affection étudiée
	19	un tableau croisé des résultats du nouveau test (incluant les données manquantes ou indéterminées) selon les résultats du test de référence; pour les résultats de variables continues, décrire la distribution des résultats du nouveau test selon les résultats du test de référence
	20	les effets indésirables du nouveau test et du test de référence
Estimations	21	les estimations de la précision diagnostique et des mesures d'incertitude statistiques (i.e. intervalles de confiance 95%)
	22	comment ont été pris en compte les résultats imprécis, les réponses manquantes, et les "outliers" du nouveau test
	23	les estimations de la variabilité de la précision diagnostique entre sous-groupes de participants, évaluateurs ou centres, le cas échéant
	24	les estimations de la reproductibilité, le cas échéant

Untitled

Discussion

DISCUSSION	25	Discuter de l'applicabilité clinique des résultats de l'étude

Untitled

Partie 1 — Selon le type d'étude

Études pronostiques

Schéma : distinction facteur de risque/facteur pronostique

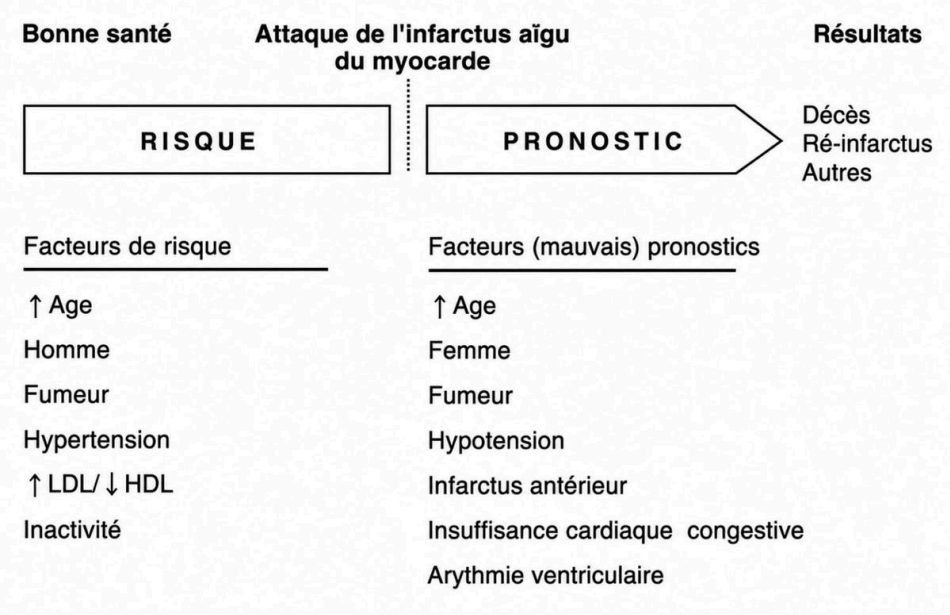


image.png

Population étudiée. Sujets malades (tous les patients d'une étude pronostique sont forcément malades ++)

Objectifs. Objectif est de montrer qu'un facteur donné prédit le devenir des patients, c'est-à-dire qu'il est associé à un **risque plus élevé de présenter le critère de jugement** (qui peut être "positif", comme la guérison, ou "négatif", comme le décès)

Objectifs (4)

- **Adapter** la décision thérapeutique/surveillance/information au patient
- Définir des groupes homogènes de pronostic pour les scores ou stadifications (utilisés dans des **études ultérieures**)
- Amélioration la planification des futures études cliniques
- Compréhension de l'**histoire naturelle** et de la **physiopathologie**

Mais contrairement aux études étiologiques, on ne cherche pas à montrer un lien causal ❌, le but est d'identifier des facteurs associés à un bon ou à un mauvais pronostic afin de pouvoir informer le patient et d'orienter la prise en charge en fonction de ce facteur

FP vs FR

- Facteur de risque : associé à la **survenue** d'une maladie et non à son evolution
- Facteur pronostique : associés (statistiquement) à l'**évolution** d'une maladie mais pas nécessairement de lien de causalité

Design idéal. Cohorte pronostique prospective[1,2] (observationnelle et explicative/comparative = analytique)

Réflèxes

- Suivi (durée et perdus de vue)
- Évaluation du critère de jugement
- Prise en compte des facteurs de confusion : analyse multivariée

Types d'étude utilisé ⭐

Cohorte pronostique prospective (observationnelle, analytique)
Il s'agit du design idéal +++
Il peut s'agir plus rarement d'une cohorte pronostique rétrospective

Cas-témoin (observationnelle)
Beaucoup plus rare, ici :

- Cas = patients atteints de la maladie et ayant présenté une complication
- Témoins = patients atteints de la même maladie mais sans complications

Essai contrôlé randomisé. **Rare**, car **habituellement impossible ou non éthique** de randomiser des patients selon les différents facteurs pronostiques

Biais dans les études pronostiques

Nom du biais

Biais de sélection — À quoi ça correspond ? : Sélection d'une population non représentative de la population d'intérêt ; Comment limiter le risque de biais ? : Sélection d'une population représentative de la population d'intérêt

Biais de classement — À quoi ça correspond ? : L'évaluateur peut être influencé s'il connaît le statut exposé non exposé du patient vis à vis du facteur pronostique ; Comment limiter le risque de biais ? : Évaluation du critère de jugement en aveugle du statut exposé ou non exposé

Biais de confusion — À quoi ça correspond ? : Liés à des facteurs de confusion dans la relation facteur pronostique-maladie ; Comment limiter le risque de biais ? : Analyse multivariée avec ajustement et éventuellement appariement sur les facteurs de confusion

Biais d'attrition

À quoi ça correspond ? :
Liés aux perdus de vue et à leur exclusion de l'analyse

Comment limiter le risque de biais ? :
Limiter au maximum les perdus de vue
Imputer les données manquantes

Méthodologies des cohortes pronostiques

Hormis quelques spécificités, la méthodologie est celle des études épidémiologiques analytiques de cohortes

Critères de jugement d'une cohorte pronostique - Choix des facteurs pronostiques

Objectif
(ex. décès ou la survie)

- Évaluation est incontestable et ne peut pas être sujet à des interprétations différentes selon la personne qui l'évalue
  - Dans ce cas, le risque de biais de classement est faible ✅

Subjectif

(ex. rechute tumorale ou la récidive d'événement cardiovasculaire)

Afin de limiter le biais de classement et limiter la variabilité liée à l'évaluation subjective :

- Mode d'évaluation doit être défini a priori et standardisé
- Évaluation du critère doit se faire en aveugle de l'exposition au facteur pronostique : en double (par 2 personnes de manière indépendante) voire centralisée avec un comité indépendant (appelé comité d'adjudication ou comité d'évènements cliniques)

Caractéristiques du (des) critère(s) de jugement de qualité :

- **pertinents – valides – objectifs – non biaisés**
- **définis** ***a priori***
- **mesurés de la même manière** dans tous les groupes par des évaluateurs formés
- **évaluation en aveugle** des caractéristiques initiales des patients
- ± recours à un **comité d'adjudication en aveugle**, si critère subjectif

On privilégie idéalement :

- les **facteurs pronostiques les plus pertinents**, car seul un nombre limité de facteurs pourra être testé (la règle des 10 % est souvent retenue en pratique en LCA avec, par exemple, pour étude avec 100 patients une limite d'étude de 10 facteurs pronostiques maximum)
- les facteurs pronostiques **déjà connus et validés dans la littérature** (permet d'éviter les facteurs de confusion potentiels)
- les facteurs pronostiques **facilement mesurables en routine** possédant un une « sens clinique » pour pouvoir appliquer les résultats de l'étude à la pratique courante

Inclusion et Recrutement des patients

Malades. Tous les patients d'une étude pronostique sont forcément **malades** ++

Biais à risque

- Biais lié à la surestimation ou sous-estimation du risque
- Biais de sélection lors du recrutement = **population hospitalière** (qui est généralement de moins bon pronostic)
  - justifie de privilégier un recrutement non spécialisé, hors CHU

Homogénéité pronostique

Modalités qui assurent l'homogénéité pronostique des groupes :

- Définition cohérente et précise des stades de la maladie
- Tous les patients doivent être inclus au même **stade** d'évolution de la maladie
  - on parle de cohorte incidente *(en anglais : incipient cohort)*

Ne pas faire. Cohorte ne doit pas être définie rétrospectivement à partir du suivi d'une autre cohorte utilisée pour une autre étude car risque de biais de sélection majeur

Suivi d'une cohorte pronostique

Suivi de qualité

- Suffisamment long afin de **tenir compte de l'évolution naturelle** (temps de latence) de la maladie et ainsi **détecter les événements**
  - *facteur préditif de la survie à 1 an n'est pas forcément prédictif de la survie à 3 ans*
- Complet, Correct, Homogène pour tous les patients

Biais à risque

Biais des perdus du vue (biais d'attrition) :

- Si nombre de perdus de vue **> 10-15%**
- Il est **encore plus important que pour les cohortes épidémiologiques classiques** +++ (car pdv ont un pronostic différent)
- Influence de la proportion de pdv sur la validité de l'étude dépend de la fréquence de survenue de l'événement étudié

(**très préjudiciable si l'événement ne survient que chez peu de patient**)

Analyse des données d'une cohorte pronostique

Si variables qualitatives. Mesures d'associations (RR ou OR)

Si variables censurées

- Décrire la survie → courbe de Kaplan-Meier
- Comparer 2 courbes de survie → test du Logrank
- Analyse multivariée → modèle de Cox

Notion de « score pronostique » et de « cohorte de validation »

Validation interne d'un score pronostique

Score pronostique ne pourra être validé (validation **interne**) que si ses performances dans le classement des patients ont été vérifiées sur un autre échantillon, on peut ainsi décider a priori que :

- Moitié de l'échantillon (définie par tirage au sort) sera l'échantillon-test (training set) qui sert à construire le score
- Autre moitié sera l'échantillon de validation (validation set)

Cohorte de validation

(validation externe d'un score pronostique)

Utilisée pour valider la fiabilité d'un score pronostique déjà décrit dans une 1ère cohorte pronostique (≠ *échantillon de validation*), il s'agit donc toujours d'une 2nd cohorte (si la validation du score pronostique se faire sur un échantillon **totalement indépendant du 1er**, alors cela augmente la validité **externe**)

Étapes de la validation :

- Vérifier la force d'association (OR, HR …)
- Mesurer la discrimination = capacité du modèle à **distinguer les malades qui feront ou ne feront pas l'événement** (ex. via l'aire sous la courbe ROX si le devenir est oui/non)
- Mesurer la calibration = capacité du modèle à **prédire correctement les probabilités d'événement**

(elle s'effectue via la confrontation des probabilités observées aux probabilités prédites)

Modèles d'analyse multivariée utilisés en fonction de l'événement étudié en étude pronostique

Modèles d'analyse multivariée utilisés

Si l'événement attendu est précoce (ex. mortalité à 1 mois)

Ici, pas de prise en compte du facteur temps

- Modèle de régression logistique

Si l'événement attendu est tardif (ex. survie à 5 ans)

Ici, prise en compte du facteur temps

- Modèle de Cox (rôle du facteur pronostique d'intérêt, indépendamment des facteurs de confusion, sera évalué par le Hazard Ratio ajusté sur les facteurs de confusion, qui s'interprète comme un risque relatif)

Revue systématique et Méta-analyse

Revue systématique de la littérature

Toute méta-analyse doit être précédée d'une revue systématique afin d'identifier l'ensemble des études réalisées (publiées et non publiées)

Revue systématique comportement notamment les étapes suivantes :

1. Recherche des études publiées : via la consultation de plusieurs bases de données électroniques
2. Recherche des études non publiées (littérature grise) :
   - Via registres d'essais, actes des principaux congrès du domaine, requête auprès des industriels et des experts du domaine
   - Important pour **limiter le biais de publications**
3. Sélection des études :
   - Études identifiées seront ensuite **sélectionnées par 2 personnes de manière indépendante** ✅
   - À l'aide de critères de sélection préalablement établis
4. Évaluation du risque de biais des études sélectionnées : doit être systématiquement **réalisée par 2 évaluateurs indépendants** ✅

Méta-analyse

Il s'agit de produire une synthèse quantitative de l'effet du traitement combinant les résultats des essais sélectionnés et de qualité méthodologique satisfaisante, cette synthèse est une moyenne pondérée en fonction de la précision de l'effet traitement dans chaque essai

- résultat d'une méta-analyse fréquemment représenté par un graphique appelé forest-plot

Intérêts d'une

méta-analyse

- Améliorer la précision de l'estimation de l'effet du traitement
- Augmenter la puissance statistique pour mettre en évidence une différence statistiquement significative
- Accroître la représentativité des patients car les essais ont inclus des populations différentes
- Apporter une réponse quand les résultats des essais sont discordants et d'explorer les causes de ces discordances

(par l'exploration de l'hétérogénéité entre les essais)

- Aider à la planification des futurs essais

Généralités

Définitions : Revue systématique vs Méta-analyse

- **Définition : REVUE SYSTÉMATIQUE**

La revue systématique avec ou sans méta-analyse est une **forme d'étude qui apporte des données exhaustives et synthétisées des informations disponibles pour une question donnée**.

Jusqu'à là, la grande majorité des revues systématiques faisait la synthèse d'essais contrôlés randomisés, mais actuellement les revues systématiques d'études observationnelles et d'études diagnostiques se développent.

- **Définition : MÉTA-ANALYSE**

Cette synthèse issue de la revue systématique des données pourra s'accompagner d'une méta-analyse consistant en une **agrégation des données numériques des études incluses dans la revue systématique**.

Les revues systématiques, particulièrement lorsqu'elles contiennent une méta-analyse, sont considérées comme le **type d'étude apportant le plus haut niveau de preuve** (niveau de preuve 1).

Quelles sont les étapes nécessaires à la réalisation d'une revue systématique ? → grille PRISMA

- Critères méthodologiques d'une revue systématique :
  - **méthodologie rigoureuse** (comme un essai contrôlé randomisé), **contrairement à une revue générale dite narrative** (pas de rigueur particulière)
  - **rédaction d'un protocole *a priori***

Une grille d'extraction est réalisée afin d'extraire de manière systématique et homogène toutes les informations nécessaires pour chacune des études.

- Quel est le nom de la grille décrivant les items devant être rapportés lors de la rédaction d'une revue systématique ?

Grille PRISMA

- 5 étapes de la réalisation d'une revue systématique :
  - **recherche** sur les bases de données et autres sources
  - **sélection** sur titre puis sur résumé et enfin sur texte intégral
  - **extraction** des données pour chaque étude
  - **évaluation** des biais
  - **synthèse** sous forme de méta-analyse si possible ou à défaut descriptive

Informations à récupérer dans chaque partie de chaque étude lors d'une revue systématique :

Partie. Informations à récupérer

Introduction. ContexteQuestion posée par l'étude (PICOS)

Matériel et méthode(protocole de l'étude à récupérer)

Critères d'éligibilité des études

Sources utilisées pour retrouver les études et la date de la dernière consultation
Stratégies de recherche
Procédure de sélection des études, d'extraction des données et d'évaluation du risque de biais
Méthodes statistiques utilisées
Choix de la forme sous laquelle les données seront synthétisées

Résultats
Diagramme de flux avec les raisons d'exclusions
Caractéristiques des études
Évaluation du risque de biais
Résultats pour chaque étude et des méta-analyses
Discussion. Résumé des principaux résultatsLimites sur la réalisation de la revueNiveau de preuve des résultats principauxImplications pour les futures recherches.

Étapes clés d'une revue systématique suivie d'une méta-analyse

Évaluation de la qualité de chaque étude

Permet d'examiner les jugements des deux auteurs en aveugle sur chaque élément de risque de biais présenté sous forme de pourcentages dans toutes les études incluses.

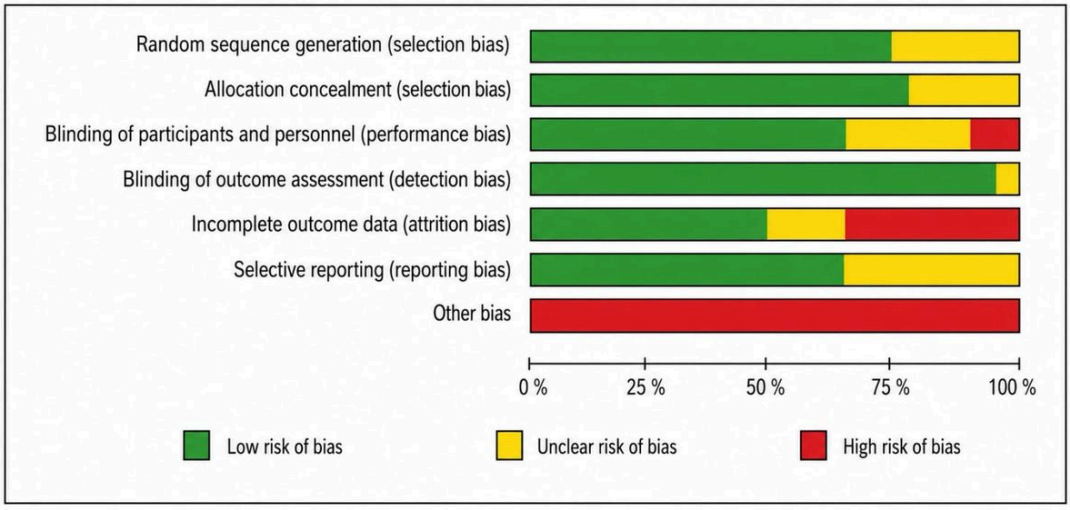


image.png

1°) **Formuler un objectif clair** pour la Méta-analyse (« PICO »)

2°) **Rechercher de façon structurée toutes les études** :

- Élaborer une **stratégie de recherche bibliographique claire** (permettant à n'importe quel lecteur de retrouver la méthodologie de recherche)
- **Préciser la méthode pour rechercher les études non publiées**, si c'est le cas, permettant de **limiter le risque de biais de publication**

3°) **Sélectionner les études qui sont à intégrer dans la revue systématique** :

- **Sélection réalisée par deux observateurs en aveugle qui doivent retrouver les mêmes études (PCZ)** → limiter le problème de reproductibilité *(3ème en divergence)*

- Selon les critères d'éligibilité précis qui répondent au « PICO » de l'objectif principal de la revue systématique

4°) **Évaluation de la qualité de chaque étude**

- **Recherche de la présence de biais à risque pour chacune des études** : biais de sélection, de classement et de confusion
- Une **grille** permet de référencer les biais de chaque étude à l'aide d'une échelle de couleurs (**Figures 1 et 2**)

5°) **Extraction des données** à l'aide d'une **grille de recueil standardisée**

6°) **Analyse statistique**

- **Évaluation de l'hétérogénéité de la revue systématique** permettant ou non de réaliser la méta-analyse (**PCZ**).

Détail des 3 étapes-clés du Funda's statistique de la méta-analyse :

- Détail des 3 étapes clés de l'analyse statistique de la méta-analyse :
- Choisir la mesure commune de l'effet de l'intervention : risque relatif (RR) ou odds ratio (OR)
- Puis utiliser cette expression commune (RR ou OR) pour recalculer le résultat dans chaque étude indépendamment
- Puis calculer une estimation combinée de l'effet de la nouvelle intervention dans toutes les études
- Cette estimation combinée correspond à la moyenne pondérée en fonction de l'inverse de la variance.
- Détail des 3 étapes clés de l'analyse statistique de la méta-analyse :

Il existe sur l'analyse statistique spécifique des méta-analyses 2 modèles possibles d'agrégation des données du modèle

- Modèle à effet fixe : on considère alors que l'effet de l'intervention est le même dans toutes les études et que les différences mesurées sont simplement liées aux fluctuations d'échantillonnage
- Modèle à effet aléatoire : il prend en compte l'existence d'une variabilité de l'effet de l'intervention entre les études

7°) Interprétation des résultats

- Analyse du résultat de l'estimation combinée (RR ou OR) permettant de conclure sur le résultat principal
- Mesure de l'hétérogénéité qui doit être interprétée dans la partie « Discussion » en évoquant les causes possibles de l'hétérogénéité (clinique, méthodologique et statistique) +++ (PCZ).

8°) Rapporter l'ensemble de ces étapes de la méta-analyse dans une check-list **PRISMA**

Obligatoire lors de la soumission de l'article.

Grille d'analyse d'une méta-analyse → grille AMSTAR

GRILLE AMSTAR (recommandation HAS 2014)

Question. Détails

1. A-t-on fourni un protocole a priori du travail ? La question de recherche et les critères d'inclusion doivent être établis avant la conduite de l'examen systématique. Existe-t-il un protocole publié de l'étude, l'approbation par un comité d'éthique ou des objectifs préétablis pour l'étude ?

2. La sélection des études et l'extraction des données ont-elles été faites en double ? Il doit y avoir au moins deux extracteurs de données indépendants et un mécanisme pour arriver à un consensus en cas de divergences.

3. A-t-on effectué une recherche complète documentaire ? La recherche doit porter sur **au moins deux sources électroniques**. Le rapport doit inclure les années et les bases de données utilisées (ex. : Central, EMBASE, MedLine). Les auteurs doivent indiquer les mots-clés et/ou les termes MeSH utilisés, pour la recherche et au mieux la stratégie de recherche. Toutes les recherches devront être complétées par une consultation de revues, de manuels, de registres spécialisés ou de spécialistes du domaine et par la consultation des contenus des études repérées.

4. Est-ce que la nature d'une publication (ex. : littérature « grise ») a servi de critère d'inclusion ? Les auteurs doivent déclarer avoir recherché des rapports indépendamment de leur type de publication. Les auteurs doivent indiquer si **un rapport au type de publication, à la place de la publication, ou la langue, ont été exclus ou non**. Il doit y avoir une recherche explicite de la littérature « grise », comme par exemple la base SIGLE.

5. Les auteurs ont-ils fourni la liste des études incluses et des études exclues ? Une liste électronique des études incluses et des études exclues devrait être fournie. La liste des études incluses peut être disponible avec la description des études et la liste électronique des études exclues, à la demande, devrait être acceptable.

Question

1. Les auteurs ont-ils fourni une **description des caractéristiques des études incluses** ?
2. La qualité scientifique des études incluses a-t-elle été analysée et documentée ?
3. La **qualité des études incluses a-t-elle été prise en compte de façon appropriée dans la formulation des conclusions** ?
4. Les méthodes d'analyse des résultats étaient-elles appropriées ?
5. A-t-on analysé la **possibilité d'un biais de publication** ?
6. A-t-on déclaré les conflits d'intérêt ?

Détails

Présentées sous une forme condensée comme un tableau, les données de l'étude originale doivent inclure les participants, les interventions et les résultats. L'étude doit rendre compte des différentes caractéristiques de toutes les études analysées (ex. : âge, sexe, données socio-économiques pertinentes, état de la maladie, durée, sévérité ou autres maladies).

Les critères de choix *a priori* du type d'études incluses doivent être fournis (par exemple les essais contrôlés randomisés, les essais en double insu, les essais comparatifs avec placebo, d'autres types d'études…).

La qualité de chaque étude a-t-elle été analysée : score de Jadad, risque de biais…

Les résultats concernant la qualité scientifique des études incluses doivent être **pris en compte dans l'analyse et les conclusions de la revue**, et doivent être mentionnés explicitement dans la formulation des recommandations. Par exemple : « les résultats doivent être pris avec réserve en raison de la faible qualité des études prises en compte »

Lorsqu'on regroupe des résultats, on doit d'abord vérifier si les études sont combinables en appliquant un **test d'homogénéité** (par ex., le test I^2 qui détermine l'homogénéité des données). S'il existe de l'hétérogénéité, on devrait utiliser un modèle d'analyse des effets aléatoires et/ou considérer la pertinence de regrouper les résultats des études (est-il approprié de les regrouper ?). Les auteurs doivent expliquer la raison de leur mode de présentation des résultats.

L'analyse d'un biais de publication doit comprendre une **représentation graphique** (par ex., graphique en entonnoir ou autres tests disponibles) et/ou des **analyses statistiques** (par ex. : le test de régression de Egger).

Les sources potentielles de soutien doivent être clairement présentées, pour les auteurs de la revue systématique et pour chacune des études incluses dans la revue.

Grands types de méta-analyses

Méthodes suivantes ne peuvent pas être mélangées :

Méta-analyses à partir de données résumées de la littérature (90% des cas)

Définition. Méta-analyses qui proposent la synthèse de résultats uniquement à partir d'articles déjà publiés dans la littérature

Avantages

- Données facilement accessibles
- Bonne reproductibilité : permet d'évaluer la méthodologie de recherche bibliographique systématique

(permettant au lecteur de la réaliser éventuellement par lui-même)

Inconvénient. Soumis à la qualité du reporting des données

Méta-analyses à partir de données individuelles (10% des cas)

Définition

Méta-analyses réalisées directement à partir des bases de données individuelles complètes, de chacune des études

- Nécessite de contacter tous les auteurs des précédentes études, qui doivent accepter de communiquer l'ensemble de la base de données de leur centre pour permettre la méta-analyse
  - Il s'agit du gold standard de la méta-analyse, mais à condition d'avoir récupéré la totalité des bases de données de toutes les études

Avantages

- Résultats plus précis
- Permet de choisir parmi les critères de jugement mesurés
  - auteurs peuvent choisir de refaire entièrement les analyses à partir d'un ou plusieurs CDJ secondaires

- Permet de choisir des critères de sélection (PMZ)
- Permet de faire une analyse multivariée avec ajustement
- Permet de faire des courbes de survie de Kaplan-Meier (PMZ)

Inconvénients

- **Difficile à mettre en place** en pratique (auteurs partagent rarement leurs données)
- **Impossible d'évaluer la reproductibilité** de la méta-analyse : il n'y a plus du tout de méthodologie de recherche bibliographique systématique, réalisable par soi-même

Cas particulier : méta-analyses d'études observationnelles

Majorité des méta-analyses qui peuvent être proposés à l'ECN sont des études randomisées interventionnelles, mais bon … mdr

Principe. Synthèse mélangeant cas témoin, études de cohorte et/ou études transversales

2 biais majeurs

- Biais de publication majeur : encore plus important ici car le nombre d'études observationnelles non publiées est élevé
- Biais « SELECTIVE REPORTING OUTCOME » : seuls les facteurs d'exposition significatifs sont rapportés dans les études alors que dans ce type d'études observationnelles, de nombreux facteurs sont évoqués

Focus

Figures

Diagramme de flux spécifique des méta-analyses

Le **diagramme de flux** (figure ci-après) doit **préciser le nombre de références retrouvées initialement sur les différentes bases de données et décrire pour chaque étape de sélection les raisons d'exclusions**

L'extraction des données est réalisée sur une grille identique pour chacune des études. La grille la plus utilisée et reconnue aujourd'hui pour évaluer le risque de biais dans les études contrôlées randomisées est le **Risk of Bias Tool de la collaboration Cochrane** qui consiste à évaluer pour différents aspects méthodologiques le risque de biais est faible, élevé, ou non clair. Les différents points évalués sont la randomisation, l'aveugle, les pertes de vue, le caractère sélectif des jugements rapportés et les données manquantes ainsi que d'autres biais en fonction de l'intention de l'étude.

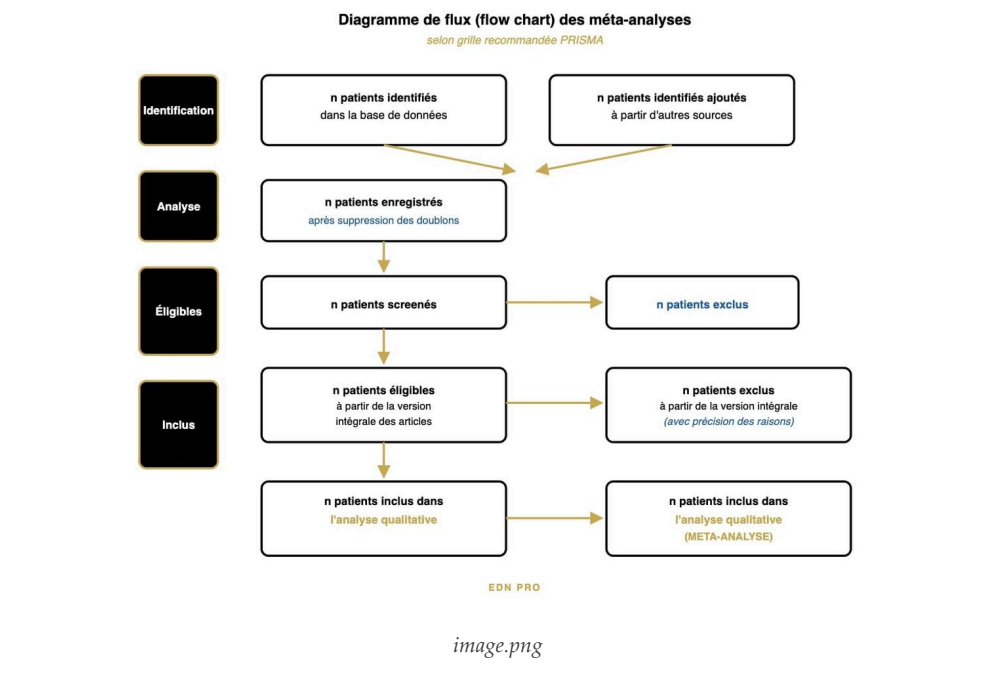


image.png

Diagramme de Forest spécifique des méta-analyses

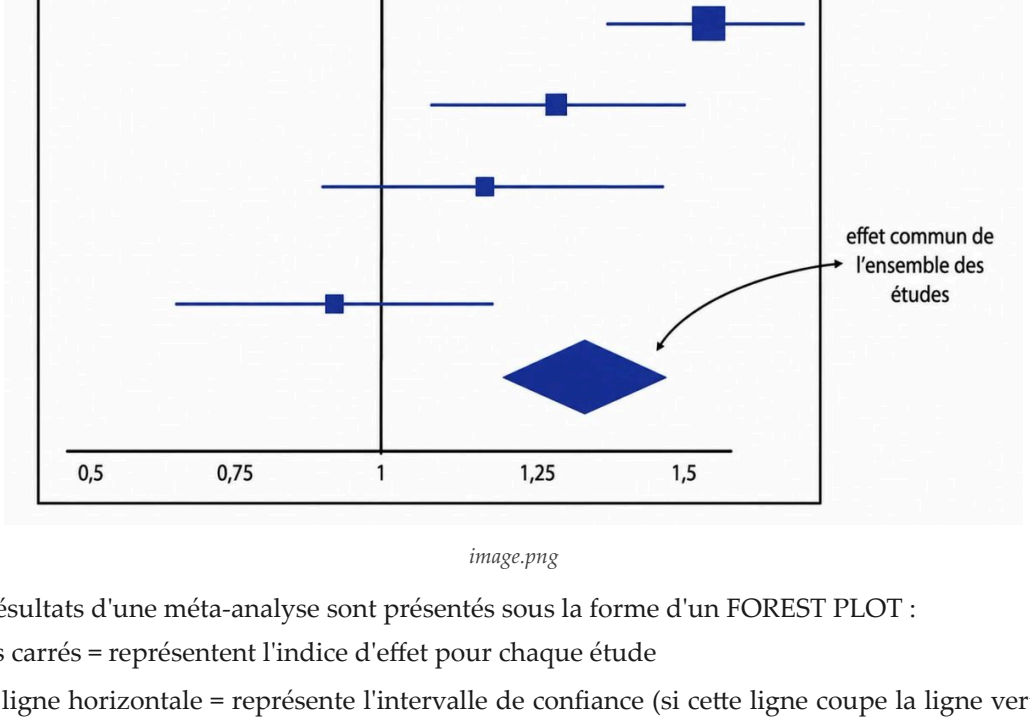


image.png

Les résultats d'une méta-analyse sont présentés sous la forme d'un FOREST PLOT :

- les carrés = représentent l'indice d'effet pour chaque étude
- la ligne horizontale = représente l'intervalle de confiance (si cette ligne coupe la ligne verticale centrale cela signifie que la différence n'est pas significative avec OR = 1)
- la taille des carrés = représente le poids de l'étude dans l'effet commun (la taille du carré est d'autant plus élevée que l'étude correspondante a été réalisée sur un nombre de patients inclus important et que son résultat est précis)

- losange = représente l'effet commun de l'ensemble des études obtenu en combinant par un calcul statistique les résultats de chaque étude, pondéré en fonction du nombre de patients inclus

Notions d'hétérogénéité d'une revue systématique ou d'une méta-analyse

Définitions - généralités

Définition. Hétérogénéité correspond à toutes les différences qui existent entre les études d'une revue systématique puis d'une méta-analyse

Pourquoi l'évaluer ?

C'est une revue systématique qui permet d'évaluer l'hétérogénéité des études entres elles :

- Évaluation de l'hétérogénéité est indispensable pour pouvoir proposer une méta-analyse ⭐
- **Si l'hétérogénéité est trop importante**, la **méta-analyse n'est pas autorisée** ⚠️

Hétérogénéité clinique

- Différence de **populations** étudiées entre les études
- Différence d'**intervention** entre les études (différence de doses …)

Hétérogénéité méthodologique

- Différence de définition du critère de jugement principal
- Différence de design de l'étude avec étude randomisée ou non randomisée
- Aveugle ou Non-aveugle
- Différence de durée de l'étude …

Hétérogénéité statistique

Effet du traitement n'est pas le même dans toutes les études

- il faudra alors évaluer par un **test d'hétérogénéité**

Comment évaluer l'hétérogénéité d'une revue systématique ou d'une méta-analyse ?

Il existe 3 techniques possibles :

Forest plot. Évaluation à vue d'oeil du degré de chevauchement de l'intervalle de confiance à 95% de chaque étude, sur le diagramme de Forest → plus les intervalles de confiance des études se chevauchent, et plus l'hétérogénéité sera basse +++

Test statistique. Si un **test statistique d'hétérogénéité** est significatif ($p < alpha$) → alors l'hétérogénéité est prouvée

Paramètre d'hétérogénéité

Calcul du paramètre d'hétérogénéité I^2 (proportion de variation due à l'hétérogénéité plutôt qu'à la chance)

I^2 est compris entre 0-100%, et plus I^2 est élevé plus l'hétérogénéité est importante :

- $I^2 > 50\%$ → correspond à une hétérogénéité importante

- I^2 **> 70%** → correspond à une hétérogénéité trop importante qui **n'autorise pas la réalisation d'une méta-analyse** ensuite ⚠️
- *Autres chiffres : hétérogénéité faible (0-40%), hétérogénéité modérée (30-60%), hétérogénéité substantielle (50-90%), hétérogénéité considérable (75-90%)*

Conduite à tenir devant une hétérogénéité

- conduite à tenir devant une hétérogénéité détectée entre les résultats des différents essais d'une méta-analyse :
  - effectuer des **études de sensibilité** afin de comprendre les raisons
  - **regarder comment se modifie l'effet commun si on ne garde que les études ayant telle ou telle caractéristique** (dose utilisée, degré de sévérité de la maladie, haut ou bas risque de biais…)
- **Les résultats des différentes études sont-ils cohérents ?**

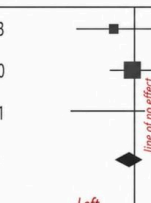
La confiance dans les résultats de la méta-analyse sera moins forte si les résultats des différentes études incluses vont dans des directions différentes, si la taille de l'effet est très variable ou si les intervalles de confiance ne se recoupent pas.

Focus

Notion du « poids » d'une étude au sein de la méta-analyse

Exemple ++

Study IDs	Intervention group n/N (1)	Control group n/N	Relative risk (fixed) 95 % CI (2)	Weight (3) (%)	Relative risk (fixed) 95 % CI (2)
Rowling JK 2000[3]	1/131	2/133		17.8	0.50 (0.05 – 5.49)
Albus D 2003[4]	7/279	9/290		77.7	0.84 (0.36 – 1.93)
Hermione G 2005[5]	3/102	1/101		4.5	3.00 (0.12 – 72.77)
Total	512	542		100.0	0.87 (0.41 – 1.87) (4)



Test for heterogeneity Chi-square = 0.79, df = 2, $p = 0.67$, $I^2 = 0.0$ % (5)
Test for overall effect $z = 0.35$, $p = 0.7$ (6)

(1) N = nombre total de patients dans le groupe ; n = nombre de patients avec critère de jugement dans le groupe.
(2) Représentation graphique du critère de jugement principal avec la mesure commune de l'effet de l'intervention (RR ou OR).
(3) Poids de l'étude en % : influence de chaque étude sur le résultat global de l'ensemble de la méta-analyse.
(4) Dernière ligne correspondant toujours au résultat global de la méta-analyse.
(5) Paramètre d'hétérogénéité I^2.
(6) Degré de significativité p du résultat global de la méta-analyse.

image.png

Définition

Correspond à l'inverse de la variance de la mesure de l'effet dans chaque étude, autrement dit, le poids de l'étude est d'autant plus important que :

- **Nombre de patients** est important

- **Degré de précision** de la mesure de l'effet de l'intervention dans l'étude est élevé

Unité. En **pourcentage**

Comment le déterminer ?
Figure du Forest plot renseigne en général sur la valeur du poids de l'étude :
- Soit via la **taille du carré de l'étude** sur le diagramme
- Soit indiqué sur une **colonne dédiée**

Limites

Biais de dissémination

> *Biais de dissémination sont un ensemble de biais entraînant un **risque de surestimer l'effet de la nouvelle intervention** (nouveau traitement) en mettant plus en avant les essais avec des résultats significatifs que les essais négatifs*

Biais de publication. Essais à résultats statistiquement significatifs sont plus souvent publiés que les essais négatifs (certains journaux acceptent en priorité les résultats novateurs et/ou positifs), mais ce n'est pas une fatalité, il est désormais obligatoire dans de nombreux pays de déclarer la conduite d'un essai de grande ampleur et de consigner les résultats même négatifs, auprès de bases de données publiques
Biais de délai de publication. Essais avec des résultats significatifs sont plus rapidement publiés que les essais négatifs
Biais de publications multiples. Essais avec des résultats statistiquement significatifs sont plus souvent publiés plusieurs fois, avec plusieurs types de résultats différents, que les essais négatifs
Biais de citation. Essais avec des résultats significatifs sont plus souvent cités dans les références des autres articles que les essais négatifs
Biais de langage. Essais avec des résultats significatifs sont plus souvent publiés en anglais que les essais négatifs

Méta-analyse est un processus rétrospectif

Risque
Par définition, une méta-analyse est toujours réalisé à posteriori des autres études déjà publiées,
- ainsi, le risque est que les **auteurs choisissent d'orienter l'axe de la méta-analyse en fonction de ce qu'ils veulent montrer** +++

Limiter le risque
Protocole d'analyse (critères de sélection, choix du CDJ, choix de l'analyse statistique …)
- Doit être fixé à priori, avant le début de la méta-analyse
  - Doit être déposé a priori sur PROSPERO ⭐ (site internet de référence permettant de valider le protocole d'une méta-analyse)

Rationnel est qu'on ne doit pas pouvoir modifier le protocole d'une méta-analyse au fur et à mesure de l'obtention des 1ers résultats (comme pour tout essai clinique)

Méta-analyse est un processus subjectif

Risques

Il existe un **problème de reproductibilité** lors de la réalisation d'une méta-analyse, à 2 étapes-clé :

- Sélection des études
- Extraction des données

Limiter ces risques

Afin de limiter ce phénomène subjectif, il est recommandé pour ces 2 étapes :

- Avoir recours à une double évaluation, par **2 opérateurs** en **aveugle**
- Avec un rapport des différences entre les 2 auteurs qui doit être fourni
- Il est alors indiqué de prévoir un **3ème** expert prêt à intervenir en cas de **divergence**

PARTIE 2

Cours

Structure d'un article

Un article scientifique a pour objectif de rapporter le déroulement et les résultats d'une étude dans le but de diffuser ces résultats auprès de la communauté scientifique. Il s'agit d'un rapport d'étude, c'est fréquemment le seul document accessible à la communauté scientifique.

2 types d'articles médicaux à distinguer

- Article de revue (review article) = article publié dans une journal scientifique par un expert d'un domaine, dont le but est de faire l'état des lieux des connaissances scientifiques dans un domaine particulier
- Article de recherche (research article) = étude scientifique visant à repondre à une question particulière à l'aide d'un ou plusieurs groupes de patiens (recherche clinique) ou d'expériences sur animal ou en laboratoire (recherche fondamentale)

En amont du début de l'étude : Protocole de l'étude

Définition. Protocole = planification des détails techniques de l'essai (plan expérimentale, population étudiée, randomisation, NSN, plan d'analyse statistique, descriptions des intervention etc etc)

Quand ?
Doit être rédigé et enregistré à priori (avant l'inclusion du premier patient)
De plus en plus fréquemment, ce protocole est publié sous la forme d'un article

Pourquoi ?
Permet de mettre en évidence des **écarts au protocole**
(évaluer s'il y a eu des changements importants pouvant affecter les résultats au cours de l'essai)
Qui l'enregistre ? Investigateur principal ou Promoteur de l'essai
Où est-il enregistré ? Registre gratuit reconnu par l'OMS (le plus connu étant **ClinicalTrials.gov**, mais autres registres reconnus par OMS possible)
Exemple typique. Si les investigateurs font leur essai et se rendent compte au moment de l'analyse que le critère de jugement principal qui avait été défini dans le protocole n'est pas significatif et qu'il change pour mettre comme critère de jugement principal un critère de jugement secondaire dont le résultat est statistiquement significatif
Risque. En cas d'écart au protocole, cela va biaiser les résultats de l'essai (**Biais de présentation sélective des critères de jugement** ou « Selective outcome reporting »), car on **augmente le risque alpha** en faisant plus de tests statistiques (on va faire plusieurs tests sur plusieurs critères de jugement secondaires, jusqu'à choisir celui qui est statistiquement signitifs, hors cela va des résultats statistiquement significatifs qui sont potentiellement dus au hasard et surestimer l'effet du traitement)

Prévention. Vérifier que ce qui est rapporté dans l'article est conforme à ce qui a été planifié dans le protocole est un élément essentiel pour apprécier la validité des résultats d'un essai

Format de l'article

Titre

> *Il doit être court mais informatif, on doit idéalement y trouver les différents éléments de l'objectif principal de l'étude*

Éléments à toujours mettre dans un titre = PICO + type/design de l'étude ± lieu et date

Vérifier le contenu du titre

- Critère de jugement principal avec la durée à laquelle il est évalué
- Traitement ou test à l'essai
- Traitement ou test de référence
- Maladie en question, ou la population étudiée
- Type et design de l'étude
- ± lieu et date

Vérifier la forme du titre (4 règles)

- Concis = 10 à 15 mots
- Clair = pas d'abréviations
- Précis = mots-clés utiles pour les recherches bibliographiques
- Neutre = pas de résultat (ne jamais faire figurer le résultat principal de l'étude dans le titre) ❌

Vérifier que le titre est conforme au contenu

- Titre conforme ou non à la question posée dans l'introduction (objectif)
- Titre conforme ou non aux réponses apportées par la conclusion

Auteurs

Tous les auteurs ayant contribué de manière significative à l'étude sont ensuite listés

- Le 1er auteur correspond généralement à celui qui rédige l'article
- Le dernier auteur est la personne qui supervise cette recherche

Les **affiliations** des auteurs sont également indiquées (appartenance à des services cliniques et/ou à des laboratoires de recherche

Un « corresponding author » doit être identifié avec ses coordonnées pour le contacter en cas de questions sur l'article.

Les auteurs doivent indiquer s'ils ont des **liens d'intérêt notamment financiers** (ex. si les auteurs ont été rémunérés par le laboratoire pharmaceutique pour des activités de conseil ou s'ils détiennent des actions du laboratoire ou si le laboratoire a financé des voyages pour aller en

congrès) en rapport avec l'étude car ces liens peuvent influencer les résultats et les conclusions de l'étude.

Résumé (abstract) : élément essentiel de l'article

Il synthétise les éléments les plus importants de l'étude en 200 à 300 mots selon un plan précis

Points qu'un abstract doit impérativement comporter

- Objectif principal
- Plan expérimental
- Description de la population et des interventions ou des facteurs d'exposition étudiés
- Critère de jugement principal
- Résultats pour le critère de jugement principal
- Conclusions en rapport avec les résultats du critère de jugement principal

Plan de l'abstract

Il suit toujours un même plan, même si la terminologie précise peut différer d'un journal à l'autre :

Introduction (contexte + objectif)

- Contexte de l'étude (nature du problème étudié, sévérité du problème étudié ...)

Objectif de l'abstract selon le fameux plan "PECO" :

- Population concernée par l'étude
- Éléments évalués : interventions ou facteurs de risques étudiés
- Contrôle (groupe contrôle)
- Outcome (critère de jugement principal)

> **Penser à toujours noter sur son brouillon PECO et à les noter**

Méthodes

Cette section comprend généralement plusieurs phrases/parties, dans l'ordre :

1. Informations sur le **type d'étude** (prospective/rétrospective/transversale, randomisée ou non, double aveugle/en ouvert ...), mais attention les auteurs ne sont pas obligés de présenter toutes les caractéristiques du types d'études dans l'abstract
1. **Critères d'inclusion, d'exclusion et de non-inclusions** les plus pertinents (attention, pas forcément tous les critères, donc toujours se référer à la partie "méthodes" pour ne pas passer à côté d'une information) : informe sur la population source et la population étudiée de l'article
1. Dates de **début et de fin de recrutement** ainsi que le **lieu** de recrutement (les conditions de recrutement informent sur la population étudiée)
1. Définition du **critère de jugement principal**
1. Principaux **tests statistiques** réalisés dans l'étude (peu important dans l'abstract, se référer à la partie "méthodes"

Résultats

- Cette partie commence systématique par des valeurs chiffrées et descriptives sur la population étudiée dans l'étude : nombre de patients dans chaque groupe, moyenne d'âge, proportion hommes/femmes ... (ici aussi les auteurs n'ont pas l'obligatoire d'exhaustivité et mettent les points descriptifs qu'ils jugent les + pertinents, là où ils souhaitent insister)
- Puis expose les **résultats sur le critère de jugement principal**, et va permettre de savoir si ce résultat est statistiquement significatif ou non (les autours doivent adjoindre l'intervalle de confiance et/ou la p-value au résultat principal de l'étude)
- La dernière partie de cette section est variable d'un article à l'autre (certains auteurs mettent en avant certains critères de jugement secondaires (ex. tolérance dans le cadre d'une étude thérapeutique), d'autres vont choisir de mettre en avant une analyse en sous-groupe, ou le résultat d'une analysie multivariée ...

Cette partie va permettre de déterminer s'il s'agit de :

Étude négative (résultat principal de l'étude est statistiquement non significatif)

Ici, la majorité des QCM vont porter sur :

- Notion du manque de puissance
- Biais de sélection, biais de classement, biais de confusion

Étude positive (résultat principal de l'étude est statistiquement significatif)

Ici, la majorité des QCM vont porter sur :

- Notion d'applicabilité des résultats (viabilité externe)
- Pertinence clinique de l'étude
- Quelques notions de biais (moins que si l'étude était négative)

Conclusion

- Exprime le résultat principal de l'étude, sans chiffres
- Puis texte de l'article, qui suit le plan : introduction, méthodes, résultats, discussion

Structure du texte

Introduction

Évaluation de la pertinence clinique

Il s'agit de justifier l'hypothèse de recherche, en recherchant des éléments justifiant la réalisation de l'étude : EDIE

Éléments du contexte de l'étude

- Nature, coût (enjeu économique), sévérité, fréquence du problème étudié
- Si diagnostique : enjeu fort du traitement de la maladie à diagnostiquer

Description de l'intervention

- Pour toute étude : données physiopathologiques expliquant le rôle possible de tel facteur
- Si étude thérapeutique : données pharmacologiques avec mécanisme d'action du médicament
- Si étude diagnotisque : performances diagnostiques du test étudié etc

Intérêt de l'étude

- Hypothèses d'efficacité, de moindre coût, de meilleur tolérance ...
- Si test diagnostique : test de référence trop invasif, trop couteux, peu accessible ou insuffisamment performant ...

Éthique

- Connaissance non disponible autrement, avec nécessité d'un nouvel essai pour répondre à la question posée
- Revue systématique de la littérature (conseillée) indique les résultats d'études antérieures : absence d'études antérieures, niveau de preuve insuffisant, résultats contradictoires entre différentes études, absence d'ajustement sur de potentiels facteurs de confusion découverts récemment et qui n'était pas connus sur les études antérieurs

Objectif de l'étude 🎯

Déterminer le PECO (éléments de l'objectif d'une étude)

Population (P) — Élément : **Population cible** ; Explication : population pour laquelle on souhaite pouvoir généraliser les résultats de l'étude

Evaluation (E) — Élément : **Elément soumis à évaluation** ; Explication : facteur de risque, nouveau traitement, test diagnostique…

Comparaison (C) — Élément : **Population de référence** ; Explication : Dans les études comparatives, population servant de référence pour mesurer une association

Outcome (O) — Élément : **Critère de jugement principal** ; Explication : Synonymes : maladie, issue clinique, *outcome, endpoint*

> ***Exemple :*** *Evaluer l'efficacité d'un traitement par azithromycine (E) versus placebo (C) sur le risque d'exacerbation de BPCO (O), chez des patients ayant une BPCO modérée à sévère (P)*

Focus sur les différents objectifs possible d'une étude

Objet de l'étude. **Principe**

Évaluation thérapeutique (médicamenteuse ou non). Évaluer l'**efficacité** d'un traitement (médicaments – chirurgie…)

Évaluation d'une procédure diagnostique. Évaluer les **performances diagnostiques** = validité – fiabilité du testÉvaluer la **reproductibilité** du test

Évaluation d'un programme de dépistage. Évaluer l'**efficacité** d'un programme de dépistageRecherche de l'**impact clinique** *(PCZ)*

Évaluation d'un pronostic. Évaluer le **devenir des patients** et les différences d'évolutionIdentifier des **facteurs pronostiques**

Enquête épidémiologique

DESCRIPTIVE = caractéristiques d'une population (prévalence – incidence)
ou
ANALYTIQUE = recherche d'association et de FDR ou Facteur protecteurs

Critères de qualité d'une hypothèse de travail d'un article de LCA?

- Être pertinente : quel impact sur la pratique clinique et sur les patients
- Être plausible/vraisemblable : est-ce qu'elle s'appuie sur un subtratum de données scientifiques biologiques (physiologie, physiopathologie, biochimie, génétique ...) et cliniques (épidémiologiques, études observationnelles ou interventionnelles)
- Être précise

Méthodes

Types d'étude (Study design)

- Plan expérimental de l'étude
- Justification du type d'étude par rapport à l'objectif principal

> **Déterminer le type de l'étude, et analyser si le type d'étude est adapté à la question posée**

Population

- Mode de recrutement de la population
- Critères d'éligibilité

> **Évaluer la validité interne (biais de sélection ?)**

Évaluer la validité externe (caractéristiques de la population correspondent-elles à celle de la population en pratique courante ?)

Randomisation (dans les essais)

- Méthode pour générer la séquence
- Mise en oeuvre (respect de l'assignation secrète ou clause d'ignorance)

> **Évaluer la qualité de la randomisation et la validité interne (biais de sélection ?)**

Facteurs évalués

Interventions (essais)

- Description des interventions à l'étude (traitement évalué, durée, dose)
- Utilisation d'un placebo ou d'un double placebo (l'étude est-elle en aveugle ?)

> **Evaluation de la validité externe (pourra-t-on utiliser l'intervention évaluée en pratique courante ?) Evaluation de la validité interne (risque de biais de performance)**

Facteur d'exposition (étude observationnelle)

- Définition des facteurs d'exposition

> **Evaluation de la validité interne (risque de biais de classement)**

Test évalué et test de référence (études diagnostiques)

- Description du test évalué et du test de référence

> **Réalisation systématique du test de référence ? Évaluation des résultats des tests indépendamment l'un de l'autre ?**

Critères de jugement principal

- Description du critère de jugement principal
- Mesure du critère de jugement principal (comment, par qui, en aveugle ou non ?)

> **Est-il pertinent cliniquement ? Est-il objectif ou subjectif ?**

Si subjectif : est-il reproductible ? Aveugle ? Évaluer la validité interne (biais de classement)

Analyse statistique

- Calcul d'effectif
- Analyse descriptive, univariée et analyse multivariée (études étiologiques et pronostiques)
- Population d'analyse dans les essais (intention de traiter, per protocol)
- Valeur du risque alpha (en général 5%), tests unilatéraux ou bilatéraux ?

> **Les analyses statistiques sont-elles appropriées ? L'analyse est-elle en intention de traiter ?**

Résultats

Description de la population

> **Validité externe (caractéristiques de la population correspondent-elles à celles de la population en pratique courante ?)**

Validité interne (vérification de la comparabilité des groupes dans les essais : qualité de la randomisation)

Pour les essais

Résultats pour le critère de jugement principal

- Comparaison du critère de jugement principal entre les 2 groupes de traitement

> **Différence statistiquement significative ? Taille d'effet (différence cliniquement pertinente ?)**

- Tous les résultats des critères de jugement doivent apparaître : pas uniquement les analyses statistiques significatives

Paramètres à toujours précisier avec le critère de jugement principal

- Mesure du critère dans chaque groupe
- Taille estimée de l'effet (contraste entre les groupes)
- Précision du résultat = Intervalle de confiance à 95% ou degré de significativité "p"

Évaluation de la tolérance

- Les évènements indésirables doivent être rapportés avec leur description et leur nombre, par groupe
- En précisant le nombre et la nature des évènements indésirables graves

> **Y a-t-il des problèmes de tolérance (comparer les pourcentages entre les 2 groupes car les tests statistiques ne sont pas puissants pour mettre en évidence des différences concernant les évènements indésirables)**

Pour les études observationnelles

- Analyse univariée : comparaison des caractéristiques des patients selon le critère de jugement principal
- Analyse multivariée : identification des facteurs indépendamment associés à la survenue du critère de jugement principal

> **Les résultats de l'analyse multivariée sont les résultats principaux car ils prennent en compte les facteurs de confusion.**

L'analyse univariée est une étape préalable à la réalisation de l'analyse multivariée

Analyser la partie résultat

- Cette partie ne doit contenir que des résultats : pas de commentaires ou discussion, pas de référence bibliographique
- Les résultats peuvent être présentés sous forme de figures ou tableaux
- Chaque résultat ne doit être présenté qu'une seule fois

Interprétation des résultats

- Résultats conformes : à la question posée, au type d'étude réalisé
- Résultats statistiquement significatifs sur le critère de jugement principal : sur l'ensemble de la popultion à l'étude (analyse en ITT) dans les essais randomisés
- Résultats provenant d'une comparaison entre les groupes, prévue a priori : interprétation fondée sur les résultats finaux obtenus à la clôture de l'essai pour les essais ayant comporté des analyses intermédiaires

L'étude permet-elle de répondre à la question posée ?

- Vérifier que le critère de jugement principal est pertinent par rapport à l'objectif clinique
- Vérifier que les conditions du calcul du NSN sont respectées

NB : le résultat principal de l'étude doit être la 1ère phrase de la conclusion qui doit alors répondre à la question posée dans l'introduction

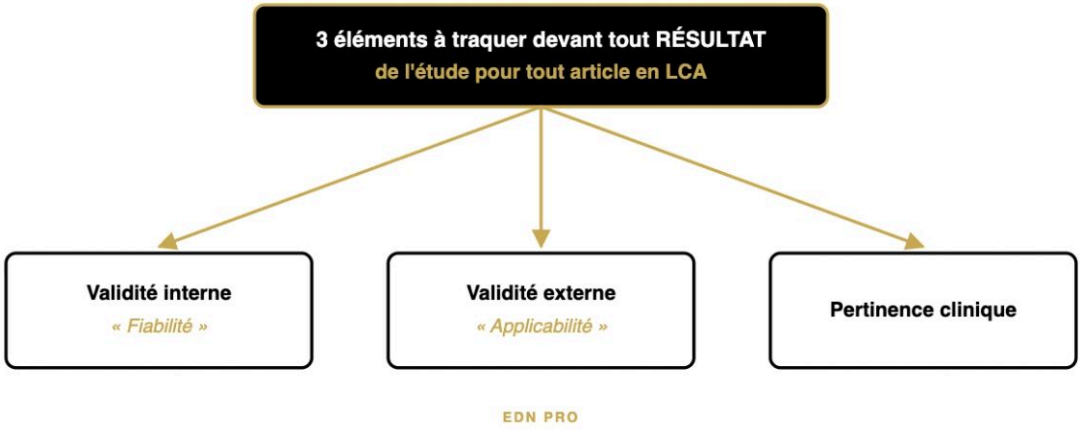


image.png

Discussion

Discussion

Règles de rédaction de la discussion

- Doit être argumentée
- Doit être courte (maximum 30-50% de l'article)
- Ne doit pas présenter de nouveaux résultats, ou de résultats détaillés sous une fomr différente que dans la partie résultat
- Ne doit pas détailler la méthodologie de l'article

Toute discussion doit comprendre 3 étapes :

Résumé des principaux résultats

> **En accord avec les résultats pour le critère de jugement principal ?**

Rappel non chiffré des résultats principaux de l'étude pour répondre à la question posée

- Rappel du résultat principal et son apport au regard de l'objectif de l'étude
- Principales forces de l'études
- Implication pour l'avenir : pratique clinique et hypothèses de recherche (⚠️ en faisant toujours bien attention de ne pas confondre signification statistique et pertinence clinique)

Place de l'étude dans la littérature

- Les résultats de l'étude sont-ils concordants avec les autres études réalisées ?

Évaluation de la cohérence externe

Discussion de la cohérence externe :

- Comparaison avec une revue systématique de la littérature en lien avec le sujet
- Discussion des hypothèses physiopathologiques comme mécanismes et explications possibles de ces résultats
- Ne pas se limiter aux études qui corroborent le résultat obtenu
- Distinguer les données de la littérature (références) et de l'opinion de l'auteur

Limites

- Les auteurs doivent présenter les principales limites de leur étude

Évaluation de la validité interne et externe

- Validité interne : discussion des biais et des imprécisions
- Validité externe : généralisabilité des résultats

Conclusion

- Les auteurs concluent en précisant les implications pour la pratique

La conclusion est-elle en accord avec les résultats du critère de jugement principal ?

- Se trouve à la 1ère phrase la discussion, et à la fin de la discussion (peut être individualisée ou non)

Structure et contenu de la conclusion

- Reprend les résultats principaux en répondant à la question posée (elle doit être fondée sur les seuls résultats de l'analyse du critère de jugement principal, qu'il soit positif ou négatif)
- Précise les implications en pratique clinique (en respectant les limites de l'étude : pas d'extrapolation des résultats en dehors de la population cible et dans les conditions de l'étude)
- Indique la nécessité d'études complémentaires ultérieures
- ❌ Elle ne contient jamais de données chiffrées détaillées
- ❌ Elle ne contient jamais d'interprétation ou d'opinion de l'auteur

---

Focus : références bibliographiques

Exemple avec format de « l'index Medicus »

Exemple — Décomposition d'une référence bibliographique

> ***Exemple :*** *Duration of anticoagulant therapy for deep vein thrombosis and pulmonary embolism. Kearon C, Akl EA Blood. 2014 Mar 20 ; 123 (12) :1794-801.*

Décomposition de la référence selon les éléments réglementaires :

- **Kearon C, Akl EA** : nom des auteurs après le titre complet (prénom abrégé par sa première lettre apparaît après le nom)
- **Blood** : titre complet de la revue, ou abréviation selon l'US Library of medicine
- **2014 Mar 20** : année (obligatoire) Mois (facultatif) Jour (facultatif) de publication
- **123** : numéro de volume
- **(12)** : numéro de fascicule ou de tome
- **1794-801** : page de début – page de fin

Numérotation des références
= style de « Vancouver »
Références sont numérotées par ordre d'apparition dans le texte (1) - (2) - (3) … ou [1] - [2] - [3] …
Mais noter que certaines revues utilisent encore une présentation des références par ordre alphabétique

Présentation de chacune des références
= format de « l'index Medicus »

- Premier auteur (nom et 1ère lettre du prénom)
- Liste des auteurs (citer les 6 premiers auteurs et ajouter « et al. » si > 6 auteurs)
- Titre de l'article
- Nom du journal
- Date de parution (année obligatoire, mais le mois et le numéro peuvent être omis)
- Numéro de la page de l'article
- Mention « sous presse » pour les articles en cours de publication

Focus : Transparence (reporting)

Permet d'évaluer la qualité méthodologie de l'étude et la validité des résultats

Il est essentiel que tous les éléments présentés dans la structure du texte soient clairement rapportés afin que le lecteur puisse évaluer la qualité méthodologique de l'étude et la validité des résultats ce qui n'est malheureusement pas toujours le cas.

En fait, de nombreux travaux méthodologiques ont souligné le manque de transparence de certains articles.

Afin d’améliorer la transparence dans les articles scientifiques, des recommandations internationales ont été élaborées par un groupe constitué de méthodologistes, d'éditeurs de journaux et d'investigateurs. Ces recommandations listent tous les items devant être rapportés dans la publication d'une étude afin de permettre l'évaluation de la validité et de la pertinence des résultats.

Recommandations de "reporting" selon le type d'étude

Type d'étude

Essai contrôlé randomisé

Étude diagnostique

Étude de cohorte ou cas témoin

Recommandations pour rapporter les articles

CONSORT Statement

STARD Statement

STROBE Statement

Types d'étude

Synonymes : schéma expérimental, plan d'étude, plan expérimental, study design

*En LCA **on étudie surtout les études comparatives**, les études non-comparatives sont plus rares : ce sont des études descriptives qui peuvent être transversales ou longitudinales*

Arbres de synthèse à suivre pour déterminer le type d'étude

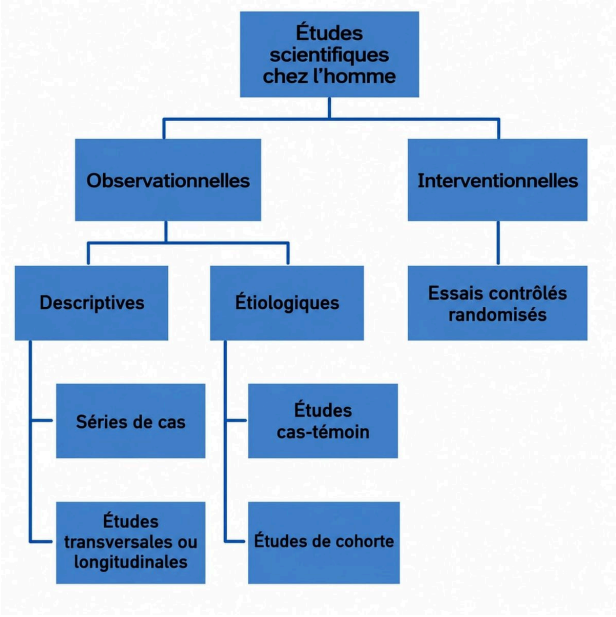


image.png

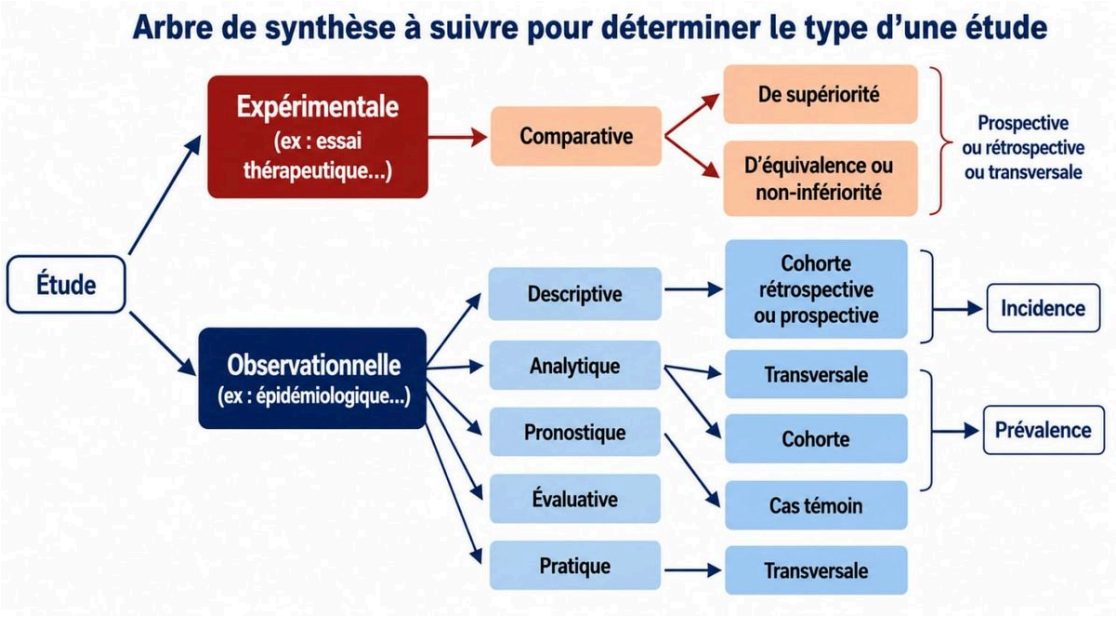


image.png

Selon l'objectif de l'étude

- Étude thérapeutique
- Étude diagnostique
- Étude de dépistage

Étude épidémiologique

Analytique (à visée étiologique) ou descriptive

- **Analytique** = recherche d'une association statistique entre une maladie et un facteur d'exposition étudié, ce sont des études comparatives, peuvent être de cohorte, cas-témoin ou transversales (transervales sont non recommandées tout de même pour montrer une association)
- **Descriptive** = description de caractéristiques brutes de l'état de santé d'une population, elle ne recherche pas d'association, ce sont souvent des études de prévalence (si transversale) ou des études d'incidence (si longitudinale)

- Étude de cohortes (ouvertes ou fermées) ou étude cas-témoins ou étude transversale ou étude de registre

- Étude pronostique
- Étude étiologique

Objet de l'étude. **Principe**

Évaluation thérapeutique
(médicamenteuse ou non)
Évaluer l'**efficacité** d'un traitement (médicaments – chirurgie…)
Évaluation d'une procédure diagnostique. Évaluer les **performances diagnostiques** = validité – fiabilité du testÉvaluer la **reproductibilité** du test

Évaluation d'un programme de dépistage
Évaluer l'**efficacité** d'un programme de dépistage
Recherche de l'**impact clinique** *(PCZ)*

Évaluation d'un pronostic
Évaluer le **devenir des patients** et les différences d'évolution
Identifier des **facteurs pronostiques**

Enquête épidémiologique
DESCRIPTIVE = caractéristiques d'une population (prévalence – incidence)
ou
ANALYTIQUE = recherche d'association et de FDR ou Facteur protecteurs

1. Observationnelle ou interventionnelle ?

Observationnelles

Ici, on ne modifie pas la prise en charge des patients, on se contente d'observer et de receuillir les données (l'exposition au facteur étudié ne dépend pas de l'investigateur, on ne choisit pas d'exposer le sujet)

Il peut s'agir de :

Études descriptives

- Séries de cas
- Études transversales ou longitudinales

Études étiologiques

- Études cas-témoin : elle est toujours **rétrospective**
- Études de cohorte (= exposés-non exposés) : peut être **prospective**, rétrospective ou mixte

Souvent ce sont des études descriptives, ou analytiques [peuvent être à visée étiologique (facteur de risque-maladie) ou à visée pronostique (facteur pronostique-survenue d'un évènement)], ou pronostiques, évaluatives, pratiques

Expérimentales = interventionnelles

Ici, on modifie la prise en charge des patients **en introduisant un traitement** ou **en contrôlant le facteur d'exposition étudié**

Ce sont essentiellement des études thérapeutiques ou diagnostiques

Ajouter ESCARPIN pour les études interventionnelles

- Étude interventionnelle
- **Supériorité** ou (de **non-infériorité = d'équivalence**) ou de faisabilité ou compassionnelle *Essai de supériorité nécessite un nombre de patient inférieur à un essai de non-infériotité; un essai de supériorité est plus adapté quand le traitement à l'étude est contraignant en terme de coût ou d'organisation*
- **Contrôlée** contre placebo ou contrôle traitement/test de référence, **ou non-contrôlée** (contrôlé = présence d'un groupe contrôle pendant toute la durée de l'étude)
- Aveugle : triple aveugle, double aveugle, simple aveugle, ou ouvert
- **Randomisée** ou **non randomisée**
- Plan expérimental = 2 groupes parralèles, ou groupes croisés (cross-over), ou séquentiel
- ITT = analyse en intention de traiter, ou analyse per-protocle, ou analyse en traitement reçu
- Numéro de phase = phase 3 ++, ou phase 1, ou 2, ou 4

> **Dans les ECNi il s'agit généralement d'essais contrôlés randomisés**

2. Transversale vs Longitudinale et Prospective vs Rétrospective ?

Transversale. À un moment donné, pas de suivi des patients dans le temps

Longitudinale. Faite sur une période donnée, on suit les patients dans le temps

Prospective. Suivi des patients pour receuillir des données postérieurement à l'enregistrement de l'exposition au facteur de risque (l'évenement survient après l'inclusion des patients dans l'étude)

Rétrospective

Receuille à postériori des informations sur l'exposition à des FR ou des évenements qui se sont déjà produits

(l'évenement survient avant l'inclusion du patient dans l'étude)

Quelques règles ⭐ :

Études cas-témoins. Toujours rétrospectives

Études de cohorte. Toujours longitudinales, peuvent être prospective ou rétrospective

Essais contrôlés randomisés. Toujours des études longitudinales et toujours prospectives

3. Est-ce le type d'étude est adaptée à la question posée (à l'objectif) ?

Grandes lignes des différents types d'étude (SP)

Études diagnostiques

Établir la valeur diagnostique d'un test clinique ou paraclinique (Se, Sp, VPN, VPP)

- que ce soit dans une démarche de dépistage ou de diagnostic

Études épidémiologiques descriptives

Décrire la distribution ou l'évolution de la fréquence des événements de santé et de leurs déterminants dans la population :

- Ne génèrent pas de conclusion causale ou inférentielle
- Peuvent générer des hypothèses qui sont à l'origine d'études explicatives

Études épidémiologiques explicatives

Identifier l'existence d'une association entre l'exposition à un facteur et un phénomène de santé, quantifier l'ampleur de cette association, interpréter cette association, les études explicatives sont de 2 types :

- Si le facteur étudié est maîtrisable et maîtrisé par l'expérimentateur (on peut décider de donner un médicament ou non)
- Si le facteur n'est pas maîtrisé ou non (on ne peut pas décider qu'un groupe d'individus consomme du tabac ou non)

Études d'épidémiologie analytique

Il s'agit des études explicatives où le facteur étudié est non maîtrisable. Le but des enquêtes étiologiques est d'établir un lien entre un facteur de risque (ou un facteur protecteur) et une maladie (ou phénomène de santé), en comparant 2 groupes d'individus, on distingue 2 grands types de méthodes supports des enquêtes analytiques, qui se complètent souvent :

- Méthode « cas-témoins » : rétrospective, plus rapide et moins coûteuse
- Méthode « cohorte » : prospective, logistique beaucoup plus lourde

Études d'épidémiologie analytique reposent sur le principe fondamental de la comparaison (de l'exposition au facteur chez les cas vs chez les témoins, ou de la survenue de la maladie chez des exposés vs des non-exposés au sein de la cohorte)

Étude d'épidémiologie expérimentale (essais cliniques contrôlés). Il s'agit des études où le facteur étudié est maîtrisable. La dénomination d'enquête expérimentale devrait être réservée à ce type d'études où le facteur est maîtrisé. Il arrive qu'on parle parfois d'étude expérimentale pour toute étude protocolisée. Le but des études explicatives expérimentales (ou essais cliniques) est d'établir un lien de causalité entre un facteur d'exposition maîtrisée (le plus souvent un médicament, mais aussi une stratégie chirurgicale ou de dépistage, etc.) et un événement de santé (maladie, guérison, rechute, détérioration de la qualité de vie, décès, etc.). Elles reposent sur des études comparatives (par exemple, un groupe traité comparé à un groupe non traité) dites contrôlées, randomisées (attribution au hasard du facteur étudié, par exemple un nouveau traitement)

Étude épidémiologique		
Descriptive	Décrire la **prévalence**	Étude observationnelle – transversale
	Décrire l'**incidence**	Étude observationnelle – cohorte prospective
Analytique/Étiologique (association FR-maladie)	Étude des **FR non-contrôlables** d'une maladie	Étude observationnelle : - Cohorte : si phénomène *(maladie)* fréquent - Cas-témoins : si phénomène rare
	Étude des **FR contrôlables** d'une maladie	Essai contrôlé randomisé : en cas de phénomène fréquent
Étude thérapeutique		
Évaluer l'**efficacité** d'un traitement		Essai contrôlé randomisé
Évaluer la **sécurité** d'un traitement		Essai contrôlé randomisé ou Suivi de cohorte
Étude pronostique		
Maladie fréquente		Cohorte prospective (design idéal) ou Essai contrôlé randomisée (rarement éthique)
Maladie rare		Étude observationnelle – cas-temoins (rare)
Étude diagnostique		
Évaluer la **performance diagnostique**		Étude observationnelle – transversal : à privilégier Étude de cohorte prospective : si il s'agit de suivre les patients pour compléter le Gold Standard Étude cas-témoins : si maladie rare, ou stade de développement initial d'un nouveau test
Évaluer l'**impact clinique**		Essai contrôlé randomisé : à préférer Observationnelle : possible si le test est déjà en place avant l'étude

Untitled

4. Quel est le niveau de preuve de l'étude ?

Niveau de preuve de l'étude ++ 🥇

Niveau de preuve scientifique

Appréciée lors de la synthèse des résultats de l'ensemble des études sélectionnées

- constitue la conclusion des tableaux de synthèse de la littérature

Gradation du niveau de preuve scientifique

Gradation du niveau de preuve scientifique repose sur 3 éléments :

- Existence de données de la littérature pour répondre aux questions posées
- Niveau de preuve des études disponibles
- Cohérence de leurs résultats

Niveau de preuve d'une étude

Capacité d'une étude à répondre à la question posée, dépend des caractéristiques suivantes :

- Schéma de l'étude
- Adéquation de l'étude à la question posée

- Adaptation de l'analyse statistique aux objectifs de l'étude
- Existence de **biais** dans la planification ou la conduite de l'étude
- Puissance de l'étude et en particulier la taille de l'échantillon utilisé

Si divergence de résultat entre études

En cas de divergence des résultats, il appartient aux « experts » de pondérer les études en fonction de leur niveau de preuve, de leur nombre, et pour des études de même niveau de preuve en fonction de leur puissance

- Accord d'experts si approbation de **≥ 80%** des membres du groupe de travail

Facteurs conditionnant le niveau de preuve

- Schéma de l'étude
- Adéquation de l'étude à la question posée
- Adaptation de l'analyse statistique aux objectifs de l'étude
- Existence de **biais** dans la planification ou la conduite de l'étude
- Puissance de l'étude et en particulier la taille de l'échantillon utilisé

Facteurs ne conditionnant pas le niveau de preuve ⚠️

- Ne dépend pas du type d'étude entre étude de supériorité ou de non-infériorité
- Ne dépend pas du résultat positif ou négatif de l'étude
- Ne dépend pas de la pertinence clinique ou non du critère de jugement principal

Attention

Selon le collège de thérapeutique un CDJ non pertinent n'influe pas sur le niveau de preuve, par contre il va influer sur la pertinence clinique

Pertinence de la question posée (objectif) qui dépend de :

- Critères de jugement choisis (doivent être importants pour le patient)
  - Choix de la population d'étude
  - Nature de l'intervention évaluée
  - Choix du traitement contrôle (comparateur)
  - Pertinence de la durée de suivi

Démarche à suivre pour déterminer rapidement le niveau de preuve :

> **Toutes les études rétrospectives sont de niveau 4, sauf l'étude cas-témoin (niveau 3)**

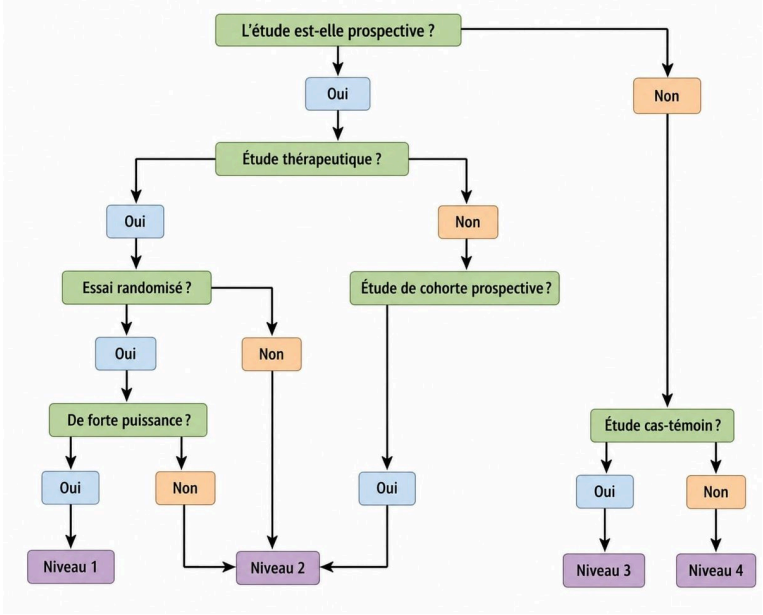


image.png

Niveau de preuve

Niveau 1

Type d'étude :

- Essais comparatifs randomisés de **forte puissance**
- Méta-analyses d'essais comparatifs randomisés
- Analysie de décision fondée sur des études bien menées

Grade des recommandations :

GRADE A ✅ = preuve scientifique établie

Niveau 2

Type d'étude :

- Essais comparatifs randomisés de **faible puissance**
- Études comparatifs **non randomisées** bien menées
- Études de cohorte (prospectives)

Grade des recommandations :

GRADE B 🤔 = présomption scientifique

Niveau 3

Type d'étude :

- Études cas-témoins

Grade des recommandations :

GRADE C = faible niveau de preuve scientifique

Niveau 4

Type d'étude :

- Études comparatives comportant des **biais importants**

- Études **rétrospectives** *(toutes études rétrospectives sauf les cas-témoins)*
- Séries de cas
- Études épidémiologiques descriptives (transversales, longitudinales)

Grade des recommandations :
GRADE C = faible niveau de preuve scientique

Population

Pourquoi faire un échantillon?

Il n'est généralement pas possible de réaliser une étude dans l'ensemble de la population, on va donc constituer un échantillon qui doit être représentatif (avoir les mêmes caractéristiques de la population), *on va mesurer un paramètre dans cette échantillon puis on va essayer d'estimer ce paramètre dans la population cible.*

Un échantillon représentatif d'une population est un échantillon constitué par un tirage au sort aléatoire dans cette population

Fluctuations d'échantillonage

Définition

Si on constitue plusieurs échantillons, le hasard fera que l'estimation du paramètre d'un échantillon à un autre ne sera pas la même :

fluctuation d'échantillonage (inévitable)

Mesurer la fluctuation. **Variance** ou **Écart-type** (toujours préciser le paramètre de dispersion)

Diminuer la fluctuation. Plus la taille de l'échantillon augmente, plus la fluctuation d'échantillonage diminue (par augmentation de la puissance)

Intervalle de confiance. Afin de prendre en compte la fluctuation d'échantillonage, plutôt que de donner une seule valeur de l'estimation, on donne un intervalle : **Intervalle de confiance** (intervalle dans lequel la vraie valeur a de grandes chances de se trouver (souvent fixé à 95% de chances), il est calculé à partir de la mesure du paramètre et de la mesure de sa variabilité)

Test statistique

Rôle est de déterminer si les résultats obtenus sont attribuables aux seules fluctuations d'échantillonnage ou s'ils sont bien réels

Soit P le paramètre inconnue d'une population, et E son estimation sur un échantillon. À partir de E on détermine un intervalle de confiance dans lequel on peut parier que P soit dans cet intervalle avec un risque α (souvent fixé à α = 0,05 soit 5%) de se tromper :

- On accepte qu'il y ait (α x 100)% de chance de se tromper en disant que P appartient à cet intervalle
- On accepte qu'il y ait (100 - α)% de chance de ne pas se tromper
- Plus l'intervalle est large, plus α est petit, car en prenant un intervalle large on diminue le risque de se tromper
- Plus n (effection de l'échantillon) est grand, plus l'intervalle est étroit (moins de chance de se tromper sur un grand échantillon)

Définitions

Population

Cible

Réelle ? :
Théorique

Définitions :
Population à laquelle on souhaite extrapoler les résultats de l'étude

- décrite dans l'objectif de l'étude (dernière phrase de l'introduction) : dans le PECO

Source

Réelle ? :
Théorique

Définitions :
Décrite par des **critères d'inclusions**, de **non-inclusion** et **d'exclusion**, population dans laquelle l'échantillon a été constitué car il est souvent très difficile de constituer l'échantillon à partir de la population cible
(certains sujets moins facilement joignable : populations en situation de précarité par exemple)£

- Idéalement les populations source et cible doivent se recouvrir parfaitement,

Éligible — Réelle ? : Réelle ; Définitions : Correspond à la part de la population source qui satisfait les critères d'éligibilités (présente l'ensemble des critères d'inclusion, et aucun critères de non-inclusion/exclusion), qui sera présente sur lieu de recrutement et durant la période de recrutement

Étudiée

Réelle ? :
Réelle

Définitions :
Correspond à l'échantillon tiré de la population source par le recrutement des patients
(part de la population éligible qui sera inclu dans l'étude)

Schéma

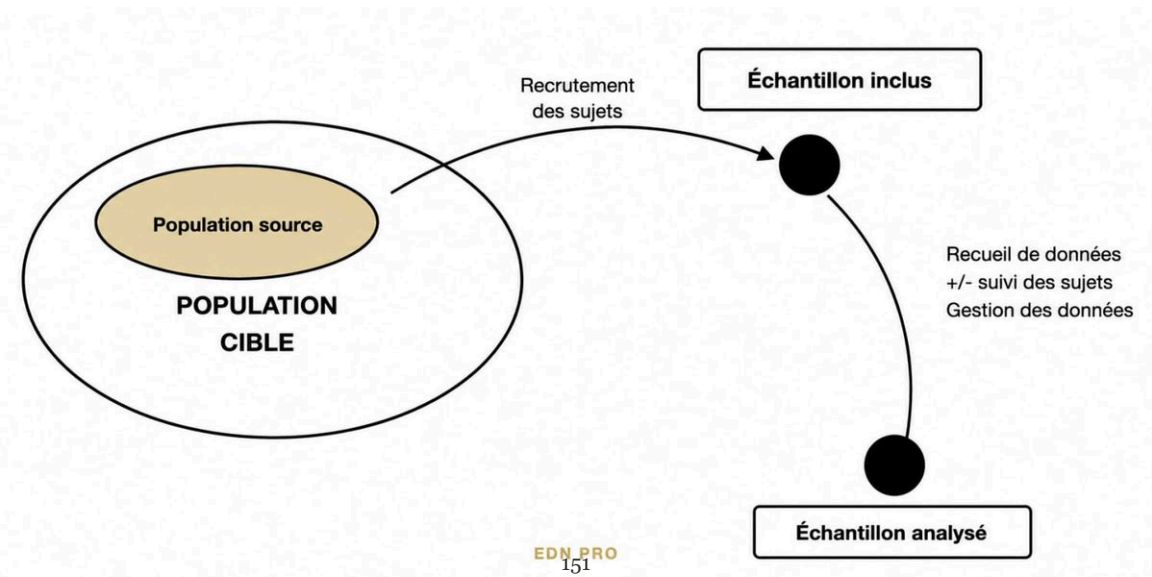


image.png

Définir une population source (critères d'éligibilité)

Ils peuvent comporter des critères d'intérêt pour la question posée, mais aussi des critères pratiques (ex. exclusion des patients qui ne parlent pas français, ou des patients avec des troubles de la mémoire)

Critères

Inclusion — Définition : Définissent les caractéristiques que les patients doivent présentés pour entrer dans l'étude ; Patient doit TOUS les présenter

Non-inclusion — Définition : Définissent les caractéristiques des patients qui ne peuvent pas être inclus ; Patient doit en présenter AUCUN

Exclusion — Définition : Définissent les caractéristiques des patients qui ne peuvent pas participer à l'étude malgré leur inclusion initiale (exclus dans un 2nd temps) ; Patient doit en présenter AUCUN

3 cas particuliers de critères d'exclusion

Femmes enceintes, mineurs,
sujets incapables
Il y a 3 conditions indispensables pour autoriser ces patients à être inclus :

- Étude présente un bénifice potentiel direct pour la personne, et un bénéfice pour le type de population auquel elle appartient
- Risque est minime
- Étude thérapeutique qui vise à étudier un traitement qui touche uniquement cette population particulière de patients

Patients avec comorbidités majeures
Il y a 3 raisons qui justifient que l'on exclut les personnes avec des comorbidités majeures :

- Risquent de moins bien tolérer le traitement
- Risquent de présenter des épisodes de décompensation, ce qui va limiter l'évaluation de l'efficacité réelle du traitement testé
- Risquent de présenter des événements indépendants du traitement

Patients très âgés. Bien qu'il n'existe généralement pas de limitation d'âge dans les protocoles, il y a souvent une auto-limitation par les investigateurs qui ne proposent pas leur étude à des patients très âgés : risque de biais de sélection

Notions de clause d'ambivalence (uniquement pour les études interventionnelles)

Il s'agit d'un pré-requis éthique indispensable

Quand ? Uniquement pour les études interventionnelles

Principe d'ambivalence
Tout patient inclus dans un essai thérapeutique doit pouvoir recevoir n'importe lequel des traitements étudiés, donc :

- Patient **ne doit pas présenter de contre-indication** à l'un ou l'autre des traitements pour pouvoir être inclus
- Patient **ne doit pas présenter d'indication** à l'un ou l'autre des traitements pour pouvoir être inclus
  - *principe réalisé en modulant les critères d'exclusion*

Principe d'équipoise. Il doit exister une incertitude sur l'efficacité de l'intervention évaluée, si ce n'est pas le cas, ce n'est pas éthique de conduire l'essai car cela expose les patients du groupe contrôle à une perte de chance

À ne pas confondre

*À ne pas confondre avec la **clause d'ignorance** dans la randomisation*
(où le médecin ne sait pas dans quel groupe va aller le patient : rien à voir)

Piège en annale

Si le patient refuse de donner son consentement, ou ne peut pas consentir (ex. démence), il ne sera pas inclus

- mais **ça n'a rien à voir avec la clause d'ambivalence**

Critiquer ou analyser le recrutement des patients

Avantages d'une étude multicentrique

Puissance. Recrutement + important (+ de patients donc + de puissance)

Validité externe

Recrutement + large donc + de validité externe
(à condition de **randomisation stratifiée sur le centre** pour limiter **biais effet-centre**)
Validité interne. Recrutement + rapide donc + de validité interne (évite un **biais effet-temps**)

Lieu de recrutement

- Monocentrique ou multicentrique (international ou non)
- Pays - système de santé
- Type de centre = CHU (cas graves souvent), ambulatoire/HAD, clinique privée ...
- Période de récrutement : début et fin

Mode de recrutement

- Publicité
- Volontariat : risque de biais de sélection car souvent non représentatif
- Sélection systématique et consécutive de tous les patients se présentant aux urgences : très bonne valeur
- Tirage aléatoire
- Tirage séquentiel

- Tirage au sort sur un registre ...
- Consentement écrit et signé

Vérifier que les populations sont comparables

- Vérification se fait sur le **Tableau 1**
- Vérifier la validité externe et interne

Comparabilité des groupes

Il existe 3 niveaux de comparabilité : comparabilité initiale ; en cours d'essai ; finale dans l'analyse

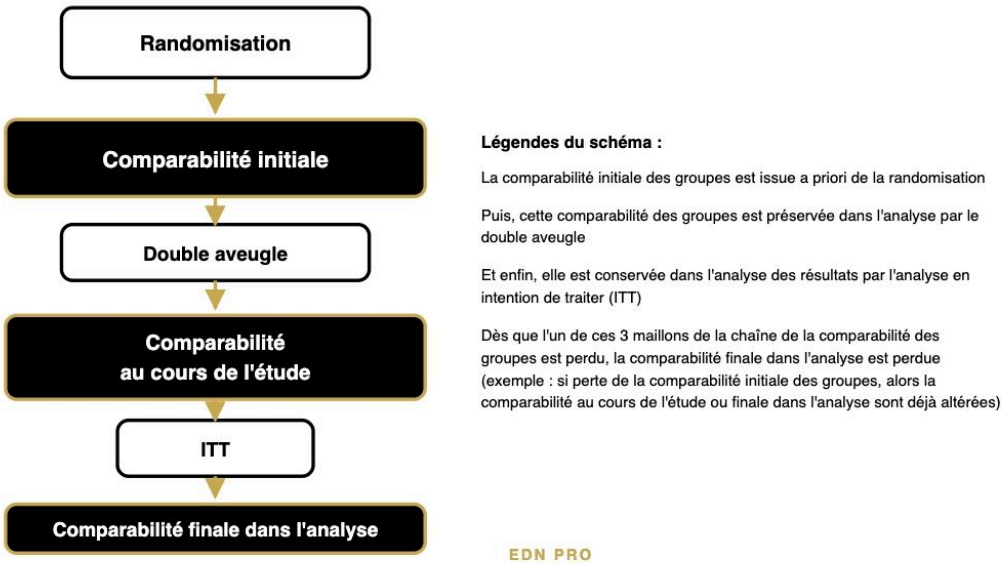


image.png

Comparabilité initiale : Randomisation

Randomisation

Définition. Correspond au **tirage au sort** des patients permettant une répartition aléatoire des patients au sein des groupes, elle concerne donc la comparabilité initiale des groupes ✅ et non la comparabilité pendant la durée de l'étude ❌

Principes

Objectifs

- Minimiser les biais de sélection
  - car ne laisse pas le choix de l'intervention au médecin qui pourrait favoriser l'attribution du traitement à certains patients
- Assurer que l'assignation d'un patient à un groupe donné ne peut être prédite
- Permet la répartition uniforme et équilibrée des facteurs de **confusion** potentiels (= facteurs pronostiques) connus et inconnus
- Assure la comparabilité initiale des groupes (ils sont identiques en tout point sauf pour le traitement reçu par le groupe testé)

- Permet une analyse en ITT (intention de traiter) = par définition il n'existe pas d'ITT sans randomisation
- Permet une analyse en sous-groupes de qualité
  - la randomisation stratifiée permet de stratifier sur les sous-groupes qui seront analysés à postériori

Qualité

Qualité de la randomisation ✅ repose sur 3 points (élément clef pour évaluer la validité interne d'un essai contrôlé randomisé) :

1/ Génération de la séquence de randomisation

(méthodes aléatoires, randomisation resteinte, équilibrée/déséquilibrée, centralisé pour les essais multicentriques)

2/ Assignation secrète = clause d'ignorance *(investigateur ne doit pas pouvoir prévoir dans quel bras va être randomisé le patient)*

3/ Vérification de la comparabilité initiale des groupes *(se vérifie sur le tableau 1 à vue d'oeil)*

Risque. Si l'un de ces 3 éléments pose problème, il y a un **risque de biais de sélection**

OUI

Randomisation et toutes ses caractéristiques ont pour but de :

- Garantir la comparabilité initiale des groupes ;
- Assurer que la seule différence entre les bras est liée au traitement ;
- Conférer aux essais cliniques un niveau de preuve élevé ;
- Limiter l'effet des facteurs de confusion

NON

Randomisation ne garantit pas :

- Éthique de l'étude
- Comparabilité du suivi entre les deux groupes → permis par le double aveugle
- Diminuer la fluctuation d'échantillonage → permis en augmentant l'effectif
- que le critère de jugement soit mesuré de la même manière dans les 2 groupes
- l'absence d'effet placebo

Génération de la séquence de randomisation

Méthodes adéquates vs méthodes inadéquates

Fluctuation d'échantillonage en cas de méthodes aléatoires

Le harsard du tirage au sort peut également être à l'origine de déséquilibre entres les groupes (que ça soit en termes d'effectif ou en termes de facteurs de confusion/facteurs pronostiques) : ces erreurs aléatoires sont des fluctuations d'échantillonage par opposition aux biais qui sont des erreurs systématiques

> **Attention à ne pas confondre le tirage au sort de l'échantillon dans une population (condition nécessaire pour que l'échantillon soit représentatif) avec le processus de randomisation (répartition aléatoire des patients en plusieurs groupes), tout deux à l'origine de fluctuations d'échantillonage.**

Méthodes adéquates = aléatoires ✅

- Séquence informatique ++
- Table de nombres aléatoires (random number table) : si pas d'ordinateur
- Tirage à pile ou face (coin toss) : pas vraiment faisable en pratique

Méthodes inadéquates = non aléatoires ❌

Toute méthode comportant une attitude décisionnelle systématique :

- Randomisation alternée (ABABAB ...)
- Randomisation basée sur une caractéristique du malade

(initiale du prénom, date de naissance ...)

- Randomisation basée sur le jour d'inclusion (lundi = A, mardi = B, mercredi = A ...)

Randomisation simple vs randomisation restreinte

Simple

Séquence aléatoire non contrôlée (simple séquence de nombres) :

- Peut aboutir à des **déséquilibres liés au hasard** en **cas de faibles effectifs** ⚠️
- *Ex. pour 10 patients, le hasard peut faire que la randomisation (pile ou face) aboutisse à 8 patients dans un groupe et 2 patients dans l'autre, ce qui poserait problème pour interpréter les résultats de l'essai*

Restreinte. Contrôle de certains facteurs par bloc, stratifiée, par cluster ou par minimisation (à utiliser en cas de faibles effectifs)

Focus sur la randomisation restreint (mais c'est toujours du tirage au sort) :

Randomisation par blocs

Principe

Consiste à s'assurer qu'à tout moment de l'essai, le même nombre de patients soit alloué dans chaque groupe

- Tous les "n" patients, randomisation par bloc de taille "n" dans chaque groupe

Intérêts

- Éliminer le biais "effet-temps" liés au moment de l'inclusion
- Distribution équivalente des patients dans chaque groupe à tout moment
- Évite la levée de l'aveugle, car la **taille des blocs peut être variable** (la taille des blocs peut changer au cours de l'étude, **pour ne pas être prévisible**), les médecins ne pourront pas deviner le groupe d'allocation du patient inclus

Condition

Risques

Investigateur ne doit pas connaître la taille des blocs ++, sinon peut deviner le groupe d'allocation du patient inclus :

- Biais de suivi : il ne va pas suivre de la même façon les 2 groupes
- Biais de sélection : l'investigateur va préférer inclure un patient plus jeune et avec moins de comorbidités pour recevoir le traitement (si il sait que le bloc est de taille 4, et qu'il a randomisé 2 patients dans le groupe A, il saura que les 2 prochains seront dans le groupe B), ce qui pourrait entraîner une **violation de la clause d'ignorance**

Randomisation par stratification

Principe. Correspond à une répartition **équilibrée** de l'échantillon entre 2 groupes, sur un **facteur de stratification** qui correspond à un **facteur de confusion potentiel majeur** = facteur pronostique important (âge, la gravité, comorbidités sévères, ou le centre dans un essai multicentrique

Objectif. Vise à limiter les déséquilibres liés au hasard sur des facteurs pronostiques importants

Conditions

- Il peut y avoir plusieurs facteurs de stratification et donc plusieurs strates → mais éviter de multiplier les strates car **risque de manque de puissance** avec des résultats non significatifs et des strates vides (maximum de 5 strates en théorie)
- Si il y a un faible effectif et beaucoup de facteurs pronostics, on utilisera la randomisation par minimisation

Exemple. *Ex : Si la randomisation est stratifiée sur le sexe et sur le stade de la maladie (précoce et avancé), il y aura 4 strates et donc 4 listes de randomisation : 1 pour les F en stade précoce, 1 pour les F en stade avancé, 1 pour les H en stade précoce, 1 pour les H en stade avancé*

Intérêts

- Répartition équilibré d'un facteur entre les groupes : force la comparabilité initiale
- Élimine le biais "effet-centre" dans les essais multicentriques (il est fréquent dans les essais multicentriques de stratifier sur le centre)
- Renforce la validité interne d'une analyse en sous-groupes (puisqu'on a fait la stratification à priori, on ne pourra pas dire qu'on aura choisit des sous-groupes significatifs à postério pour nous arranger)

À ne pas confondre

Randomisation par stratification ne doit pas être confondue avec :

- Ajustement ⚠ = analyse multivariée ajustée sur les facteurs de confusion à posteriori
- Appariement ⚠ = **dédié aux études cas-témoins**, avec appariement d'un cas à un ou plusieurs témoins au moment de l'inclusion
- Analyse stratifiée = synonyme d'analyse en sous-groupes à postériori

Randomisation par minimisation (type particulier de randomisation par stratification)

Indication. Utilisée si faible effectif et si nombre important de facteurs pronostiques (souvent dans les essais en cancérologie)

Principe

Permet une égalisation dynamique des groupes (limite les déséquilibres sur les facteurs pronostiques importants):

1/ Lors de l'inclusion d'un patient, l'investigateur enregistre les facteurs pronostiques du patient sur un site

2/ Algorithme détermine ensuite le groupe du patient selon les caractéristiques des patients précedemment inclus

3/ Paramètres d'attribution des traitements sont modifiés au cours de l'essai (pour chaque nouveau patient) pour permettre une bonne égalisation des groupes (= cas particulier de randomisation adaptative)

Randomisation en clusters (ou en grappes) : s'oppose à la randomisation dite « individuelle »

Principe

On randomise des groupes entiers de patients, pas les patients eux-mêmes

(ex. randomisation de centres entiers par rapport à d'autres centres)

Intérêt. Permet d'éviter la contamination entre les bras dans un même cluster (centre), par exemple pour éviter que le groupe placebo dans un centre recoive le nouveau traitement, ou l'inverse, par des erreurs délivrance, si le centre est désigné pour avoir le nouveau traitement, ce problème n'aura pas lieu car tous les patients recevront le traitement, et un autre centre sera désigné pour recevoir le placebo (Hôpital A reçoit le traitement, Hôpital B reçoit placebo)

Contamination entre les bras. Phénomène indiquant que certains individus d'un des bras de l'essai bénéficient également de l'intervention mise en place dans l'autre bras de l'étude → a pour conséquence la **remise en cause de l'indépendance des 2 bras de l'essai**

Inconvénients

Risques

- *Risque de biais de sélection majeur (soit car on recrute moins de patients dans l'un des groupe, soit parce qu'on ne recrute pas le même type de sujet dans les 2 groupes)*
- *Biais de classement, de suivi et de mesure : lié à l'**absence d'aveugle** dans le suivi et l'évaluation du critère de jugement*
- *Manque de puissance (**NSN d'un essai en cluster plus important** que celui d'un essai classique*
- *Analyse statistique complxe*
- *Chronologie des essais classiques non respectées*

Randomisation équilibrée vs randomisation non équilibrée

Équilibrée (situation la plus fréquente)

Autant de patient dans chaque groupe (ratio de 1/1 dans le groupe expérimental et le groupe contrôle), se fait par tables de nombres au hasard ou génération aléatoire par ordinateur

Respecte le principe d'équipoise (ou clause d'ambivalence)

Déséquilibrée

Nombre dans chacun des groupes est différents (souvent on souhaite un ration 2/1 pour randomiser 2x fois plus de sujets traités par le nouveau médicament)

- 1er avantage = augmenter le nombre de données pour étude de la tolérance (plus de patients vont recevoir le traitement expérimental)
- 2ème avantage = augmenter le recrutement dans l'essai (ne **permet pas d'augmenter la puissance** ❌) car les patients auront plus de chance de recevoir le traitement expérimental que le placebo, utile surtout aussi si un nombre de données manquantes est prévu (ex. si le traitement expérimental a des effets secondaires, on risque d'avoir des sujets qui vont arrêter le traitement)

Pour essais multicentriques : randomisation localisée/décentralisée vs randomisation centralisée

Localisée

Randomisation organisée localement par chaque centre

- méthode très critiquables car **risque de défaut d'assignation par tricherie**

Centralisée

Externalisée

Critère quasi-indispensable pour les essais multicentriques, ici la randomisation sera centralisée et externalisée vers un **centre unique de randomisation** pour l'ensemble des centres de recrutement (par serveur vocal, internet ...)

Précions de l'ATBC : la liste de randomisation se trouve dans un lieu unique à distance du centre d'inclusion du patient, l'investigateur doit contacter un serveur pour savoir dans quel bras (qui peut être masqué ou non) sera inclus le patient

- nécessité de faire appel à un centre tiers, impossible de fonctionner uniquement localement

Focus

Cas de la RANDOMISATION CENTRALISÉE STRATIFIÉE SUR LE CENTRE :

- Objectif : avoir 2 bras équilibré au sein d'un même centre, pour éviter que les patients soient traités différemment

(si un centre a 1 bras majoritaire par rapport à un autre, à l'échelle de l'étude on aura un bras qui aura était traité différement)

- Comment ? on utilise une liste de tirage au sort par centre (ex. si on a 4 centres il y aura 4 listes de tirage au sort)
- ATTENTION, si on a une autre strate, par ex. un essai multicentrique centralisée avec stratitification sur le centre et le sexe, on aura 2 listes de tirage au sort pour chaque centre 1 liste pour sexe féminin, et 1 liste pour le sexe masculin pour chaque centre
- *En annale malheureusement l'item « il y a une liste de tirage au sort par centre » alors qu'il y en avait plusieurs, était coché vrai à une année et coché faux à une autre année selon le décodage de la correction par asclepia (la LCA c'est une part de hasard)*

Respect de la clause d'ignorance

Principes de la clause d'ignorance

Synonymes. Non divulgation de l'allocation, masquage de l'allocation, allocation concealment, assignation secrète

Principe. Au moment où l'investigateur choisit d'inclure ou non le patient dans l'étude, il ne doit pas pouvoir prédire dans quel bras ce patient va être randomisé, il ne doit connaître le résultat de la randomisation (groupe du patient), seulement une fois que le patient est entré dans l'essai

Risque. Si l'investigateur peut prévoir dans quel bras va être randomisé le patient, il existe un biais de sélection : l'investigateur sera influencé dans sa décision d'inclure ou non le sujet (il priviligiera les sujets peu graves pour recevoir le nouveau traitement)

Ne pas confondre. *Ne pas confondre avec la clause d'ambivalence (éthique) = les patients doivent pouvoir recevoir l'un des 2 traitements*

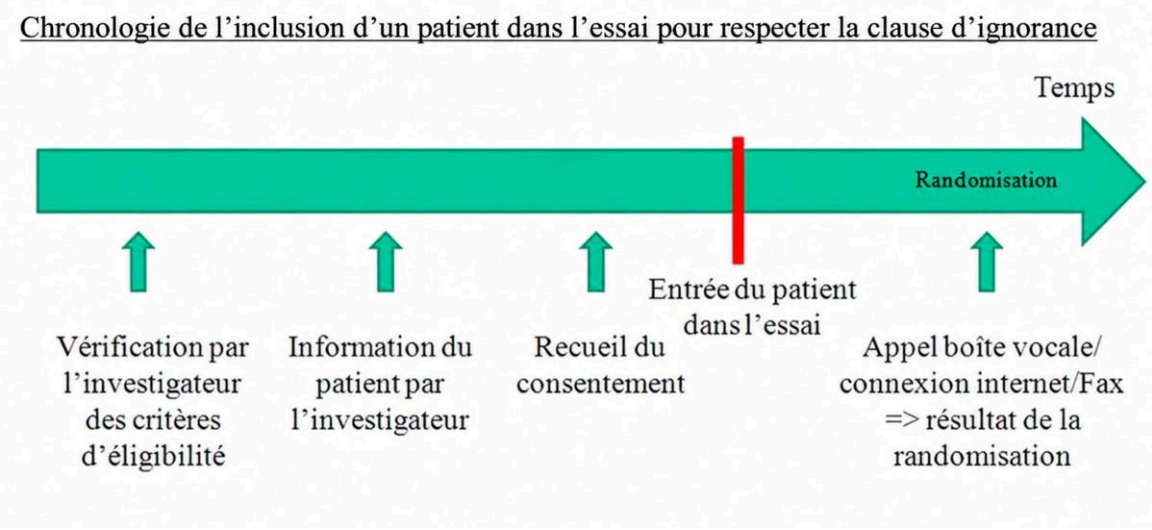


image.png

Modalités qui assurent une assignation secrète ✅

Modalités qui assurent une assignation secrète ✅

Investigateur n'a pas l'accès à la liste de randomisation (coffre ...), avec enveloppes scellés, opaques, numérotées de façon séquentielle : après inclusion du patient, l'investigateur ouvre l'enveloppe avec le plus petit numéro

Randomisation centralisée et sécrète (via téléphone, faxe, site internet) à priviligier : après inclusion du patient, l'investigateur prend contact avec la centrale de randomisation

Randomisation par bloc de taille "n" variable

Médicaments préparés par la pharmacie dans des containers d'apparence identiques, numérotés de façon séquentielle : après inclusion du patient, l'investigateur contacte la pharmacie qui fournit le container alloué par la randomisation, sans savoir de quel traitement il s'agit

Méthodes inadéquates et à éviter, qui ne respectent pas la clause d'ignorance ❌

Liste sur papier, enveloppes non scellés ou non opaques

Randomisation alternée (ABABAB), selon une caractéristique du patient ou selon le jour de la semaine

Ne pas confondre l'assignation secrète avec le concept de l'aveugle (insu)

- En ouvert = absence d'insu
- Simple aveugle = le patient ignore à quel groupe il appartient
- Double aveugle = le patient et le médecin ignorent le groupe dans lequel le patient se trouve
- Triple aveugle = patient, médecin, statisticien qui analyse les résultats et le médecin qui évalue le critère de jugement principal ignorent le groupe dans lequel le patient se trouve

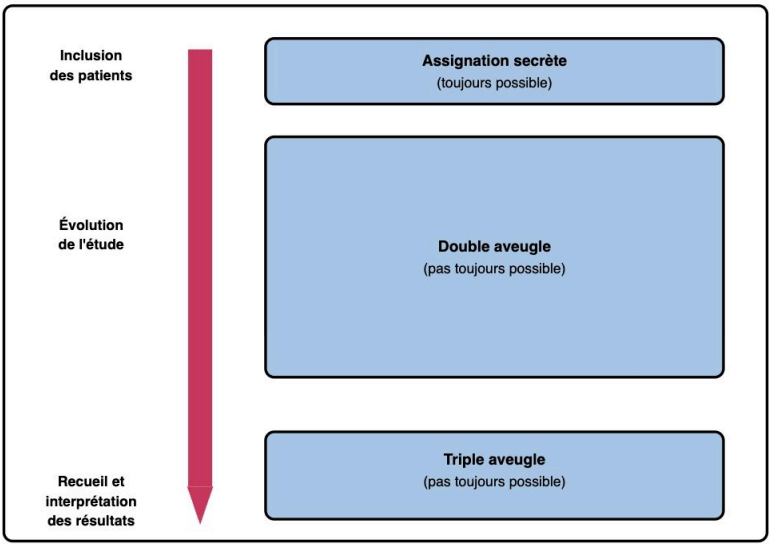


image.png

> **La <u>clause d'ignorance est toujours possible</u>, <u>mais pas l'aveugle</u> (il est parfois non possible de réaliser un simple ou double aveugle, par exemple si on veut comparer un médicament à une chirurgie, on ne peut pas dissimuler la chirurgie au patient, ça sera donc réalisé en ouvert)**

Randomisation peut être dissumulée au moment de l'inclusion du patient, puis être révélée au médecin/patient/statisticien ...

Vérification de la comparabilité initiale

Exemple

Table 1. Baseline Characteristics of Study Participants*

Characteristics	Placebo (n = 187)	Efalizumab (n = 369)
Sex, No. (%)		
Male	132 (71)	251 (68)
Female	55 (29)	118 (32)
Race/ethnicity, No. (%)		
White	167 (89)	331 (90)
Hispanic	7 (4)	17 (5)
Other†	13 (7)	21 (6)
Age, y	45 (20-75)	45 (18-75)
Duration of psoriasis, y	19 (1-53)	19 (1-62)
Prior systemic psoriasis therapy, No. (%)		
Yes	139 (74)	283 (77)
No	48 (26)	86 (23)
PASI score	19 (11-50)	19 (10-59)
BSA affected by psoriasis, %	27 (10-90)	28 (10-95)
DLQI score	12 (0-30)	12 (0-30)
Itching VAS score	6 (0-10)	6 (0-10)
PSA frequency score	14 (2-24)	14 (2-24)
PSA severity score	15 (2-24)	15 (0-24)

Abbreviations: BSA, body surface area; DLQI, Dermatology Life Quality Index; PASI, Psoriasis Area and Severity Index; PSA, Psoriasis Symptom Assessment; VAS, Visual Analog Scale.
*Data are presented as mean (range) unless otherwise noted. Mean values have been rounded.
†Other includes persons who described their race/ethnicity as Asian or Pacific Islander, black, American Indian or Alaskan Native, or other.

Dans cet exemple, les groupes sont relativement comparables en termes de caractéristiques initiales.

image.png

Rappel sur score de propension

Études non randomisées

Méthode d'analyse particulièrement adaptée pour minimiser le biais de confusion dans les études en pharmaco-épidémiologie (lorsque les études ne sont pas randomisés), elle vise à évaluer la comparabilité des groupes, afin d'estimer au mieux les effets causaux d'une intervention

- En effet, dans ce type d'étude, les **investigateurs n'ont pas le contrôle sur l'attribution du traitement** (qui est **souvent influencé par les caractéristiques du patient à l'état initial**), ce qui implique potentiellement des **groupes de patients déséquilibrés non comparables**
- Score de propension = outil de détection et de correction du biais de sélection, utilisé pour pallier ce problème

Études randomisées. Ici, le score de propension sert à juger l'efficacité de la randomisation en évaluant la comparabilité des groupes

Principe

On l'estime à l'aide d'une **régression logistique** avec :

- Variable à expliquer : prescription ou non du traitement
- Variables explicatives : caractéristiques des patients, éventuellement des médecins les prenant en charge

Permet de tenir compte des facteurs de confusion liés à la prescription du traitement (patients qui reçoivent le traitement ne sont pas les mêmes que les patients qui ne le reçoivent pas) et de minimiser ainsi un éventuel biais d'indication (qui est un biais de confusion)

Limite

Principale limite réside dans la possibilité d'un biais de confusion résiduelle
(si tous les facteurs de confusion n'ont pas fait l'objet d'un recueil de données dans l'étude)

Interprétation

- Score de propension estime, pour chaque individu, la probabilité conditionnelle P de recevoir le traitement étudié, étant donné ses caractéristiques initiales, il s'agit donc d'une **probabilité estimée entre 0** (pas de chance de recevoir le traitement) à **1** (de chance de recevoir)
- *On « découpe » ensuite des strates de patient en fonction de leur probabilité de recevoir le traitement (ex. strate à probabilité élevée)*
- Plus le nombre de variables introduites pour estimer le score de propension est élevé, meilleure sera la description de la probabilité des effets nets du traitement

Évaluation de la qualité du score

Afin d'évaluer la qualité du score de propension :

1. Comparation de la distribution dans chaque strates de chacune des variables intégrées dans la construction du score de propension
2. Si différences détectées, il faut examiner le nombres de variables concernées, si peu de variables concernées on retient une sous-classification de la strate et on vérifie si la différence persiste, si elle persiste ou si le nombre de variables concernées est importants, on réestime le score de propension
3. Répéter ces étapes jusqu'à l'obtention d'un score de propension équilibrée

Analyse de sensibilité. Analyse de sensibilité permet de s'assurer de la robustesse des résultats du score de propension, en examinant comment les résultats de l'analyse varient si on fait varier la valeur des variables clés dans un intervalle déterminé

Définition et intérêt du score de propension

Définition

- La méthode du **score de propension** est une technique statistique assez récente avec pour **objectif d'évaluer la comparabilité des groupes**, afin d'estimer au mieux les effets causaux d'une intervention. Cette technique est l'instrument le plus souvent utilisé dans les études expérimentales **non randomisées**, mais aussi parfois en théorie au sein des études expérimentales randomisées
- Sur le plan statistique, le **score de propension est estimé, pour chaque individu**, la probabilité conditionnelle P de recevoir le traitement étudié. **Sa valeur est comprise entre 0 et 1**
- Le score de propension est exprimé sous une probabilité donc, sa **valeur est comprise entre 0 et 1**.

Intérêts du score de propension

- Dans une étude expérimentale non randomisée +++ (le plus classique) :
- il sert à **évaluer la comparabilité des groupes afin de pallier l'absence de randomisation** en effet, les essais cliniques randomisés ne sont pas toujours possibles à mettre en place (coût élevé, attribution du traitement par tirage au sort posant des problèmes éthiques)
- lors d'études de ce type, les investigateurs n'ont pas la maîtrise d'éventuels biais inhérents aux groupes ; ils ne sont en général pas comparables d'un point de vue des caractéristiques des patients à l'état initial. Cela implique alors potentiellement, des **groupes de patients déséquilibrés** entre les variables observées et non observées. Le score de propension permet

alors d'éviter cette limitation de l'effet traitement (biais de sélection) ; le score de propension peut alors être utilisée pour palier ce problème

▶ Dans une étude expérimentale randomisée :

- il **sert à juger l'efficacité de la randomisation** en **évaluant la comparabilité des groupes** (*Dans les études randomisées, les individus ont en moyenne une chance sur deux de faire partie du groupe témoin. La randomisation doit permettre, du moins en théorie, d'obtenir deux groupes identiques en moyenne, c'est-à-dire que les caractéristiques initiales des individus du groupe traité et du groupe témoin sont semblables, tant du point de vue des caractéristiques observables qu'inobservables*)

▶ En résumé :

- la distribution du **score de propension offre un critère de comparabilité des groupes**. La **comparaison de la distribution des scores dans chacun des groupes**, permet de s'assurer que les individus traités et témoins sont suffisamment semblables pour que la comparaison ait un sens. Si ce n'est pas le cas, que le score de propension peut être utilisé pour **corriger le biais de sélection**
- ainsi, le score de propension permet d'abord de **détecter l'existence de différences préexistantes à la mise en œuvre de l'intervention**. En cas de différences, il permet ensuite de **corriger le biais de sélection et de comparaison des effets nets d'un traitement**
- retenez que **plus le nombre de variables introduites pour estimer ce score de propension est élevé**, **meilleure sera la description de la probabilité des effets nets du traitement**…

Interprétation

Une fois le score de propension estimé, il est nécessaire de **divisier les groupes**. Une fois faite, on peut comparer les distributions des **scores de propension** dans les 2 groupes.

- Si la distribution des scores de propension est différente, on conclut que les groupes ne sont pas comparables et que la **distribution par score de propension** est utile.
- (On insère donc les variables qui résument l'ensemble des variables des 2 distributions sont une indication de la *cause* du score de propension)
- si la **différence est minime**, l'utilisation du **score de propension** ne fournira pas plus de renseignements que ne le ferait un modèle classique avec ajustement sur les facteurs de confusion
- si les **deux distributions sont totalement différentes**, retenez que les deux populations ne **peuvent en aucun cas être comparées avec le score de propension** ; le score serait dans ce cas inutilisable
- si les **deux distributions sont superposables**, c'est que la **randomisation a été efficace** et qu'il n'y a pas de biais à compenser avec le score de propension
- les deux **distributions doivent être différentes** entre elles mais avec quelques zones de superposition pour pouvoir utiliser le score de propension

Conditions statistiques pour pouvoir appliquer un score de propension

Il appuie sur 2 hypothèses fondamentales :

▶ **1) L'hypothèse d'indépendance conditionnelle à des caractéristiques observables** (*conditional independance assumption*)

Cette hypothèse stipule qu'à des variables observables près, l'évolution résultats pour les individus traités et les non traités est en moyenne la même. Cela revient à dire que les caractéristiques observables permettent de capter intégralement les processus de sélection et les phénomènes d'auto-sélection. Cette hypothèse ne peut être testée d'un point de vue statistique. Ce n'est en revanche le travail de l'investigateur, basé sur ses connaissances et sa réflexion qu'il sera mieux à même d'identifier l'ensemble des covariables pertinents pour le score de propension. Cette hypothèse est forte, et il convient de garder à l'esprit qu'il existe en général un grand nombre de potentiels confondants, qu'il s'agira au moment de la construction du score de propension d'en sélectionner certains, et donc d'en mettre d'autres en arrière-plan. C'est précisément l'origine d'un certain nombre de **limites du score de propension** vues précédemment.

▶ **2) L'hypothèse de la condition de support commun** (*overlap*) :

Cette hypothèse se rapporte au support de la distribution du score de propension. Cette hypothèse permet de s'assurer que les individus avec un même ensemble de covariables peuvent être à la fois traités ou non traités, ou autrement dit, que **les individus de chaque groupe d'analyse se ressemblent suffisamment pour que la comparaison ait un sens**. Si la condition de support commun entrainerait ce qu'on appelle un **facteur de confusion structurale** (*structural confounding*) et interdirait toute conclusion quant à l'effet causal d'un traitement.

Pour prévenir ce problème, le score de propension ne doit pas être utilisé en dehors de la zone de support commun, c'est-à-dire la zone commune de la distribution des scores de propension des groupes traités et témoin.

Trois techniques possibles pour utiliser un score de propension

Une fois le score de propension estimé pour chaque patient, il existe plusieurs méthodes d'utilisation du score de propension

Techniques d'ajustement

Appariement — Avantages : Une seule variable d'ajustement ; Limites : Patients non appariés exclus

Stratification

Avantages :

5 strates suppriment 90 % du biais

Estimation du **RR**

Limites :

Effectif par strates suffisant

Régression logistique

Avantages :

Convient aux effectifs réduits

Plus robuste qu'un modèle classique quand le nombre de facteurs de confusion est important

Limites :

Estimation de l'**OR** (et non du RR)

Principe de l'analyse de sensibilité du score de propension

Définition générale : **analyse de sensibilité**

Une analyse de sensibilité est un **processus par lequel on évalue la robustesse d'un modèle statistique** en examinant comment les résultats de l'analyse varient lorsque la valeur des variables clés varie dans un intervalle determiné.

Analyse de sensibilité évaluant un score de propension :

- Il est possible que l'équilibre des covariables les plus importantes ne soit pas atteint après l'application du score de propension
- si c'est le cas, le score de propension peut être ré-estimé en ajoutant des interactions sur les variables dans le modèle comme déjà cité plus haut. Cette méthode itérative peut être répétée jusqu'à plusieurs reprises tant que l'équilibre n'est pas atteint
- en dépit de toutes ces étapes l'équilibre n'est toujours pas obtenu, il est possible de conclure que les groupes ne sont pas tout simplement pas comparable
- Avant de valider ce type de calculs sur un score de propension, la mise en place d'une **analyse de sensibilité est recommandée pour vérifier qu'il ne manque pas de facteur confondant +++**
- En résumé : **l'analyse de sensibilité permet de s'assurer de la robustesse du résultat du score de propension +++ (PCZ)**

Où vérifier ?

Vérifie sur le **tableau 1** ✅ (qui regroupe les caractéristiques des groupes à l'inclusion), c'est une vérification à vue d'oeil (Eye Ball test) : sans faire de tests statistiques (dans le tableau 1, le petit p n'a pas d'intérêt en dehors des facteurs de confusion majeurs)

- permet aussi d'évaluer la validité externe (évaluer si la population testée est proche de celle que l'on traite en pratique)

Attention ⚠️

- **Absence de différence majeure entre les groupes randomisés** est un indice de qualité mais **n'est pas synonyme de randomisation bien faite** ⚠️, car les groupes peuvent différer sur des caractéristiques non renseignées dans l'essai
- Randomisation de bonne qualité peut ne pas aboutir à des groupes comparables,
  - par le simple fait du hasard (fluctuations d'échantillonnage), surtout en cas de petit effectif

Selon l'effectif

- Si effectif important : le déséquilibre doit être minime
- Si effectif faible : on peut s'attendre à quelques déséquilibres entre les groupes liés au hasard (fluctuations d'échantillonage) :
  - Doivent aller dans les 2 sens (favorisant tantôt le bras expérim0ental, tantôt le bras contrôle)
  - Déséquilibres favorisant toujours le même groupe doivent alerter et faire évoquer un risque de **biais de sélection**

CAT si déséquilibre

En cas de répartion inégale de facteurs pronostiques cliniquement pertinents :

- Soit on équilibre le facteur de confusion par randomisation stratifiée
- Soit on fait un ajustement au cours de l'analyse statistique *(multivariée)* pour corriger à posteriori les écarts

Maintien de la comparabilité pendant l'essai : Aveugle (insu)

Essai ouvert
Médecin et Patient connaissent la
nature du traitement
Simple aveugle (simple insu). Patient ne connaît pas la nature du traitement, mais le médecin la connaît
Double aveugle (double insu). Ni le médecin, ni le patient ne connaissent la nature du traitement

> **Comparabilité dans l'essai est assuré par le double aveugle**

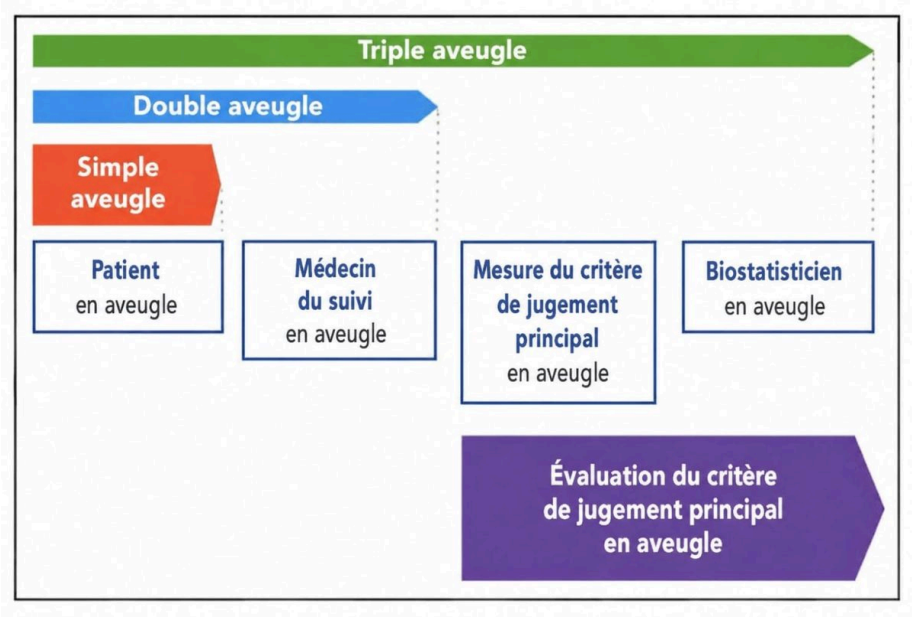


image.png

Double aveugle

Technique du double placebo : indispensable si impossible de faire des médicaments identiques

Indispensable si il est impossible de faire des médicaments identiques (ex: cas où le comparateur est un traitement actif d'apparence différente ou ayant un mode d'administration

différent, comme par ex si le traitement habituel du patient est sous forme de comprimé, et qu'on souhaite tester un traitement sous forme d'injection)

Principe = chaque patient va recevoir le même nombre de comprimé ou d'injections :

- Groupe contrôle : reçoit le placebo du traitement expérimental (injection) et le traitement contrôle (comprimé)
- Groupe expérimental : reçoit le placebo du traitement contrôle (comprimé) et le traitement expérimental

Avantage = assurer l'aveugle quand on veut comparer des médicaments de galénique différentes ou plusieurs types de traitement

Inconvénients = lourd, pas simple, contraignant parfois pour les patients (injections), coûteux, non éthique si chirurgie ou invasif uniquement

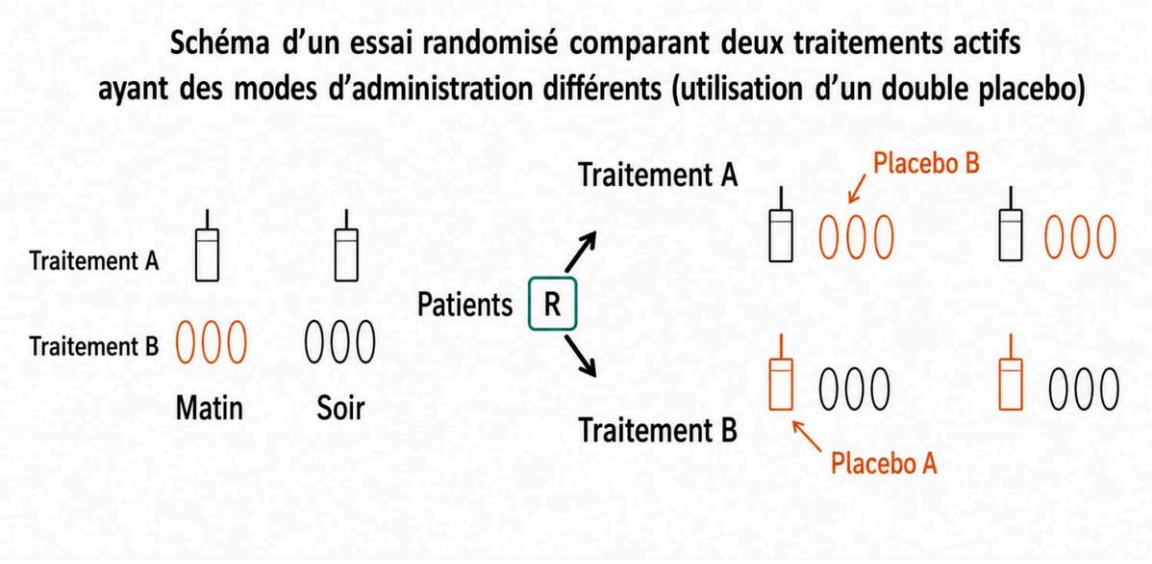


image.png

Définition. Ni le patient, ni le soignant ne savent quel traitement le patient reçoit (traitement expérimental ou traitement du groupe contrôle), et ce, tout le long du suivi → assure la comparibilité pendant l'essai, pour limiter les biais de classement

Modalités

- Validation des critères de jugement en aveugle par un comité d'adjudication
- Analyse statistique par statisticiens en aveugle des groupes
- Séquences et caractéristiques des traitements identiques (présentation galénique, goût, forme)

Intérêts

- Limiter un éventuel effet placebo
- Limiter le risque de biais de performance ou de suivi lié entre autres aux modifications de comportement du patient et du soignant

Essai en ouvert

Définition. Médecin et Sujet connaissent la nature du traitement

Situations où on a pas le choix

Situations où le double aveugle est difficile :

- Intervention invasive (chirurgie, radiologie interventionnelle …)
- Traitement par appareillage (radiothérapie, prothèses …)
- Traitement non dissimulable (physiothérapie, aide à domicile, kinésithérapie …)
- Stratégies thérapeutiques ayant un impact organisationnel (ex. domicile vs hospitalisation)

4 Avantages. Plus simples, Moins couteux, Mieux accepté par les patients en général, Indispensable pour les actes invasifs

Impact

Évaluer la nature du critère de jugement principal, puis l'impact de l'évaluation en ouvert :

- Si critère objectif (décès toute cause) : l'évaluation en ouvert n'a que peu d'impact (pas de biais)
- Si critère subjectif (douleur, échelle d'évaluation fonctionnelle) : le risque de biais d'évaluation est majeur

Si absence de double aveugle (essai en ouvert) ⚠ : la comparabilité des groupes est perdue, Deux biais à risque :

Biais d'évaluation. Il s'agit d'un **biais de classement**

Biais de performance, de suivi, ou de réalisation

Si le patient ou le médecin connait le traitement, il risque de modifier son comportement, par exemple :

- Si le patient est randomisé dans le groupe absence de traitement, il pourra être déçu et quitter l'essai
- À l'inverse, si le patient est randomisé dans le groupe expérimental, il pourra redouter de présenter des effets secondaires
- Si le médecin sait le traitement reçu par le patient, il peut modifier son comportement (inconstant), par ex. il pourra prescrire d'autres traitements s'il sait que le patient n'a pas reçu le traitement expérimental afin que celui-ci ne soit pas lésé
  - Toutes ces différences de comportement peuvent avoir un impact sur le critère de jugement et ainsi biaiser l'estimation

Limiter le biais de mesure

Afin de limiter un biais de classement de mesure dans une étude en ouvert : Procédure de type PROBE

- technique dédiée aux études en ouvert qui consiste à faire classer les événements permettant la mesure de CDJ principal par un panel d'expets, en aveugle du traitement reçu

Comparabilité finale dans l'analyse : ITT

Assurée par l'analyse en intention de traiter (ITT) = méthode d'analyse de référence des essais randomisés (de supériorité)

Analyse en intention de traiter

Exemples

Si le nombre de patients exclus est minime par rapport au nombre de patients randomisés, cela n'aura probablement pas d'impact sur les résultats, mais l'analyse n'est pas à proprement parler en ITT

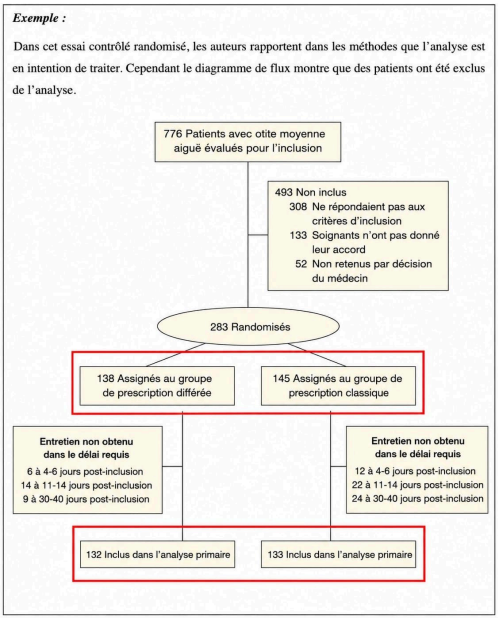


image.png

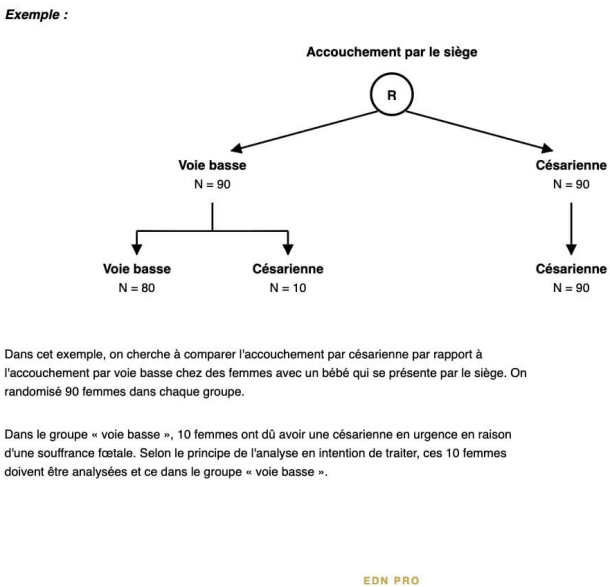


image.png

L'analyse doit donc comparer le devenir des 90 femmes du groupe « voie basse » (80 ayant vraiment accouché par voie basse plus 10 ayant eu une césarienne) par rapport aux 90 femmes

du « groupe césarienne ». La souffrance fœtale peut être liée au fait que la voie basse n'était pas adaptée. Exclure ces 10 patientes risquerait de surestimer le bénéfice de la voie basse.

Critères pour définir l'analyse en ITT

Critères doivent se vérifier sur le diagramme de flux (figure 1) et le texte :

Critères

- Tous les patients randomisés sont inclus dans l'analyse (nombre de patients analysés = nombre de patients randomisés)
- Tous les patients ont été analysés dans le groupe dans lequel ils ont été randomiés, quelque soit le traitement reçu
- Regarder les Résultats : le dénominateur (au moins pour le critère de jugement principal) doit correspondre au nombre de patients randomisés

Gestion des données manquantes

Tous les perdus de vue sont pris en compte selon une méthode de gestion des données manquantes (systématiquement associée à l'ITT) :

- Imputation multiple : analyse statistique permettant de remplacer les valeurs manquantes du critère de jugement en fonction des caractéristiques des patients perdus de vue à l'aide de modèles de régression complexes
- Méthode du pire scénario = hypothèse de biais maximum (peu utilisé car trop strict, mais **renforce le niveau de preuve d'une différence**) : pdv du bras expérimental comme ayant eu l'évènement (mort), pdv du bras placebo comme n'ayant pas eu l'évément (vivant)
- LOCF (last osbervation carried forward, souvent utilisée mais **non recommandée**) : consiste à **prendre le dernier résultat connu du CDJ pour le patient avant qu'il ne sorte de l'essai** (si on l'a vu à M6, et qu'il n'est pas revu à M9 ni à 1an, on gardera les résultats de M6

Limites. Si le nombre de données manquantes est trop important; l'interprétation de l'essai pose problème quelle que soit la stratégie d'imputation

Exemple sur l'importante d'une stratégie de gestion des données manquantes

Prenons l'exemple d'un essai contrôlé randomisé comparant un nouveau médicament à un placebo et avec comme critère de jugement principal la survenue d'un infarctus du myocarde dans l'année et avec 200 patients randomisés dans le bras expérimental et 200 dans le bras placebo. Si 20 patients sont perdus de vue dans le bras expérimental et 30 dans le bras contrôle, l'analyse en intention de traiter devra porter sur les 400 patients. Le problème, c'est que si on analyse les données comme cela, sans rien faire de plus, cela revient à considérer qu'aucun des perdus de vue n'a eu d'infarctus du myocarde dans l'année ce qui est peut être faux. Il faut donc mettre en place une stratégie de gestion des données manquantes pour imputer les données de ces 20 + 30 perdus de vue.

> ***Dogme à garder en tête face à la question : « Les auteurs précisent que l'analyse a été faite en ITT. Êtes-vous d'accord avec cela ? »***

- **ne pas toujours croire les auteurs quand ils disent avoir fait leur étude en ITT**
- mais toujours vérifier selon la définition et dire si oui ou non l'analyse aurait dû être déclarée en ITT (à tort, dans les articles !)

Type d'analyse particulière : "ITT modifiée"

Définition

Type d'analyse particulière définie par les auteurs de l'article en détaillant les critères définissant cette analyse, autrement dit : quels patients seront finalement analysé

- EXCLUT LES PATIENTS AYANT RETIRÉ LEUR CONSENTEMENT OU N'AYANT PAS REÇU AU MOINS 1 DOSE DU TRAITEMENT QUE LA RANDOMISATION LEUR AVAIT ATTRIBUÉ

Attention. Il **ne s'agit pas toujours d'une analyse proche de la véritable ITT** : c'est une appellation souvent utilisée de manière abuse par les auteurs, pour vous faire croire que c'est une ITT

> *ex. d'une ITT qui n'inclut en réalité que les patients ayant pris ≥ 1 dose du traitement :*

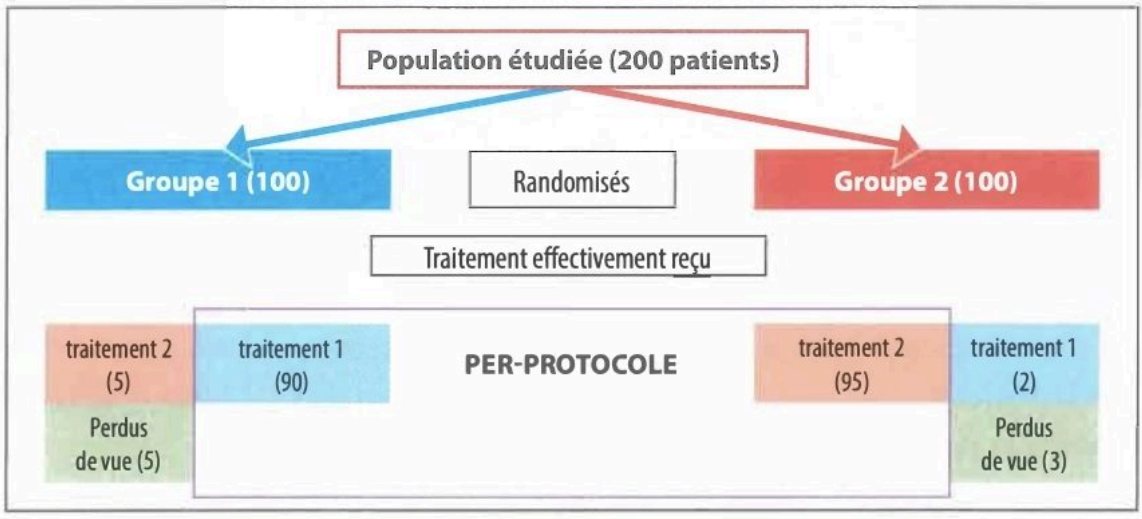


image.png

Principe

Analyse en ITT prend en compte la totalité des patients randomisés au départ, et dans le bras où ils ont été randomisés (même si traitement interrompus, ou non pris, ou modification du rythme ou de la posologie)

- on les analyse comme ils auraient dû être traités et non comme ils ont été traités réellement
  - analyse plus proche de la « vraie vie » que l'analyse per protocole, car en pratique clinique on ne sait pas ce qui va arriver lorsque l'on prend une décision médicale (le patient peut ne pas prendre le traitement, prendre son traitement 1/2 jour …)

Intérêts

Avantages

- Limite le risque de biais d'attrition (les perdus de vue ou ceux qui ont arrêté le traitement l'on peut être faire en raison d'un manque d'efficacité ou d'effets secondaires, si on les exclut on risque de surestimer l'effet du traitement)
- Maintien la comparabilité des groupes randomisés au moment de l'analyse (si on exclut des patients au moment de l'analyse, on perd le bénéfice de la randomisation) *ce qui limite le biais de*

sélection

- Renforce le niveau de preuve d'une différence via l'**hypothèse du biais maximum** ou "théorie du pire scénario"

Situations où l'ITT n'est pas suffisante ⚠️

Situations où l'on réalise l'analyse **per-protocole** + analyse en **ITT** :

- Évaluation de la tolérance : permet de mieux mettre en évidence les effets secondaires
- Essai de non-infériorité ou d'équivalence : renforce la non-infériorité si absence de différence

Autres méthodes d'analyse

Analyse per-protocole

Principe (schéma)

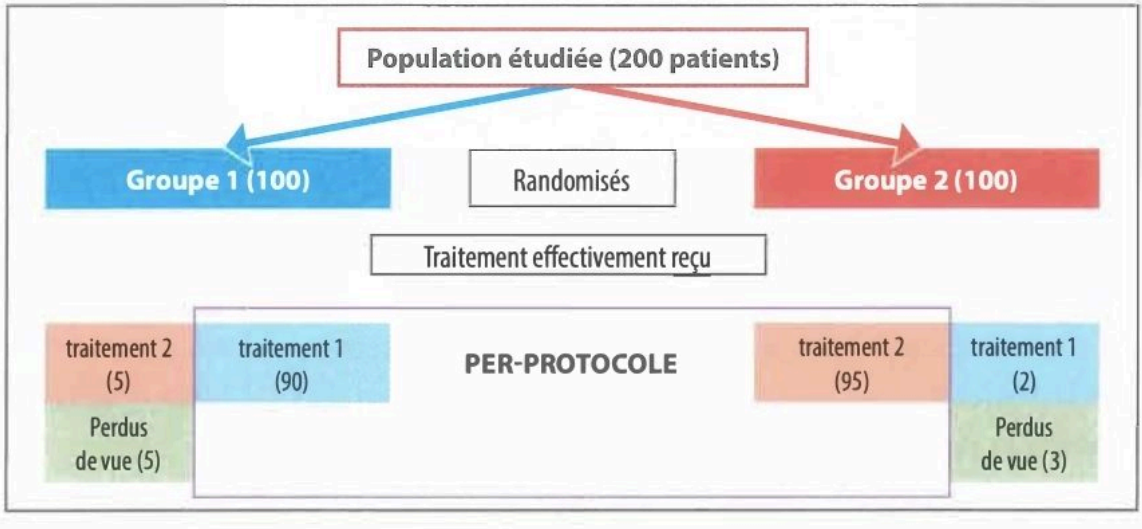


image.png

Principe. Analyse per-protocle considère seulement les patients compliants au protocole, c'est à dire ceux qui ont reçu le traitement ou le placebo pendant toute la durée de leur suivi (à la lettre, minutieusement)

Avantages

- Meilleure estimation de l'**effet propre du traitement**

Inconvénients

Risques

- Perte de comparabilité des groupes dans l'analyse → biais de sélection
- Faussement des résultats sur le CDJ avec baisse de la validité interne par biais d'attrition
- Baisse de la puissance si le nombre de patients exclus de l'analyse est important

Per protocole

vs ITT

Analyse en ITT est plus conservatrice ✅

Tandis que l'analyse per-protocole ❌ donne des résultats plus favorables car on exclut tous les patients qui n'ont pas respecté le protocole (donc on exclut ceux qui ont arrêté le traitement car il n'était pas efficace, ou car il y a eu des effets secondaires ...)

Per-protocole

+ analyse en ITT

Situations où l'on réalise l'analyse **per-protocole** + analyse en **ITT** :

- Évaluation de la tolérance : permet de mieux mettre en évidence les effets secondaires
- Essai de non-infériorité ou d'équivalence : renforce la non-infériorité si absence de différence

Exemples

> *Exemples :*

- Monsieur D. est randomisé dans un groupe, il ne sait pas lequel car c'est une étude en double aveugle. Il ne se passe rien de particulier et il arrive au bout de l'étude. On révèle alors qu'il était randomisé dans le groupe traitement.
  - En analyse en intention de traiter, on le considère dans le groupe traitement
  - En analyse per protocole, on le considère également dans le groupe traitement
- Monsieur M. est randomisé dans un groupe, il ne sait pas lequel car c'est une étude en double aveugle. Il prend le premier comprimé mais ensuite il arrête le traitement (ou le placebo). A la fin du suivi, on révèle qu'il était randomisé dans le groupe placebo et le patient avoue n'avoir pris qu'un comprimé.
  - En analyse en intention de traiter, on le considère dans le groupe placebo
  - En analyse per protocole, le patient sera exclu de l'analyse
- Madame V. est randomisée dans un groupe, elle ne sait pas lequel car c'est une étude en double aveugle. A la moitié du suivi, elle présente un événement indésirable grave. Le protocole de l'étude prévoit qu'en cas d'effet indésirable grave potentiellement imputable au nouveau traitement, l'aveugle doit être levé. On révèle que Madame V. a été randomisée dans le groupe traitement. Elle arrête alors le traitement jusqu'à la fin de l'étude.
  - En analyse en intention de traiter, on la considère dans le groupe traitement
  - En analyse per protocole, la patiente sera exclue de l'analyse

> **Pour essais contrôlés randomisés de supériorité : seule l'analyse en ITT est recommandée**

Analyse en traitement reçu (*as-treated*) = *annales 2018*

Principe

- Tous les patients sont analyses, sauf les perdus de vus
- Patients sont analysés en faisant abstraction de la randomisation :
  - Patients du groupe B qui ont reçu le traitement A, sont analysés avec les A
  - Patients qui ont reçu le traitement B alors qu'ils sont dans le groupe A, sont analysés avec les B
  - **Patients perdus de vue ne sont pas analysés**

Avantage. Augmente l'effectif des patients analysés *(par rapport à l'analyse per-protocole)*

Inconvénient. Risque majeur de biais de sélection car le bénéfice de la randomisation n'est pas conservé

Piège annale

Attention à ne pas confondre avec l'analyse per-protocole où on analyse seulement :

- Patient du groupe A traité par le traitement A
- Patient du groupe B traité par le traitement B
- **Patients ayant pris le mauvais traitement**, et **les perdus de vus ne sont pas analysés**

Schémas permettant de faire la différence entre Analyse per-protocle vs Analyse en traitement reçu :

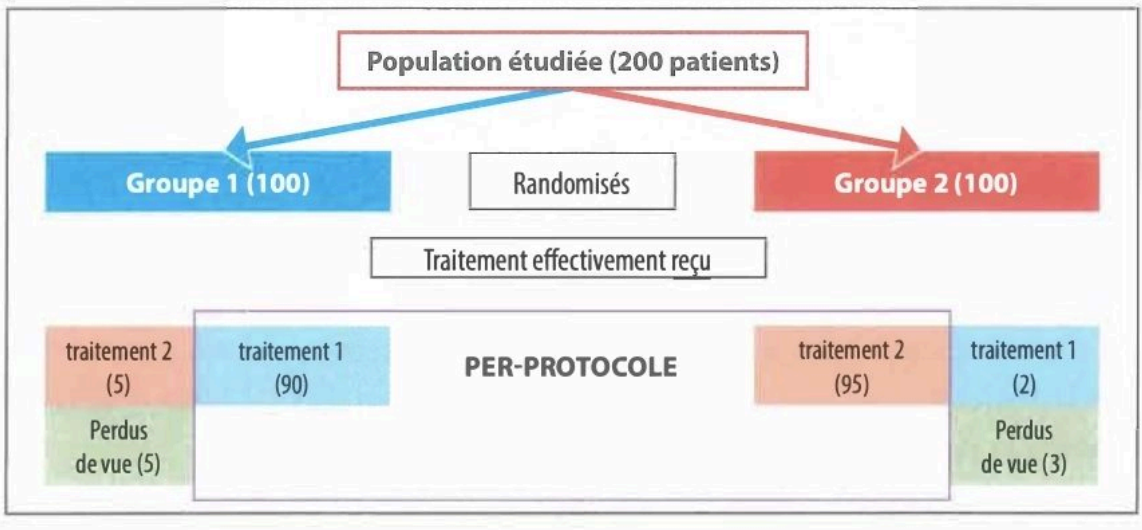


image.png

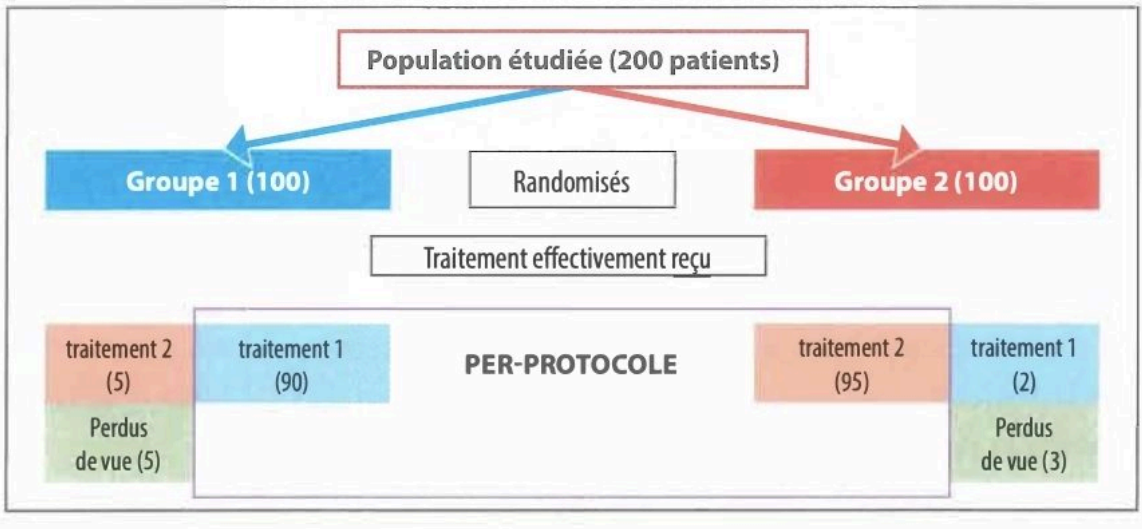


image.png

Biais, Validité interne et Validité externe

Focus : sur la pertinence clinique (signification clinique)

Exemples de questions : Au vu des résultats de cette étude faut-il recommander l'utilisation du traitement expérimental ? Quelles conséquences pratiques thérapeutiques tirez-vous de cette ? Discuter la pertinence clinique des résultats ? T PRINCES BTP

Pré-requis

Pré-requis à l'étude de la pertinence clinique = bonne validité interne, soit :

- Peu de biais
- Résultats statistiquement signficatifs (avant de parler de pertinence clnique il faut que le résultat soit statistiquement significatif)

T. Taille de l'effet clinique pertinente (traduit le constraste entre les groupes)

P. Pertinence clinique du CDJ principal

R. Résultats homogènes dans les différents sous-groupes (en cas d'analyse en sous-groupe réalisée)

I

Intervalle de confiance de l'effet ou degré de signficativité p

- résultat d'autant plus fort que l'IC est étroit ou que le p est petit

N. Nombre de sujets à traiter avec NST = 1/RAR

C. Cohérence externe (comparaison aux résultats d'études antérieures et à la physiopathologie)

E

Echelle = toujours penser en termes de bénéfice individuel versus échelle populationnelle (un faible bénéfice individuel peut être intéressant à l'échelle populationnelle, et vice versa)
ex. une augmentation relative du risque de 25% peut être négligeable si la maladie en question est très rare !!!

B. Balance bénéfices/risques favorable au traitement testé = toujours parler de tolérance *(ex. on peut avoir un bon niveau de preuve d'un traitement qui diminue la glycémie mais qui augmente la mortalité par un autre mécanisme)*

T. Traitements concomittants bien adaptés avec comme comparateur le traitement de référence

P. Population étudiée proche de la population cible = toujours parler de validité externe

Focus : notion de robustesse des résultats

3 critères pour parler de « RÉSULTAT ROBUSTE » en LCA :

- la **survenue de quelques évènements de plus ou de moins** dans un groupe ne modifie pas les résultats
- la **suppression des résultats d'un centre**, d'une étude multicentrique ne modifie pas les résultats *(sinon évoquer un biais effet centre)*
- la **gestion des données manquantes par une technique de type hypothèse de biais maximum** ne modifie pas les résultats

Biais

Définition

Correspond à une **erreur systématique** dans l'estimation du paramètre sur un échantillon et de la valeur de ce paramètre dans la population, qui fausse les résultats en diminuant la **validité interne**

"Systématique" = erreur qui se répéterait de la même façon si l'on constituait un nouvel échantillon en continuant à fausser les résultats

À différencier de l'erreur aléatoire ⚠️

L'erreur aléatoire est due à la fluctuation d'échantillonnage qui entraîne une imprécision autour du paramètre estimé ; plus l'échantillon est petit et plus l'erreur aléatoire est importante (elle opère dans tous les sens : surestimation ou sous-estimation)

Erreur aléatoire vs Erreur systématique

Type d'erreur

Causes — Erreur aléatoire = fluctuation d'échantillonnage : L'erreur aléatoire est due à la **fluctuation d'échantillonnage** qui est d'autant plus importante que l'échantillon comporte peu de sujets ; Erreur systématique = biais : **Toute erreur ou défaut dans la conception ou la mise en œuvre de l'étude peut être une source possible de biais.**

Conséquences

Erreur aléatoire = fluctuation d'échantillonnage :
Imprécision des estimations (intervalle de confiance à 95% large) et manque de puissance lié au petit échantillon (il est possible qu'on ne puisse pas conclure à une différence significative par manque de puissance)

Erreur systématique = biais :
Sur ou sous-estimation systématique
Risque de conclusion erronée



image.png

Ils peuvent être introduits lors de la conception ou le design de l'étude ou lors de son déroulement

> **Les biais sont classiquement plus importants et nombreux dans les études observationnelles, mais il peut y avoir des biais même dans un essai avec tirage au sort (ex. en raison d'une méthode de randomisation inadéquate)**

Réflexes à avoir

Il faut savoir repérer et décrire un biais, c'est-à-dire :

- Expliquer en quoi c'est un biais
- En donner le type (parmi : biais de sélection, biais de classement (ou d'information), biais de confusion, plus quelques biais plus spécifiques de certains types d'articles que nous verrons par la suite)
- En donner le sens lorsque c'est possible (surestimation ou sous-estimation, ou bien « dans le sens de la conclusion souhaitée » ou non)
- En évaluer l'intensité et l'impact potentiel sur le résultat
- Déterminer s'il s'agit d'un biais différentiel ou non, c'est-à-dire s'il modifie le résultat de la même façon pour tous les groupes

Grandes catégories de biais

Cours détaillés pour chaque biais

Biais de sélection

Biais lié à la **constitution de l'échantillon** ou des **groupes de comparaison**, il peut être dû :

- Échantillon n'est pas représentatif de la population cible pour des caractéristiques liées à la maladie
  - Problème de définition des critères d'éligibilité : critères d'éligibilité trop nombreux
    - Problème de recrutement des sujets : étude non proposée à tous les sujets éligibles, nombreux refus de participer …
- Mauvais choix du groupe de référence (possible dans les études cas-témoins)
- Erreur dans l'inclusion des patients dans les groupes de comparaison
  - Prévenue par la randomisation ⭐

Biais de classement

Signifie qu'on ne classe pas correctement les sujets (en exposés/non exposés, ou malades/non-malades) :

- Erreur dans le **receuil des données** : biais d'information, de déclaration, ou de mémorisation
- Erreur dans la **mesure du critère de jugement principal** : biais de mesure ou d'évaluation

Biais de confusion

Erreur dans l'interprétation des résultats = facteur de confusion (cofounding factor) qui perturbe l'association exposition-maladie, pour être un facteur de confusion, variable doit être liée à la fois

à la maladie et à l'exposition (n'est pas un facteur intermédiaire)

- Selon le sens de ces relations (positives ou négatives), l'effet de confusion peut conduire à une surestimation ou une sous-estimation de l'association (OR ou RR)
  - il est propre aux études observationnelles (car dans les essais contrôlés randomisés, la randomisation permet d'équilibrer les facteurs de confusion connus et inconnus entre les 2 groupes)

Biais de sélection

Différents biais de sélection ⭐

Plûtot dans les essais thérapeutiques

Biais de sélection

Biais de recrutement — Définition ou Conséquences : Perte de la comparabilité initiale des groupes ; Prévention : Randomisation correcte

Biais des perdus de vue — Définition ou Conséquences : *Trop de pdv,* risque de baisse de puissance (car diminution des effectifs) ; Prévention : *Prendre en compte les pdv dans le calcul du NSN*

Biais d'attrition

Définition ou Conséquences :

Perte de la comparabilité finale (patients sont analysés un groupe différent de la randomisation : 1 partie des partients a été exclue de l'analyse, *il s'agit en général des perdu du vue)*

Prévention :

Analyse en intention de traiter (ITT)

+ Stratégies des données manquantes

- toujours vérifier que nombre de sujet inclus

= sujets analysés

Biais « effet-centre »

(étude multicentrique)

Définition ou Conséquences :

Lié à la non-représentativité du centre (il traduit l'impact de l'hétérogénéité des performances de chaque centre, si un centre donné est excellent et que tout les patients y sont randomisés sont dans le groupe A, alors les résultats du groupe A seront tirés vers le haut par l'effet-centre et non par le traitement A)

Prévention :

Stratification sur le centre permet de s'assurer que la répartition de chaque bras dans chaque centre est équilibrée (il s'agit d'un moyen de se prémunir de l'effet centre, *le centre aura des patients avec le traitement A et des patients avec le traitement B*)

Biais des survivants — Définition ou Conséquences : Présent lorsqu'on inclut des patients qui ont déjà reçu dans le passé, l'un des traitements étudiés, crée un biais en faveur du traitement étudié (car par définition **ces patients vont mieux le tolérer car ils l'ont déjà reçu**, et **chez qui le**

traitement sera plus efficace : son effet sera donc surestimé par rapport à l'effet réel en population générale) ; Prévention : *Ne pas inclure des patients qui ont déjà reçu, dans le passé, le traitement étudié*

Plutôt dans les études épidémiologiques

Biais des témoins travailleurs (healthy worker effect)

= biais de récrutement

Sujets témoins travailleurs sont forcément en meilleur santé que les cas) : si probabilité d'inclusion dans l'étude est liée au facteur étudié

Biais d'auto-sélection

= biais du volontariat

Inclusion est due à la décision du patient (non représentatif de la population)

Biais de Berkson. Recrutement de témoins en milieu hospitalier qui ne sont pas représentatifs de la population générale

Biais de survie sélective

(biais des cas prévalents)

Dans les études **cas-témoins** si inclusion de cas prévalents (mélange de patients incidents et de malades déjà connus et ayant survécu), les cas prévalents sont forcément moins graves et biaisent la population

- Prévention par la sélection de cas incidents ✅

Biais d'attrition

(biais des perdus de vus)

Dans les études de **cohorte prospective**

- toujours vérifier que nombre de sujet inclus = sujets analysés (biaisé si les sujets perdues de vue sont exclus de l'analyse)

Biais lié à la constitution de l'échantillon ou des groupes de comparaison, il peut être dû :

Échantillon n'est pas représentatif de la population cible pour des caractéristiques liées à la maladie

Il peut résulter d'une sélection particulière des sujets aux différentes étapes de sélection de l'échantillon analysé :

- Population source non représentative de la population cible pour des caractéristiques liées à la maladie (problème de définition des critères d'éligibilité)
- Echantillon inclus non représentatif de la population source pour des caractéristiques liées à la maladie (problème de recrutement des sujets : étude non proposée à tous les sujets éligibles, nombreux refus de participer, etc.)

Mauvais choix du groupe de référence (possible dans les études cas-témoins)

> ***Exemple :***

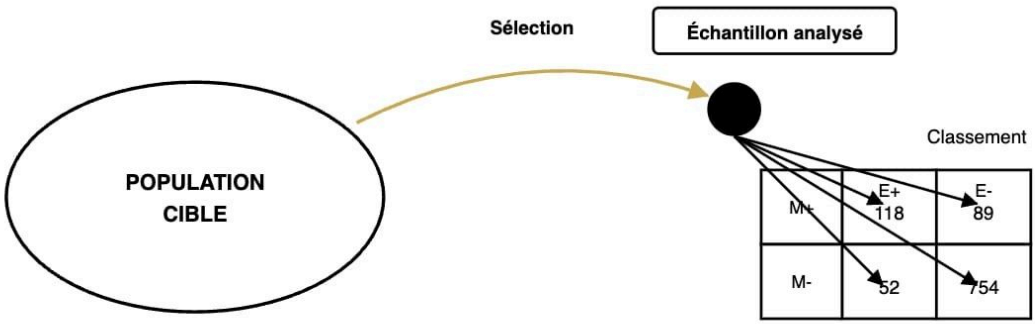
Dans une étude cas-témoin évaluant l'association entre la consommation de café et le cancer du pancréas, les témoins étaient des malades hospitalisés dans un service de gastro-entérologie pour un problème de côlon irritable. Le choix du groupe témoin pose problème ici car la consommation de café est déconseillée chez les patients ayant un syndrome du côlon irritable. Le

groupe de référence n'est pas représentatif de la population de non-malades car il s'agit de patients hospitalisés et que leur consommation de café est différente de celle de l'ensemble des non-malades.

- Erreur dans l'inclusion des patients dans les groupes de comparaison

Biais de classement

Schéma



EDN PRO

image.png

Distinguer les biais de classement différentiel, des biais de classement non différentiel ⚠️

Erreur différentielle 👎

- Soit lorsque les probabilités d'erreur de classement sur la maladie sont différentes chez les exposés et les non-exposés
- Soit lorsque les probabilités d'erreur de classement sur l'exposition sont différentes chez les malades et les sujets sains

Erreurs différentielles peuvent conduire à une **surestimation** ou à une **sous-estimation** de l'association

(valeur de l'odds-ratio ou du risque relatif peut être soit augmentée soit diminuée)

Ex. Biais de mémoire dans les études cas-témoin : les cas se souviennent davantage de l'exposition que les témoins

Erreur non-différentielle 👍

Lorsqu'elle survient indifféremment chez les exposés et chez les non-exposés

(respectivement chez malades et sains)

Erreurs non différentielles conduisent à une **sous-estimation** de l'association exposition-maladie, autrement dit rapprochent de **1** la valeur du risque relatif ou de l'odds-ratio

Cette connaissance de la direction du biais est importante pour l'interprétation des résultats. Son ampleur, et donc la perte de puissance qui en résulte, est proportionnelle à la fréquence des erreurs de classement

En général, il est préférable d'avoir des **erreurs de classement non différentielles** ✅, car le sens du biais est connu, et le manque de précision de l'estimation **peut être contrebalancé par une augmentation de l'effectif β** ✅

Comment éviter les biais de classement ? ✅

Il convient d'y penser lors la planification de l'étude (rédaction du protocle) car **après il sera trop tard** :

Éviter que les erreurs soient différentielles

- Procédures de suivi, diagnostic, recueil d'information : standardisées, objectives, et identiques pour E+ et E- (M+ et M-)
- Utiliser une procédure d'aveugle à chaque fois que possible, former (contrôler) les enquêteurs
- Même délai entre exposition et interrogatoire pour les cas et les témoins *(pour la mémoire ?)*

Limiter les erreurs

de mesures

Utiliser des définitions les plus précises (valides et reproductibles) possibles pour E et M

Biais de confusion

Comment limiter les biais de confusion ? ✅

Prise en compte du facteur de confusion lors de la planification de l'étude

- Appariement *avec un témoin* : Utiliser l'appariement de façon à équilibrer la distribution du facteur de confusion entre le groupe exposé et le groupe non-exposé, afin que le facteur de confusion ne soit plus lié à l'exposition (ex. si l'âge est facteur de confusion, on associe à chaque sujet exposé un sujet non exposé de même classe d'âge)
- Restriction de la population étudiée (ne pas inclure ceux qui présente le facteur de confusion, ou les exclure)
- Stratification : restreindre la population d'étude à 1 seule strate du facteur de confusion

Prise en compte dans

l'analyse statistique

- Analyse stratifiée = subdiviser la population de chaque pour une analyse en sous-groupe selon les facteurs
- Ajustement par l'analyse statistique multivariée : permet de corriger l'estimation des OR ou RR, mais cette correction peut malheureusement n'être qu'imparfaite, on parle alors de confusion résiduelle (residual confounding)
  - Nécessite au préalable que les informations sur ces facteurs de confusion aient été préalablement renseignées

Exemple si le facteur de confusion est le tabac[183]

- Restriction de la population étudiée : on exclut les fumeurs

- Appariement : si on inclut un fumeur dans un groupe, on inclut un fumeur dans l'autre groupe
- Stratification : on mesure l'association avec l'événement chez les fumeurs, et l'association avec l'événement chez les non fumeurs

> **Il s'agit du seul biais qui peut être pris en compte lors de l'analyse statistique (contrairement aux biais de sélection ou classement où ce n'est pas possible)**

> **Un seul élément du texte peut constituer plusieurs types de biais à la fois (ex. il y a 5x plus de patients avec une comorbodité sévère dans le placebo, cela constitue un biais de sélection, qui va constituer un biais de confusion potentiel)**

Nombreux sont décrits dans la littérature, le type de biais et la terminologie varient selon le type d'étude, mais globalement 3 types :

Biais de sélection

Définition :
Biais lié à la **constitution de l'échantillon** ou des **groupes de comparaison**

Causes :
- Échantillon n'est pas représentatif de la population cible pour des caractéristiques liées à la maladie
  - Problème de définition des critères d'éligibilité : critères d'éligibilité trop nombreux
    - Problème de recrutement des sujets : étude non proposée à tous les sujets éligibles …
- Mauvais choix du groupe de référence (possible dans les études cas-témoins)
- Erreur dans l'inclusion des patients dans les groupes de comparaison

Prévention :
Il convient d'y penser lors la planification de l'étude (rédaction du protocle) car **après il sera trop tard** :
- Biais de recrutement : Randomisation correcte
- Biais effet-centre : randomisation stratifiée sur le centre
- Biais d'attrition/Biais des perdus de vus :
  - Vérifier que le nombre de sujet inclus = sujets analysés
  - Analyse en ITT + Stratégie des données manquantes
- Biais de survie sélective : Sélection de cas incidents
- Éviter les témoins : hospitalisés, travailleurs, volontariat
- Biais des survivants : *ne pas inclure des patients qui ont déjà reçu, dans le passé, le traitement étudié*

Biais de classement

Définition :
Signifie qu'on ne classe pas correctement les sujets en E+/E-, ou M+/M-

Causes :
- Erreur dans le **receuil des données** : biais d'information, de déclaration, ou de mémorisation
- Erreur dans la **mesure du critère de jugement principal** : biais de mesure ou d'évaluation

Pour rappel :

- Erreur différentielle 👎 : survient sur 1 seul groupe, sous-estime ou surestime l'association
- Erreur non-différentielle 👍 : survient dans 2 groupes, sous-estime l'association (RR/OR vers 1)

Prévention :

Il convient d'y penser lors la planification de l'étude (rédaction du protocle) car **après il sera trop tard** :

- Procédures de suivi, diagnostic, recueil d'information : **standardisées**, **objectives**, et **identiques** pour E+/E- et M+/M-
- Utiliser une procédure d'aveugle à chaque fois que possible, former (contrôler) les enquêteurs
- Même délai entre exposition et interrogatoire pour les cas et les témoins *(pour la mémoire ?)*
- Utiliser des définitions les plus précises possibles pour E et M (**valides** et **reproductibles**)

Biais de confusion

Définition :

facteur de confusion (cofounding factor) qui perturbe l'association exposition-maladie, p

Causes :

Pour être un facteur de confusion, variable doit être liée à la fois à la maladie et à l'exposition (n'est pas un facteur intermédiaire)

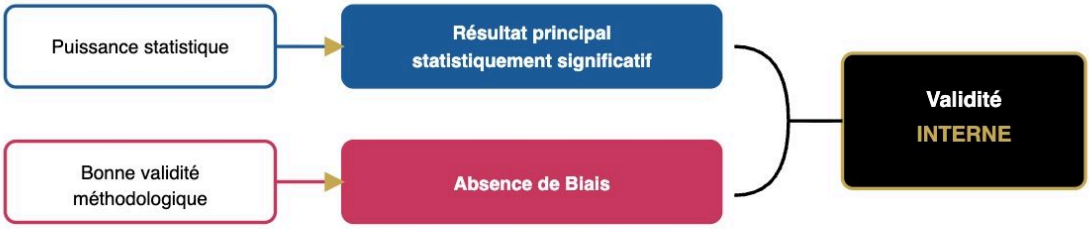
Propre aux études observationnelles (car dans les essais contrôlés randomisés, la randomisation permet d'équilibrer les facteurs de confusion connus et inconnus entre les 2 groupes)

Prévention :

1. Prise en compte du facteur de confusion lors de la planification de l'étude :
   - Appariement avec un témoin (on équilibre le facteur de confusion chez les E+/E-)
   - Restriction de la population étudiée (on exclut ceux qui présentent le facteur de confusion)
   - Stratification : restreindre la population d'étude à 1 seule strate du facteur de confusion
2. Prise en compte dans l'analyse statistique (seul biais pouvant être pris en compte dans l'analyse) :
   - Analyse stratifiée = subdiviser la population de chaque pour une analyse en sous-groupe selon les facteurs
   - Ajustement par l'analyse statistique multivariée :

Validité interne (cohérence interne)

Schéma



EDN PRO

image.png

Définition

Validité interne est le fait qu'un résultat observé soit un bon reflet de la réalité et qu'il n'est pas dû à un biais :

- Correspond au contrôle des différents biais potentiels = qualité méthodologique de l'étude (est-ce que les résultats sont fiables ?)
- Étude avec une méthodologie adéquate, permettant de limiter le risque de biais, aura une bonne validité interne

Biais

Vérifier l'absence de biais majeur permettant une comparabilité des groupes :

- Biais de sélection : randomisation bien faite / perdus de vue / analyse en ITT ...
- Biais de classement : double aveugle / critère principal unique, standard ...
- Biais de confusion : groupes comparables / stratification ...

Résultat. Résultat statistiquement significatif sur le critère de jugement principal, avec contrôle du risque alpha si tests multiples

Méthodologie

Méthodologie correcte et adaptée à la question posée, évaluée a posteriori :

- Bons critères d'inclusion et d'exclusion
- Méthode de randomisation correcte, Bonne comparabilité des groupes au départ
- Critère de jugement adapté
- Traitement comparateur adapté
- Bon suivi, Pas de problèmes d'évaluation du critère de jugement
- Peu de perdus de vue (< 10%), Bonne gestion de l'analyse des perdus de vue prévue a priori

Focus : différencier comité d'adjudication vs comité de pilotage

Comité d'adjudication

En Anglais :

Adjudication comittee

Définition-Objectif :

Comité de médecins ou statisticiens indépendants qui rend une expertise pour la mesure du CDJ, ils ne doivent pas avoir un lien d'intérêt avec l'étude en cours :

- Aveugle facile à mettre en place (car ils ne sont pas impliqués dans la PEC du patient, ils n'interviennent souvent que sur des données anonymisées)
- Permet de contrôler la subjectivité d'un CDJ évalué en ouvert par les investigateurs, c'est un critère fort de validité interne par contrôle du biais de mesure

Comité de pilotage

En Anglais :
Steering commitee

Définition-Objectif :
Il s'agit d'un comité de médecins ou statisticiens indépendants chargé de contrôler la bonne tenue de l'essai, notamment en lien avec les données de sécurité monitorées de manière continue

- Si des analyses intermédiaires sont prévues, c'est le comité de pilotage qui est chargé de rendre une expertise à leur sujet et de décider de poursuivre ou non l'essai (critère de **sécurité**)
- Leur indépendance signifie qu'ils ne sont pas impliqués dans la production des données dans le suivi des patients et qu'idéalement ils n'ont pas de lien d'intérêt avec la population de l'étude

Validité externe - Cohérence externe

Définition
Correspond à la transposabilité/applicabilité/générabilité des résultats à la pratique courante (caractéristiques de létude qui autorisent l'extrapolation des résultats à la population cible)
Évaluation de la validite externe (repose sur plusieurs éléments) :

- Validité externe à proprement parler (généralisabilité)
- Cohérence externe

Validité externe proprement dite
Caractéristiques des patients inclus :

- Population incluse était-elle représentative de la population cible ? → tirage au sort
  - Vérifier que les critères d'éligibilité ne soient pas trop restrictifs/pas trop nombreux
  - Caractéristique de la population étudiée : sur le tableau 1
  - Vérifier le lieu et mode de recrutement
  - Nombre de patients éligibles et nombre de patients inclus : taux et raison des refus de participation (sur le diagramme de flux)
- Caractéristiques des centres :
  - Résultats des études monocentriques sont moins généralisables que les résultats d'études multicentriques
  - Prendre en compte l'expertise des centres (résultats d'un centre de référence universitaire ne seront pas généralisables à des centres pratiquant moins d'interventions ou avec un plateau technique différent) : sont-ils similaires à la pratique courante ? centre trop spécialisé ? voie de médecine générale
- Caractéristiques des pays : Résultats d'études dans un pays étranger ne sont pas forcément généralisables en France

- Caractéristiques des interventions dans les essais :
  - Peut-on reproduire les interventions évaluées dans l'étude, dans notre contexte de soin?
  - Les interventions sont-elles suffisamment bien décrites pour être reproduites ?

Cohérence externe

Définit par la concordance des résultats avec les connaissances préalables de la littérature, s'évalue par 2 critères :

- Cohérence avec les résultats antérieurs de la littérature (confirmé par ≥ 1 autre essai, ou par une méta-analyse)
  - Cohérence avec les données physiopathologiques

Attention ⚠️, noter que le niveau de preuve ne dépend pas du tout de la cohérence externe ❌
Revues systématiques et Méta-analyses permettent d'explorer les discordances entres les études

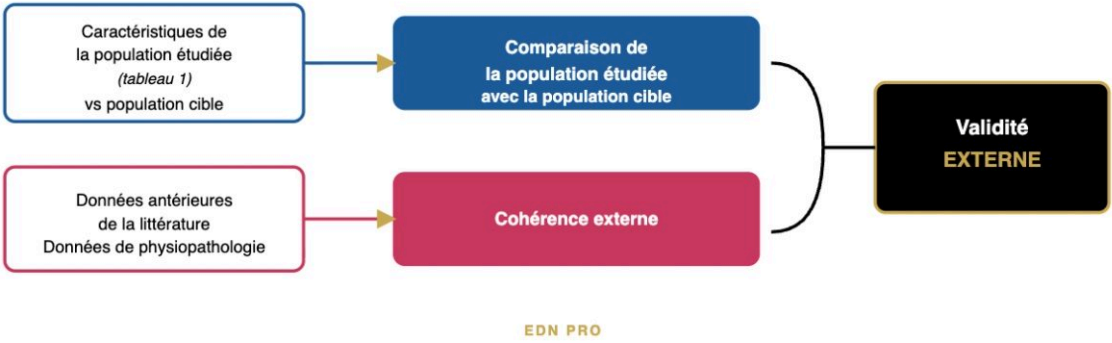


image.png

Critère de jugement principal

> **Intérêts du critère de jugement principal :**

- Utile au **calcul du NSN** des essais cliniques
- Sa mesure conduit au résultat principal de l'étude (conclusion doit porter sur ce critère de jugement principal)

Caractéristiques recommandées pour le critère de jugement principal : C COUARDS

C. Consensuel et valide : par des publications antérieures ou des recommandations consensuelles (définitions internationales)

C. Cliniquement pertinent et directement lié à l'objectif thérapeutique : doit correspondre à l'objectif principal de l'essai

O. Objectif

U. Unique : afin de conserver un risque α de 5%

A. Adapté à la question posée et au type d'étude

R. Reproductible et quantifiable

D. Défini a priori dans le protocole : de manière précise, et **ne change pas au cours de l'essai** ⚠

S. Standardisé = avec description précise des modalités de mesure du critère de jugement

Focus

Exemples

> *Exemple :*

Pour évaluer l'efficacité d'une chimiothérapie contre le cancer de la prostate, on pourrait s'intéresser :

- à la **mortalité toutes causes confondues**, la **mortalité par cancer de la prostate** (critères pertinents)
- à la **réduction de la taille de la tumeur**, la **baisse du taux sanguin de PSA** (critères intermédiaires)

Critère Pertinent/Final ou Intermédiaire ?

Définition

Cliniquement pertinent/final :
Directement liés à l'objectif clinique (thérapeutique) de l'étude
(il s'agit de l'objectif même du traitement)

Intermédiaires ou Critères de substitution (en anglais : surrogate) :
Critère de jugement facile d'accès à une mesure simple, et dont on suppose qu'il est lié à l'effet clinique (thérapeutique) recherché
Ex. — Cliniquement pertinent/final : *Étude thérapeutique sur un anti-ostéoporotique : critère pertinent sera la diminution du nombre de fractures* ; Intermédiaires ou Critères de substitution (en anglais : surrogate) : *Étude thérapeutique sur un anti-ostéoporotique : on suppose que l'augmentation de la DMO sera corrélée à une diminution de survenue du nombre de fractures ostéoporotiques*

Exemples classiques

Cliniquement pertinent/final :

- Mortalité toute cause ++ (CDJ le plus robuste, le plus indiscutable, mais nécessaire souvent beaucoup de patients pour assurer une puissance statistique suffisante pour montrer une différence)
- Mortalité spécifique d'une pathologie
- Survenue de la pathologie étudiée (IDM, infection , AVC ...), d'une complication de la pathologie étudiée, d'effets secondaires du traitement
- Qualité de vie, incapacités, handicaps

Intermédiaires ou Critères de substitution (en anglais : surrogate) :

- Dosages biologiques (glycémie, CRP …)
- Constantes cliniques (PA, FC, PIC …)
- Scores radiologiques (densité minérâle osseuse …)

Avantages — Cliniquement pertinent/final : Augmente la pertinence clinique de l'étude ; Intermédiaires ou Critères de substitution (en anglais : surrogate) : Permettent une évaluation à court-terme avec une durée de l'étude **moins longue** et un nombre de patients recrutés moins importants (**coût moindre**), **plus simple**

Inconvénients

Cliniquement pertinent/final :

- Étude plus **longue**
- Étude plus **chère**
- Étude plus **complexe**

Intermédiaires ou Critères de substitution (en anglais : surrogate) :
Critères intermédiaires ne sont pas forcément corrélés avec la mortalité ou les évènements cliniques (lié peut être faussé avec le CDJ pertinent) ⚠️

- être très critique

Objectif ou Subjectif ?

Comment limiter les conséquences d'un critère de jugement subjectif ? ✅

Validité interne

- Risque du CDJ subjectif : **défaut de reproductibilité inter-observateur** et **intra-observateur**
- Afin de limiter ce risque :
  - Échelle validée pour évaluer le CDJ (ex. pour la qualité de vie : échelle SF36)
  - Mode d'évaluation doit être défini a priori et standardisé

- Critère de jugement doit être bien standardisée
- Évaluation double aveugle (par 2 personnes de manière indépendante)
- Évaluation centralisée avec un comité indépendant (appelé **comité d'adjudication**)

Biais d'évaluation

- **Risque de biais d'évaluation majeur si l'évaluation du CDJ se fait en ouvert** ⚠️
- Patient doit être en aveugle du traitement reçu + Évaluation doit être faite en aveugle du traitement reçu

Décès toute cause vs Décès spécifique

> ***Justifier un critère de jugement principal de type « mortalité totale » ou « mortalité toute cause » par rapport à un critère de type « mortalité spécifique »***

Question EDN sélective

- Un critère de type « **décès toute cause** » sera toujours préférable à un « **décès spécifique** » car :
  - **évite le biais de classement** (**PCZ**) (lié à la difficulté de déterminer la cause spécifique du décès)
  - prend en compte les décès non spécifiques mais **liés à l'intervention** (ex : AVP sur insomnie comme effet secondaire du traitement testé)
  - **ne diminue pas la probabilité de montrer une différence** car la randomisation assure *a priori* une comparabilité initiale des groupes avec une probabilité de décès avant intervention proches dans les deux groupes (même moyenne d'âge, même proportion d'insuffisants rénaux, même proportions de fumeurs…)

Définition — Critère objectif : CDJ dont l'évaluation est incontestable et ne peut pas être sujette à des interprétations différentes selon la personne qui l'évalue ; Critère subjectif : Critères rapportés par le patient ou dont l'évaluation est soumise à l'interprétation de l'individu

Exemples

Critère objectif :

- Mortalité toute cause ++ (c'est le meilleur)
- Survenue d'une pathologie avec des critères diagnostiques précis et fiables (SCA, syndrome d'activation macrophagique ...)
- Survenue d'une complication de la pathologie avec des critères diagnostiques précis et fiables
- Examens biologiques sans interprétation par le biologique

(ex. mesure de la glycémie)

Critère subjectif :

- **Rapportés par le patient** :
  - Douleur évaluée par EVA
  - Échelles fonctionnelles, sur la qualité de vie, sur la dépression ...
- **Soumise à l'interprétation de l'individu** :
  - Évènements cliniques (ex. IDM)
  - Critères radiologiques (ex. récidive tumorale évaluée par TDM)
  - Mortalité cause-spécifique (ex. mortalité cardiovasculaire)

Avantages

Inconvénients

Critère objectif :

- Augmente la validité interne
- Évaluation du critère de jugement principal possible en ouvert **sans risque de biais d'évaluation** ✅

Critère subjectif :

- **Diminuent la validité interne** (car ↓ reproductibilité)
- **Risque de biais d'évaluation majeur** en cas d'évaluation du critère de jugement principal en ouvert

---

Disponibilité chez tous les patients (faisabilité du receuil du critère de jugement)

Certains critères de jugement sont évalués lors d'examens radiologiques comme la présence d'un thrombus à la phlébographie de contrôle à 12 mois. Ces critères sont peu pertinents cliniquement, leur évaluation est subjective et en plus ils sont souvent associés à un grand nombre de données manquantes (regarder sur le flow chart le nombre de patients ayant reçu l'examen...)

Exemple

> *Exemple :*

Essai contrôlé randomisé pour évaluer l'efficacité de 2 dosages différents d'Enoxaparine (héparine de bas poids moléculaire)[1] :

"The primary outcome with respect to efficacy was venous thromboembolism (defined as deep-vein thrombosis, pulmonary embolism, or both) between days 1 and 14. The secondary outcome with respect to efficacy was venous thromboembolism between days 1 and 110. Patients were examined for deep-vein thrombosis by systematic ascending contrast venography of the legs between days 6 and 14, or earlier if thrombosis was clinically suspected. If venography was infeasible, venous ultrasonography was performed."

Temps d'intérêt principal

Biais de comparaisons multiples

Définition

Lorsqu'on réalise plusieurs mesures, il existe un risque que l'une des mesures soit statistiquement significative simplement par le fait du hasard, plus on réalise de mesures et plus ce risque augmente

(= inflation du risque alpha, soit augmentation du risque de conclure à tort à l'existence d'une différence qui existe)

Situations

à risque

- Analyse sur plusieurs critères de jugement secondaires
- Analyse en sous-groupes avec analyse sur plusieurs sous-groupes de patients
- Analyse intermédiaire avec mesures répétées du critère de jugement principal

- Analyse du critère de jugement principal sur > 2 groupes différents (3 ou 4 maximum en pratique)

Comment le limiter ?

Afin de limiter le biais des comparaisons multiples (inflation du risque alpha), il existe l'ajustement du risque alpha (pondération du risque) par une méthode type Bonferroni (la plus simple) ou O'Biren et Flemming

Principe de la méthode de Bonferroni :

- Consiste à diviser le seuil de signification (en général fixé à alpha = 0,05) par le nombre de tests
- ex. si 10 comparaisons multiples sont faites, on retiendra comme significatives celles dont le seuil est < 0,005

Autre solution

Dans les cas des mesures répétées du CDJ principal, afin de contrôle le risque d'inflation du risque alpha, on peut se ramener à 1 seul critère de jugement qui sera suivi dans le temps par une analyse de survie de Kaplan-Meier

(pas pour la réduction du risque d'inflation du risque alpha dans les mesures de plusieurs CDJ secondaires)

Définition. CDJ principal doit toujours être **évalué à un moment précis**, appelé le temps d'intérêt principal de l'étude (ex. à J9 du traitement, ou après 12 semaines de suivi …)

Risques. Si le CDJ principal est évalué à de nombreuses reprises (plusieurs mesures), il existe un risque de **biais de comparaisons multiples** avec inflation du risque alpha

Critères de jugement secondaires

Schéma

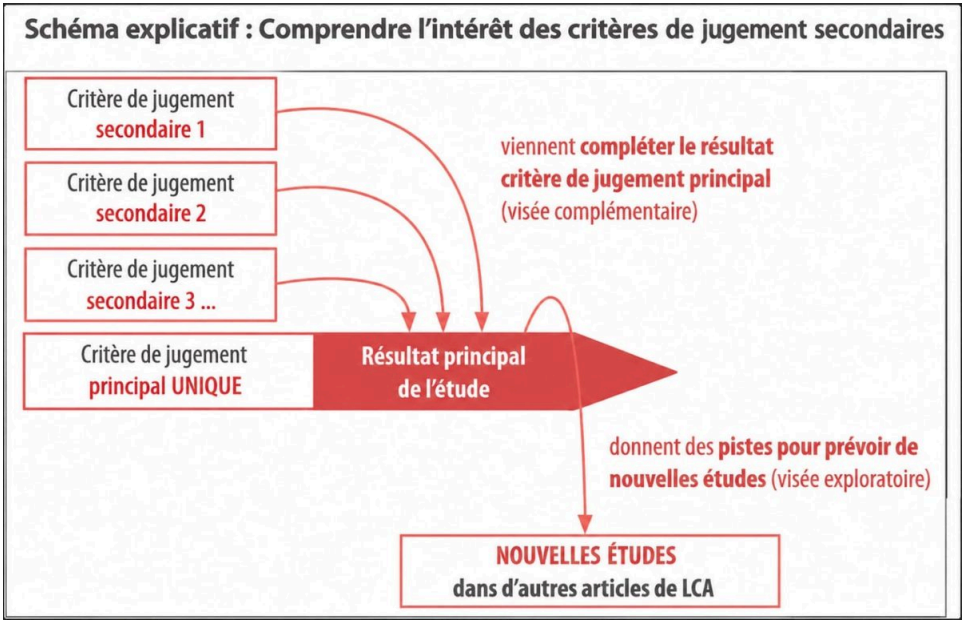


image.png

Focus : Analyse séquentielle des critères de jugement

- **Principe**
  - type de stratégie très particulier (et de plus en plus à la mode) qui consiste à **prévoir *a priori* un ordre dans lequel les critères vont être testés** (critère de jugement principal, puis critère de jugement secondaire n°1, puis critère de jugement secondaire n°2…)
  - puis, si la différence est statistiquement significative sur le critère de jugement principal, alors on s'autorise à conclure sur le critère de jugement secondaire n°1 si c'est statistiquement significatif, puis si c'est le cas alors on pourra conclure sur le critère de jugement secondaire n°2… et ainsi de suite pour les critères suivants, jusqu'à tomber sur un critère non significatif
- **1 intérêt**
  - autorise à conclure sur un ou plusieurs critères de jugement secondaires autre que la tolérance

Rôle

Rôle seulement **exploratoire** ou **complétement** :

- **seulement si le résultat attendu est significatif sur le CDJ principal** ⚠️ (analyse dépendante de celle du CDJ principal)
  - permet de renforcer le message apporté par l'analyse du CDJ principal, et de dégager des pistes pour des études ultérieures

Conclusion

Ils **n'influencent jamais la conclusion principale de l'étude** ❌ (on ne peut jamais conclure sur un CDJ secondaire), car :

- **NSN** calculé pour une puissance suffisante sur l'évaluation du CDJ principal seul *(donc NSN est insuffisant pour CDJ secondaires)*

Risque. Si ils sont trop nombreux → risque d'inflation du risque alpha

Cas des essais thérapeutiques

Ici, le « 1er CDJ secondaire » correspond toujours aux critères de tolérance ou de sécurité avec effets indésirables

- Tolérance est le seuil CDJ secondaire qui peut être **analysé indépendamment du CDJ principal d'efficacité** ⭐

(**exception importante** très sortable en QCM)

Si pertinent

et significatif

En cas de CDJ secondaire pertinent et signficatif

- CAT : réaliser une autre étude en mettant de CDJ secondaire en CDJ principal dans une nouvelle étude ✅

Critères composites (ou combinés)

Exemple

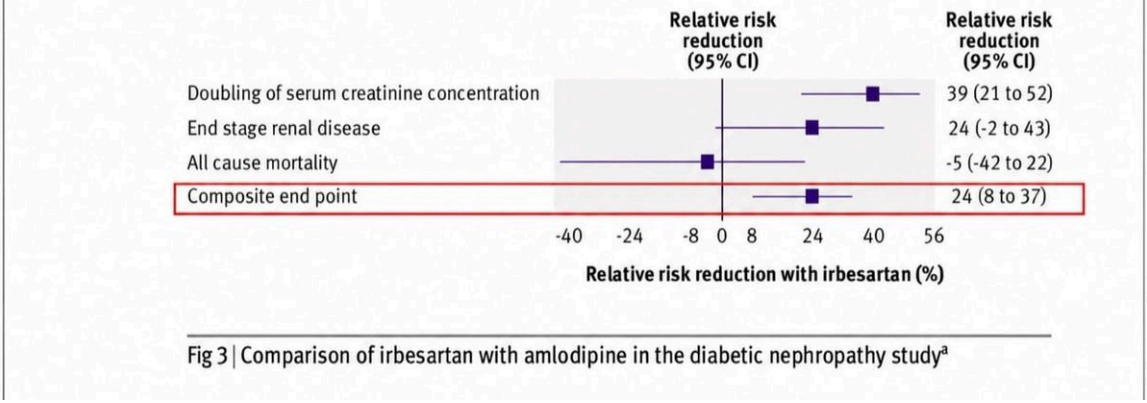


Fig 3 | Comparison of irbesartan with amlodipine in the diabetic nephropathy study[a]

image.png

> *Dans cet exemple, le critère de jugement composite est défini comme la survenue d'un décès, d'une insuffisance rénale terminale ou d'un doublement de la créatinine. Il y a une différence statistiquement significative pour le critère de jugement composite. Quand on regarde les composantes du critère composite, il n'y a pas de différence statistiquement significative pour la mortalité globale ni pour l'insuffisance rénale terminale qui sont deux critères importants pour le patient. La seule différence statistiquement significative observée est pour le critère « doublement de la créatinine » qui du fait de sa plus grande fréquence entraine la significativité statistique du critère composite. Mais ce critère est un critère intermédiaire qui n'est pas important pour le patient. Cet essai pose donc un problème d'interprétation du bénéfice pour le patient.*

Focus : critère composite homogène vs critère composite hétérogène

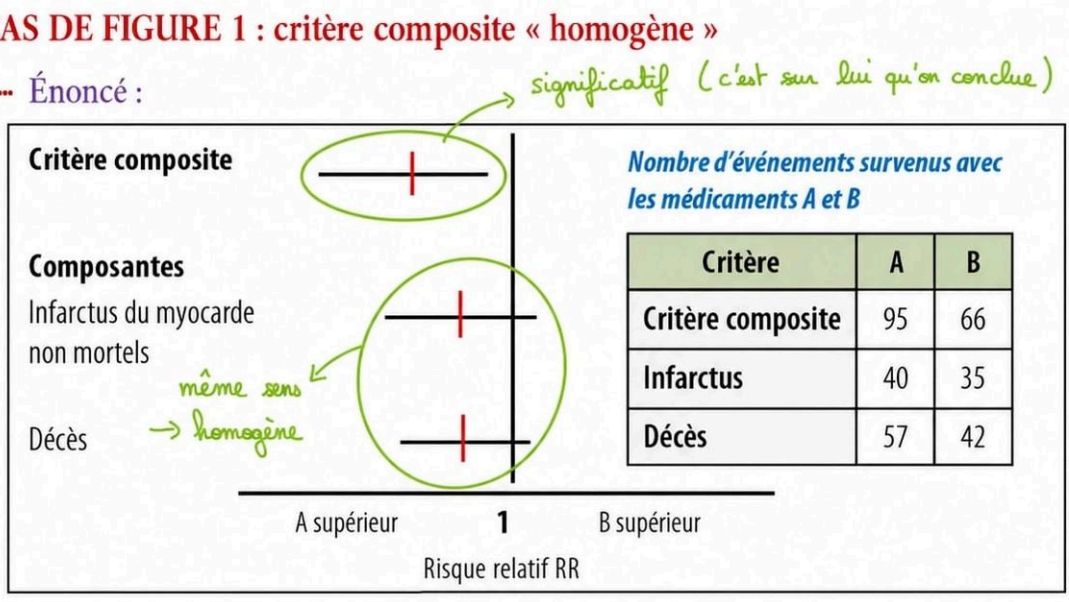


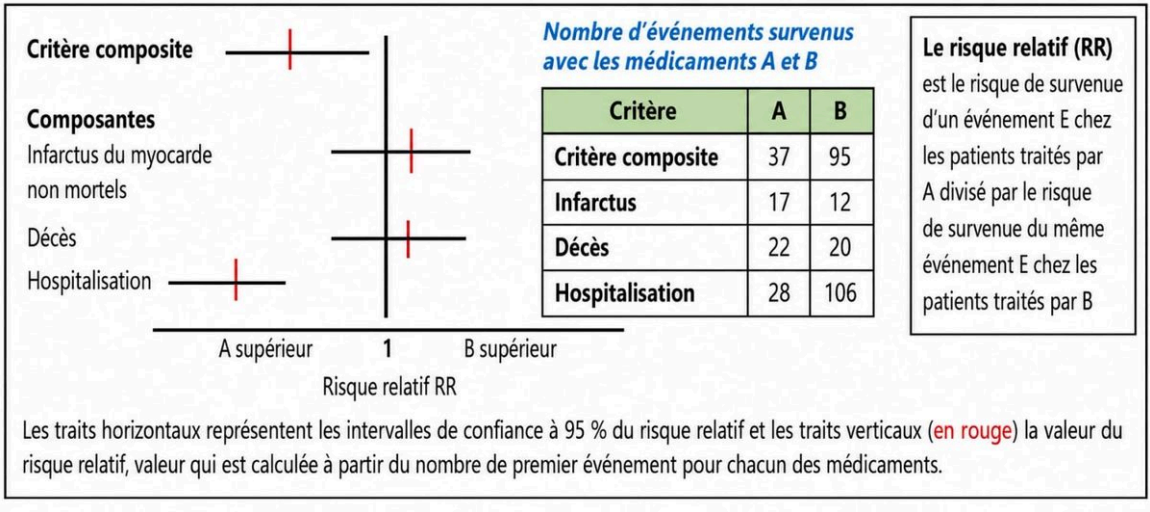
image.png

- **interprétation de la figure :**
  - **situation idéale** car bien que les résultats sur les deux composantes du critère composite ne soient pas significatifs, ils **vont tous les deux dans le même sens d'une réduction du risque relatif**

- le fait d'être non significatif n'est pas grave en soi puisque ce n'est pas sur ces composantes que nous allons conclure mais sur le critère composite (*pour rappel, c'est à partir de ce dernier que le calcul du NSN a été réalisé, calcul qui assure une puissance a priori suffisante au test sur le critère composite, contrairement aux tests réalisés sur les composantes prises isolément*)

- **conclusion de la figure :**
  - il s'agit d'un **critère composite HOMOGÈNE** (**PCZ**)
  - il est donc **possible de conclure que le traitement B est plus efficace dans la réduction à la fois des infarctus et des décès**

... énoncé :



Nombre d'événements survenus avec les médicaments A et B

Critère	A	B
Critère composite	37	95
Infarctus	17	12
Décès	22	20
Hospitalisation	28	106

Le risque relatif (RR) est le risque de survenue d'un événement E chez les patients traités par A divisé par le risque de survenue du même événement E chez les patients traités par B

Les traits horizontaux représentent les intervalles de confiance à 95 % du risque relatif et les traits verticaux (en rouge) la valeur du risque relatif, valeur qui est calculée à partir du nombre de premier événement pour chacun des médicaments.

image.png

- **interprétation de la figure :**
  - l'action du médicament A n'est pas homogène, car **aucune action positive de A n'est observable sur les infarctus et les décès** (le RR est supérieur à 1), contrairement aux hospitalisations
  - ainsi, **bien que le résultat sur le critère composite soit positif**, il n'est **pas licite de conclure simplement que le traitement B diminue à la fois le nombre d'infarctus, le nombre de décès et le nombre d'hospitalisations** (d'où l'importance d'analyser séparément chaque composante du critère composite car ici, le résultat du composite est probablement lié uniquement à la réduction du nombre d'hospitalisations)

- **conclusion de la figure :**
  - il s'agit d'un **critère composite HÉTÉROGÈNE** (**PCZ**)
  - cela **suggère un défaut de fiabilité (validité interne) du résultat énoncé sur le critère de jugement principal composite** (*le résultat n'est probablement que lié à la réduction du nombre d'hospitalisations*)

Focus : différencier un « CDJ composite » et des « critères de jugement multiples » ⭐

> **Attention, le modèle des critères de jugement multiples est très critiquable, car on ne peut pas conclure sur plus d'un critère de jugement**

Définition — CDJ composite : Fusion de plusieurs CDJ en 1 seul ; CDJ multiples : Étude en parallèle de plusieurs CDJ simultanément

Exemple — CDJ composite : *[SCA ou Décès toutes causes ou AVC] survenus au cours des 90 jours de suivi, avec le principe qu'un patient ne compte qu'une seule fois dès qu'il a réalisé l'un des événements* ; CDJ multiples : [SCA] et [Décès toutes causes] et [AVC] survenus au cours des 90 jours du suivi

Cependant, malgré ses définitions, la distinction entre ces deux entités n'est pas toujours simple en pratique. En effet, lorsque les auteurs définissent le critère de jugement principal dans la partie **Matériel et Méthode** en citant plusieurs critères, ce n'est pas toujours aisé de savoir s'il s'agit d'une **étude fusionnée** (evocatrice d'un critère composite) d'une « **étude en parallèle** » de ces critères (évocatrice de critères multiples).

La seule technique vraiment fiable pour en faire la différence est d'aller regarder dans la **partie Résultat**, le **nombre de résultats** présentés par les auteurs (voir schéma ci-dessous) :

- si présence d'autant de résultats que de critères mesurés = il s'agit de **critères de jugement multiples**
- si présence d'autant de résultats que de critères mesurés **+ 1 résultat global portant sur l'ensemble du composite** = il s'agit du **critère de jugement composite** (et les autres mesures de chacun des paramètres correspondent aux critères de jugement secondaires)

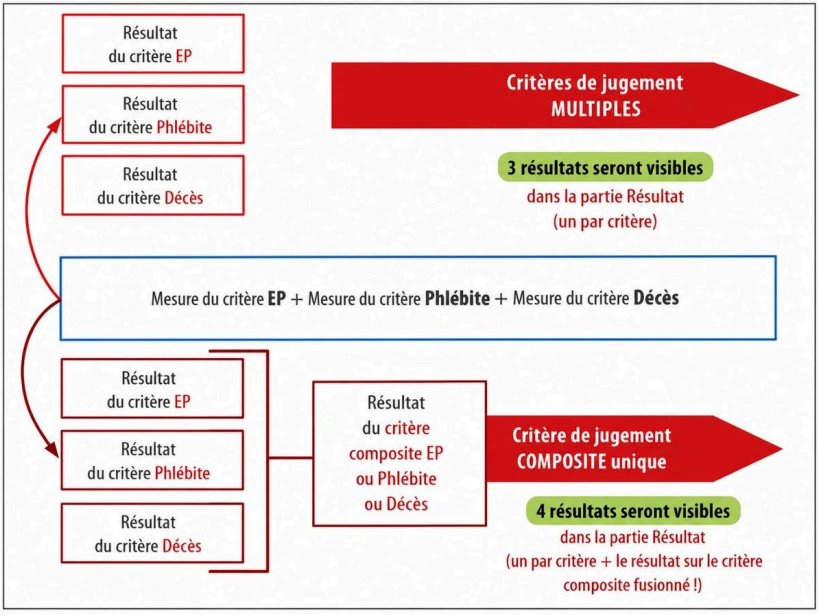


image.png

Définition

Combinaison de plusieurs critères en 1 seul et unique critère de jugement :

- Plusieurs sous-critères qui valident le CJP, réalisation de 1 seul de ces sous-critères suffit à valider le CJP ✅
- Si le patient a présenté plusieurs évènements du critère, on retient la date du 1er évènement

Exemple. *Il s'agit de critères composés de plusieurs évènements (souvent utilisés dans les essais en cardiologie, ex : la survenue d'un infarctus du myocarde, d'un AVC ou d'un décès), on considère que le patient a présenté le critère de jugement s'il a eu ≥ 1 de ces évènements*

Conditions

- NSN doit être calculé avec l'incidence cumulée de tous les critères : ce qui **permet de diminuer le NSN**
- Impossible de conclure que le traitement remplit 1 sous-critère précis : on pourra seulement conclure qu'il remplit de CDJ composite

(ex de conclusion : « nouveau traitement permet de diminuer de manière significative la survenue d'un IDM, d'un AVC ou d'un décès »)

- Conditions sur les composants du critère composite :
  - **Définis** comme des **critères secondaires** et rapportés dans l'essai
  - Même nature (on ne va pas additionner la pression artérielle et le décès)
  - Importance similaire (on va pas mettre au même niveau l'apparition d'une verrue à un d'AVC)

(en annale le CDJ composite incluait TVP et décès par EP)

- Fréquence de survenue approximativement similaire

(cette condition n'était pas prise en compte en annale)

- Estimation des effets du traitement similaires pour chacun des composants (car l'effet traitement est souvent plus important pour les évènements les moins graves mais qui sont le plus souvent les plus fréquents, il y a aura alors une différence statistiquement significative pour le critère composite et pas forcément pour les évènements les plus graves → pose problème quant à l'interprétation d'un bénéfice pour le patient)

Avantages

- Gain de puissance : en **augmentant la probabilité de survenue de l'évènement** (ou de **réduire l'effectif nécessaire** pour même puissance)
- Prendre en compte l'ensemble des évènements importants notamment quand on veut évaluer la balance bénéfice-risque (ex. si on veut évaluer l'intérêt d'un traitement anti-thrombotique, il peut être intéressant d'avoir un critère de jugement composite combinant des évènements ischémiques (évaluant l'efficacité du traitement) et des évènements hémorragiques (évaluant sa tolérance)
  - Correspond à la **situation clinique réelle**
  - Mesure la balance bénéfices/risques en regroupant facteur d'efficacité et tolérance (ex. décès par thrombolyse ou décès par IDM)
  - Aide les investigateurs à choisir le CDJ et à **gérer le problème des comparaisons multiples**C

Inconvénients

- Rend difficile l'interprétation du résultat et la comparaison avec d'autres études

(garder en tête que le critère composite ne pourra être analysé que dans son ensemble)

- Regroupe des événements de gravité différente
- Sous-estime la gravité d'une suite d'événements

Calcul du NSN

Afin d'assurer une puissance statistique suffisante (c'est-à-dire limiter suffisamment les fluctuations d'échantillonnage pour montrer une différence jugée cliniquement importante), il faut calculer le nombre de sujets nécessaires.

L'estimation du nombre de sujets nécessaires pour l'étude doit être faite a priori et planifiée pour des raisons scientifiques et éthiques

Il faut théoriquement inclure suffisamment de sujets pour avoir une forte probabilité de détecter une différence statistiquement significative qui doit correspondre à une différence « cliniquement importante » sur le critère de jugement principal

Calcul du nombre de sujet nécessaires (NSN)

Définition. Correspond au nombre de sujets chez qui le critère de jugement principal doit être évalué, avec une estimation du nombre de perdus de vue (souvent < 10%) afin de démontrer l'hypothèse de l'étude, il doit être **calculé à priori** dans le protocole de l'article

Calcul. NSN = (nombre de sujets à inclure) - (nombre estimé de perdus de vue)

Intérêt

Intérêts de calcul du NSN : réduire les coûts, réduire les délais de l'étude, garantir la puissance statistique des résultats du critère de jugement principal (NSN est étroitement lié à la puissance)

- En cas de NSN important : peut être nécessaire de réaliser une étude multicentrique

NSN des études descriptives

Pour une étude descriptive, le NSN est fonction de la précision souhaitée de l'estimation du paramètre évalué

- Précision = largeur de l'intervalle de confiance qui encadre l'estimation ponctuelle du paramètre évalué
- NSN est d'autant plus important que l'estimation souhaitée est précise

NSN des études explicatives

Pour une étude explicative, le NSN est déterminé à partir de :

- Risque α de 1ère espèce (**fixé par les auteurs**) : NSN d'autant plus grand que le risque alpha est faible
- Risque β de 2ème espèce (*puissance* = 1 - β, **fixé** par les auteurs) : NSN d'autant plus grand que la puissance souhaitée est élevée
- Taille Δ (delta) de la différence ou écart à mettre en évidence → **choisie pour être cliniquement significative**
  - Plus la taille de l'effet à mettre en évidence est **petite**, plus le NSN est **grand**
- Selon le type de critère de jugement principal ⭐ *(et non pas les critères de jugement secondaire)* :
  - Si critère quantitatif : **variance** ou **écart-type** (**estimée sur des études antérieures**)

- Si critère qualitatif : **risque de base du critère de jugement principal** (= risque en l'absence de traitement)

- Probabilité P de survenue ou incidence du critère principal dans le groupe contrôle (**non fixé par les auteurs**)
  - Plus l'évenement est **rare**, plus le NSN devra être **grand** pour montrer une différence
  - Si critère composite : calcul du NSN doit être fait avec comme incidence l'incidence cumulée de tous les critères

Autres paramètres

- Type d'étude (NSN sera plus grand pour infériorité >> supériorité > équivalence)
- Type de test statistique : test unilatéral ou bilatéral
- Plan expérimental = groupes parrallèles, croisés (cross-over) ou séquentiel
- Durée de l'étude : qui est fonction de la probabilité de survenue du critère principal
- Nombre de perdus de vue attendu : on ajoute habituellement 5% au nombre de sujet nécessaires calculé

(donc nombre d'inclus > NSN calculé)

- Données appariées
- Analyses intermédiaires ou mesures répétées prévues
- Nombre de groupes : plus le nombre de groupe est important, plus le NSN augmente

---

Il existe 2 types de puissance à distinguer :

Puissance à priori. Correspond au calcul du NSN

Puissance à posteriori

Puissance à posteriori dépend de :

- Validité interne : résultats statistiquement significatifs, absence de biais
- Effectif de l'échantillon : préciser la différence entre le nombre de malades analysés et le NSN
- Type d'analyse statistique

Alternative au NSN : calcul du nombre d'événements nécessaires

Proposée dans certains études (notamment en cas de progrès thérapeutiques récents importants sur la pathologie étudiée) : souvent le nombre d'événement observés est inférieur à ce qui était prévu dans le calcul du NSN car ce nombre d'évènement est prévu à priori selon les études précédentes (à une époque où la prise en charge de la maladie était moins bonne donc avec plus d'évènement)

Dans ce cas, on arrête l'étude lorsqu'on aura observé le nombre d'événements nécessaires

Règles d'éthique

Lois qui encadrent la recherche médicale (4)

- Déclaration d'Helsinki
- Loi Huriet-Sérusclat (décembre 1988)
- Loi de bioéthique (6 août 2004)
- Loi Jarde (16 juin 2016)

Conflit d'intérêt

- Pour les auteurs : les conflits d'intérêt en rapport avec l'étude doivent être mentionnées au début ou à la fin de l'article
- Si le promoteur est un laboratoire pharmaceutique : son rôle dans la conception, réalisation de l'étude et l'analyse des résultats, doit être précisé clairement

Résumé des autorisations nécessaires

Type de recherche

Recherche interventionnelle impliquant la personne humaine — Catégorie : Catégorie 1 : hors soins courants ; CNIL : Autorisation ou conformité MR1 ; CPP : Autorisation ; ANSM : Autorisation ; Consentement : Écrit ; Assurance : Oui *(pour le promoteur)*

Recherche interventionnelle impliquant la personne humaine — Catégorie : Catégorie 2 : soins courants ; Consentement : Oral

Recherche non interventionnelle impliquant la personne humaine (cohorte, cas-témoins, etc.)

Catégorie :
Catégorie 3

CNIL :
Autorisation ou conformité MR3

CPP :
Autorisation

ANSM :
Information

Consentement :
Non-opposition
(≠ consentement)

Assurance :
Non

Prérequis pour les études interventionnnelles ✅
Obtention de l'avis favorable du Comité de Protection des Personnes (CPP) = comité d'éthique de l'hôpital indépendant multi-disciplinaire

Obtention de l'accord de l'ANSM seulement si étude thérapeutique
Comité indépendant de surveillance
(gère les analyses intermédiaires pour arrêt éventuel de l'étude)
Assurance obligatoire pour le **promoteur**
Consentement libre et éclairé
Seules les personnes bénéficiant de la Sécurité Sociale peuvent être incluses en France

Vérifier le respect des règles éthiques

Consentement libre et éclairé, par écrit et signé après information du patient, avec délai de réflexion

Révocable ? Révocable à tout moment = droit de mettre fin à sa participation à tout moment de l'essai sans conséquences

Révocable ?

- Information du patient et délai de réflexion sur : objectif de l'étude, méthodologie, bénéfices, risques, contraintes prévisibles ...
- Autorisation de publication de documents si photographies
- Confidentialité des données
- Respect des lois et bonnes pratiques cliniques

Si Mineur ? Si le patient est mineur **< 18 ans** : autorisation des 2 parents nécessaires

Cas où le consentement écris n'est pas nécessaire. Études observationnelles épidémiologiques (non-interventionnelles) : néanmois le **principe de la non-opposition** doit être présent (le patient n'a pas exprimé son opposition à ce type de recherche, le plus souvent il s'agit de récupérer les dossiers médicaux du patient pour récupérer les données)

Cas où le consentement éclairé n'est pas nécessaire

- Études épidémiologiques de cohorte rétrospectives sans modification de prise en charge du patient
- Si étude épimiologique cas-témoin avec contraintes (liées à la quantification de l'exposition) : consentement éclairé sera nécessaire ⚠️

Respect de la clause d'ambivalence (équipoise en anglais)

Quand ? Uniquement pour les études interventionnelles

Principe d'ambivalence
Tout patient inclus dans un essai thérapeutique doit pouvoir recevoir n'importe lequel des traitements étudiés, donc :

- Patient **ne doit pas présenter de contre-indication** à l'un ou l'autre des traitements pour pouvoir être inclus
- Patient **ne doit pas présenter d'indication** à l'un ou l'autre des traitements pour pouvoir être inclus
  - *principe réalisé en modulant les critères d'exclusion*

Principe d'équipoise. Il doit exister une incertitude sur l'efficacité de l'intervention évaluée, si ce n'est pas le cas, ce n'est pas éthique de conduire l'essai car cela expose les patients du groupe contrôle à une perte de chance

À ne pas confondre

*À ne pas confondre avec la **clause d'ignorance** dans la randomisation*
(où le médecin ne sait pas dans quel groupe va aller le patient : rien à voir)

Piège en annale

Si le patient refuse de donner son consentement, ou ne peut pas consentir (ex. démence), il ne sera pas inclus

- mais **ça n'a rien à voir avec la clause d'ambivalence**

Vérifier que la conception de l'étude est en accord avec les règles éthiques

- Protocole en accord avec les lois qui encadrent la recherche médicale
- Étude justifiée et utile au regard des connaissances actuelles
- Méthodologie adaptée pour répondre à la question posée
- Absence de conflits d'intérêt
- Existence d'un groupe contrôle : par traitement de référence si il existe, ou sinon par placebo
- Existence d'analyses intermédiaires prévues à priori dans le protocle, permettant un arrêt prématuré de l'étude si besoin : nécessité de fournir à la société des preuves solides, mais risque de priver les patients d'un traitement efficace

> **Absence de l'un de ces élements éthiques est une faute grave, avec des santions qui peuvent être pénales**

Acteurs importants d'une étude de LCA

Promoteur
(sponsor)
Correspond à un groupe pharmaceutique ou laboratoire ou entreprise ou un individu, qui est à l'initiative de l'essai

- Si le promoteur est un laboratoire pharmaceutique ⚠️ : son rôle dans la conception/réalisation de l'étude et analyse des résultats, doit être précisé
- **Finance** le déroulement de l'étude, et/ou est chargé de trouver le financement
- Recueille les autorisations et avis obligatoires des différents comités (**CPP**, **ANSM**)
- Contracte une assurance obligatoire (seulement **en cas d'étude interventionnelle**)
- Désigne l'investigateur

Investigateur
(investigators)
Qui peut devenir investigateur (auteurs) dans une étude de recherche clinique ?

1. Classiquement : **médecin thesé** ou **chirurgien-dentiste associé à un médecin**

2. Depuis la loi Jarde 2016 : pour une étude de recherche clinique interventionnelle "hors médicaments, risques et contraintes minimes", l'investigateur n'est pas forcément un médecin mais une personne qualifiée

(**sage-femme**, **pharmacien**, **kinésithérapeutique**, **psychologue** ...)

- Rédige et **définit le protocole** a priori
- Assure le suivi des patients en cas d'étude prospective
- Produit les résultats de l'étude
- Doit rester indépendant des enjeux financiers = absence de conflit d'intérêt
- Dans le cas des essais multicentriques : il y a classiquement **1 investigateur par centre**, tous coordonnés par **1 unique investigateur principal**

Financeurs

(funders, funding sources)

Organismes responsables du financement de l'étude

Financement peut être en **espèce** ou en **nature** (provision de médicaments)

- il est attendu que les financeurs n'aient pas d'influence sur l'analyse des résultats pour ne pas biaiser les conclusions

Focus

Enregistrement du protocole de l'étude, à priori

Définition. Protocole = planification des détails techniques de l'essai (plan expérimentale, population étudiée, randomisation, NSN, plan d'analyse statistique, descriptions des intervention etc etc)

Quand ?

Doit être rédigé et enregistré à priori (avant l'inclusion du premier patient)

De plus en plus fréquemment, ce protocole est publié sous la forme d'un article

Pourquoi ?

Permet de mettre en évidence des **écarts au protocole**

(évaluer s'il y a eu des changements importants pouvant affecter les résultats au cours de l'essai)

Qui l'enregistre ? Investigateur principal ou Promoteur de l'essai

Où est-il enregistré ? Registre gratuit reconnu par l'OMS (le plus connu étant **ClinicalTrials.gov**, mais autres registres reconnus par OMS possible)

Exemple typique. Si les investigateurs font leur essai et se rendent compte au moment de l'analyse que le critère de jugement principal qui avait été défini dans le protocole n'est pas significatif et qu'il change pour mettre comme critère de jugement principal un critère de jugement secondaire dont le résultat est statistiquement significatif

Risque. En cas d'écart au protocole, cela va biaiser les résultats de l'essai (**Biais de présentation sélective des critères de jugement** ou « Selective outcome reporting »), car on **augmente le risque alpha** en faisant plus de tests statistiques (on va faire plusieurs tests sur plusieurs critères de jugement secondaires, jusqu'à choisir celui qui est statistiquement signitifs, hors cela va des

résultats statistiquement significatifs qui sont potentiellement dus au hasard et surestimer l'effet du traitement)

Prévention. Vérifier que ce qui est rapporté dans l'article est conforme à ce qui a été planifié dans le protocole est un élément essentiel pour apprécier la validité des résultats d'un essai

5 missions classiques de la HAS

- Élaboration de recommandations pour la pratique clinique
- Gestion des indicateurs pour l'amélioration de la qualité et de la sécurité des soins
- Certification des établissements de santé
- Rend des avis dans le cadre de sa mission d'aide à la décision des pouvoirs publics
- Améliore la qualité de l'information médicale sur internet et dans la presse, ainsi que les logiciels d'aide à la prescription

Analyse statistique

Éléments à prendre en compte pour le choix du test statistique

- Type de variable : qualitative, quantitative, censurée
- Distribution de la variable : normale (test paramétriques), non-normale
- Type d'expérience : données appariées, groupes parrallèles, étude de survie ...
- Conditions d'application : pour Chi-2 (n > 5), pour T de Student ou l'ANOVA (n > 5 ou distribution normale)
- Logiciels utilisés : reconnus (SAS - SPSS - Stata - EPI info ...) ou non
- Références bibliographiques

Globalement, une analyse statistique suit toujours le même plan

Analyse descriptive. Description brute des variables étudiées (résultats du CDJ), dans 1 seul groupe

Analyse univariée

Comparaison de 2 analyses descriptives portant sur le CDJ principal produites dans chacun des groupes

- Noter qu'en cas d'essais thérapeutiques randomisés, l'analyse univariée est suffisante en général grâce à la randomisation (sauf si stratification)
  - Noter qu'une analyse en sous-groupe est une analyse univariée pour chacun des sous-groupes analysés par rapport à l'événement étudié

Analyse multivariée (optionnelle). Comparaison de 2 analyses descriptives portant sur le CDJ principal produites dans chacun des groupes, en ajustant a posteriori ces résultats sur de potentiels facteurs de confusion, en tenant compte de co-variables

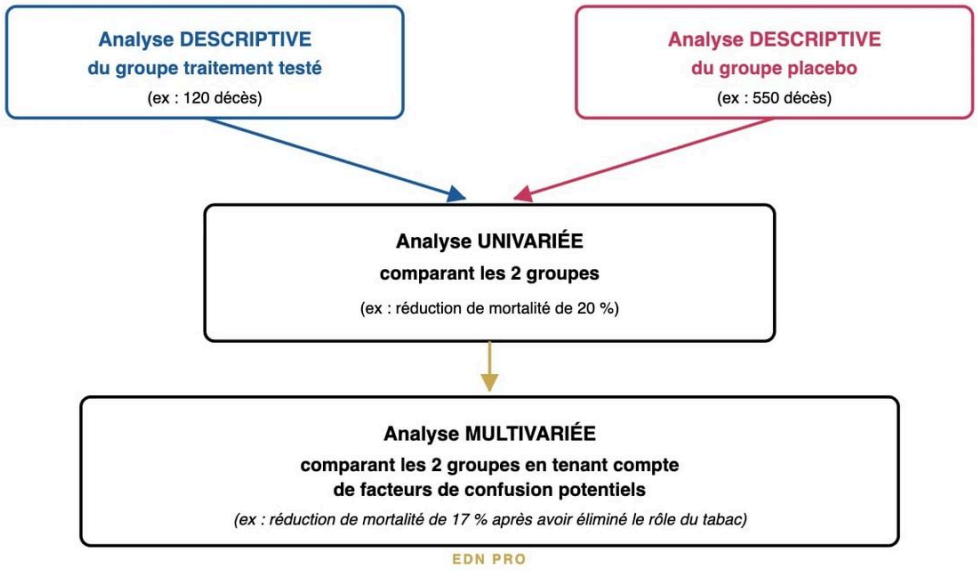


image.png

Ces niveaux d'analyse diffèrent selon le type de variable, certains tests statistiques correspondent à un certain type de variable

Types de variables

> **Ne pas confondre "variable qualitative" (décès) et l'expression quantitative de cette variable (pourcentage de décès)**

Variable quantitative

- Mesure d'une quantité prenant des **valeurs numériques**, reflète une **notion de grandeur**

(un résultat est plus grand ou plus petit qu'un autre)

- Il existe 2 types de variables quantitatives :
  - Discrètes : nombre fini et dénombrable de valeurs possibles, sans valeur intermédiaire possible (âge, nombre d'enfants, PAS)
  - Continues : nombre infini et non dénombrable de valeurs possibles (poids, dosage, échelle visuelle analogique continue)

Variable qualitative ou catégorielle

- Variable qui n'est pas naturellement associée à une valeur numérique, ne reflète pas une notion de grandeur
- Il existe 3 types de variables qualitatives :
  - Ordinales : catégories ordonnées (stade de gravité d'une maladie ...)
  - Nominales : catégories non-ordonnés (malade-non malade, groupe sanguin, sexe)
  - Dichotomiques/Binaires : uniquement 2 catégories possibles (sexe, malade/non-malade, 2 stades de gravité d'une maladie)

Variable censurée

- Suivi d'un groupe de patient pendant une période donnée jusqu'à une date de point (= date de fin de l'étude), :
- Critère de jugement un évenement binaire, VARIABLE CENSURÉE = VARIABLE QUALITATIVE ⭐

(ex. mort/pas mort, complication/pas de complication)

- Variables censurées :
  - Après la date de point, les données sont censurées à la date de point (vivants à la date de point)
  - Patients perdus de vue avant la date de point sont censurés à la date de dernière visite
- Calcul de la durée de participation dans l'étude :
  - Patient décédé avant la date de point : différence entre la date de décès et la date d'entrée dans l'étude
  - Patient perdu de vue : différence entre la date de dernier contact et la date d'entrée dans l'étude
  - Patient présente l'événement binaire : différence entre la date de survenue de l'événement et la date d'entrée
  - Patient n'a pas présenté l'événement binaire à la date de point : différence entre date de point et date d'entrée
- Types d'études qui utilisent des courbes de survie : Essais thérapeutiques, Cohortes pronostiques

Schéma

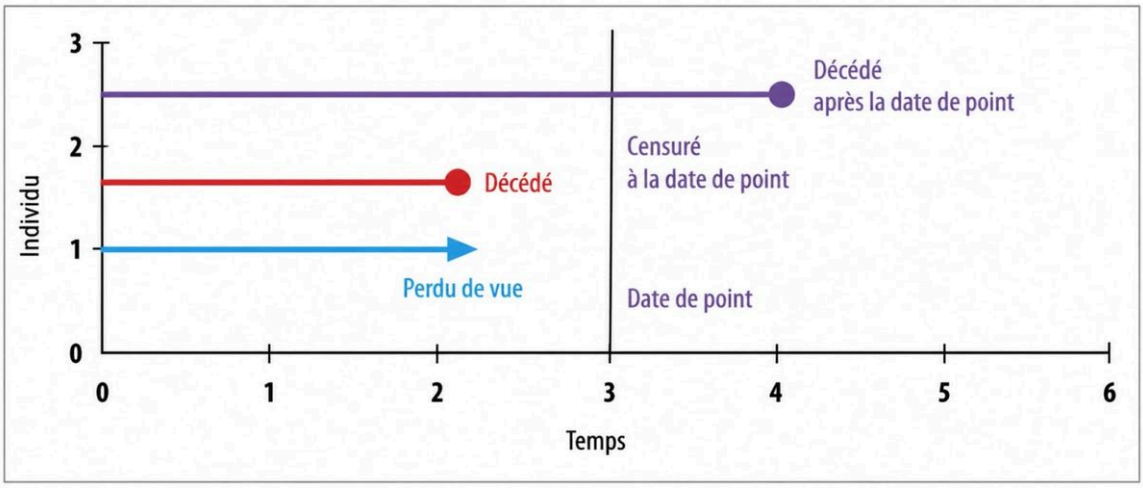


image.png

En médecine, on s'intéresse fréquemment au délai avant la survenue d'un évènement, par exemple le décès. En effet, ce n'est pas la même chose de décéder après un mois. C'est le cas par exemple dans les essais en cancérologie dans lesquels on veut montrer un bénéfice en termes de durée de survie avec un nouveau traitement. La durée de survie est continue. Cependant, on aura une valeur pour les patients décédés mais pas pour les patients survivants à la fin de l'étude. On sait seulement que leur durée de survie dépasse leur

durée de participation dans l'étude. Afin d'analyser correctement ces patients, on doit définir une date de point qui correspond à la fin de l'étude. Les patients qui ne sont pas décédés à la date de point sont censurés.

Pièges et points à comprendre ⚠️

- Variable binaire est un cas particulier de variable qualitative
- Ne pas confondre "variable qualitative" (décès) et l'expression quantitative de cette variable (pourcentage de décès)
- On précisera dans l'énoncé du QCM si la variable a une distribution normale ou non

Distinction parfois difficile entre variable qualititative ordinale et variable quantitative discrète

- Qualitative ordinale = les écarts entre 2 catégories ne peuvent pas être comparés

Focus : Indices d'effet

Risque relatif (RR) et Odds Ratio (OR)

- Objectifs : mesurer la force de l'association entre un facteur d'exposition et un événement
- Savoir dresser le **TABLEAU DE CONTINGENCE** (à connaître parfaitement !) :

Exposés (E^+)
Non-exposés (E^-)

M^+
a
c
Cote M^+ (cas) = a / c
OR = Cote M^+ / Cote M^-

M^-
b
d
Cote M^- (témoins) = b / d
Incidence E^+ = a / (a + b)
Incidence E^- = c / (c + d)
RR = IE^+ / IE^-

Exemples

- *Si le RR = 2,2 on peut dire que le risque de maladie chez les exposés est 2,2x plus élevé que chez non-exposés*
- *Si la prévalence de la maladie dans la population cible est de 8% et que l'on estime un OR à 1,5 sur un échantillon, alors on peut dire sans trop se tromper « le risque de maladie est 1,5 fois plus élevé chez les exposés que chez les non exposés » (phrase qui correspond normalement au risque relatif)*
- *Si la prévalence de la maladie dans la population cible est de 35% et que l'on estime un OR à 3,2 sur un échantillon, alors il est probable que la phrase « le risque de maladie est 3,2 fois plus élevé chez les*

exposés que chez les non exposés » soit fausse. Il faudra dire « il y a 3.2 fois plus de malades par rapport aux non-malades chez les exposés que de malades par rapport aux non-malades chez les non exposés. »

Risque relatif RR

Rapport de l'incidence estimée chez les exposés sur l'incidence estimée chez les non-exposées

- Utilisés pour les études de cohortes prospectives ou études transversales ⭐
  - Attention, le **calcul de l'incidence est impossible dans les études de cas-témoins** ❌

(car le nombre de cas et de témoins est fixé à priori)

Odds ratio OR

Rapport de la cote estimé chez les exposés sur la cote estimée chez les non-exposés

- on peut le calculer quel que soit le type d'étude (contrairement au risque relatif)

Si la prévalence de la maladie est faible (**maladie rare**) dans la population cible : OR est proche de RR, on dit que c'est un bon estimateur du RR, et on pourra l'interpréter comme un RR *(notamment dans les études cas-témoins)*

- détail important car dans les modèles de régression logistique, on ne peut estimer que des OR

Interprétation

- RR ou OR = 1 → pas de relation démontrée (mais ne n'élimine pas)
- RR ou OR > 1 → facteur de risque *(ex. OR ou RR de 1,2 augmente le risque de 20%)*
- RR ou OR < 1 → facteur protecteur *(ex. OR ou RR de 0,6 réduit le risque de 40%)*

Conditions d'interprétation

Il faut toujours interpréter un RR ou OR avec son :

- Intervalle de confiance à 95% → significatif si le RR/OR > IC et que l'IC ne comprend pas 1
- Degré de significativté p → p < alpha

Attention piège. Attention aux études de survie où le OR < 1 signifie que c'est un facteur de mortalité

Hazard Ratio (*hazard* = risque)

Définition. Il est l'**équivalent du RR pour des variables censurées**, pour donner les résultats des modèles de **survie** (modèle de Cox), il s'interprète comme un risque relatif à chaque instant (constant) : on parle de **rapport des risques instantanés de chaque groupe** (même principe qu'un RR mais plus précis car exprimé en fonction du temps)

Quand ? Utilisé quand le risque n'est pas constant au cours du temps (ex. étude pronostique)

Exemple. Pour HR = 3 sur étude épidémiologique sur le cancer = "3x plus de risque d'avoir un cancer à 2 ans"

Objet de l'étude

Interventionnelle

Variable qualitative

Indices d'effet :

Risque relatif (RR)

Réduction relative du risque

(RRR)Nombre de sujets à traiter (NST) = 1/RAR

Interventionnelle
Variable quantitative

Indices d'effet :
Comparaisons de moyennes

Corrélation

Interventionnelle — Variable censurée ; Indices d'effet : Analyse de survie (médiane de survie…)

Etiologique — Cohorte ; Indices d'effet : Risque relatif (RR)

Etiologique — Cas-témoins ; Indices d'effet : Odds ratio (OR)

Test diagnostique
Performance diagnostique

Indices d'effet :
Sensibilité (Se)
Spécificité (Sp)
Valeur prédictive positive (VPP)
Valeur prédictive négative (VPN)
Rapport de vraisemblance positif (RV +)
Rapport de vraisemblance négatif (RV -)

Test diagnostique — Impact du test ; Indices d'effet : **Idem études interventionnelles !!**

Différentes étapes de l'analyse statistique

> *voir aussi l'interprétation des tableaux de résultats en analyse univariée et multivariée : page 241-243*

> **Par convention il faut toujours un seul test statistique pour le critère de jugement principal**

Tableau récapitulatif des différentes étapes de l'analyse statistique selon le type de variable ⭐

Exemple — Variable qualitative (binaire souvent) : Mortalité à 30 jours ; Variable quantitative (souvent continu) : Douleur, qualité de vie ; Variable censurée (variable de survie) : Mortalité, survenue d'un IDM

Analyse descriptive
(objectif = décrire)

Variable qualitative (binaire souvent) :
Pourcentages (fréquences relatives)
Fréquences absolues

Variable quantitative (souvent continu) :

- Moyenne ET écart-type
- Médiane ET minimum-maximum ou Q1-Q3
  - *box plot*

Variable censurée (variable de survie) :

- Courbe de survie de Kaplan-Meier (médiane de survie)
- *Incidence cumulée*

Objectif — Variable qualitative (binaire souvent) : Comparaison de 2 pourcentages ; Variable quantitative (souvent continu) : Comparaison de 2 moyennes ; Variable censurée (variable de survie) : Comparaison de 2 courbes de survie

Analyse univariée :

- Tests statistiques
- Modèles statistiques univariés

(1 seule variable explicative)

Variable qualitative (binaire souvent) :

- Test du Chi-2 (paramètrique)
- Test exact de Fisher

(non paramètrique)

- Régression logistique univariée

(**OR** brut)

Variable quantitative (souvent continu) :

- Test t de T-Student

(paramètrique)

- Test de Wilcoxon

(non paramètrique)

- Test de Mann Whitney

(non paramètrique)

Variable censurée (variable de survie) :

- Test du Log rank
- Modèle de Cox univarié

(**HR** brut)

Analyse multivariée :

- Modèles statistiques multivariées (plusieurs variables explicatives), permet l'ajustement des facteurs de confusion

Variable qualitative (binaire souvent) :

Régression logistique

(permet d'obtenir un **OR** ajusté)

Variable quantitative (souvent continu) :

Régression linéaire multiple

Variable censurée (variable de survie) :

Modèle de Cox

(permet d'obtenir un **HR** ajusté)

Paramètrique (majorité des tests) : ne sont utilisables que si leurs conditions d'utilisation sont remplies (comme l'égalité et la distribution normale des variances pour le test de Student, ou des effectifs théoriques > 5 pour le test du Chi2)

Tests non paramétriques : **utilisés lorsque les conditions d'application ne sont pas remplies** (test de Mann-Whitney, le test de Wilcoxon, le coefficient de corrélation de Spearman sont les tests non paramétriques à connaître)

Variable

Principaux tests adaptés : **Si distribution normale** ; **Si distribution non-normale**

Qualitative (expression sous la forme de pourcentage …) — Principaux tests adaptés : soit Chi-2 (Mac Nemar si apparié)soit test de Fisher ; (idem)

Quantitative (expression sous la forme de moyenne …)

Principaux tests adaptés :

si 2 groupes = T de Student

si > 2 groupes = ANOVA

si 2 groupes = Mann Whitney

si > 2 groupes = Kruskal Wallis

Données appariées

Principaux tests adaptés :

si 2 groupes = T apparié

si > 2 groupes = ANOVA mesures répétées

si 2 groupes = Wilcoxon

si > 2 groupes = Friedman

Variable

Principaux tests adaptés : **Si distribution normale** ; **Si distribution non-normale**

Association entre 2 variables

Principaux tests adaptés :

Régression linéaire

Coefficient de corrélation (Pearson)

Coefficient de corrélation (Spearman)

Courbes de survie (données censurées)

Principaux tests adaptés :

Courbe de **Kaplan-Meier** = pour estimation de la probabilité de survie

Test du **Log-rank** = pour comparaison de 2 courbes de survie

Modèle de **Cox** = pour analyse multivariée (ajustement sur potentiels facteurs de confusion)

(idem)

Récap' sur choix du test statistique et Conditions d'application

En gros pour Z de l'écart réduit, T-student, et Test de corrélation il faut $n \geq 30$ avec une loi normale, et pour Chi-2 $n \geq 5$

Stratégie d'utilisation des tests statistiques (domaines d'application)

LE TEST. SERT À COMPARER OU À TESTER

Z de l'écart réduit. 1 moyenne observée à une moyenne théorique2 moyennes observées2 moyennes de 2 séries appariées

T de Student. 1 moyenne observée à une moyenne théorique2 moyennes observées2 moyennes de 2 séries appariées

Wilcoxon-Mann-Whitney. 2 moyennes de rangs de 2 séries ordonnées

Wilcoxon. 2 moyennes de rangs de 2 séries appariées

Chi-2 de conformité. 1 distribution observée à une distribution théorique

Chi-2 d'homogénéité. Plusieurs distributions, plusieurs pourcentages

Chi-2 de McNemar. 2 pourcentages sur 2 séries appariées

Chi-2 d'indépendance. Liaison entre 2 variables qualitatives

Chi-2 de tendance. Liaison entre variable ordinale et plusieurs pourcentages

Fisher exact. Des pourcentages, des distributions

Choix d'un test en fonction de la nature du problème

Comparer un échantillon à une population de référence ou théorique

Grandeur mesurée

Moyenne — Test statistique adapté : **Z de l'écart réduitT Student** ; Conditions d'application : Effectif échantillon **n ≥ 30Normalité** de la distribution

Pourcentage — Test statistique adapté : **Chi-2 de conformité** ; Conditions d'application : Effectifs théoriques **≥ 5**

Comparer deux échantillons entre eux

Grandeur mesurée

Moyennes — Séries Comparées : Indépendantes ; Test statistique adapté : Z de l'écart réduitT Student ; Conditions d'application : Effectif des 2 échantillons n1 et n2 ≥ 30Normalité des 2 distributions

Moyennes — Séries Comparées : Appariées ; Test statistique adapté : Z de l'écart réduitT Student ; Conditions d'application : Nombre de paires ≥ 30Normalité des différences

Moyennes de rangs — Test statistique adapté : Wilcoxon ; Conditions d'application : Nombre de paires > 20

Pourcentages — Séries Comparées : Indépendantes ; Test statistique adapté : Chi-2Fisher ; Conditions d'application : Effectifs théoriques ≥ 5

Pourcentages — Séries Comparées : Appariées ; Test statistique adapté : Chi-2 McNemar ; Conditions d'application : Nombre de paires discordantes ≥ 10

Distributions — Séries Comparées : Indépendantes ; Test statistique adapté : Chi-2 d'homogénéité ; Conditions d'application : Effectifs théoriques ≥ 5

Comparer plusieurs échantillons entre eux

Grandeur mesurée
Pourcentages

Test statistique adapté
Chi-2 d'homogénéité

Conditions d'application
Effectifs théoriques ≥ 5

Tester la liaison entre deux variables

Grandeur mesurée

Distributions — Test statistique adapté : Chi-2 d'indépendance ; Conditions d'application : Effectifs théoriques ≥ 5

Pourcentages — Test statistique adapté : Chi-2 de tendance ; Conditions d'application : Variable explicative de type qualitatif ordinal

Coefficients de corrélation — Test statistique adapté : Test de corrélationTest de Spearman ; Conditions d'application : Conditions d'un **test T de Student**Nombre de paires **> 10**

Choix d'UN test en fonction des paramètres à comparer

Comparaison de MOYENNES

Type de comparaison

Observé / théorique

TEST :
Z de l'écart réduit
T Student

Conditions d'application :
Effectif échantillon n ≥ 30
Normalité de la distribution

2 moyennes sur séries indépendantes

TEST :

Z de l'écart réduit

T Student

Conditions d'application :

Effectifs des 2 échantillons n1 et n2 ≥ 30

Normalité des 2 distributions

2 moyennes sur séries appariées

TEST :

Z de l'écart réduit

T Student

Conditions d'application :

Nombre de paires ≥ 30

Normalité des différences

Comparaison de POURCENTAGES

Type de comparaison

Observé / théorique

2 pourcentages sur 2 séries indépendantes

Sur 2 séries appariées

Plusieurs pourcentages

TEST

Chi-2 de conformité

Chi-2 d'homogénéité

Chi-2 McNemar

Chi-2 d'homogénéité

Conditions d'application

Effectifs théoriques ≥ 5

Effectifs théoriques ≥ 5 / test exact

Nombre de paires discordantes ≥ 10

Effectifs théoriques ≥ 5

Comparaison de DISTRIBUTIONS

Type de comparaison

Observée / théorique

2 ou plusieurs distributions

TEST

Chi-2 de conformité

Chi-2 d'homogénéitéFisher exact

Conditions d'application

Effectifs théoriques ≥ 5

Effectifs théoriques ≥ 5aucune

Résumé d'application

TEST

Z de l'écart réduit

pour COMPARER ou TESTER :
Moyenne observée/théorique
2 moyennes
2 moyennes de 2 séries appariées

Conditions d'application :
Effectif échantillon ≥ 30
Effectifs échantillons n1 et n2 ≥ 30
Nombre de paires ≥ 30

T de Student

pour COMPARER ou TESTER :
Moyenne observée/théorique
2 moyennes
2 moyennes de 2 séries appariées
Un coefficient de corrélation de Spearman
Un coefficient de corrélation

Conditions d'application :
Normalité de la distribution de la population
Normalité des 2 distributions et égalité des variances
Normalité des différences

Kruskal-Wallis — pour COMPARER ou TESTER : Plusieurs moyennes de rangs ; Conditions d'application : Effectifs de chaque échantillon ≥ 5

Chi-2 de conformité — pour COMPARER ou TESTER : Pourcentage observé/théorique ; Conditions d'application : Effectifs théoriques ≥ 5

Chi-2 d'homogénéité — pour COMPARER ou TESTER : Plusieurs distributions ou plusieurs pourcentages ; Conditions d'application : Effectifs théoriques dans chaque case ≥ 5

Chi-2 de McNemar — pour COMPARER ou TESTER : 2 pourcentages sur 2 séries appariées ; Conditions d'application : Effectifs théoriques dans chaque case ≥ 5

Chi-2 d'indépendance — pour COMPARER ou TESTER : Liaison entre 2 variables qualitatives ; Conditions d'application : Effectifs théoriques dans chaque case ≥ 5

Fisher exact — pour COMPARER ou TESTER : Pourcentages ou distributions ; Conditions d'application : Aucune

Analyse descriptive

Analyse descriptive des variables quantitatives : position (moyenne, médiane, mode), dispersion (écart-type, variance, interquartile)

Toute variable quantitative doit être décrite avec un paramètre de position (ou paramètre central) associé à un paramètre de dispersion qui permet de donner une estimation de la dispersion de la mesure au sein de l'échantillon

Paramètres de position

- Moyenne
- Médiane (50ème percentile, médiane est moins sensible aux valeurs extrêmes que la moyenne)
- Mode (valeur la plus représentée d'un variable quelconque dans une population donnée)

Paramètres de dispersion

- Écart-type, et Variance (carré de l'écart-type) : classiquement associés à la moyenne (représentent « l'écart à la moyenne »)
- Intervalle interquartile, quartile, déciles, centiles, étdendue (min-max), extrêmes : classiquement associé à la médiane

Selon la distribution de la variable

On représente en abscisse les valeurs de la variable, et en ordonnée, le nombre de patients

- Si la courbe a une forme de cloche, la variable à une distribution normale : utiliser la moyenne
- Si la distribution des valeurs est asymétriques, et que la courbe n'a pas une forme de cloche : utiliser la médiane ⭐
- Quand la distribution est unimodale et symétrique : mode = moyenne = médiane

Indices de POSITION — Pour une distribution NORMALE (selon une courbe de Gauss) : **Moyenne** ; Pour une distribution NON NORMALE : **Médiane**

Indices de DISPERSION

Pour une distribution NORMALE (selon une courbe de Gauss) :

Variance

Écart-type

Coefficient de variation

Pour une distribution NON NORMALE :

Extrêmes

Étendue

Quartiles

Intervalle interquartile

Déciles

Centiles

Analyse descriptive des variables qualitatives : fréquences absolues, pourcentages (fréquences relatives)

Repose sur le calcul de **fréquences** (absolues) et des **pourcentages** (fréquences relatives) ; elle permet d'évaluer :

Prévalence

Calcul de la prévalence

$$\text{Prévalence} = \frac{M}{N} = \frac{\text{Nombre de malades}}{\text{Population totale à un moment donné}}$$

Untitled

Mesure la proportion de malades présents dans la population à un moment donné, elle intègre 2 dimensions différentes :

- Durée de la maladie (plus la maladie dure longtemps, plus le nombre de malades est important)
- Vitesse d'apparition de nouveaux cas de la maladie dans la population (plus elle est grande, plus la prévalence augmente)

Comme la prévalence est estimée dans un échantillon de la population, il faut donner une mesure de la précision de cette estimation. Pour cela, on calcule l'intervalle de confiance à 95% de la prévalence

Calcul de l'intervalle de confiance d'une proportion (fréquence)

Soit un échantillon **n** sujets où la prévalence observé vaut **f**

Conditions : n suffisamment grand et f n'est pas voisin de 1 ou 0
avec $f = \frac{k}{n}$ où k est le nombre de fois où le caractère est présent dans n

La loi de distribution de la fréquence f a une distribution Normale de moyenne p et d'écart-type sf

$$sf = \sqrt{\frac{f \times (1-f)}{n}} \quad \text{soit une variance} \quad sf^2 = \frac{f \times (1-f)}{n}$$

Calcul de l'intervalle de confiance :

$$IC = \left[f - N_\alpha \times sf \; ; \; f + N_\alpha \times sf \right]$$

$$= \left[f - N_\alpha \times \sqrt{\frac{f \times (1-f)}{n}} \; ; \; f + N_\alpha \times \sqrt{\frac{f \times (1-f)}{n}} \right]$$

Avec $N_\alpha = 1,96$ pour $\alpha = 0,05$
$N_\alpha = 1,645$ pour $\alpha = 0,10$

Untitled

Incidence

Calcul du taux d'incidence

> *Elle peut être calculée de façon exacte dans les études de cohorte*

$$\text{Taux d'Incidence} = \frac{\text{Nombre de nouveaux cas pendant } \Delta t}{\text{Nombre de personnes - temps "à risque" pendant } \Delta t} = \frac{m}{PT}$$

Avec PT : Nombre de Personnes-Temps à risque cumulé sur la période c'est-à-dire la somme cumulée des durées pendant lesquelles les non-malades sont « à risque » de devenir malade.

Untitled

Quantifie le nombre de nouveaux cas de malades qui surviennent dans la population pendant une période de temps donnée (nécessité de préciser sur quelle période de temps le compte est fait)

Calcul de l'intervalle de confiance du taux d'incidence

> *Soit **TI** le taux d'incidence dans l'échantillon :*

$$\mathrm{Var}(TI) = \frac{m}{PT^2}$$

$$\sigma(TI) = \sqrt{\frac{m}{PT^2}}$$

$$IC = TI \pm N_\alpha \times \sqrt{\frac{m}{PT}}$$

image.png

Il existe une relation entre le taux d'incidence et la prévalence

Cette relation est valable si la population est stable, et le taux d'incidence est faible :

- Prévalence = Incidence x Durée moyenne de la maladie
- P = I x D

Calcul des personnes-temps (PT)

Méthode exacte

Dans le cas d'une étude de cohorte (suivi longitudinal), les données de suivi ainsi que les dates de survenues des événements sont connues de façons précises pour chaque sujet inclus : ceci permet

de calculer de manière exacte les PT « à risque »

Le **temps de participation** ou **durée d'exposition** au risque est la différence entre la date de fin de participation et la date d'origine (inclusion du patient), sachant que la date de fin de participation peut être selon les patients la date de l'événement d'intérêt (patient C), la date des dernières nouvelles (patient A), la date de point de l'étude (patient B) :

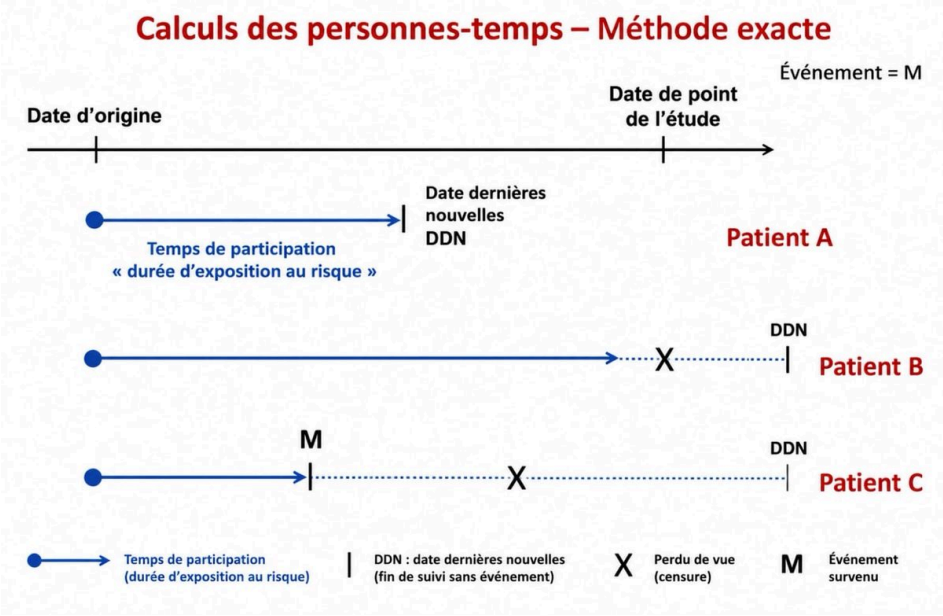


image.png

Méthode approchée

Il arrive souvent que la date exacte des évènements, comme une maladie, soit inconnue. La méthode exacte n'est donc plus utilisable car le temps réel d'exposition au risque (comme tomber malade ou être perdu de vue) ne peut être estimé exactement, celui-ci nécessitant un suivi longitudinal précis.

On utilise alors une méthode approchée qui suppose que les personnes décédées, perdues de vue ou tombées malades, ont été présentes et non malades pendant la moitié de la période observée :

- N0 et Nfin = nombre de sujets non malades présents respectivement en début et fin de période
- Nfin = N0 - (perdus de vus + malade)

$$PT = \frac{(N_{0\ \text{début de l'étude}} + N_{\text{fin de l'étude}})}{2} \times \Delta T$$

Untitled

Analyse descriptive des variables censurées : Kaplan-Meier, Incidence cumulée

Ici, on s'intéresse au risque instantané de décès, ou plus généralement de survenue de l'événement (risque d'instantané d'un évenement = probabilité de présenter cet événement à un moment donné, sachant qu'il n'est pas survenu précédement)

L'analyse descriptive des variables censurées repose sur la réalisation de courbes de survie (bien que le critère qui nous intéresse ne soit pas toujours le décès, cela peut être une infection, un IDM ...), généralement tracée avec la méthode de Kaplan-Meier

Méthode de Kaplan-Meier

Autre méthode de représentation graphique du Taux du survie : courbe actuarielle

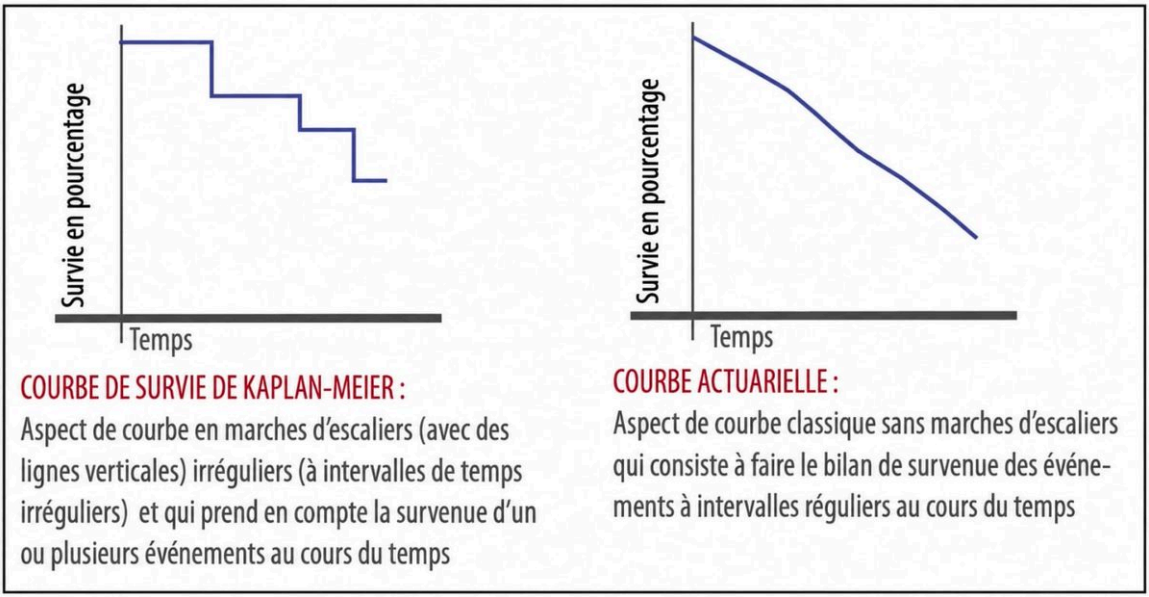


image.png

Variable

Courbe de Kaplan-Meier ne peut être utilisée que sur des variables dites censurées

Figure clé de toute étude avec analyse de survie (autrement dit : toute étude prospective évaluant la survenue d'un événement binaire en fonction du temps : survenue d'une complication [oui/non], hospitalisation [oui/non], décès [oui/non] ...)

Abscisse

Ordonnée

Permet de représenter, à chaque temps d'événement, le pourcentage de sujets n'ayant pas encore présenté l'événement d'intérêt :

- En abscisse : durée de suivi
- En ordonnée : probabilité (entre 0 et 1) de ne pas avoir présenté l'évènement, ou la proportion de patients (entre 0-100%) n'ayant pas encore présenté l'évènement

Date de point. Date à la laquelle les données de l'étude sont censurées, autrement dit, la date à laquelle on arrête de suivre les patients

Durée médiane de survenue

- Durée de suivi pour laquelle 50% des sujets n'ont pas encore eu l'événement (ou date pour laquelle 50% de l'effectif du groupe a réalisé l'événement binaire étudié),
- Attention si l'étude est terminée, et que < 50% des sujets ont présenté l'événement lors du suivi (ou que > 50% n'a pas présenté l'événement) :

- on ne peut pas estimer la durée médiane de survenue de l'événement

Nombre de sujet à risque

Souvent situé sous la courbe, le nombre de sujet à risque décroit en fonction du temps puisque à chaque palier de temps on enlève :

- perdus de vus, ceux qui présentent l'événement, exclus

p- value

Correspond à l'analyse univariée du test Logrank de comparaison entre les 2 courbes de survie de Kaplan-Meier :

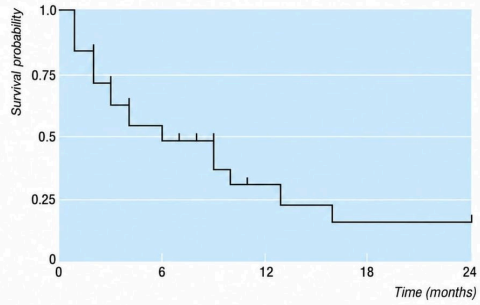
- si $p < \alpha$ on pourra dire qu'il existe une différence significative de survenue de l'événement binaire entre ces 2 groupes, en fonction du temps

La courbe commence à 1 (ou 100%) au temps 0, puisqu'au début de l'étude aucun patient n'a présenté l'évènement doit retrouver la population en intention de traiter). La courbe est décroissante, puisqu'au cours du temps certains patients vont présenter l'évènement

Ex. de courbe de Kaplan-Meier

Exemple :

Figure 5: Exemple de courbe de Kaplan-Meier



Survival curve showing probability of not conceiving among 38 subfertile women after laparoscopy and hydrotubation[2]

Le suivi était de 24 mois dans cette étude.

Ici, l'évènement est l'absence de conception (chez des femmes subfertiles). L'axe des ordonnées représente donc la probabilité de ne pas concevoir au cours du temps.

image.png

Exactement pareil ici.

Plan d'interprétation (4 étapes)

- Commencer par identifier la date de point : date à la laquelle les données de l'étude sont censurées, autrement dit, la date à laquelle on arrête de suivre les patients *(dans l'exemple ci-dessus : il est de 24mois)*

Estimation de la durée médiane de survenue de l'événement à partir d'une courbe de Kaplan-Meier

Il s'agit de la durée de suivi pour laquelle 50% ~~des~~ sujets n'ont pas encore eu l'événement (ou date pour laquelle 50% de l'effectif du groupe a réalisé l'événement binaire étudié)

Si l'étude est terminée, et que < 50% des sujets ont présenté l'événement lors du suivi (ou que > 50% n'a pas présenté l'événement) : on ne peut pas estimer la durée médiane de survenue de l'événement ❌

Question piège déjà tombée 2x au concours

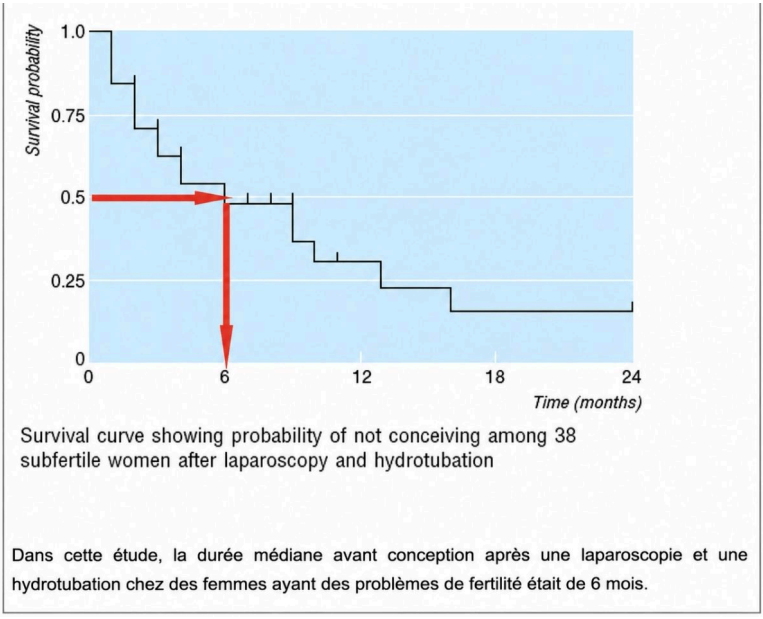


image.png

- Rechercher la p-value sur la figure (correspond à l'analyse univariée du test Logrank de comparaison entre les 2 courbes de survie de Kaplan-Meier) : si $p < \alpha$ on pourra dire qu'il existe une différence significative de survenue de l'événement binaire entre ces 2 groupes, en fonction du temps
- Être prêt à interpréter le nombre de sujet à risque (souvent situé sous la courbe, *absent dans l'exemple ci-dessus, mais présent dans l'exemple du Pezel*) : il est essentiel de comprendre que le nombre de sujet à risque décroit en fonction du temps puisque à chaque palier de temps on enlève : les perdus de vus, ceux qui présentent l'événement, et les exclus

Étudier l'allure de la courbe

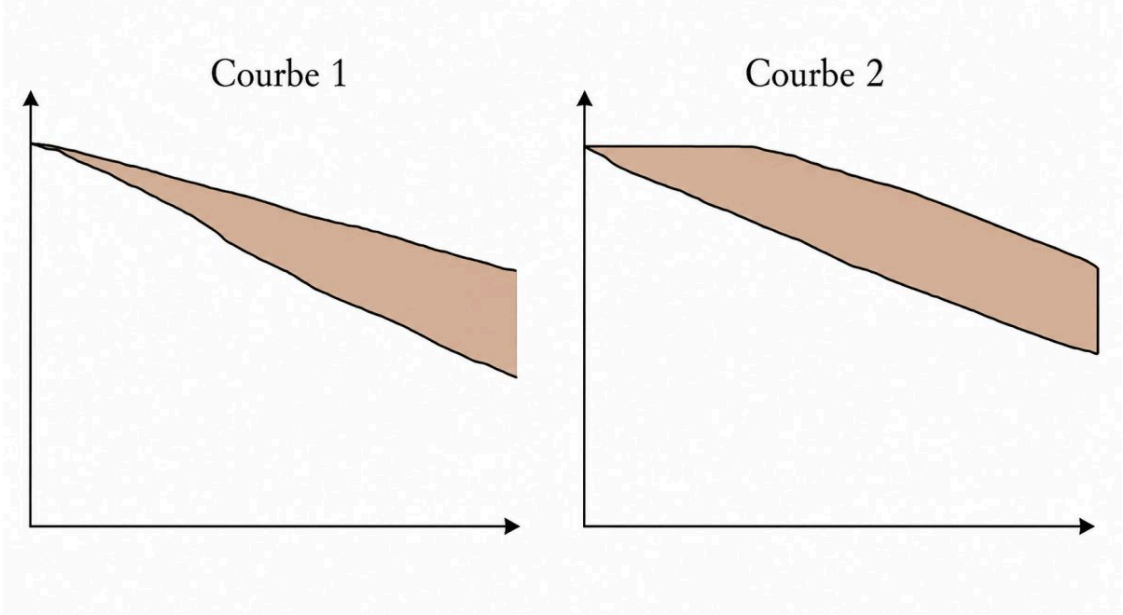


image.png

Il peut arriver que le correcteur demande si l'effet du traitement est continu ou prédomine à un moment de la prise en charge (initialement ou tardivement). Cette information peut être issue de l'analyse de la courbe de survie. Le moment où le traitement apporte un bénéfice se retrouve au moment où il arrive le mieux à « aplatir » la courbe de survie. Voici un exemple de courbe où le traitement orange est efficace sur le CJ de manière continue (courbe de gauche), et une seconde où le gain se joue initialement puis les courbes sont parallèles (courbe de droite). On voit que la différence entre les deux groupes (zone beige clair) est progressivement croissante pour la courbe 1 mais reste stable après un gain initial pour la courbe 2. Dans les deux cas, l'analyse sera significative. Le correcteur pourrait nous demander de donner notre impression sur l'effet continu ou initial du traitement

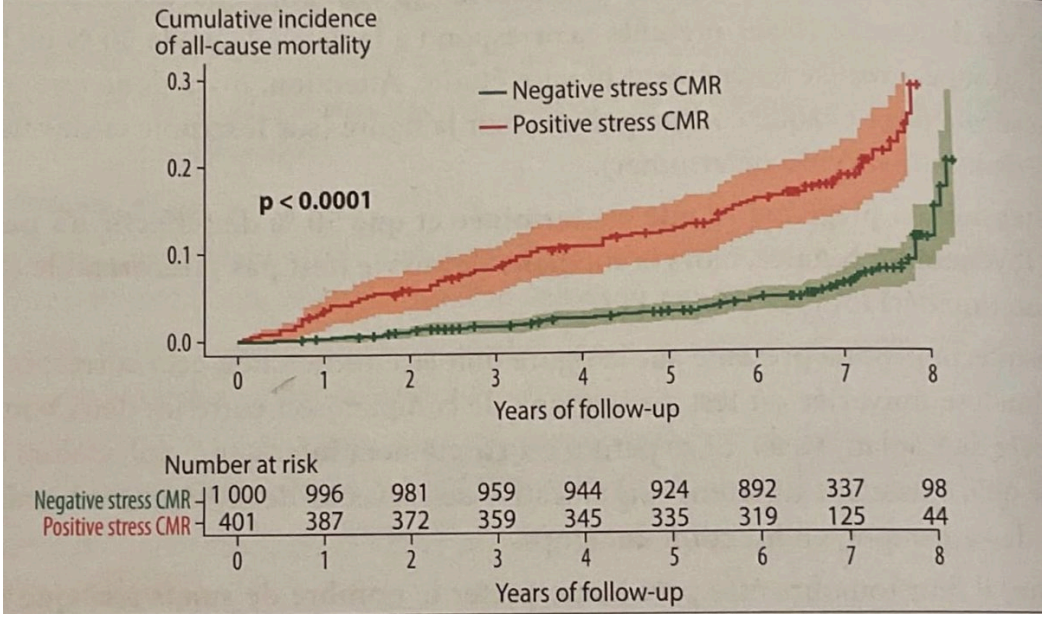
Cas particulier : courbe de survie de Kaplan-Meirer avec intervalle de confiance de 95%

Il s'agit d'un cas particulier de plus en plus recommandé en LCA, et qui s'analyse exactement comme une Kaplan-Meier classique

La seule différence est que l'on ajoute une représentation graphique de l'intervalle de confiance à 95% de chaque de Kaplan-Meier, qui apparaît comme une zone colorée de part et d'autre de la courbe

Intérêt = vérifier l'absence de chevauchement entre les 2 intervalles de confiance de chaque courbe :

- Si absence de chevauchement : augmente la validité interne des résultats *(comme dans l'exemple)*
- Si présence de chevauchement : diminue la validité interne des résultats



Untitled

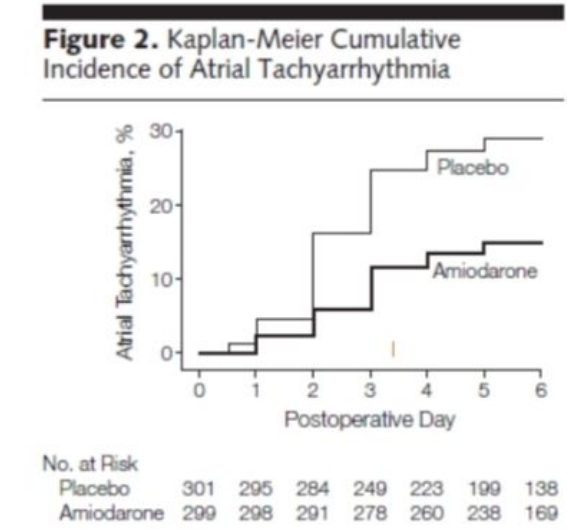
Piège : ne pas confondre la courbe de survie de Kaplan-Meier avec la Courbe d'incidence cumulée :

- Courbe de survie de Kaplan Meier : effectifs partent du haut de la figure en ordonnée, avec des courbes qui décroissent progressivement au fur et à mesure de la survenue des événements
- Courbe d'incidence cumulée, c'est le contraire : courbes augmentent avec le temps, au fur et à mesure de la survenur des événements
- Au-delà de cette différence, l'interprétation de ces 2 figures est absolument identique ✅

Incidence cumulée (autre présentation équivalente à la courbe de Kaplan-Meier)

> *Correspond à l'incidence de survenue d'un événement calculée en moyenne sur une longue période*

Consiste à représenter la proportion de sujets ayant présenté l'événement au cours du temps (incidence cumulée). La courbe est alors inversée : elle commence à 0 (personne n'a encore présenté l'événement au temps 0) et la courbe est croissante au cours du temps



Untitled

Focus : Comment identifier une variable qui suit une loi normale ?

Méthode descriptive

- Moyenne = Médiane
- Intervalle interquartile est symétrique autour de la médiane

(ex. moyenne = 10 = médiane, et intervalle interquartile = [6-14]

Méthode graphique. Courbe en cloche

Méthode analytique

Il existe 2 tests statistiques permettant de confirmer qu'une variable suit une loi normale :

- Test de Shapiro-Wilk
- Test de Kolmogorox-Smirnov

Analyse univariée ou bivariée (étude de l'association entre 2 variables)

Généralités sur les Tests statistiques

Lorsqu'on fait un test statistique, on cherche à déterminer si l'association entre 2 variables au niveau d'un échantillon est le simple fait du hasard, ou si elle est due à une différence réelle dans la population

Principaux éléments à prendre en compte dans les conditions d'applications d'un test statistique

- Adéquation entre la **distribution de la variable** étudiée, et la distribution théorique du test
- Vérifier la bonne comparabilité des 2 échantillons
- Taille **n** suffisante des échantillons ++
- Vérifier le rôle du hasard dans la sélection des échantillons comparés (recrutement systématique et consécutif)

Réalisation de ce test repose sur 2 Hypothèses

Situations à risque "d'inflation du risque alpha"

Définition

Lorsqu'on réalise plusieurs mesures, il existe un risque que l'une des mesures soit statistiquement significative simplement par le fait du hasard, plus on réalise de mesures et plus ce risque augmente

(= inflation du risque alpha, soit augmentation du risque de conclure à tort à l'existence d'une différence qui existe)

Situations

à risque

- Analyse sur plusieurs critères de jugement secondaires
- Analyse en sous-groupes avec analyse sur plusieurs sous-groupes de patients
- Analyse intermédiaire avec mesures répétées du critère de jugement principal
- Analyse du critère de jugement principal sur > 2 groupes différents (3 ou 4 maximum en pratique)

Comment le limiter ?

Afin de limiter le biais des comparaisons multiples (inflation du risque alpha), il existe l'ajustement du risque alpha (pondération du risque) par une méthode type Bonferroni (la plus simple) ou O'Biren et Flemming

Principe de la méthode de Bonferroni :

- Consiste à diviser le seuil de signification (en général fixé à alpha = 0,05) par le nombre de tests
- ex. si 10 comparaisons multiples sont faites, on retiendra comme significatives celles dont le seuil est < 0,005

Autre solution

Dans les cas des mesures répétées du CDJ principal, afin de contrôle le risque d'inflation du risque alpha, on peut se ramener à 1 seul critère de jugement qui sera suivi dans le temps par une analyse de survie de Kaplan-Meier

(pas pour la réduction du risque d'inflation du risque alpha dans les mesures de plusieurs CDJ secondaires)

Exemples

Exemple 1 :

« At the end of the 12-week treatment courses, 27% of patients treated with efalizumab (98/369) achieved PASI-75 compared with 4% of patients who received placebo (8/187), p<0.001 »

Dans cet exemple, p<0.05, il y a une association significative entre le traitement et le PASI-75 qui est le critère de jugement principal de l'étude. **p<0.001** signifie qu'il y a moins d'une chance sur

1000 que le hasard puisse expliquer à lui tout seul une différence au moins aussi grande que celle qu'on a observée (27% vs. 4%).

Exemple 2 :

« Overall, 32 of the 229 (14%) had complete clearance of all plantar warts at 12 weeks, corresponding to 17/119 (14%) patients in the salicylic acid group and 15/110 (14%) patients in the cryotherapy group, p=0.89 »

Dans cet exemple, p > 0.05, la probabilité de disparition de la verrue plantaire (le critère de jugement principal) ne diffère pas significativement entre les 2 groupes de traitements (acide salicylique et cryothérapie). On ne peut rien conclure d'autre. Notamment, **on ne peut pas conclure que les 2 traitements ont une efficacité équivalente** en termes de disparition de la verrue.

H0

Hypothèse nulle (H0) : il n'y a pas de différence entre les 2 groupes

- *il s'agit le plus souvent de l'hypothèse qui n'est pas souhéaité par l'auteur qui réalise son étude*

H1

Hypothèse alternative (H1) : il y a une différence entre les 2 groupes

- *il s'agit le plus souvent de l'hypothèse que le clinicien souhaite démontrer dans son étude*

Risque α

Il s'agit du risque de 1ère espèce, considéré comme le plus grave :

- Risque de conclure à une différence qui n'existe pas en réalité (probabilité d'accepter H1 alors que H0 est vraie)
- Valeur : généralement fixé à 5%
- Risque alpha est **fixé a priori** (car le clinicien souhaite montrer H1, donc le fait de fixer alpha a priori permet de protéger la société d'une mauvaise intention du clinicien à vouloir prouver H1 coute que coute)

Risque β

Il s'agit du risque de 2nd espèce :

- Risque de ne pas mettre en évidence une différence qui existe (probabilité d'accepter H0 alors que H1 est vraie)
- Valeur : 1 - puissance
- Risque beta **n'est pas fixé**, mais l'objectif sera de choisir le test statique adapté à la situation clinique afin de minimiser le β

Puissance

- Probabilité de mettre en évidence une différence qui existe (probabilité de rejeter H0 si H1 est vraie)
- Valeur : en général > 80%

p

Résultat du test statistique est le p ou degré de significativité (ou degré de signification, ou p-value), il s'agit de la probabilité que le hasard puisse expliquer à lui tout seul une différence au

moins aussi grande que celle observée, en d'autres termes c'est la probabilité de se tromper en affirmant à tord qu'il existe une différence entre les 2 groupes

- p est une **mesure a posteriori** ⚠️ *(dans une étude si vous avez un p = 0.01 et qu'on vous demande quel est le risque alpha, celui-ci reste de 5%. A posteriori, la probabilité de se tromper en concluant à une différence reste de 5%)*

Si le risque alpha est de 5% :

- Si p < 0,05 (donc < au risque α) : on peut conclure que la différence est statistiquement significative
- Si p ≥ 0,05 (donc ≥ au risque α) : il n'y a pas de différence statistiquement significative, on ne peut rien conclure d'autre

> **En aucun cas les tests statistiques n'indiquent l'importance d'une différence**

Ce n'est pas parce que la différence est statistiquement significative qu'elle est cliniquement pertinente

> **En aucun cas un test statistique non significatif ne permet de conclure à l'exactitude de l'hypothèse « H0 », c'est-à-dire à l'égalité des paramètres dans les groupes comparés (sauf essais cliniques de non-infériorité et d'équivalence pour lesquelles l'hypothèse Ho est différente). Ainsi dans un essai thérapeutique de supériorité (le plus classique), il est erroné de conclure que les traitements sont équivalents quand la différence n'est pas statistiquement significative.**

Test bilatéral ou unilatéral ?

Test bilatéral (recommandé)

La différence entre traitement A et traitement B peut aller dans les 2 sens :

- "Le traitement A peut être meilleur, égal, ou moins bon que le traitement B"
- Utile dans le cas si on ignore si le traitement A est supérieur ou inférieur à B (cas d'un essai thérapeutique de supériorité)

> **Un "test bilatéral non significatif peut donner un test significatif en unilatéral" : car la puissance nécessaire pour un test unilatéral est moindre**

Test unilatéral

Hypothèse que la différence ne peut aller que dans un sens, c'est-à-dire que l'un des 2 traitements est supérieur à l'autre

- "Le nouveau traitement 1 est forcément meilleur ou égal à l'ancien traitement B"
- On ne fait ce test qui si le sens de la différence attendue ne fait aucun doute et repose sur des données indiscutables de la littérature
- La réalisation d'un test unilatéral impose une correction du risque alpha qui devrait être à 2.5% mais cela n'est pas fréquemment fait en pratique par les auteurs

Intérêts d'utiliser un test unilatéral (2)

- Soit on augmente la puissance car le "degré de significativité p d'un test unilatéral est égal à la moitié du p d'un test bilatéral)
- Soit on diminue le nombre de sujet à inclure (pour une même puissance) mais attention : NSN d'une étude non-infériorité >> NSN d'une étude de supériorité > NSN d'une étude d'équivalence

Choix d'un test unilatéral ou bilatéral doit être défini a priori dans le protocole

Test bilatéral (recommandé) ✅
Différence entre traitement A et traitement B peut aller dans les 2 sens

Test unilatéral
Différence ne peut aller que dans un sens, c'est-à-dire que l'un des 2 traitements est supérieur à l'autre

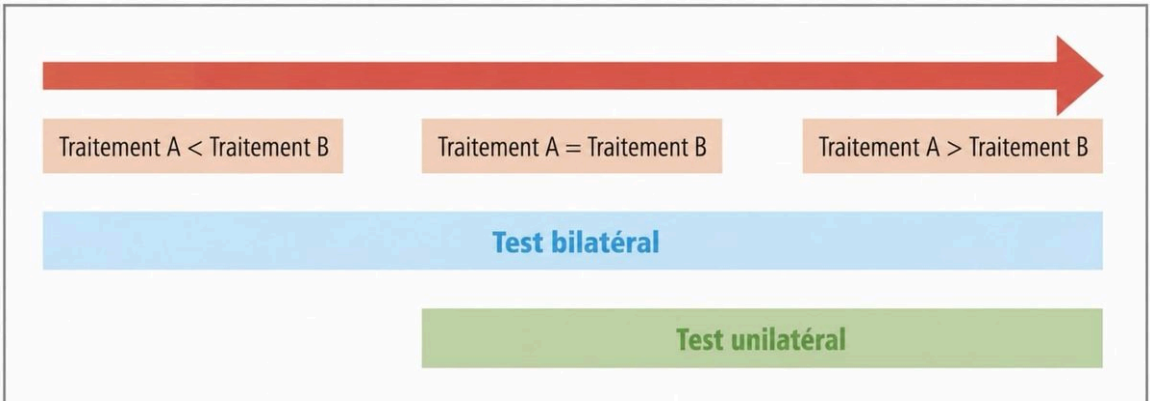


image.png

Supériorité, non-infériorité ou d'équivalence ?

Essai de supériorité *(le plus souvent)*

Objectif. Démontrer que l'un des traitements est supérieur à l'autre "traitement A meilleur que traitement B"

Type d'analyse
Analyse en intention de traiter : diminue la probabilité de mettre en évidence une différence

- ce qui **renforce la supériorité du traitement si le résultat est positif malgré cela**

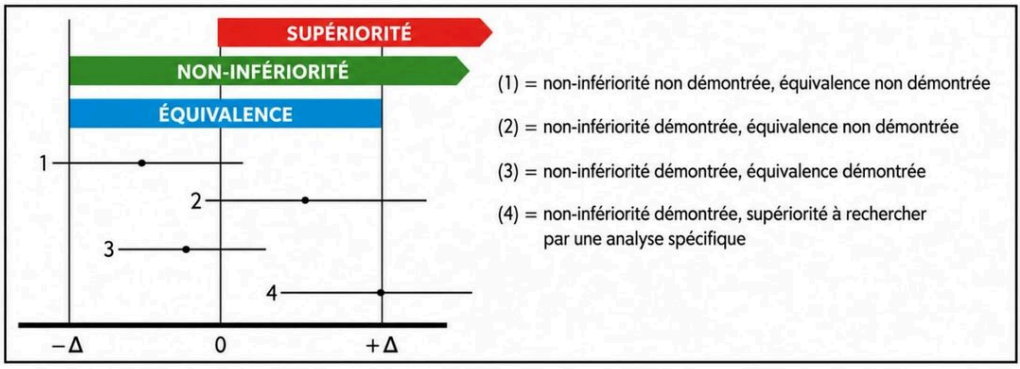
Si négative
Hypothèses à évoquer devant une étude de supériorité négative :

- Traitement testé est bien **meilleur mais manque de puissance** pour le montrer
- Traitement testé est "**équivalent**" au traitement contrôle
- Traitement testé est **inférieur** au traitement contrôle

Piège ⚠️ : ne pas interpréter "essai de supériorité négatif" comme de l'équivalence

Essai de non-infériorité ou d'équivalence

Schéma



Conduite à tenir si $IC_{95\ \%}$ situé entre [0 ; + ∞] : on peut proposer une étude de **supériorité complémentaire** par une analyse spécifique

image.png

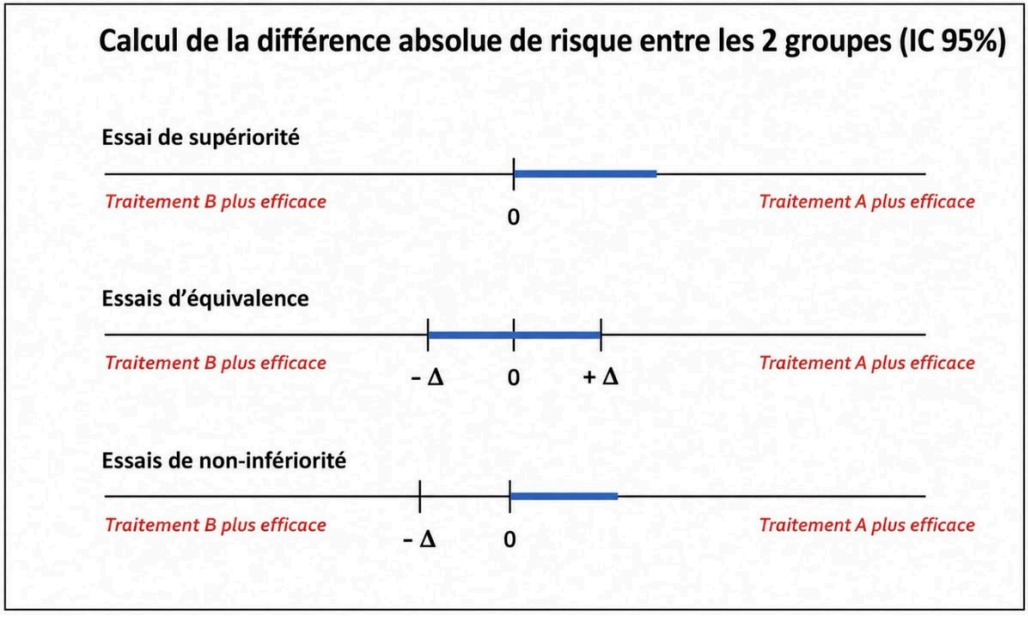


image.png

Dans ce schéma, Δ représente la borne d'équivalence ou de non infériorité. Dans le premier cas de figure, pour conclure à la supériorité du traitement A, il faut que l'IC à 95% de la différence soit strictement supérieur à 0. Dans le second cas de figure, pour conclure à l'équivalence entre A et B, il faut que l'IC à 95% de la différence soit strictement inclus entre – Δ et + Δ (le traitement A ne doit être ni trop inférieur à B ni trop supérieur). Dans le 3ème cas de figure, pour conclure à la non infériorité de A par rapport à B, il faut que l'IC à 95% de la différence soit strictement supérieur à – Δ (le traitement A peut être supérieur).

Objectif

Démontrer que la différence entre les 2 traitements est négligeable "traitement A est aussi bon que le B"

- *Non-infériotié : le traitement A est au moins aussi performant que le B (équivalent ou superieur)*
- *Équivalence : le traitement A est aussi performant que le traitement B*

Intérêt

Utile seulement si le traitement expérimental est avantageux autrement que par son efficacité (ex. moins cher, mieux toléré, meilleur galénique, moins de prises par jour, surveillance plus simple, générique)

Particularités méthodologiques

- Tout essai de non-infériorité ou d'équivalence doit être justifié dans le protocole de l'étude **a priori** (il **n'est pas accetable de tirer a posteriori, des conclusions d'équivalence ou de non-infériorité d'une étude de supériorité négative**, par contre, une étude de non-infériorité peut être complétée d'une étude de supériorité)
- Seuil Δ d'équivalence ou de non-infériorité (ou borne/limite/marge conservatrice) doit être fixé a priori
  - Pour conclure à une non-infériorité : ensemble de l'**IC 95%** doit se trouver dans le domaine de non infériorité [**-Δ** ; **+∞**]
  - Pour conclure à l'équivalence : ensemble de l'**IC 95%** doit se trouver dans le domaine d'équivalence [-Δ ; **+Δ**]
  - Choix de la borne est très difficile, il doit se faire en fonction de la spécialité et du type de critère de jugement
  - Borne va conditionner le nombre de patients à inclure :
    - Plus la borne est petite, **plus il faudra inclure de patients** dans l'essai
      - Si la borne est trop large, ce serait erroné de considérer que les 2 traitements ont une efficacité comparable

Type d'analyse

à réaliser

Réaliser analyse per-protocole + ITT, et les résultats des 2 analyses doivent être concordantes pour pouvoir trancher :

- Rôle du per-protocole : **augmente la probabilité de mettre en évidence la différence** entre les 2 groupes et donc **renforce la non-infériorité** si l'hypothèse de non infériorité est retenue (absence de différence malgré le fait d'avoir augmenté la différence entre les groupes par le per-protocole)
- Rôle de l'ITT : permettre la réalisation d'une étude de supériorité complémentaire si besoin (l'analyse en ITT a tendance à **diminuer les différences entre les groupes** : risque de faire conclure plus facilement à l'équivalence ou à la non-infériorité)

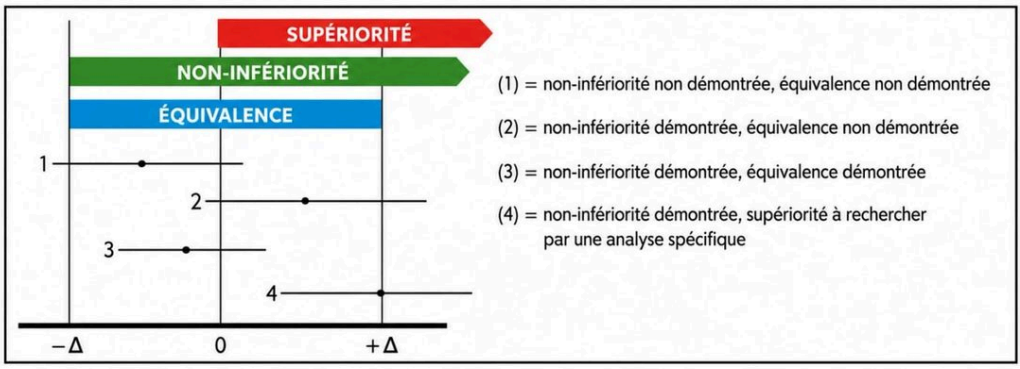
Tests statistiques. Test statistiques d'une étude de non-infériorité sont spécifiques de ce type d'études *(en effet, si on utilisait des tests classiques comme le Chi-2 dédié à une étude de supériorité, les résultats n'apparaîtraient pas significatifs à tord)*

Distinction entre ces différents types d'études

Hiérachie des grandeurs de NSN pour les 3 types d'études

NSN d'une étude de non-infériorité >>> NSN d'une étude de supériorité > NSN d'une étude d'équivalence

En effet, le calcul du NSN doit tenir compte du territoire d'hypothèses explorées NSN est plus bas en cas d'essai d'équivalence car territoire plus étroit des hypothèses explorées : en regard la figure le nombre de territoire exploré en vert (non-infériorité) > rouge (supériorité) > équivalence (bleu)



Conduite à tenir si $IC_{95\ \%}$ situé entre [0 ; + ∞] : on peut proposer une étude de supériorité complémentaire par une analyse spécifique

image.png

Pour faire le distinction entre supériorité/non-infériorité, il faut regarder l'hypothèse utilisée pour le calcul du NSN :

- Si c'est une "différence attendue" = supériorité
- Si c'est une "borne d'équivalence" = non-infériorité

L'hypothèse de recherche vise à montrer que :

- soit, l'une des deux interventions est meilleure que l'autre (hypothèse de **supériorité bilatérale**)
- soit, l'intervention A est meilleure que le comparateur B (hypothèse de **supériorité unilatérale**)
- soit, l'intervention testée est au moins aussi performante que le comparateur (hypothèse de **non-infériorité**)
- soit, les deux interventions sont autant performantes l'une que l'autre (hypothèse d'**équivalence**)

Test est-il statistiquement significatif ou non?[234]

Conditions pour qu'un test soit considéré comme statistiquement significatif ✅

- Si p < risque alpha
- Pour un ratio : IC 95% ne comprend pas la valeur 1
- Pour une différence : IC 95% ne comprend pas la valeur 0

CAT si test statistiquement significatif

- Différence est bien réelle entre les 2 groupes
- *Risque alpha*
- Vérifier que l'on a bien réalisé la bonne comparaison

(tests cohérents avec le type de variable, tests réalisés sur un CDJ défini a priori dans le protocole)

- Vérifier l'absence du problème de comparaisons multiples
- Test significatif ne corrige pas les biais d'une étude

Que peut-on évoquer en cas de test non statistiquement significatif ?

On ne peut pas tout de suite conclure à une absence de différence devant un test statistiquement non significatif ⚠️ :

- Soit absence de différence réelle entre les 2 groupes
- Soit validité interne défectueuse avec présence de nombreux biais
- Soit défaut de puissance 🔔 (risque β) : effectifs sont trop faibles

Soit défaut de puissance 🔔 :

- Test ne parvient pas à mettre en évidence une différence existante car les effectifs sont trop faibles

Inversement :

- Une faible différence peut être statistiquement significative pour que l'effectif (soit la puissance) soit important
- Dans ce cas (face à une toute petite différence statistiquement significative) : il faut évoquer en 1er lieu une puissance trop importante avec un nombre de sujets recrutés trop important et probablement supérieur au NSN calculé à priori

Tests statistiques de comparaison

Consiste à comparer 1 échantillon à la population, ou 2 échantillons entre eux ⭐ ++++++

Repose sur 2 étapes

1. Calcul de l'écart entre 2 paramètres mesurés :
   - Différence entre 2 moyennes
   - Différence entre 2 pourcentages
   - Rapport entre 2 variances
1. Confrontation de cette quantité mesurée à un modèle de distribution théorique de la variable (consiste à comparer la mesure avec la valeur probable qu'aurait dû prendre cette variable si

elle suivait un modèle mathématique théorique connu)

Situations statistiques dans un article
Évaluer une différence entre 2 moyennes
(variable **quantitative**)
Évaluer un rapport de 2 variances
(variable **quantitative**)
Évaluer une différence de pourcentage
(variable **qualitative**)

Modèles mathématiques à utiliser
Soit **Loi Normale centrée-réduite**
Soit **Loi T de Student**
Loi F de **Fisher**
Loi de **Chi-2**

> **En résumé, si la variable étudiée remplit un certain nombre de conditions d'application, il sera facile de traduire l'ensemble des valeurs prises par cette variable à l'aide d'une courbe (densité de distribution) définie par ces modèles mathématiques**

L'enjeu aux ECN est de connaître et vérifier ces conditions d'application des différents tests statistiques

Choix du test statistique dépend du type de variable que l'on veut évaluer et de sa nature :

1. Comparer une variable qualitative entre 2 groupes
   - Si la variable a une distribution normale (test paramétrique) : Test du Chi-2
   - Si la variable n'a pas une distribution normale (test non-paramétrique) : Test exact de Fisher
1. Comparer une variable quantitative entre 2 groupes
   - Si la variable a une distribution normale (test paramétrique) : Test de Student
   - Si la variable n'a pas une distribution normale (test non-paramétrique) : Test de Wilcoxon pour les séries indépendantes
1. Comparer une variable censurée entre 2 groupes
   - Test du Log-Rank (permet de comparer les courbes de survie entre les 2 groupes, en comparant la surface sous la courbe)

Exemple d'interprétation graphique d'un Log-Rank
Si les 2 courbes de survie sont décalées puis restent écartées de manière parallèle

- Il y a une différence au tout début de l'étude entre les 2 groupes : avantage probable en phase précoce/aiguë
- Puis la différence entre les 2 groupes est restée constante au cours du temps, signifiant donc que le médicament testé n'a pas continué à faire une différence significaitve entre les groupes
- Conclusion : avantage initial du traitement mais plus aucun effet supplémentaire au traitement contrôle ensuite

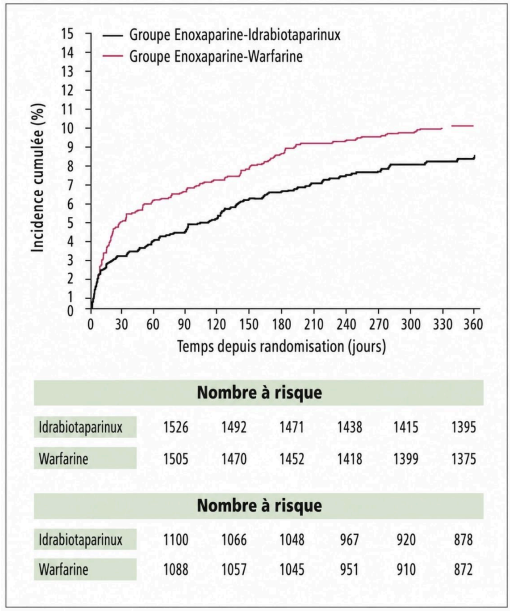


image.png

Si les courbes de survie sont décalées initialement puis l'écart entre les courbres ne cesse d'augmenter

- Il y a eu une différence au tout début de l'étude entre les 2 groupes
- Puis la différence a continué d'exister entre les 2 groupes tout au long de l'étude avec un écart entre les groupes qui n'a cessé d'augmenter
- Conclusion : différence significative entre les 2 groupes avec un effet sur toute la durée de l'étude (situation idéale attendue par les auteurs)

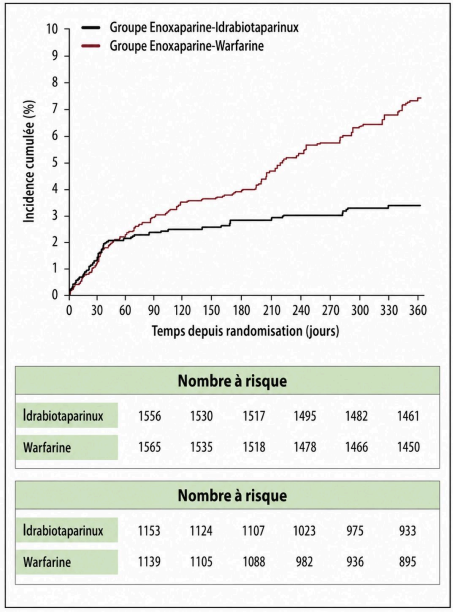


image.png

Ex. Paris Descartes

Un essai randomisé contre placebo étudie l'efficacité de l'azithromycine en antibiotique de classe des macrolides) pour la prévention des exacerbations de BPCO, chez des patients ayant un antécédent de BPCO. Les investigateurs utilisent une **méthode de survie**. Ils s'intéressent au risque de survenue d'une exacerbation de BPCO.

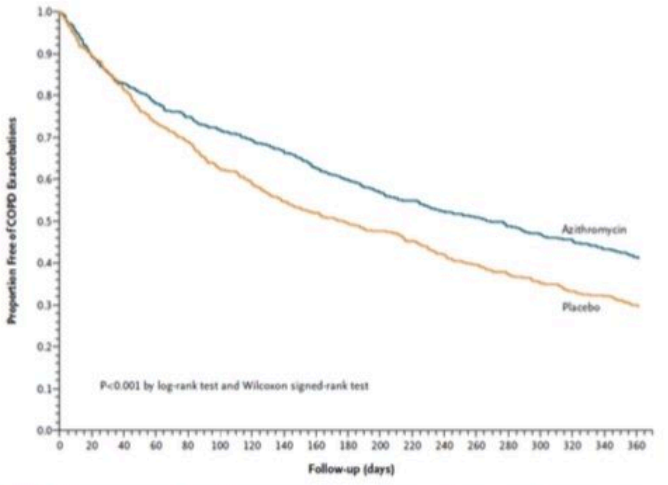


Figure 2. Proportion of Participants Free from Acute Exacerbations of Chronic Obstructive Pulmonary Disease (COPD) for 1 Year, According to Study Group.
The analyses were based on the participants who were randomly assigned to the group minus those who did not return for any follow-up assessment — 558 participants in the azithromycin group, of whom 317 (57%) had an acute exacerbation, and 559 in the placebo group, of whom 380 (68%) had an acute exacerbation.

Untitled

Vous pouvez constater que :

- 2 **courbes** sont présentées, une pour chaque **groupe** de traitement
- l'axe des abscisses correspond au **temps écoulé** depuis l'inclusion du patient
- l'axe **des ordonnées** correspond à la **proportion** de patients n'ayant **pas encore** présenté d'exacerbation de BPCO. Les courbes commencent à 1,0 au temps 0 puisqu'au début de l'étude aucun patient n'a encore présenté l'événement d'intérêt.
- les courbes sont décroissantes, puisqu'au cours du temps les patients vont présenter *une exacerbation de BPCO. La proportion de patients n'ayant pas encore présenté d'exacerbation de BPCO diminue en conséquence.*
- *la courbe « azithromycine » est au-dessus de la courbe « placebo » donc à chaque temps du suivi, la proportion de patients n'ayant pas encore présenté d'exacerbation de BPCO est plus élevée dans le groupe azithromycine que dans le groupe placebo.* ***On dit aussi que le risque d'exacerbation de BPCO est plus bas dans le groupe azithromycine que dans le groupe placebo.***
- *Une autre manière d'interpréter ces courbes, peut-être plus intuitive, est de dire que la courbe azithromycine est « plus à droite » que la courbe placebo, donc que la première exacerbation de BPCO survient plus tard dans le groupe traité par azithromycine que dans le groupe placebo. Cette phrase est équivalente à la précédente.*
- *on peut retrouver les durées médianes de survenue de la première exacerbation de BPCO en retrouvant l'abscisse correspondant à une ordonnée de 0,5 :* ***266 jours*** *pour le groupe azithromycine et* ***174 jours*** *pour le groupe placebo.*

- *La différence apparente entre les courbes est-elle statistiquement significative, ou bien pourrait-elle être due au hasard ? La valeur du degré de signification p du test du log-rank est* ***< 0,001****, donc inférieure à 0,05. On peut conclure que les deux courbes de survie obtenues sont significativement différentes (au risque alpha = 5% près), donc que le risque de première exacerbation de BPCO est différent dans le groupe azithromycine et dans le groupe placebo.*

Fait que la variable ait une distribution normale ou non sera précisé dans l'énoncé du QCM (pas dans l'article)

Tests statistiques de liaison

Mesure de l'association entre 2 variables (au sein d'un échantillon, ou entre 2 échantillons distints)
Objectif est de rechercher une relation statistique entre 2 variables X et Y (vocabulaire : indépendance, dépendance, liaison)

Association entre :
2 variables qualitatives
Test du Chi-2 d'indépendance

Association entre :
- Variable qualitative binaire (exprimée souvent en %)
- Variable qualitative ordinale

Test du Chi-2 de tendance vise à mettre en évidence une relation dose-effet [permet de montrer qu'il existe une relation proportionnelle entre l'augmentation au sein de la variable qualitative ordinale (ex. le fait d'avoir un grade plus élevé dans la sévérité d'une maladie) et la survenue de la variable binaire étudiée (ex. mortalité)]

Association entre :
2 variables quantitatives
- Entre 2 variables quantitatives qui ne sont pas la conséquence l'une de l'autre : Test de corrélation
- Entre 2 variables quantitatives où l'une est conséquence de l'autre : Test de régression linéaire simple

Tests de corrélation

Schémas

Test de corrélation ne peut s'interpréter que pour la plage des valeurs étudiées dans l'étude (relation entre X et Y peut s'éloigner d'une relation linéaire en-dessous ou au-dessus de la plage de valeurs étudiées) :

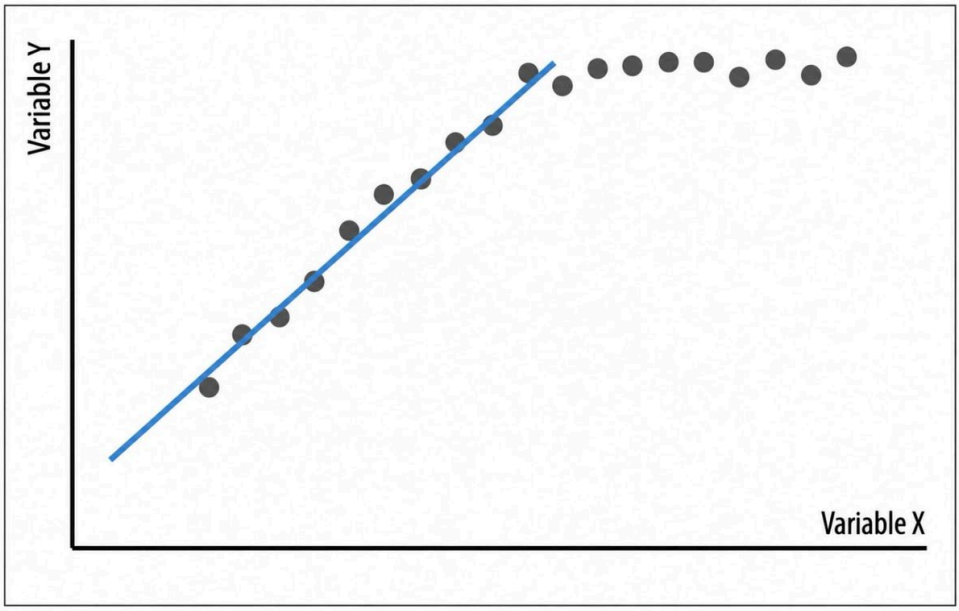


image.png

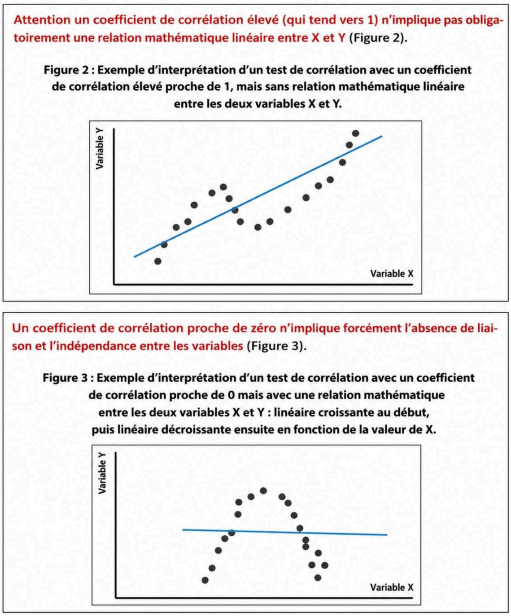


image.png

Objectif

Étudier la liaison entre 2 variables quantitatives X et Y quand elles sont aléatoires et ne jouent pas un rôle symétrique :
on dit que l'une n'est pas la conséquence de l'autre

Différents types

Il existe différents types de tests de corrélation, mais ils sont tous interprétable de la même façon (test linéaire de Pearson, test de corrélation de Spearman ...)

Coefficient de corrélation r

Coefficient de corrélation r (permet la mesure de l'intensité entre 2 variables, sa valeur est comprise entre -1 et +1)

- il s'agit d'un **indicateur sans unité** ⭐

Plus le coefficient de corrélation r en valeur absolue est proche de 1 et plus la liaison évaluée est forte :

- Coefficient de corrélation = 1 : corrélation parfaite entre les 2 variables
- Coefficient de corrélation = -1 : corrélation inverse parfaite entre les 2 variables
- Coefficient de corrélation = 0 : absence totale de corrélation entre les 2 variables
- Coefficient de corrélation ≥ 0,7 : corrélation correcte entre les 2 variables

ex. étude diagnostique comparé le coroscanner à la coronarographie pour le diagnostic du pourcentage de sténose coronaire, le coefficient de corrélation calculé est de 0,77 (IC 95% = 0,67-0,87) ce qui signifie que ces 2 examens sont correctement corrélés

Coefficient de détermination R^2

Coefficient de détermination R^2 correspond au carré de r (soit $R^2 = r^2$)

- il est juste plus facile à manipuler avec des valeurs allant de 0 à 1, ce qui permet une expression sous forme de pourcentage

Test de corrélation

Après avoir calculé le coefficient de corrélation r entre 2 variables X et Y, un test de corrélation permettra d'évaluer cette force de liaison mesurée, permettant de juger si le résultat est bien significatif (estimer si il est suffisamment éloigné de 0)

Test de corrélation fournira 2 valeurs :

- Valeur du degré de significativité p qui mesure le degré de signification statistique de la force mesurée
- Valeur de degré de corrélation r qui mesure la force de l'association de la liaison mesurée

Points clés

Pièges

- Attention un test de corrélation ne peut s'interpréter que pour la plage des valeurs étudiées dans l'étude ⭐
- Coefficient de corrélation élevé (qui tend vers 1) n'implique pas obligatoire une relation mathématique linéaire entre X et Y
- Coefficient de corrélation proche de 0 n'implique forcément l'absence de liaison et l'indépendance entre les variables
- Coefficient de corrélation très élevé, même proche de 1, ne permet jamais de conclure à la causalté du résultat ++++ ⚠️

Tests statistiques de régression linéaire simple

Objectif

Étudier la liaison entre 2 variables quantitatives X et Y quand elles sont aléatoires et ne jouent pas un rôle symétrique (X et Y ne sont pas interchangeable sur l'axe des abscisses et ordonnés), on dit que l'une est la conséquence de l'autre

ex. si étudie une liaison entre le poids des enfants et leur âge, on sait que plus l'âge de l'enfant augmente et plus son poids augmente, il y a donc une conséquence du poids par rapport à l'âge

Variables dépendante et explicative

- Variable dépendante (Y)= *poids de l'enfant dans l'exemple*
- Variable explicative (X) = *âge de l'enfant dans l'exemple*

Lorsqu'on réalise une régression linéaire simple, on cherche à savoir quelle est la relation de dépendance de Y par rapport à X, on dit « on recherche une régresson de Y par rapport à X »

Intérets

- Décrire la façon dont la variable X et liée à la variable Y
- Tester l'existence de liaise entre les variables X et Y
- Pouvoir estimer une valeur de la variable Y pour une valeur donnée de la variable X = intérêt principal +++

Principe

Lorsqu'on réalise une régression linéaire simple :

- On tente de trouver la droite passant iéalement au milieu du nuage de points → c'est la droite de régression
- Meilleure droite est la droite pour laquelle la somme des distances entre chaque point à cette droite sera la plus faible

Test statistique

Lorsqu'on interprète une droite de régression, il faut observer sa pente

Test statistique sera effectué sur la pente de la droite de régression +++

- Plus la pente de la droite est élevée, plus la liaison est importante
- En cas de pente nulle (droite horizontale), il n'y aura pas de liaison

Analyse multivariée (prise en compte d'un ou plusieurs facteurs)

Synonyme : analyse ajustée

Jusqu'ici on s'est intéressé au lien entre 2 facteurs : une exposition et une maladie Dans la réalité, d'autres facteurs sont susceptibles d'influencer cette relation, à moins que l'étude ait été randomisée

Généralités sur l'analyse multivariée

Définition. Comparaison de 2 analyses descriptives portant sur le CDJ principal produites dans chacun des groupes, en ajustant a posteriori ces résultats sur de potentiels facteurs de confusion, en tenant compte de co-variables

Objectif

- Déterminer les facteurs indépendamment associés à la survenue de la maladie
- Ajuster les facteurs de confusion potentiels qui sortent dans l'analyse en sous-groupe
- Si elle est réalisée, il faut que sa réalsation potentielle ait été annoncée avant l'étude

Dans quelle étude ?

- Si études épidémiologiques : analyse multivariée est l'analyse la plus importante
- Si essais thérapeutiques : pas d'analyse multivariée dans un essai thérapeutique le plus souvent

(car une randomisation bien faite permet la comparabilité des groupes-

Principe

- Variable dépendante = survenue de l'événement étudié (ex. maladie)
- Variables indépendantes = facteurs étudiés (FDR ou protecteurs)

Réalisation pratique

1/ En analyse univariée : repérer les facteurs indépendants correspondant aux facteurs de confusion, avec un nombre maximum de facteurs indépendants (1 pour 10 événements)

2/ Puis régression logistique : donne l'association entre la variable indépendante et l'événement étudié en tenant compte des autres variables indépendantes (= analyse ajustée)

- régression logistique ne prend pas en compte le délai de survenue
  - si on fait une analyse de survie = analyse multivariée selon le modèle de Cox

Limite

Fiabilité d'une analyse multivariée dépend des variables indépendantes

- il faudrait donc toutes les intégrer = mais impossible de toutes les connaître

Comment identfier un facteur de confusion ou un facteur d'interaction ?

Exemples

Facteur intermédiaire



image.png

> ***Exemple :***

On étudie la relation entre la consommation de tabac et la mortalité globale. Dans cette relation, on peut supposer que le fait d'avoir un cancer broncho-pulmonaire, un cancer de la vessie, un syndrome coronaire aigu sont des **facteurs intermédiaires** car ce sont des pathologies causées par la consommation de tabac, et qu'elles sont potentiellement létales.

Facteur de confusion

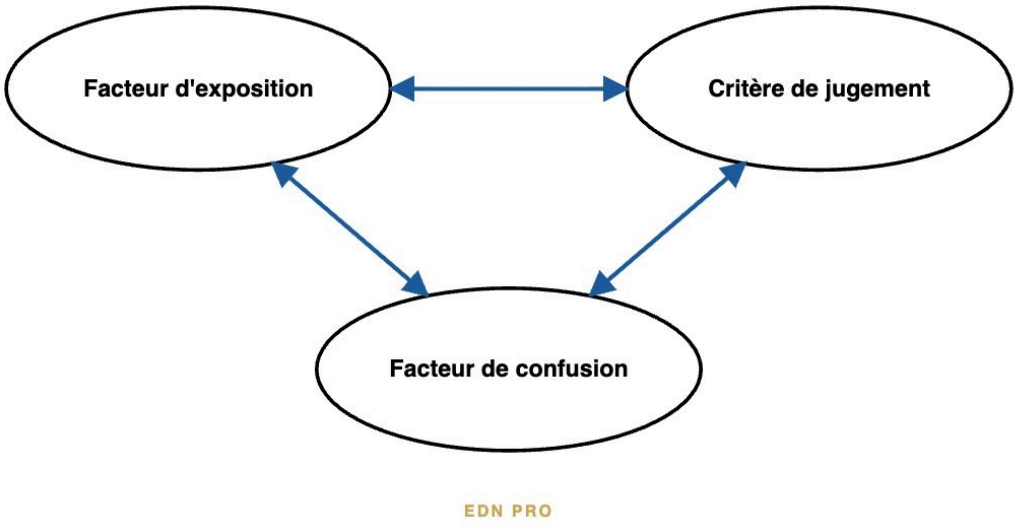


image.png

> *Exemple :*

On étudie l'association entre la profession et la mortalité en milieu hospitalier. On trouve que les infirmières ont une espérance de vie plus longue que les médecins. Mais il existe un **facteur de confusion** évident : il y a plus de femmes parmi les infirmières que parmi les médecins, et les femmes ont une espérance de vie plus longue que les hommes. Le sexe est donc un facteur associé à la fois à la profession et à la mortalité (ces associations doivent normalement être vérifiées statistiquement), c'est un **facteur de confusion** dans la relation retrouvée entre ces deux facteurs.

Facteur d'interaction

> *Exemples :*

- Chez le sujet âgé, le syndrome métabolique prédit mieux le risque de syndrome coronaire aigu chez les femmes que chez les hommes (**interaction quantitative**, facteur d'interaction = sexe)
- Traitement efficace sur la mortalité globale chez des patients ayant un cancer de la prostate à un stade avancé, mais délétère chez ceux ayant un cancer à un stade moins avancé (**interaction qualitative**, facteur d'interaction = sévérité de la maladie)

Facteur intermédiaire. Il s'agit d'un facteur qui intervient dans la chaîne causale entre le facteur d'exposition et le critère de jugement, seule la connaissance du problème étudié permet de supposer qu'un facteur donné est un facteur intermédiaire

Facteur de confusion. Il s'agit d'un facteur associé à la fois au facteur d'exposition et au critère de jugement et qui n'est pas un facteur intermédiaire, un facteur de confusion peut expliquer une association (ou au contraire masquer une association existante)

Facteur d'interaction (ou facteur modificateur). Il y a interaction lorsque la relation entre 2 facteurs diffère selon les modalités d'un troisième facteur, appelé facteur d'interaction, l'interaction peut être quantitative (RR plus élevé chez les femmes que chez les hommes) ou qualitative (relation dans un sens chez les femmes, dans l'autre chez les hommes)

Distinction entre facteur de confusion et facteur d'interaction : ⚠️

- Pour voir si un facteur joue un rôle dans la relation entre l'exposition et la maladie et si oui comment, il faut stratifier l'analyse selon ce facteur, c'est-à-dire estimer le paramètre pour chaque sous-groupe (strate) correspondant à chaque modalité du facteur
- On s'affranchit ainsi de l'effet du facteur, il y a alors 3 cas possibles :

Exemple +++

Exemple pour bien comprendre

Énoncé : Une étude qu'on retrouve en analyse univariée une association entre la consommation de boissons énergétiques et le risque de mort subite, avec un **RR de 2,8 (intervalle de confiance à 95 % : 1,8 – 3,9)**.

> *Boissons énergétiques ↔ Mort subite* ***RR = 2,8 (IC à 95 % : 1,8 – 3,9)***

Positionnement du problème : Mais puisqu'il est **rapporté que la consommation de boissons énergétiques est souvent associée à une consommation d'alcool** (notamment en boîte de nuit), on peut se poser la question du rôle de cette consommation d'alcool dans la relation entre « boissons énergétiques » et la survenue de « Mort subite ».

→ On va donc estimer **le RR de la relation « Boissons énergétiques – Mort subite »** d'une part chez les patients qui consomment de l'alcool, puis d'autre part, chez ceux qui ne consomment pas d'alcool

1) Exemple de facteur indépendant :

- la relation **Boissons énergétiques – Mort subite EXISTE À L'IDENTIQUE chez les consommateurs d'alcool et les non-consommateurs d'alcool**
- car présence d'un RR statistiquement significatif avec intervalle de confiance qui ne comprend pas 1 et **approximativement identique** chez les consommateurs d'alcool et les non-consommateurs d'alcool
- elle est donc **indépendante de la consommation d'alcool** (car retrouvée approximativement à l'identique dans chaque strate)

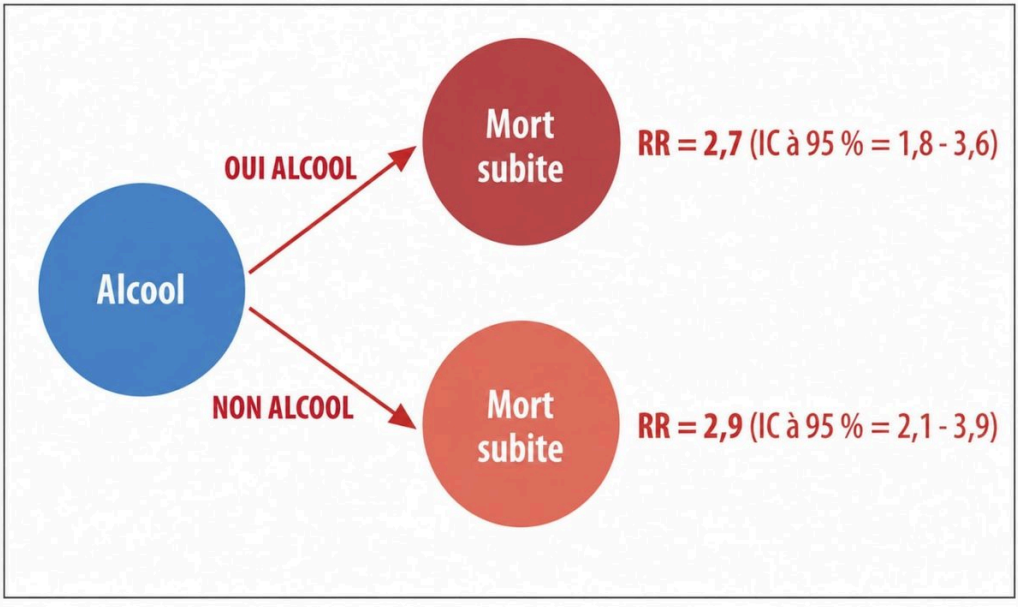


image.png

> *OUI ALCOOL : Alcool ↔ Mort subite —* ***RR = 2,7 (IC à 95 % : 1,8 – 3,6)*** *NON ALCOOL : Alcool ↔ Mort subite —* ***RR = 2,9 (IC à 95 % : 2,1 – 3,9)***

2) Exemple de facteur de confusion :

La relation « **Boissons énergétiques – Mort subite** » **N'EXISTE PAS, ni chez les consommateurs d'alcool, ni chez les non-consommateurs d'alcool**

- car présence d'un RR non statistiquement significatif avec intervalle de confiance qui comprend 1 (voir schéma page suivante)

« l'association est donc expliquée par la consommation d'alcool : autrement dit, la **consommation d'alcool est un facteur de confusion** dans la relation « Boissons énergétiques – Mort subite »

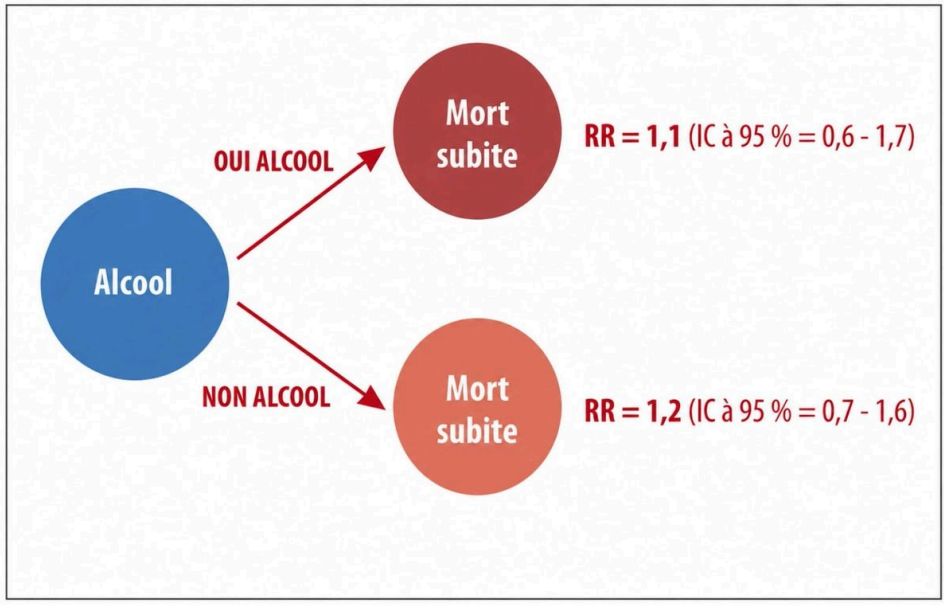


image.png

3) Exemple de facteur d'interaction :

- la relation « **Boissons énergétiques – Mort subite** » **est DIFFÉRENTE chez les consommateurs d'alcool et les non-consommateurs d'alcool**
- car présence d'un RR statistiquement significatif avec intervalle de confiance qui ne comprend pas 1 dans le sous-groupe consommateurs d'alcool ; alors que le RR est non statistiquement significatif avec intervalle de confiance qui comprend 1 dans le sous-groupe non-consommateurs d'alcool (voir schéma ci-dessous)
- la consommation d'alcool est un **facteur d'interaction** dans la relation « Boissons énergétiques – Mort subite »

→ Ici on pourrait penser à une **SYNERGIE** entre alcool et boissons énergétiques +++ (*si l'on suppose que les relations sont causales*)

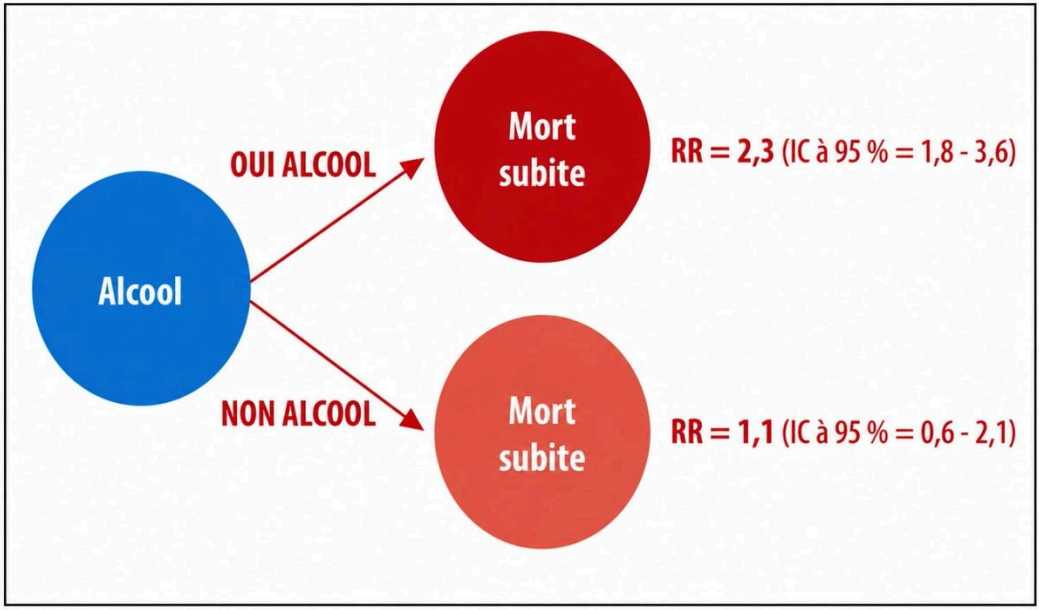


image.png

Facteur indépendant. Si la relation est indépendante du facteur, elle sera retrouvée dans chaque strate

Facteur de confusion. Si le facteur explique (au moins partiellement) la relation retrouvée, alors la relation disparaîtra (ou sera atténuée) dans chaque strate, on dit que le facteur est un facteur de confusion

Facteur d'interaction. Si le facteur modifie la relation, on trouvera un résultat différent dans chaque strate : le facteur est un facteur d'interaction

---

Donc en pratique :

1. On vérifie qu'il ne s'agit pas d'un facteur intermédiaire
1. On cherche s'il y a une interaction
1. Si oui, on sépare l'analyse en sous-groupes
1. Si non, on calcule un paramètre ajusté

- Attention, modèle de régression possible en :
  - **univarié** = si une **seule variable explicative** → estimation **OR brut**
  - **multivarié** = si **plusieurs variables explicatives** (prise en compte des facteurs de confusion) → estimation **OR ajusté**

Prise en compte d'un seul facteur de confusion : l'ajustement de Mantel-Haenszel

L'ajustement est une technique statistique permettant de prendre en compte un facteur de confusion au moment de l'analyse, donc a posteriori par rapport au tirage de l'échantillon et au recueil de données.

Le principe est d'estimer un OR ou un HR (selon le type de variable considéré) ajusté sur le facteur de confusion. Pour cela, la méthode la plus simple est d'estimer le paramètre dans chaque

strate du facteur de confusion potentiel, comme nous l'avons expliqué précédemment, puis d'en faire une « moyenne » (méthode de Mantel-Haenszel).

En comparant le paramètre brut au paramètre ajusté, on peut également en déduire si le facteur d'ajustement est un facteur de confusion.

Exemple

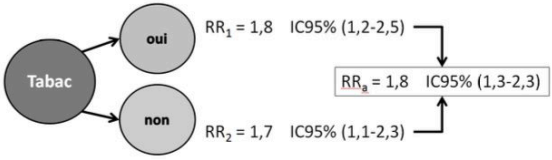
Exemple :

Reprenons l'exemple de la relation café – risque de SCA.



Ce RR est appelé le **RR brut** ou **RR non ajusté**. Stratifions maintenant l'analyse sur la consommation de tabac, en estimant un risque relatif ajusté (RR_a) sur le tabagisme, qui est une sorte de moyenne de RR_1 et RR_2. Nous retrouvons les cas exposés précédemment.

- **Cas n°1 :**

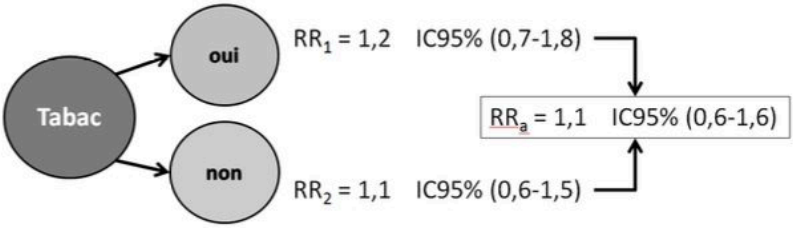


Le RR ajusté est très proche du RR brut, donc la relation café-SCA est indépendante de la

Untitled

consommation de tabac.

- **Cas n°2 :**



Le RR ajusté est différent du RR brut et est proche de 1. L'association café-SCA est expliquée par la consommation de tabac. La consommation de tabac est un facteur de confusion dans la relation café-SCA.

Untitled

En cas d'interaction (cas n°3), les RR étant différents chez les fumeurs et les non-fumeurs, cela n'a pas de sens d'en calculer une «moyenne». Les résultats seront présentés séparément chez les fumeurs et les non-fumeurs.

Prise en compte de plusieurs facteurs de confusion à la fois : les modèles multivariés (régression multivariée)

Le principe est de prédire la valeur d'une variable qui est le critère de jugement en fonction d'autres variables. On les appellera respectivement la variable à expliquer et les variables explicatives. Le modèle peut s'écrire comme suit :

```
Y (variable à expliquer) = (a × variable explicative 1) + (b × variable explicative 2) + … + constante
```

C'est à dire :

```
Y = aX1 + bX2 + … + constante
```

Où "a" et "b" sont des coefficients que l'on va pouvoir estimer en connaissant les valeurs de la variable à expliquer et des variables explicatives pour chaque sujet

Un modèle de régression peut être univarié s'il n'y a qu'une seule variable explicative (dans ce cas, on estimera un OR brut) ou multivarié s'il y a plusieurs variables explicatives (prise en compte des facteurs de confusion) dans le modèle (dans ce cas on estimera des OR ajustés).

L'analyse multivariée permet d'identifier des facteurs indépendamment associés à la variable à expliquer, c'est-à-dire au critère de jugement. L'analyse multivariée est essentielle dans les études étiologiques ou pronostiques car elle permet de prendre en compte les facteurs de confusion en ajustant simultanément sur toutes les variables incluses dans le modèle. Les résultats de cette analyse (les OR ou HR ajustés) sont les résultats principaux dans ces études devant être mis en avant.

> **Principaux modèles de régression :**

les seules choses qui vont changer entre les différents modèles de régression, ce sont le type de variable à expliquer et l'interprétation des coefficients (a, b, ...)

- Critère de jugement binaire : régression **logistique** (permet d'obtenir un OR ajusté)
- Critère de jugement continu : régression **linéaire**
- Critère de jugement censuré : Modèle de **Cox** (permet d'obtenir un HR ajusté)

Focus

Analyse de sensibilité

Définition. Analyse réalisée pour évaluer la sensibilité des résultats d'une étude à des changements dans la façon dont cela a été fait (autrement dit, quels résultats aurait-on obtenu en refaisant l'étude de telle ou telle façon)

Intérêts. Évaluer la robustesse des résultats par rapport à des décisions incertaines ou des hypothèses qui ont été faites sur les données et les méthodes utilisées

Réalisation pratique

1/ Analyses toujours réalisées après l'analyse principale

2/ On refait tout ou une partie de l'analyse statistique en modifiant certains points de la méthode (modifie la définition du critère de jugement principal, on utilise un autre modèle statistique) et on évalue si les résultats sont modifiés ou non par cette manœuvre

3/ **Moins on à arrive à faire varier les résultats**, et **plus ces résultats seront dit robustes** ✅

Test de permutation

Définition d'un test de permutation sort de cadre de la LCA, mais dans l'annale de 2017 il a déjà été évoqué, il fallait simplement trouver l'information dans le texte : "est-ce que d'un test de permutation a été utilisé" réponse dans le texte

Définition = test statistique que les auteurs utilisent **lorsque les critères d'application des tests statistiques standard ne sont pas correctement remplis** (exemple : situation avec < 30 patients pour faire un T-student)

Tableaux et figures

Règles de présentation communes aux tableaux et figures

- Ils doivent **pouvoir se lire indépendamment du texte**
- Apportent des informations supplémentaires, complémentaires et convergentes au texte
- Mais ils ne doivent pas être redondants avec le texte
- Ils doivent porter sur des éléments essentiels des résultats
- **Échelle respectée** pour toutes les figures portant sur la même grandeur ⚠️

Tableau 1 (1er tableau systématiques de toutes les études)

Rôle = présenter les caractéristiques initiales au début de l'étude de l'ensemble de la population étudiée

Il est obligatoire pour tous les types d'études

Différentes présentations sont possibles

- Soit une seule colonne globale "all patients"
- Soit autant de colonnes qu'il y a de groupes pour comparer les groupes de l'étude

Soit 1 colonne globale + autant de colonnes qu'il y a de groupes (de plus en plus recommandé)

	All patients (N = 538)	Traitement A (N = 464)	Traitement B (N = 74)	p value
Age, years	72.2 ± 9.3	71.9 ± 9.5	74.5 ± 7.9	0.01
Male, n (%)	412 (76.6)	350 (75.4)	62 (83.8)	0.11
Body mass index, kg/m²	29.9 ± 5.2	29.2 ± 5.4	28.1 ± 4.3	0.04
Body surface area, m²	2.0 ± 0.2	2.0 ± 0.2	2.0 ± 0.2	0.43

image.png

Plan d'interprétation

1. Regarder la taille de chaque groupe (n = ...) pour vérifier le caractère équilibré des effectifs (sinon, penser à une randomisation déséquilibrée)
1. Regarder uniquement le colonne "all patients" si elle présente : afin de vérifier que la population étudiée est comparable à la population cible sur des points cliniquement pertinents (âge, sévérité de la maladie étudiée, comorbidités associées, traitement de base)

1. Vérifier ligne par ligne s'il existe une différence entre les groupes : se fait à vue d'oeil sur les effectifs (si les auteurs ont réalisé une p-value, on ne peut pas conclure dessus car risque de biais des comparaisons multiples), mais cela peut nous aider à gagner du temps, penser à vérifier que les effectifs soient largement différents pour évoquer un risque de biais de sélection)

Intérêts

- Évaluer la validité externe : via la colonne "all patients", ou à défaut les colonnes de chaque groupe ensemble
- Évaluer la validité interne : vérifier la comparabilité initiale des groupes de la population étudiée

Déterminer le type de distribution d'une variable continue à l'aide du Tableau 1

- Déterminer le type de distribution d'une variable continue à l'aide du Tableau 1 ?

Dans le tableau 1, une variable continue peut être exprimée sous deux formes en fonction du fait que la distribution de la variable soit normale ou non normale (voir exemple ci-dessous) :

- si à **distribution normale** : on utilise la **moyenne ± écart type** *(mean ± standard deviation)*
- si à **distribution non normale** : on utilise la **médiane [intervalle interquartile]** *(median [interquartile range])*

Age, years
Male, n (%)
ECG parameters
Atrial fibrillation, n (%)
QRS duration, ms
LBBB, n (%)
Echocardiographic parameters
LVEF, %

Non-Responders (N = 11)
69 (64-73)
10 (91)
1 (9)
163.4 [141.9-185.0]
10 (90.9)
31 ± 8

Responders (N = 18)
70 (65-75)
11 (61.1)
8 (44)
142.3 [128.7-154.8]
8 (44.4)
35 ± 7

p value

0.97

0.08

0.10

0.12

0.04

0.06

Courbe de survie de Kaplan-Meier

Autre méthode de représentation graphique du Taux du survie : courbe actuarielle

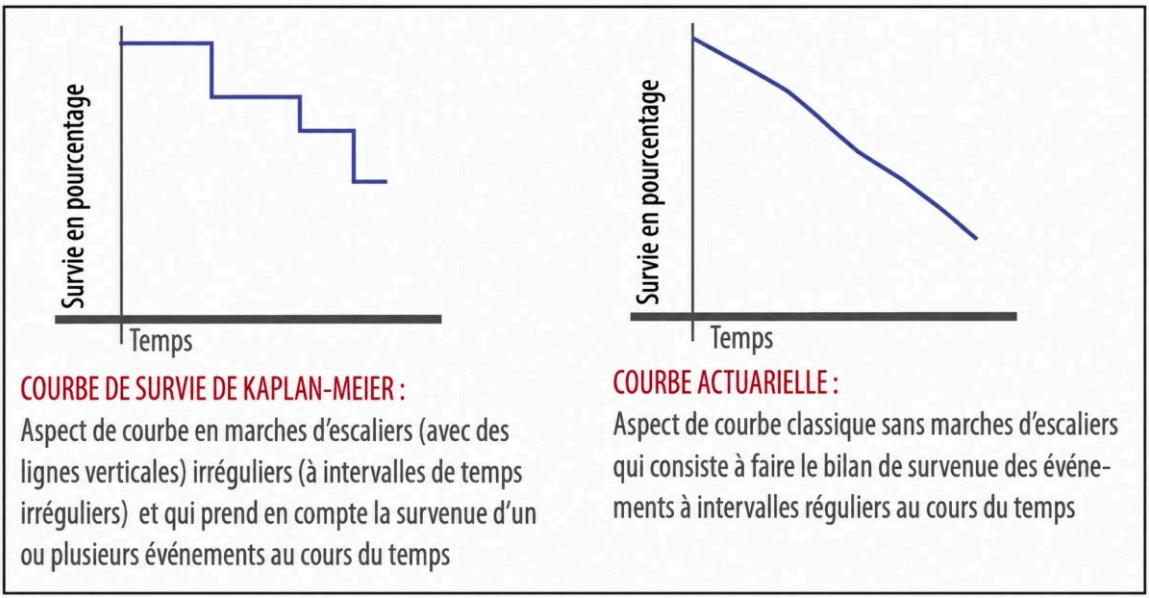


image.png

Variable

Courbe de Kaplan-Meier ne peut être utilisée que sur des variables dites censurées

Figure clé de toute étude avec analyse de survie (autrement dit : toute étude prospective évaluant la survenue d'un événement binaire en fonction du temps : survenue d'une complication [oui/non], hospitalisation [oui/non], décès [oui/non] ...)

Abscisse

Ordonnée

Permet de représenter, à chaque temps d'événement, le pourcentage de sujets n'ayant pas encore présenté l'événement d'intérêt :

- En abscisse : durée de suivi
- En ordonnée : probabilité (entre 0 et 1) de ne pas avoir présenté l'évènement, ou la proportion de patients (entre 0-100%) n'ayant pas encore présenté l'évènement

Date de point. Date à la laquelle les données de l'étude sont censurées, autrement dit, la date à laquelle on arrête de suivre les patients

Durée médiane de survenue

- Durée de suivi pour laquelle 50% des sujets n'ont pas encore eu l'événement (ou date pour laquelle 50% de l'effectif du groupe a réalisé l'événement binaire étudié),
- Attention si l'étude est terminée, et que < 50% des sujets ont présenté l'événement lors du suivi (ou que > 50% n'a pas présenté l'événement) :
  - on ne peut pas estimer la durée médiane de survenue de l'événement

Nombre de sujet à risque

Souvent situé sous la courbe, le nombre de sujet à risque décroit en fonction du temps puisque à chaque palier de temps on enlève :

- perdus de vus, ceux qui présentent l'événement, exclus

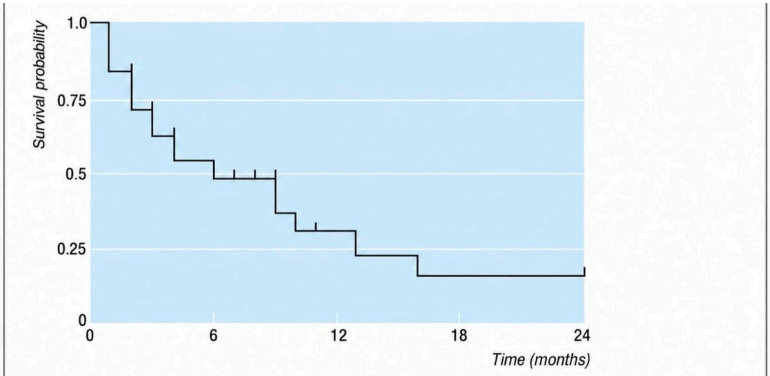
p- value

Correspond à l'analyse univariée du test Logrank de comparaison entre les 2 courbes de survie de Kaplan-Meier :

- si p < α on pourra dire qu'il existe une différence significative de survenue de l'événement binaire entre ces 2 groupes, en fonction du temps

La courbe commence à 1 (ou 100%) au temps 0, puisqu'au début de l'étude aucun patient n'a présenté l'évènement doit retrouver la population en intention de traiter). La courbe est décroissante, puisqu'au cours du temps certains patients vont présenter l'évènement

Ex. de courbe de Kaplan-Meier



Survival curve showing probability of not conceiving among 38 subfertile women after laparoscopy and hydrotubation[2]

Le suivi était de 24 mois dans cette étude.

Ici, l'évènement est l'absence de conception (chez des femmes subfertiles). L'axe des ordonnées représente donc la probabilité de ne pas concevoir au cours du temps.

image.png

Plan d'interprétation (4 étapes)

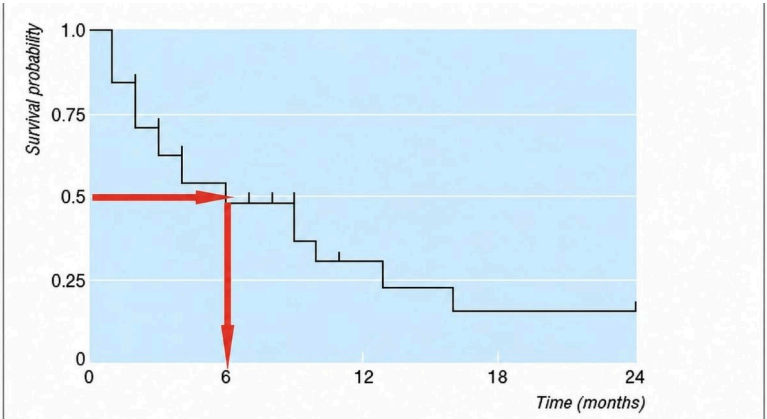
- Commencer par identifier la date de point : date à la laquelle les données de l'étude sont censurées, autrement dit, la date à laquelle on arrête de suivre les patients *(dans l'exemple ci-dessus : il est de 24mois)*

Estimation de la durée médiane de survenue de l'événement à partir d'une courbe de Kaplan-Meier

Il s'agit de la durée de suivi pour laquelle 50% des sujets n'ont pas encore eu l'événement (ou date pour laquelle 50% de l'effectif du groupe a réalisé l'événement binaire étudié)

> **Si l'étude est terminée, et que < 50% des sujets ont présenté l'événement lors du suivi (ou que > 50% n'a pas présenté l'événement) : on ne peut pas estimer la durée médiane de survenue de l'événement** ❌

Question piège déjà tombée 2x au concours



Survival curve showing probability of not conceiving among 38 subfertile women after laparoscopy and hydrotubation

Dans cette étude, la durée médiane avant conception après une laparoscopie et une hydrotubation chez des femmes ayant des problèmes de fertilité était de 6 mois.

image.png

- Rechercher la p-value sur la figure (correspond à l'analyse univariée du test Logrank de comparaison entre les 2 courbes de survie de Kaplan-Meier) : si $p < \alpha$ on pourra dire qu'il existe une différence significative de survenue de l'événement binaire entre ces 2 groupes, en fonction du temps
- Être prêt à interpréter le nombre de sujet à risque (souvent situé sous la courbe, *absent dans l'exemple ci-dessus, mais présent dans l'exemple du Pezel*) : il est essentiel de comprendre que le nombre de sujet à risque décroit en fonction du temps puisque à chaque palier de temps on enlève : les perdus de vus, ceux qui présentent l'événement, et les exclus

Cas particulier : courbe de survie de Kaplan-Meirer avec intervalle de confiance de 95%

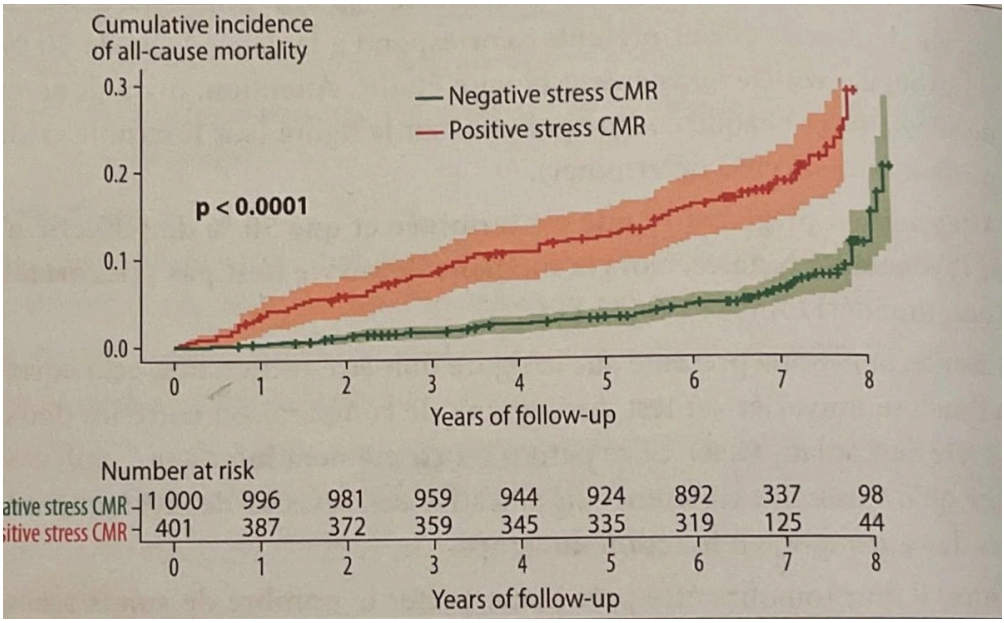
Il s'agit d'un cas particulier de plus en plus recommandé en LCA, et qui s'analyse exactement comme une Kaplan-Meier classique

La seule différence est que l'on ajoute une représentation graphique de l'intervalle de confiance à 95% de chaque de Kaplan-Meier, qui apparaît comme une zone colorée de part et d'autre de la courbe

Intérêt = vérifier l'absence de chevauchement entre les 2 intervalles de confiance de chaque courbe :

- Si absence de chevauchement : augmente la validité interne des résultats *(comme dans l'exemple)*

- Si présence de chevauchement : diminue la validité interne des résultats



Untitled

> **Piège : ne pas confondre la courbe de survie de Kaplan-Meier avec la Courbe d'incidence cumulée :**

- Courbe de survie de Kaplan Meier : effectifs partent du haut de la figure en ordonnée, avec des courbes qui décroissent progressivement au fur et à mesure de la survenue des événements
- Courbe d'incidence cumulée, c'est le contraire : courbes augmentent avec le temps, au fur et à mesure de la survenur des événements
- Au-delà de cette différence, l'interprétation de ces 2 figures est absolument identique ✅

Boîte à moustache (box-plot)

Exemple

Figure : Exemple de Boîte à moustache (box-plot)

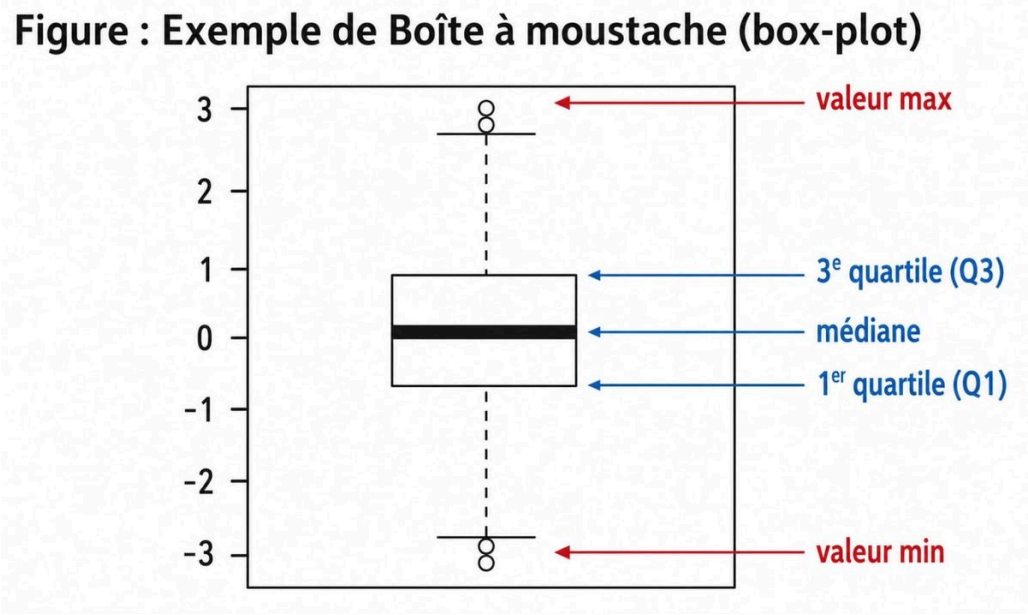


image.png

Objectif. Résume les indicateurs de position clé de la variable étudiée (le plus souvent le critère de jugement principal s'il est quantitatif)

Condition

- Uniquement pour une variable quantitative continue
- Recommandé surtout lorsque les 2 populations sont de taille différente (très utile pour d'éventuelles analyses en sous-groupe)

Interprétation

Boîte à moustache correspond à un rectangle pour lequel :

- Bord inférieur : correspond au 1er quartile de la variable étudiée
- Bord supérieur : correspond au 3ème quartile de la variable étudiée
- Bord au milieu en gras : correspond à la médiance

Il est aussi possible d'ajouter (comme dans l'exemple) des segments aux extrémités

- correspondant à la valeur minimum et à la valeur maximum de la variable dans la population (valeurs extrêmes)

Diagramme de flux

Diagramme de flux n'est pas obligatoire pour un article de LCA

Renseigne sur l'évolution des effectifs des groupes aux 4 étapes principales de l'étude

Analyser chacune des 4 étapes : RASA

1. Recrutement ou enrôlement ou inscription (représentativité avec un nombre d'inclus proche de celui des éligibles)

1. Allocation de l'intervention ou répartition des traitements

1. Suivi (nombre, raisons et répartition des perdus de vue et des écarts de protocole)
1. Analyse : en ITT ou non

Décrire le protocole de l'étude : TRIM

1. Type d'étude
1. Randomisation
1. Intervention
1. Mesure des critères

3 informations à vérifier sur un diagramme de flux

Applicabilité des résultats en termes de validité externe

- Vérifier que la population incluse n'est pas trop différente de la population éligible
- Plus la différence entre le nombre de patients éligibles et le nombre de patients inclus est minime, mieux est la validité externe

Déterminer le type d'analyse : ITT ou per-protocle ou en traitement reçu

- Dépend de la différence entre le nombre de patients randomisés et le nombre de patients analysés
- Pour vérifier ITT : il faut avoir une population incluse randomisée : population analysée dans le bras où elle a été randomisée

Vérifier les nombres de perdus de vue, d'arrêt et de retrait de patients

- Biais de sélection des perdus de vue si : nombre de pdv > 10-15%
- Biais de classement différentiel si = nombre de pdv répartis non-équitablement entre les 2 groupes
- Biais d'attrition si : les pdv ne sont pas analysés en biais maximum

Construire un diagramme de flux selon les recommandations CONSORT

Diagramme en bâtons

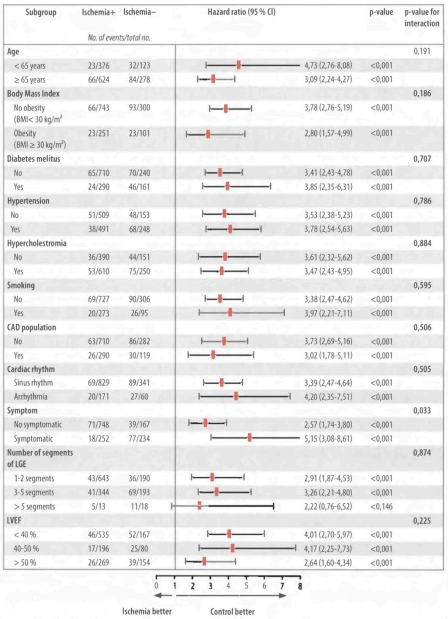
Figure description classique qui illustre simplement une différence entre les groupes (ou entre les sous-groupes dans une analyse en sous-groupes)

> **Attention, il existe 2 façons d'analyser les résultats d'un diagramme en bâtons :**

- Soit il n'y a pas de p-value visible sur la figure : il ne s'agit alors que d'une description de résultat *(on ne pourra pas cocher en QCM par ex. que "le taux d'événements annuel est supérieur dans le groupe A comparé à celui du groupe B)*
- Soit il y a une p-value visible sur la figure : signifie que des tests statistiques ont été réalisés (test Chi2 ou Student), autorisant à dire si le résultat est statistiquement significatif en termes de comparaison

Diagramme de Forest (Forest plot)

Exemple



Untitled

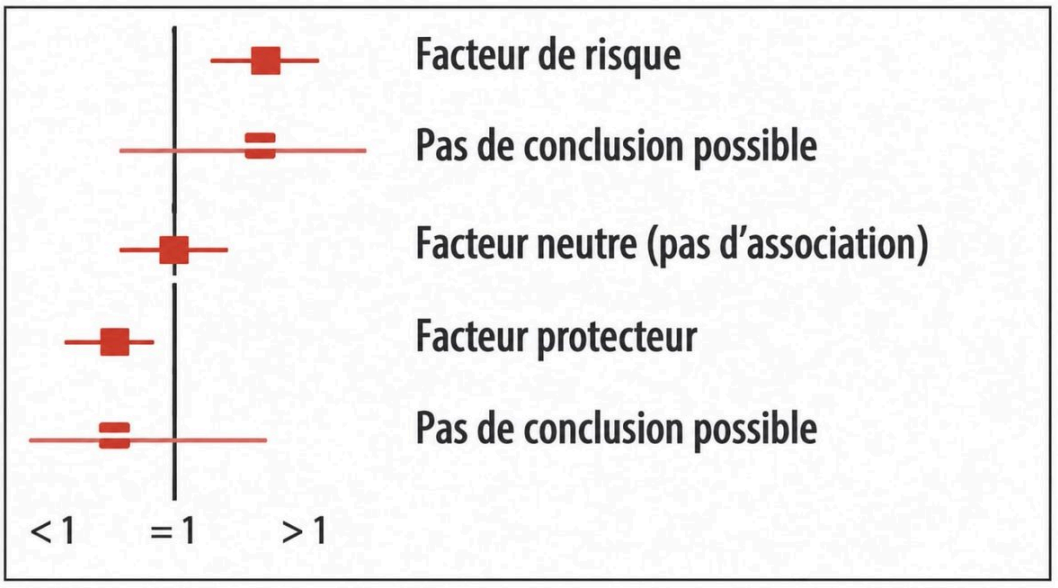


image.png

Contexte. Figure de référence pour présenter les résultats d'une analyse en sous-groupe (peut être utilisé dès lors qu'une analyse en sous-groupe est proposée, que ce soit pour une étude interventionnelle ou épidémiologique)

Objectif. Permet de visualiser très facilement le résultat d'intérêt sur le critère de jugement principal, et/ou les critères de jugement secondaire au sein d'un grand nombre de sous-groupes de l'étude

Abcisses (horizontal). Effet du traitement (rapport de cotes pour le décès ou l'invalidité)

Ordonnées (vertical). Sur lequel on place les sous-groupes selon une échelle arbitraire

Chaque ligne. Sur chaque ligne, l'effet du traitement observé dans un sous-groupe est représenté par un symbole (rond ou carré) entouré d'un trait horizontal qui représente l'intervalle de confiance associé

« p value for interaction »
= test
d'homogénéité
Permet de mettre en évidence l'existence de facteurs de confusion au sein de l'étude (interaction entre l'un des facteurs étudiés et la survenue du critère de jugement principal, indépendemment du FR étudiés ou de l'intervention étudiée)

- Si p value for interaction < alpha : alors le facteur étudié est bien un **facteur de confusion potentiel**
  - *dans l'exemple du pezel : la présence de symptômes est un facteur de confusion*

Intérêts

- Soit à visée complémentaire en soutenant que le **résultat principal de l'étude est retrouvée sur la totalité de la population étudiée** (homogène dans les différents sous-groupes)
- Soit à visée exploratoire lorsque le **résultat est plus pertinent cliniquement dans certains sous-groupes**, et permet de proposer de nouvelles études explorant ces différents sous-groupes

Interprétation ⚠️
Piège :

- Il est possible de dire qu'une différence étudiée est plus importante dans l'un des sous-groupes

(= « est-ce que c'est significatif ? »)

- Mais attention, on n'a jamais le droit de conclure sur une analyse en sous-groupe ⚠️

(même si le résultat est statistiquement significatif)

Études de performance diagnostique d'un nouveau test quantitatif

Courbre ROC *(Receiver Operating Characteristic)*
Schémas ++

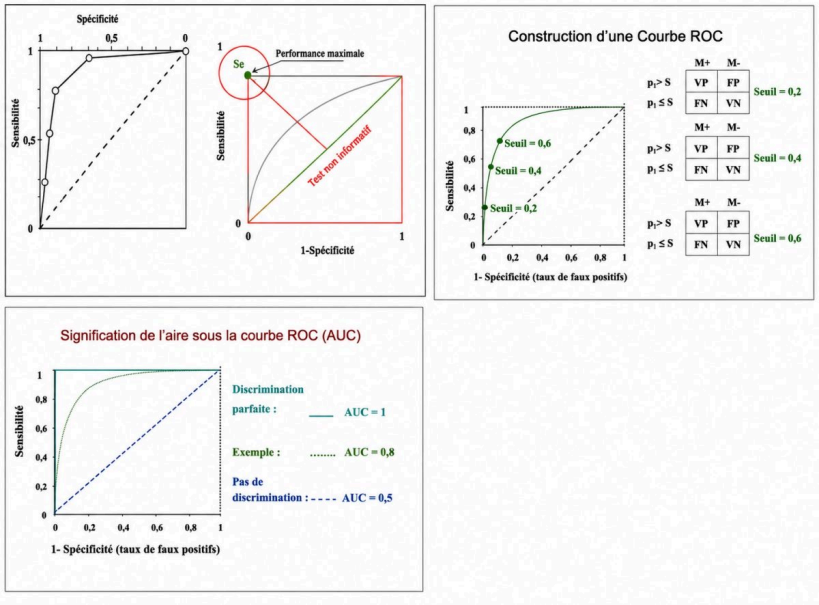


image.png

Construction d'une courbe ROC / Seuil de normalité S (ou ligne de partage)

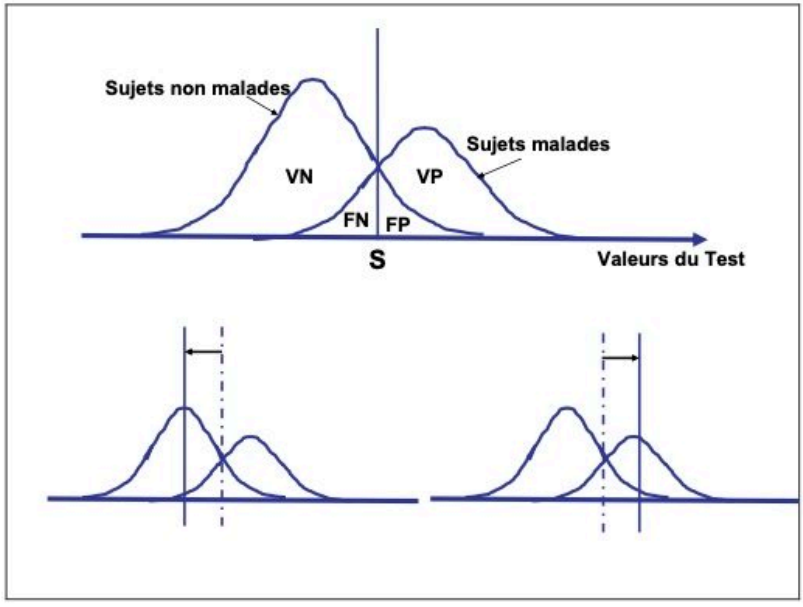
Utilité. Courbes ROC permettent d'étudier les vairations de la spécificité et de la sansibiltié d'un test pour les différentes valeurs du seuil de discrimination entre tests positifs et tests négatifs (patients présents malades ou présents non malades)

Construction. Courbe ROC se construit de façon empirique en calculant la sensibilité puis la spécificté d'un test pour les différents niveaux d'un seuil de discrimination

Seuil de normalité S

Fixation d'un seuil de normalité S (ou ligne de partage) définit la répartition des vrais positifs, vrais négatifs, faux positifs et faux négatifs

- déplacement de la ligne de partage du test modifie les proportions de VP, VN, FP, FN



Untitled

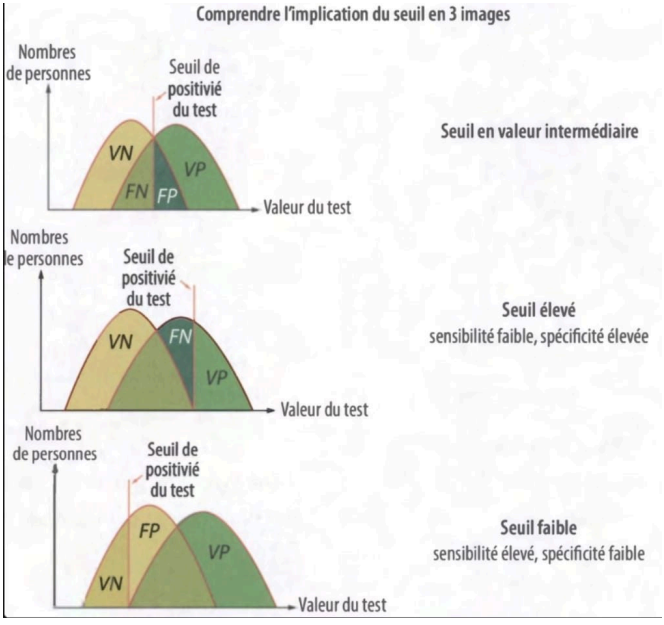


image.png

Cas particulier : courbe ROC évaluant l'intérêt d'une variable par rapport à un modèle multivarié de base

Cas particulier : Courbe ROC évaluant l'intérêt d'une variable par rapport à un modèle multivarié de base

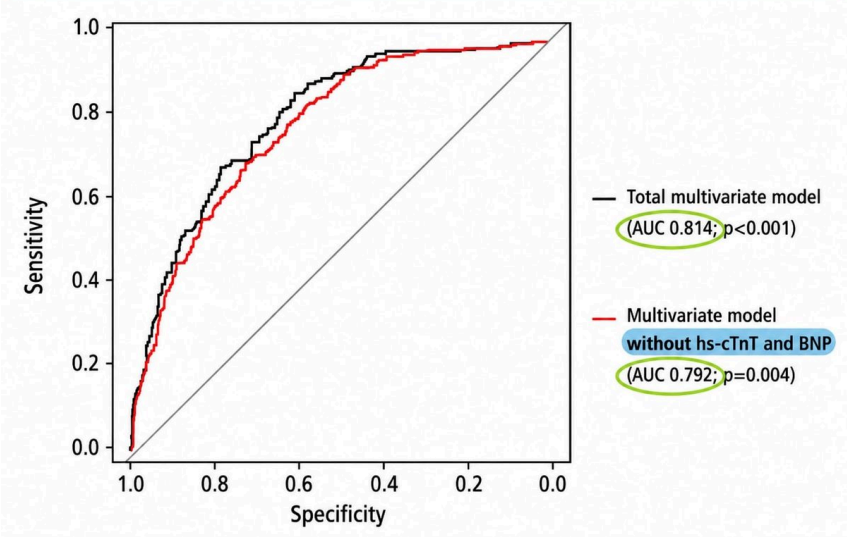


image.png

- En effet, la question posée ici (plus rarement rencontrée dans les dossiers SIDES) permet d'évaluer, non pas la performance diagnostique du test, mais **à quel point le nouveau test diagnostique étudié**, ajouté aux facteurs de risque étudiés déjà connus, permet d'améliorer la prédiction du modèle de survenue de l'événement étudié (la maladie) (**FdR**). C'est prédire la maladie.
- Ainsi le principe est de construire un **premier modèle multivarié** incluant l'ensemble des **paramètres traditionnellement utilisés pour prédire la survenue de l'événement étudié** (courbe noire sur la figure ci-dessus, courbe rouge) (*dans cet exemple, les facteurs de risque connus du modèle sont les facteurs de risque cardiovasculaire : âge, sexe, tabac, diabète, hypertension, dyslipidémie, et hérédité cardiovasculaire ; l'évènement étudié est la survenue d'évènements cardiovasculaires*).
- Puis de rajouter à un des tests diagnostiques étudiés (*dans cet exemple : la troponine et le BNP courbe noire*).
- Il existe une **incrémentation = « amélioration » de la prédiction du modèle à l'aide du test ajouté** (**FdR**).
- En QCM, on est donc demandé de comparer les aires sous la courbe de cette courbe et d'observer à quel point, l'adjonction du nouveau test permet l'incrémentation de la prédiction de risque de l'évènement étudié.

Courbe ROC (Receiver Operating Characteristic)

Contexte

Figure classique utilisée dans les études diagnostiques de performance afin d'établir :

- Performance diagnostique globale du test (Aire sous la courbe, AUC = *area under the curve*)
- Seuil optimal diagnostique pour un test quantitatif

Type d'étude

(condition)

Courbe ROC ne peut être utilisée que dans les études diagnostiques de performance (pour l'ECN)

- Uniquement lorsque le test diagnostique étudiée est une variable quantitative ⭐ (ex. plupart des dosages biologiques)
  - Attention au piège : le test de référence (gold standard) n'est soumis à aucune condition particulière (pas forcément quantitatif)

Ordonnée

Abscisse

- Ordonnée : sensibilité
- Abscisse : taux de FP (1 - spécificité)

Interprétation

- Plus la courbe s'étire vers le haut à gauche, plus elle a tendance à passer par un point d'abscisse 0 et d'ordonnée 1, ce qui signifie qu'il existe un seuil du test pour lequel la sensibilité et la spécificité se rapprochent de 100%
- Inversement, si la courbe se rapproche de la diagonale, cela signifie que pour un plus grand nombre de seuils possibles, la sensibilité est égale à (1 – spécificité), ce qui équivaut à un rapport de vraisemblance positif = 1, donc un test non discriminant, dont le gain par rapport à la probabilité pré-test est nulle
- Si ROC médiane ayant 0 pour origine = test sans intérêt
- Courbe superposable à la diagonale a une AUC de 0,5 avec un test qui ne fait pas mieux que le hasard !!

AUC

Calcul de l'aire sous la courbe (± comparaison statistique avec un autre test) permet de :

- Comparer 2 tests (le plus performant a une courbe ROC qui s'écarte le plus de la diagonale, avec l'AUC la plus grande)
- Évaluer la capacité discriminante globale du test (pour être valable AUC doit être ≥ 70-75%) :
  - Excellente : AUC entre 0,9 - 1
  - Bonne : 0,8 - 0,9
  - Moyenne : 0,7 - 0,8
  - Médiocre : AUC entre 0,5 - 0,7

« Seuil optimal »

Point d'inflexion de la courbe = choisir le plus près de l'angle supérieur gauche, et donc le plus éloigné de la diagonale

Valeur seuil pour laquelle sensibilité et spécificité sont optimales, selon le type de test :

- Dépistage = on veut **Se** ≈ 100% (avec la meilleure Sp possible)
  - Confirmation = on veut **Sp** ≈ 100% (avec la meilleur Se possible)
  - Indice de Youden maximal correspond au meilleur compromis global entre Se et Sp ⭐

2 Intérêts de l'étude

- Évaluer la performance diagnostique du nouveau test diagnostique, en comparant au test de référence → via AUC

- Rechercher le seuil optimal (déterminé en ROC) : ce seuil optimal sera celui à utiliser, lors de la prochaine étude correspond à une étude diagnostique à impact clinique (afin de valider l'utilité du test)

Corrélation linéaire de Pearson

Exemples / Schéma ++

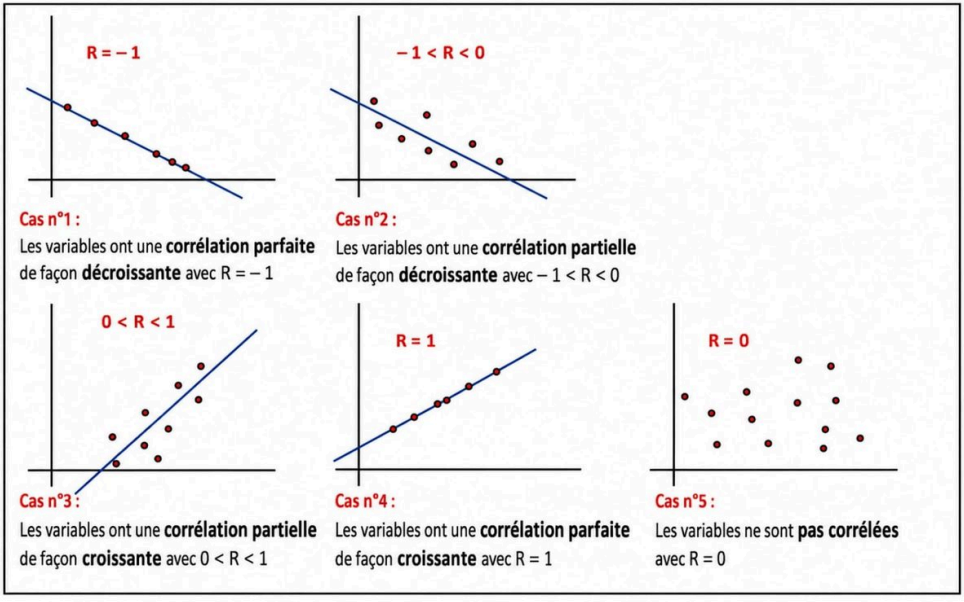


image.png

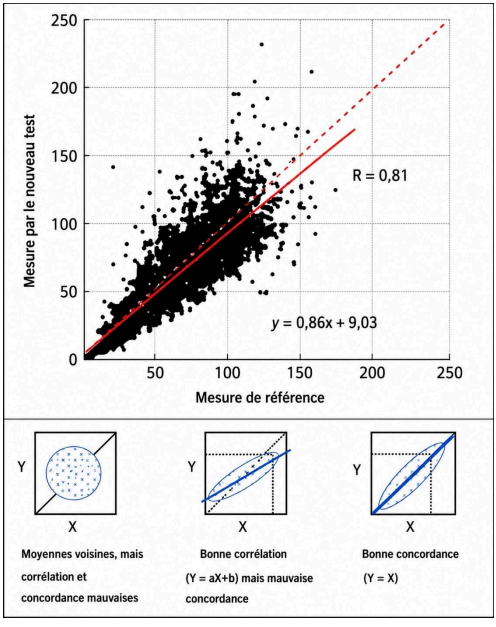


image.png

Conditions d'utilisation. Pour l'utiliser, il faut nécessairement que la mesure du nouveau test diagnostique étudié et celle du test de référence gold standard soient toutes les 2 des variables quantitatives *(à la différence de la courbe ROC où seul le nouveau test doit être quantitatif)*

Objectifs

Attention, il faut distinguer 2 situations cliniques d'utilisation différente :

- Soit celle où l'on compare les 2 tests : « est-ce que le test à l'étude est aussi bon que le test de référence ? »
  - Évalue à quel point le nouveau test donne un résultat proche (corrélé) à celui du test de référence
  - Dogme : **étude ne pourra jamais conclure que le test étudié est meilleur que le test de référence** ++

(puisqu'on part du principe que le test de référence énonce la vérité quant au statut M+/M-)

- Soit celle où l'on compare 2 méthodes de mesure du nouveau test diagnostique étudié
  - Ex. classique : comparer 2 opérateurs différents évaluant la même chose, typiquement en échographie, on placera

les résultats obtenus par l'un des opérateurs en abscisse et ceux de l'autre opérateur en ordonnée

- Attention, dans ce cas il ne s'agit plus d'une évaluation de la performance diagnostique du nouveau test diagnostique

étudié mais d'une évaluation de sa reproductibilité inter-observateurs

Principe

Construction

1/ Chaque point correspond à un patient défini, aboutit à un nuage de points (ensemble des patients), avec :

- En ordonnée : mesure obtenue avec le nouveau test diagnostique
  - En abscisses : mesure obtenue avec le test de référence

2/ Ensuite un modèle mathématique permet de tracer une droite correspondant à la synthèse linéaire mathématique passant par ce nuage de points (sous la forme d'une équation de droite : $Y = Ax + B$)

Calcul du r

Coefficient de corrélation (r) est compris entre -1 et 1, il permet d'interpréter facilement la force de liaison entre 2 variables :

- Si $R = 1$ → corrélation parfaite entre les 2 tests dans le sens positif de l'association (corrélation positive)
- Si $R = -1$ → corrélation parfaite entre les 2 tests dans le sens contraire de l'association (corrélation négative)
- Après avoir calculé le coefficient de corrélation r entre 2 variables X et Y, un test de corrélation permettra d'évaluer cette force de liaison mesurée, permettant de juger si le résultat est bien significatif (estimer si il est suffisamment éloigné de 0)

En pratique on met au carré R^2 pour éliminer les signes (on obtient une valeur absolue qui **s'exprime en pourcentage**) :

- Si $R > 0,6$ soit $> 60\%$ = bon (performances du test étudié se rapprochent bien de celles du test de référence)
- Si $R > 0,8$ = excellent (performandes du test étudié sont très proches de celles du test de référence)

- Si R = 1 = identique (théorique : les performances du test étudié sont identiques à celles du test de référence)

Calcul du p

Significativité de la corrélation (p) : obtention d'un p est significatif si p < alpha

- degré de significativité est fourni par le test de corrélation

Diagramme de Bland-Altman

Schéma / Représentation ++

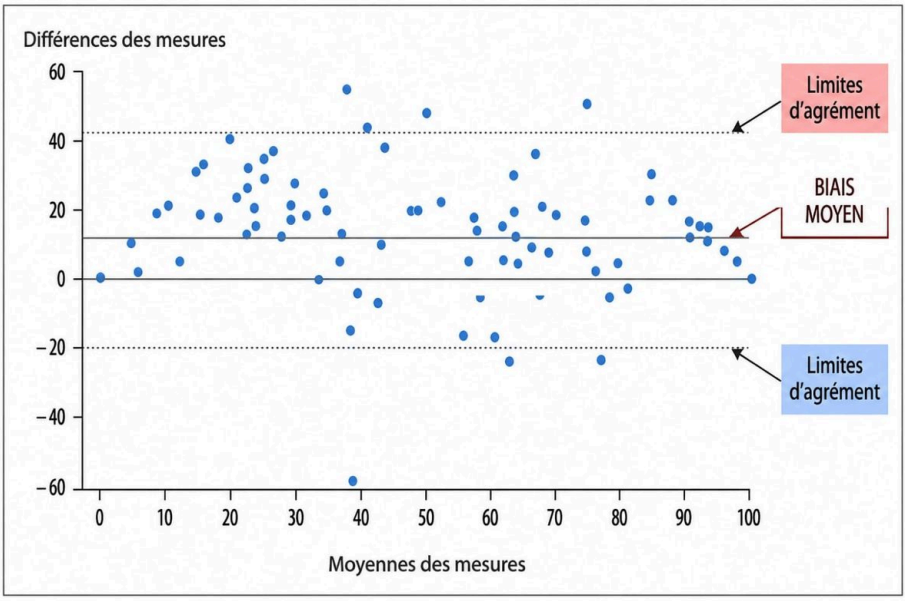


image.png

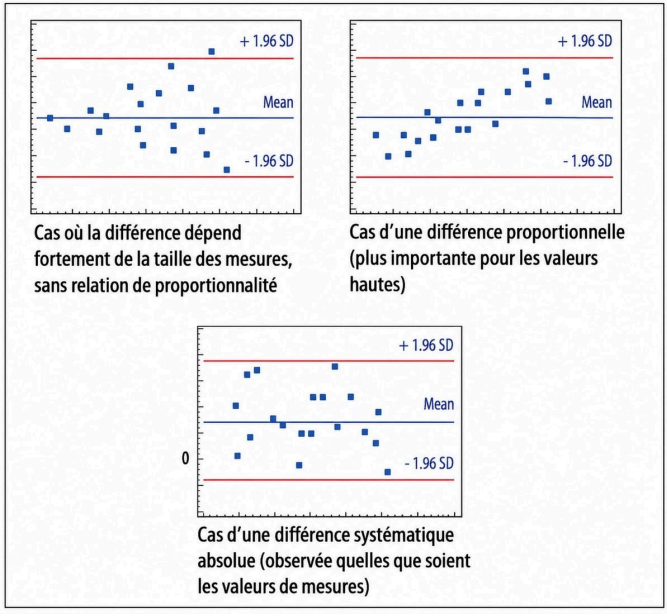


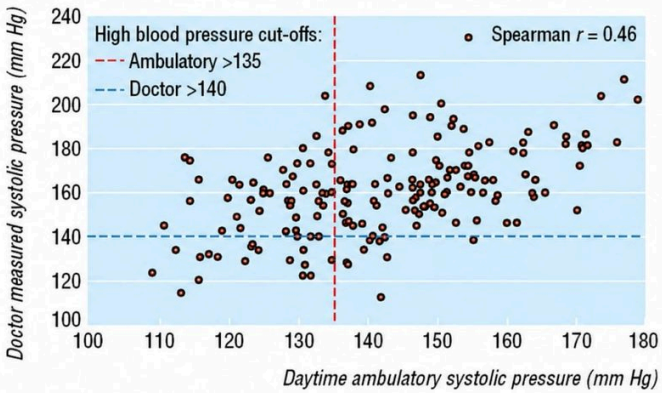
image.png

Exemples de Descartes

Ce graphe permet de visualiser :

- Un écart par rapport à 0, de la différence moyenne entre les 2 mesures (cet écart est de +18.9 dans l'exemple ci-dessous)
- Une corrélation entre la différence des deux mesures et leur moyenne (test r de Spearman dans l'exemple ci-dessous)

Exemple : Dans un échantillon de patients, on obtient pour chaque patient deux mesures de la pression artérielle obtenue l'une par un médecin avec un manomètre à mercure (Yi), l'autre obtenue par les patients avec un appareil automatique d'auto-mesure (Xi).



(d'après Little et al. BMJ 2002 ; 325 :254)

image.png

Diagramme de Bland et Altman

Objectifs

- Évaluer la performance diagnostique globale du nouveau test étudié par rapport au test de référence
  - via le **biais moyen** et les **limites d'agrément**
- Évaluer la performance diagnostique segmentaire du nouveau test étudiée
  - se fait à vue d'oeil de la **répartition du nuage de points sur l'intervalle sélectionné**

Conditions d'utilisation

Pour l'utiliser, il faut nécessairement que la mesure du nouveau test diagnostique étudié et celle du test de référence gold standard soient toutes les 2 des variables quantitatives avec nécessairement la même unité

(à la différence de la courbe ROC où seul le nouveau test doit être quantitatif)

Construction

Chaque point correspond à un patient défini par :

- En abscisse : la moyenne obtenue entre la mesure réalisée avec le nouveau test et celle avec le test de référence
- En ordonnée : la différence des mesures réalisées (entre la mesure avec le nouveau test et celle avec le test de référence)

Biais moyen

Attention aux faux amis, il ne s'agit en aucun cas d'un biais en tant qu'erreur systématique

- Correspond à la différence moyenne chez tous les patients entres les mesures du nouveau test et du test de référence
- Interprétation : plus ce biais moyen tend vers 0, plus la performance diagnostique globale du nouveau test est grande
  - cela traduit le fait que le nouveau test donne très souvent une valeur proche du test de référence

Limites d'agrément

- Définition : il s'agit de l'équivalent de l'intervalle de confiance du biais moyen
- Interprétation : plus les limites d'agrément sont resserrées autour du biais moyen, autrement dit, plus cet intervalle est étroit,

et plus la performance diagnostique globale du nouveau test est grande

- traduisant un peu de dispersion des différences de mesure autour de ce biais moyen

Performance diagnostique segmentaire

Évaluée sur l'axe des abscisses, en fonction de la mesure réalisée, interprétation en fonction de l'exemple du cours :

- Pour une valeur prise entre 0-40 (sur l'axe des abscisses) : la quasi-totalité des points se trouve au-dessus de l'axe 0
  - traduisant une tendance à la surestimation du nouveau test diagnostique par rapport au test de référence
- Pour une valeur prise entre 60-80 : majorité des points sont autour de l'axe 0
  - traduisant une performance diagnostique segmentaire, ici meilleure

En gros, la performance diagnostique segmentaire consiste à dire que le nouveau test diagnostique à une meilleure performance diagnostique pour certaines mesures (60 à 80, plutôt que 0 à 40)